



[PACKT]
PUBLISHING

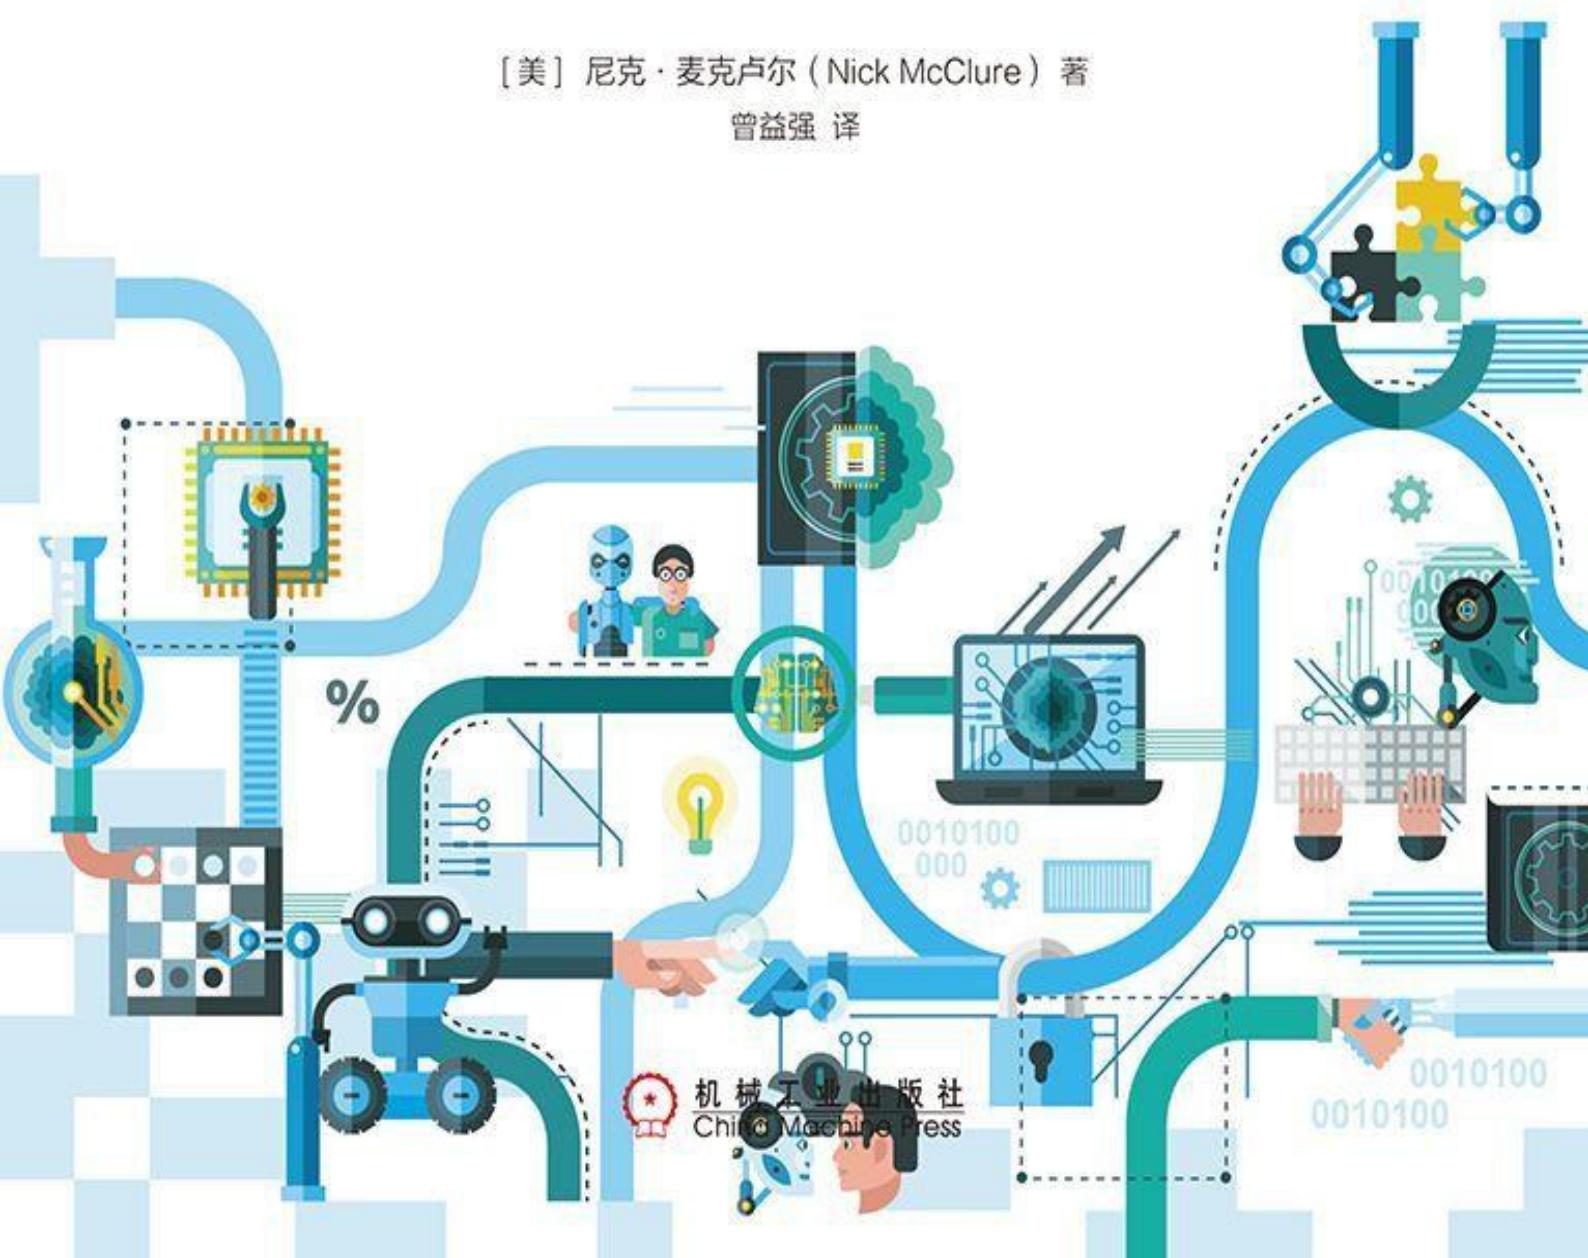
■ ■ ■ 智能系统与技术丛书

TensorFlow Machine Learning Cookbook

TensorFlow机器学习 实战指南

[美] 尼克·麦克卢尔 (Nick McClure) 著

曾益强 译



机械工业出版社
China Machine Press

前言

译者序

作者简介

审校者简介

前言

第1章 TensorFlow基础

1.1 TensorFlow介绍

1.2 TensorFlow如何工作

1.2.1 开始

1.2.2 动手做

1.2.3 工作原理

1.2.4 参考

1.3 声明张量

1.3.1 开始

1.3.2 动手做

1.3.3 工作原理

1.3.4 延伸学习

1.4 使用占位符和变量

1.4.1 开始

1.4.2 动手做

1.4.3 工作原理

1.4.4 延伸学习

1.5 操作（计算）矩阵

1.5.1 开始

1.5.2 动手做

1.5.3 工作原理

1.6 声明操作

1.6.1 开始

1.6.2 动手做

1.6.3 工作原理

1.6.4 延伸学习

1.7 实现激励函数

1.7.1 开始

1.7.2 动手做

1.7.3 工作原理

1.7.4 延伸学习

1.8 读取数据源

1.8.1 开始

1.8.2 动手做

1.8.3 参考

1.9 学习资料

第2章 TensorFlow进阶

2.1 本章概要

2.2 计算图中的操作

2.2.1 开始

2.2.2 动手做

2.2.3 工作原理

2.3 TensorFlow的嵌入Layer

2.3.1 开始

2.3.2 动手做

2.3.3 工作原理

2.3.4 延伸学习

2.4 TensorFlow的多层Layer

2.4.1 开始

2.4.2 动手做

2.4.3 工作原理

2.5 TensorFlow实现损失函数

2.5.1 开始

2.5.2 动手做

2.5.3 工作原理

2.5.4 延伸学习

2.6 TensorFlow实现反向传播

2.6.1 开始

2.6.2 动手做

2.6.3 工作原理

2.6.4 延伸学习

2.6.5 参考

2.7 TensorFlow实现随机训练和批量训练

2.7.1 开始
2.7.2 动手做
2.7.3 工作原理
2.7.4 延伸学习

2.8 TensorFlow实现创建分类器

2.8.1 开始
2.8.2 动手做
2.8.3 工作原理
2.8.4 延伸学习
2.8.5 参考

2.9 TensorFlow实现模型评估

2.9.1 开始
2.9.2 动手做
2.9.3 工作原理

第3章 基于TensorFlow的线性回归

3.1 线性回归介绍
3.2 用TensorFlow求逆矩阵
3.2.1 开始
3.2.2 动手做
3.2.3 工作原理
3.3 用TensorFlow实现矩阵分解
3.3.1 开始
3.3.2 动手做
3.3.3 工作原理
3.4 用TensorFlow实现线性回归算法
3.4.1 开始
3.4.2 动手做
3.4.3 工作原理

3.5 理解线性回归中的损失函数
3.5.1 开始
3.5.2 动手做
3.5.3 工作原理
3.5.4 延伸学习

3.6 用TensorFlow实现戴明回归算法
3.6.1 开始

3.6.2 动手做

3.6.3 工作原理

3.7 用TensorFlow实现lasso回归和岭回归算法

3.7.1 开始

3.7.2 动手做

3.7.3 工作原理

3.7.4 延伸学习

3.8 用TensorFlow实现弹性网络回归算法

3.8.1 开始

3.8.2 动手做

3.8.3 工作原理

3.9 用TensorFlow实现逻辑回归算法

3.9.1 开始

3.9.2 动手做

3.9.3 工作原理

第4章 基于TensorFlow的支持向量机

4.1 支持向量机简介

4.2 线性支持向量机的使用

4.2.1 开始

4.2.2 动手做

4.2.3 工作原理

4.3 弱化为线性回归

4.3.1 开始

4.3.2 动手做

4.3.3 工作原理

4.4 TensorFlow上核函数的使用

4.4.1 开始

4.4.2 动手做

4.4.3 工作原理

4.4.4 延伸学习

4.5 用TensorFlow实现非线性支持向量机

4.5.1 开始

4.5.2 动手做

4.5.3 工作原理

4.6 用TensorFlow实现多类支持向量机

4.6.1 开始

4.6.2 动手做

4.6.3 工作原理

第5章 最近邻域法

5.1 最近邻域法介绍

5.2 最近邻域法的使用

5.2.1 开始

5.2.2 动手做

5.2.3 工作原理

5.2.4 延伸学习

5.3 如何度量文本距离

5.3.1 开始

5.3.2 动手做

5.3.3 工作原理

5.3.4 延伸学习

5.4 用TensorFlow实现混合距离计算

5.4.1 开始

5.4.2 动手做

5.4.3 工作原理

5.4.4 延伸学习

5.5 用TensorFlow实现地址匹配

5.5.1 开始

5.5.2 动手做

5.5.3 工作原理

5.6 用TensorFlow实现图像识别

5.6.1 开始

5.6.2 动手做

5.6.3 工作原理

5.6.4 延伸学习

第6章 神经网络算法

6.1 神经网络算法基础

6.2 用TensorFlow实现门函数

6.2.1 开始

6.2.2 动手做

6.2.3 工作原理

6.3 使用门函数和激励函数

6.3.1 开始

6.3.2 动手做

6.3.3 工作原理

6.3.4 延伸学习

6.4 用TensorFlow实现单层神经网络

6.4.1 开始

6.4.2 动手做

6.4.3 工作原理

6.4.4 延伸学习

6.5 用TensorFlow实现神经网络常见层

6.5.1 开始

6.5.2 动手做

6.5.3 工作原理

6.6 用TensorFlow实现多层神经网络

6.6.1 开始

6.6.2 动手做

6.6.3 工作原理

6.7 线性预测模型的优化

6.7.1 开始

6.7.2 动手做

6.7.3 工作原理

6.8 用TensorFlow基于神经网络实现井字棋

6.8.1 开始

6.8.2 动手做

6.8.3 工作原理

第7章 自然语言处理

7.1 文本处理介绍

7.2 词袋的使用

7.2.1 开始

7.2.2 动手做

7.2.3 工作原理

7.2.4 延伸学习

7.3 用TensorFlow实现TF-IDF算法

7.3.1 开始

7.3.2 动手做
7.3.3 工作原理
7.3.4 延伸学习

7.4 用TensorFlow实现skip-gram模型
7.4.1 开始

7.4.2 动手做
7.4.3 工作原理
7.4.4 延伸学习

7.5 用TensorFlow实现CBOW词嵌入模型
7.5.1 开始
7.5.2 动手做
7.5.3 工作原理
7.5.4 延伸学习

7.6 使用TensorFlow的Word2Vec预测
7.6.1 开始
7.6.2 动手做
7.6.3 工作原理
7.6.4 延伸学习

7.7 用TensorFlow实现基于Doc2Vec的情感分析
7.7.1 开始
7.7.2 动手做
7.7.3 工作原理

第8章 卷积神经网络

8.1 卷积神经网络介绍
8.2 用TensorFlow实现简单的CNN
8.2.1 开始
8.2.2 动手做
8.2.3 工作原理
8.2.4 延伸学习
8.2.5 参考
8.3 用TensorFlow实现进阶的CNN
8.3.1 开始
8.3.2 动手做
8.3.3 工作原理
8.3.4 参考

8.4 再训练已有的CNN模型

8.4.1 开始

8.4.2 动手做

8.4.3 工作原理

8.4.4 参考

8.5 用TensorFlow实现模仿大师绘画

8.5.1 开始

8.5.2 动手做

8.5.3 工作原理

8.5.4 参考

8.6 用TensorFlow实现DeepDream

8.6.1 开始

8.6.2 动手做

8.6.3 延伸学习

8.6.4 参考

第9章 递归神经网络

9.1 递归神经网络介绍

9.2 用TensorFlow实现RNN模型进行垃圾短信预测

9.2.1 开始

9.2.2 动手做

9.2.3 工作原理

9.2.4 延伸学习

9.3 用TensorFlow实现LSTM模型

9.3.1 开始

9.3.2 动手做

9.3.3 工作原理

9.3.4 延伸学习

9.4 Stacking多个LSTM Layer

9.4.1 开始

9.4.2 动手做

9.4.3 工作原理

9.5 用TensorFlow实现Seq2Seq翻译模型

9.5.1 开始

9.5.2 动手做

9.5.3 工作原理

9.5.4 延伸学习

9.6 TensorFlow实现孪生RNN预测相似度

9.6.1 开始

9.6.2 动手做

9.6.3 延伸学习

第10章 TensorFlow产品化

10.1 简介

10.2 TensorFlow的单元测试

10.2.1 开始

10.2.2 工作原理

10.3 TensorFlow的并发执行

10.3.1 开始

10.3.2 动手做

10.3.3 工作原理

10.3.4 延伸学习

10.4 分布式TensorFlow实践

10.4.1 开始

10.4.2 动手做

10.4.3 工作原理

10.5 TensorFlow产品化开发提示

10.5.1 开始

10.5.2 动手做

10.5.3 工作原理

10.6 TensorFlow产品化的实例

10.6.1 开始

10.6.2 动手做

10.6.3 工作原理

第11章 TensorFlow的进阶应用

11.1 简介

11.2 TensorFlow可视化：Tensorboard

11.2.1 开始

11.2.2 动手做

11.3 Tensorboard的进阶

11.4 用TensorFlow实现遗传算法

11.4.1 开始

11.4.2 动手做

11.4.3 工作原理

11.4.4 延伸学习

11.5 TensorFlow实现k-means算法

11.5.1 开始

11.5.2 动手做

11.5.3 延伸学习

11.6 用TensorFlow求解常微分方程问题

11.6.1 开始

11.6.2 动手做

11.6.3 工作原理

11.6.4 参考

译者序

2017年3月底，华章公司的编辑邀请我翻译这本书。当时收到原书目录和样章时，大体浏览了一遍，感觉翻译难度不大。因为TensorFlow比较火，加上自身对机器学习及其算法有一定功底，前期也翻译了不少国外优秀的技术文章（可参见公众号：神机喵算），加之国内可学习的TensorFlow资料太少，所以我希望做出一些努力来帮助对TensorFlow感兴趣的读者。

Google公司开发的TensorFlow深度学习库因其简单易学、应用场景广泛已经快成为各家公司开展人工智能研究的标配了。TensorFlow采用数据流图进行数值计算。节点代表计算图中的数学操作，计算中的边表示多维数组，即张量。TensorFlow灵活的架构使其可以在多种设备（台式机、服务器或移动设备）的CPU或者GPU上进行计算。自从TensorFlow诞生以来，其开发版更新和功能优化非常快，当前已经发布到1.2.0。并且基于TensorFlow开发的深度学习库也越来越多，其中比较优秀的是Keras。Keras是基于TensorFlow或者Theano的，由Python编写的高级神经网络API，并且TensorFlow也提供支持Keras的API。

本书详细讲解了TensorFlow的方方面面，毫不夸张地说，如果读者能够坚持踏踏实实做完本书所有实战项目，则基本可以开始使用TensorFlow实际工作。最后本书还给出了TensorFlow产品级应用的最佳实践，以及扩展用法。

总之，本书适合广大对TensorFlow感兴趣的初中级读者。随着AI的兴起，会有越来越多的读者学习TensorFlow，希望本书能帮到大家。如果想进一步学习，那就要多看机器学习算法相关的书籍或者论文，并把TensorFlow的源代码研读几遍。

最后，感谢家人和朋友的帮助和支持。由于本人水平有限，加之翻译时间仓促，书中难免会出现错误。读者可通过本人公众号——神机喵算，反馈问题，发现问题后，我一定会虚心接受批评并立即改正，并实时在公众号更新勘误，避免其他读者再入“坑”。

曾益强

2017年6月

作者简介

Nick McClure，资深数据科学家，目前就职于美国西雅图PayScale公司，曾经在Zillow公司和Caesar's Entertainment公司工作，获得蒙大拿大学和圣本尼迪克与圣约翰大学的应用数学专业学位。

他热衷于数据分析、机器学习和人工智能。Nick有时会把想法写成博客（<http://fromdata.org/>）或者发推特（@nfmclure）。

感谢父母，他们总是鼓励我追求知识。也感谢朋友和同事能够给出很好的建议。本书的完成得益于开源社区的不懈努力，以及TensorFlow相关项目的良好文档说明。

这里，要特别感谢Google公司TensorFlow开发人员。他们给出了优秀的官方文档、教程和示例。

审校者简介

Chetan Khatri，具有5年工作经验的数据科学研究者。他现在是印度Accion Labs公司技术部门的负责人，曾就职于印度手游巨头Nazara Games公司，领导负责游戏与电信业务。

他在KSKV Kachchh大学计算机科学和数据分析专业取得硕士学位，致力于数据科学、机器学习、AI和IoT等方面的学术和会议演讲交流。他在学术研究和工业实践两方面都有特长，所以在排除两者间的隔阂方面有不错的成就。他是Kachchh大学多门课程的合作者，比如数据分析、IoT、机器学习、AI和分布式数据库。他也是Python社区（PyKuth）的建立者之一。

目前，他正致力于智能IoT设备与机器学习、增强学习和分布式计算方面的结合。

感谢Kachchh大学计算机科学学院Devji Chhang教授引导我走上数据分析研究的道路。

感谢Shweta Gorania教授介绍遗传算法和神经网络算法。

最后，感谢家人的支持。

前言

2015年11月，Google公司开源TensorFlow，随后不久TensorFlow成为GitHub上最受欢迎的机器学习库。TensorFlow创建计算图、自动求导和定制化的方式使得其能够很好地解决许多不同的机器学习问题。

本书介绍了许多机器学习算法，将其应用到真实场景和数据中，并解释产生的结果。

本书的主要内容

第1章介绍TensorFlow的基本概念，包括张量、变量和占位符；同时展示了在TensorFlow中如何使用矩阵和各种数学操作。本章末尾讲述如何访问本书所需的数据源。

第2章介绍如何在计算图中连接第1章中的所有算法组件，创建一个简单的分类器。接着，介绍计算图、损失函数、反向传播和训练模型。

第3章重点讨论使用TensorFlow实现各种线性回归算法，比如，戴明回归、lasso回归、岭回归、弹性网络回归和逻辑回归，也展示了如何在TensorFlow计算图中实现每种回归算法。

第4章介绍支持向量机（SVM）算法，展示如何在TensorFlow中实现线性SVM算法、非线性SVM算法和多分类SVM算法。

第5章展示如何使用数值度量、文本度量和归一化距离函数实现最近邻域法。我们使用最近邻域法进行地址间的记录匹配和MNIST数据库中手写数字的分类。

第6章讲述如何使用TensorFlow实现神经网络算法，包括操作门和激励函数的概念。随后展示一个简单的神经网络并讨论如何建立不同类型的神经网络层。本章末尾通过神经网络算法教TensorFlow玩井字棋游戏。

第7章阐述借助TensorFlow实现的各种文本处理算法。我们展示如何实现文本的“词袋”和TF-IDF算法。然后介绍CBOW和skip-gram模型的神经网络文本表示方式，并对于Word2Vec和Doc2Vec用这些方法来做预测。

第8章扩展神经网络算法，说明如何借助卷积神经网络（CNN）算法在图像上应用神经网络算法。我们展示如何构建一个简单的CNN进行MNIST数字识别，并扩展到CIFAR-10任务中的彩色图片，也阐述了如何针对自定义任务扩展之前训练的图像识别模型。本章末尾详细解释TensorFlow实现的模仿大师绘画和Deep-Dream算法。

第9章解释在TensorFlow中如何实现递归神经网络（RNN）算法，展示如何进行垃圾短信预测和在莎士比亚文本样本集上扩展RNN模型生成文本。接着训练Seq2Seq模型实现德语-英语的翻译。本章末尾展示如何用孪生RNN模型进行地址记录匹配。

第10章介绍TensorFlow产品级用例和开发提示，同时介绍如何利用多处理设备（比如，GPU）和在多个设备上实现分布式TensorFlow。

第11章展示TensorFlow如何实现k-means算法、遗传算法和求解常微分方程（ODE），还介绍了Tensorboard的各种用法和如何查看计算图指标。

阅读本书前的准备

书中的章节都会使用TensorFlow，其官网为<https://www.tensorflow.org/>，它是基于Python 3 (<https://www.python.org/downloads/>) 编写的。大部分章节需要访问从网络中下载的数据集。

本书的目标读者

本书适用于有经验的机器学习读者和Python程序员。有机器学习背景的读者会发现TensorFlow的代码很有启发性；有Python编程经验的读者会觉得代码注释极具参考性。

模块说明

在本书中，你会频繁看到开始、动手做、工作原理、延伸学习和参考这几个模块。

为了系统地学习相关技术，下面简单解释一下：

·开始

该节告诉读者该技术的内容，描述如何准备软件或者前期的准备工作。

·动手做

具体的操作步骤。

·工作原理

详细解释前一节发生了什么。

·延伸学习

附加资源，以供读者延伸学习。

·参考

提供有用的链接和有帮助的资源信息。

下载示例代码

读者可登录华章网站（www.hzbook.com）下载本书示例代码文件。

第1章 TensorFlow基础

本章将介绍TensorFlow的基本概念，帮助读者去理解TensorFlow是如何工作的，以及它如何访问数据集和学习资源。学完本章可以掌握以下知识点：

- TensorFlow如何工作

- 声明变量和张量

- 占位符和变量的用法

- 矩阵的使用

- 声明计算操作

- 实现激励函数

- 读取数据源

- 学习资料

1.1 TensorFlow介绍

Google的TensorFlow引擎提供了一种解决机器学习问题的高效方法。机器学习在各行各业应用广泛，特别是计算机视觉、语音识别、语言翻译和健康医疗等领域。本书将详细介绍TensorFlow操作的基本步骤以及代码。这些基础知识对理解本书后续章节非常有用。

1.2 TensorFlow如何工作

首先，TensorFlow的计算看起来并不是很复杂，因为TensorFlow的计算过程和算法开发相当容易。这章将引导读者理解TensorFlow算法的伪代码。

1.2.1 开始

截至目前，TensorFlow支持Linux、Mac和Windows操作系统。本书的代码都是在Linux操作系统上实现和运行的，不过运行在其他操作系统上也没问题。本书的代码可以在

GitHub (https://github.com/nfmccclure/tensorflow_cookbookTensorFlow) 上获取。虽然TensorFlow是用C++编写，但是全书只介绍TensorFlow的Python使用方式。本书将使用Python 3.4+ (<https://www.python.org>) 和TensorFlow 0.12 (<https://www.tensorflow.org>)。TensorFlow官方已经在GitHub上发布1.0.0 alpha版本，本书代码兼容相应版本。TensorFlow能在CPU上运行，大部分算法在GPU上会运行得更快，它支持英伟达显卡（Nvidia Compute Capability v4.0+，推荐v5.1）。TensorFlow上常用的GPU是英伟达特斯拉（Nvidia Tesla）和英伟达帕斯卡（Nvidia Pascal），至少需要4GB的RAM。为了运行GPU，需要下载Nvidia Cuda Toolkit及其v5.x版本 (<https://developer.nvidia.com/cuda-downloads>)。本书还依赖Python的包：Scipy、NumPy和Scikit-Learn。

1.2.2 动手做

这里是TensorFlow算法的一般流程，本书提炼出的纲领如下：

1.导入/生成样本数据集：所有的机器学习算法都依赖样本数据集，本书的数据集既有生成的样本数据集，也有外部公开的样本数据集。有时，生成的数据集会更容易符合预期结果，但是本书大部分都是访问外部公开的样本数据集，具体细节见第8章。

2.转换和归一化数据：一般来讲，输入样本数据集并不符合TensorFlow期望的形状，所以需要转换数据格式以满足TensorFlow。当数据集的维度或者类型不符合所用机器学习算法的要求时，需要在使用前进行数据转换。大部分机器学习算法期待的输入样本数据是归一化的数据。TensorFlow具有内建函数来归一化数据，如下：

```
data = tf.nn.batch_norm_with_global_normalization(...)
```

3.划分样本数据集为训练样本集、测试样本集和验证样本集：一般要求机器学习算法的训练样本集和测试样本集是不同的数据集。另外，许多机器学习算法要求超参数调优，所以需要验证样本集来决定最优的超参数。

4.设置机器学习参数（超参数）：机器学习经常要有一系列的常量参数。例如，迭代次数、学习率，或者其他固定参数。约定俗成的习惯是一次性初始化所有的机器学习参数，读者经常看到的形式如下：

```
learning_rate = 0.01  
batch_size = 100  
iterations = 1000
```

5.初始化变量和占位符：在求解最优化过程中（最小化损失函数），TensorFlow通过占位符获取数据，并调整变量和权重/偏差。TensorFlow指定数据大小和数据类型初始化变量和占位符。本书大部分使用float32数据类型，TensorFlow也支持float64和float16。注意，使用的数据类型字节数越多结果越精确，同时运行速度越慢。使用方式如下：

```
a_var = tf.constant(42)  
x_input = tf.placeholder(tf.float32, [None, input_size])  
y_input = tf.placeholder(tf.float32, [None, num_classes])
```

6.定义模型结构：在获取样本数据集、初始化变量和占位符后，开始定义机器学习模型。TensorFlow通过选择操作、变量和占位符的值来构建计算图，详细讲解见第2章。这里给出简单的线性模型：

```
y_pred = tf.add(tf.mul(x_input, weight_matrix), b_matrix)
```

7. 声明损失函数：定义完模型后，需要声明损失函数来评估输出结果。损失函数能说明预测值与实际值的差距，损失函数的种类将在第2章详细展示：

```
loss = tf.reduce_mean(tf.square(y_actual - y_pred))
```

8. 初始化模型和训练模型：TensorFlow创建计算图实例，通过占位符赋值，维护变量的状态信息。下面是初始化计算图的一种方式：

```
with tf.Session(graph=graph) as session:  
    ...  
    session.run(...)  
    ...
```

也可以用如下的方式初始化计算图：

```
session = tf.Session(graph=graph)  
session.run(...)
```

9. 评估机器学习模型：一旦构建计算图，并训练机器学习模型后，需要寻找某种标准来评估机器学习模型对新样本数据集的效果。通过对训练样本集和测试样本集的评估，可以确定机器学习模型是过拟合还是欠拟合。这些将在后续章节来解决。

10. 调优超参数：大部分情况下，机器学习者需要基于模型效果来回调整一些超参数。通过调整不同的超参数来重复训练模型，并用验证样本集来评估机器学习模型。

11. 发布/预测结果：所有机器学习模型一旦训练好，最后都用来预测新的、未知的数据。

1.2.3 工作原理

使用TensorFlow时，必须准备样本数据集、变量、占位符和机器学习模型，然后进行模型训练，改变变量状态来提高预测结果。TensorFlow通过计算图实现上述过程。这些计算图是有向无环图，并且支持并行计算。接着TensorFlow创建损失函数，通过调整计算图中的变量来最小化损失函数。TensorFlow维护模型的计算状态，每步迭代自动计算梯度。

1.2.4 参考

https://www.tensorflow.org/api_docs/python/

<https://www.tensorflow.org/tutorials/>

1.3 声明张量

TensorFlow的主要数据结构是张量，它用张量来操作计算图。在TensorFlow里可以把变量或者占位符声明为张量。首先，需要知道如何创建张量。

1.3.1 开始

创建一个张量，声明其为一个变量。TensorFlow在计算图中可以创建多个图结构。这里需要指出，在TensorFlow中创建一个张量，并不会立即在计算图中增加什么。只有把张量赋值给一个变量或者占位符，TensorFlow才会把此张量增加到计算图。更多信息请见下一章。

1.3.2 动手做

这里将介绍在TensorFlow中创建张量的主要方法：

1. 固定张量：

· 创建指定维度的零张量。使用方式如下：

```
zero_tsr = tf.zeros([row_dim, col_dim])
```

· 创建指定维度的单位张量。使用方式如下：

```
ones_tsr = tf.ones([row_dim, col_dim])
```

· 创建指定维度的常数填充的张量。使用方式如下：

```
filled_tsr = tf.fill([row_dim, col_dim], 42)
```

· 用已知常数张量创建一个张量。使用方式如下：

```
constant_tsr = tf.constant([1, 2, 3])
```



tf.constant() 函数也能广播一个值为数组，然后模拟tf.fill() 函数的功能，具体写法为：tf.constant(42, [row_dim, col_dim])。

2. 相似形状的张量：

· 新建一个与给定的tensor类型大小一致的tensor，其所有元素为0或者1，使用方式如下：

```
zeros_similar = tf.zeros_like(constant_tsr)
ones_similar = tf.ones_like(constant_tsr)
```



因为这些张量依赖给定的张量，所以初始化时需要按序进行。如果打算一次性初始化所有张量，那么程序将会报错。

3. 序列张量：

· TensorFlow可以创建指定间隔的张量。下面的函数的输出跟range（）函数和numpy的linspace（）函数的输出相似：

```
linear_tsr = tf.linspace(start=0, stop=1, start=3)
```

· 返回的张量是[0.0, 0.5, 1.0]序列。注意，上面的函数结果中最后一个值是stop值。另外一个rang（）函数的使用方式如下：

```
integer_seq_tsr = tf.range(start=6, limit=15, delta=3)
```

· 返回的张量是[6, 9, 12]。注意，这个函数结果不包括limit值。

4. 随机张量：

· 下面的tf.random_uniform（）函数生成均匀分布的随机数：

```
randunif_tsr = tf.random_uniform([row_dim, col_dim],  
minval=0, maxval=1)
```

· 注意，这个随机均匀分布从minval（包含minval值）开始到maxval（不包含maxval值）结束，即
(minval<=x< li="">

· tf.random_normal（）函数生成正态分布的随机数：

```
randnorm_tsr = tf.random_normal([row_dim, col_dim],  
mean=0.0, stddev=1.0)
```

· tf.truncated_normal（）函数生成带有指定边界的正态分布的随机数，其正态分布的随机数位于指定均值（期望）到两个标准差之间的区间：

```
runchnorm_tsr = tf.truncated_normal([row_dim, col_dim],  
mean=0.0, stddev=1.0)
```

· 张量/数组的随机化。tf.random_shuffle（）和tf.random_crop（）可以实现此功能：

```
shuffled_output = tf.random_shuffle(input_tensor)  
cropped_output = tf.random_crop(input_tensor, crop_size)
```

· 张量的随机剪裁。tf.random_crop（）可以实现对张量指定大小的随机剪裁。在本书的后面部分，会对具有3通道颜色的图像（height, width, 3）进行随机剪裁。为了固定剪裁结果的一个维度，需要在相应的维度上赋其最大值：

```
cropped_image = tf.random_crop(my_image, [height/2, width/2,  
3])
```

1.3.3 工作原理

一旦创建好张量，就可以通过tf.Variable() 函数封装张量来作为变量，更多细节见下节，使用方式如下：

```
my_var = tf.Variable(tf.zeros([row_dim, col_dim]))
```

1.3.4 延伸学习

创建张量并不一定得用TensorFlow内建函数，可以使用`tf.convert_to_tensor()`函数将任意numpy数组转换为Python列表，或者将常量转换为一个张量。注意，`tf.convert_to_tensor()`函数也可以接受张量作为输入。

1.4 使用占位符和变量

使用TensorFlow计算图的关键工具是占位符和变量，也请读者务必理解两者的区别，以及什么地方该用谁。

1.4.1 开始

使用数据的关键点之一是搞清楚它是占位符还是变量。变量是TensorFlow机器学习算法的参数，TensorFlow维护（调整）这些变量的状态来优化机器学习算法。占位符是TensorFlow对象，用于表示输入输出数据的格式，允许传入指定类型和形状的数据，并依赖计算图的计算结果，比如，期望的计算结果。

1.4.2 动手做

在TensorFlow中，`tf.Variable()`函数创建变量，过程是输入一个张量，返回一个变量。声明变量后需要初始化变量。下面是创建变量并初始化的例子：

```
my_var = tf.Variable(tf.zeros([2,3]))
sess = tf.Session()
initialize_op = tf.global_variables_initializer()
sess.run(initialize_op)
```

占位符仅仅声明数据位置，用于传入数据到计算图。占位符通过会话的`feed_dict`参数获取数据。在计算图中使用占位符时，必须在其上执行至少一个操作。在TensorFlow中，初始化计算图，声明一个占位符`x`，定义`y`为`x`的`identity`操作。`identity`操作返回占位符传入的数据本身。结果图将在下节展示，代码如下：

```
sess = tf.Session()
x = tf.placeholder(tf.float32, shape=[2,2])
y = tf.identity(x)
x_vals = np.random.rand(2,2)
sess.run(y, feed_dict={x: x_vals})
# Note that sess.run(x, feed_dict={x: x_vals}) will result in a self-referencing error.
```

1.4.3 工作原理

以零张量初始化变量，其计算图如图1-1所示。

在图1-1中可以看出，计算图仅仅有一个变量，全部初始化为0。图中灰色部分详细地展示计算图操作以及相关的常量。右上角的小图展示的是主计算图。关于在TensorFlow中创建和可视化计算图的部分见第10章。

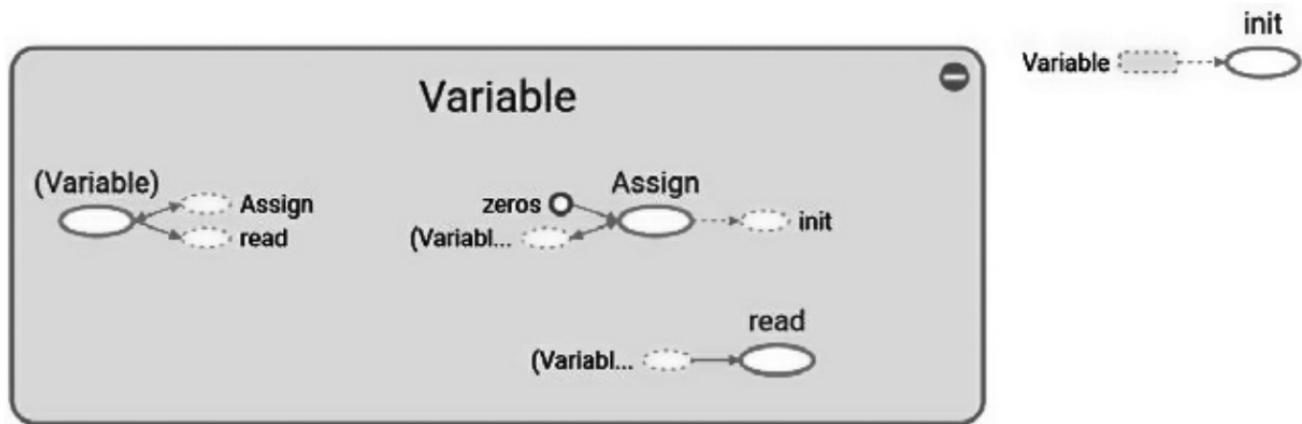


图1-1 变量

相似地，一个占位符传入numpy数组的计算图展示如图1-2所示。

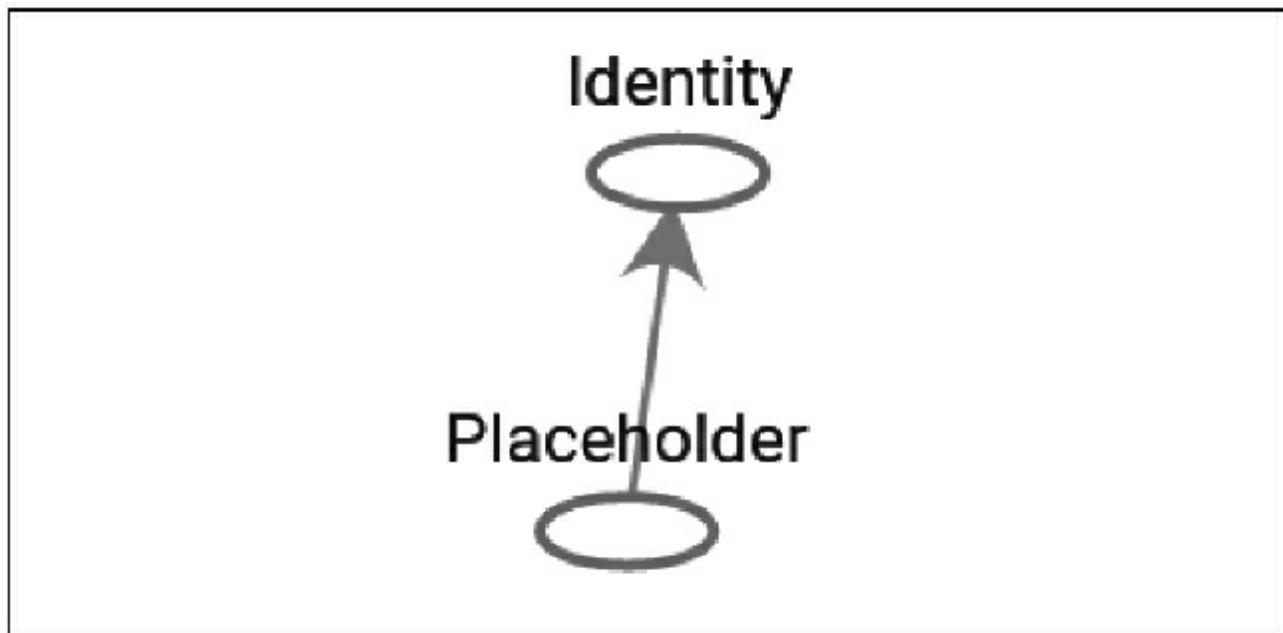


图1-2 占位符初始化的计算图。灰色部分详细地展示计算图操作以及相关的常量

1.4.4 延伸学习

在计算图运行的过程中，需要告诉TensorFlow初始化所创建的变量。TensorFlow的每个变量都有initializer方法，但最常用的方式是helper函数（global_variables_initializer（））。此函数会一次性初始化所创建的所有变量，使用方式如下：

```
initializer_op = tf.global_variables_initializer()
```

但是，如果是基于已经初始化的变量进行初始化，则必须按序进行初始化，使用方式如下：

```
sess = tf.Session()
first_var = tf.Variable(tf.zeros([2,3]))
sess.run(first_var.initializer)
second_var = tf.Variable(tf.zeros_like(first_var))
# Depends on first_var
sess.run(second_var.initializer)
```

1.5 操作（计算）矩阵

理解TensorFlow如何操作矩阵，对于理解计算图中数据的流动来说非常重要。

1.5.1 开始

许多机器学习算法依赖矩阵操作。在TensorFlow中，矩阵计算是相当容易的。在下面的所有例子里，我们都会创建一个图会话，代码如下：

```
import tensorflow as tf  
sess = tf.Session()
```

1.5.2 动手做

1. 创建矩阵：如在前面的章节描述张量时提到的，使用numpy数组（或者嵌套列表）来创建二维矩阵。也可以使用创建张量的函数（比如，zeros()、ones()、truncated_normal()等），并为其指定一个二维形状。TensorFlow也可以使用diag()函数从一个一维数组（或者列表）来创建对角矩阵，代码如下：

```
identity_matrix = tf.diag([1.0, 1.0, 1.0])
A = tf.truncated_normal([2, 3])
B = tf.fill([2,3], 5.0)
C = tf.random_uniform([3,2])
D = tf.convert_to_tensor(np.array([[1., 2., 3.], [-3., -7.,
-1.], [0., 5., -2.]]))
print(sess.run(identity_matrix))
[[ 1.  0.  0.]
 [ 0.  1.  0.]
 [ 0.  0.  1.]]
print(sess.run(A))
[[ 0.96751703  0.11397751 -0.3438891 ]
 [-0.10132604 -0.8432678   0.29810596]]
print(sess.run(B))
[[ 5.  5.  5.]
 [ 5.  5.  5.]]
print(sess.run(C))
[[ 0.33184157  0.08907614]
 [ 0.53189191  0.67605299]
 [ 0.95889051  0.67061249]]
print(sess.run(D))
[[ 1.  2.  3.]
 [-3. -7. -1.]
 [ 0.  5. -2.]]
```



注意，如果再次运行sess.run(C)，TensorFlow会重新初始化随机变量，并得到不同的随机数。

2. 矩阵的加法和减法：

```

print(sess.run(A+B))
[[ 4.61596632  5.39771316  4.4325695 ]
 [ 3.26702736  5.14477345  4.98265553]]
print(sess.run(B-B))
[[ 0.  0.  0.]
 [ 0.  0.  0.]]
Multiplication
print(sess.run(tf.matmul(B, identity_matrix)))
[[ 5.  5.  5.]
 [ 5.  5.  5.]]

```

3.矩阵乘法函数`matmul()`可以通过参数指定在矩阵乘法操作前是否进行矩阵转置。

4.矩阵转置，示例如下：

```

print(sess.run(tf.transpose(C)))
[[ 0.67124544  0.26766731  0.99068872]
 [ 0.25006068  0.86560275  0.58411312]]

```

5.再次强调，重新初始化将会得到不同的值。

6.对于矩阵行列式，使用方式如下：

```

print(sess.run(tf.matrix_determinant(D)))
-38.0

```

·矩阵的逆矩阵：

```

print(sess.run(tf.matrix_inverse(D)))
[[ -0.5          -0.5          -0.5          ]
 [  0.15789474   0.05263158   0.21052632]
 [  0.39473684   0.13157895   0.02631579]]

```



TensorFlow中的矩阵求逆方法是Cholesky矩阵分解法（又称为平方根法），矩阵需要为对称正定矩阵或者可进行LU分解。

7.矩阵分解：

·Cholesky矩阵分解法，使用方式如下：

```
print(sess.run(tf.cholesky(identity_matrix)))
[[ 1.  0.  1.]
 [ 0.  1.  0.]
 [ 0.  0.  1.]]
```

8.矩阵的特征值和特征向量，使用方式如下：

```
print(sess.run(tf.self_adjoint_eig(D)))
[[-10.65907521 -0.22750691  2.88658212]
 [ 0.21749542  0.63250104 -0.74339638]
 [ 0.84526515  0.2587998   0.46749277]
 [-0.4880805   0.73004459  0.47834331]]
```

注意，`self_adjoint_eig()`函数的输出结果中，第一行为特征值，剩下的向量是对应的向量。在数学中，这种方法也称为矩阵的特征分解。

1.5.3 工作原理

TensorFlow提供数值计算工具，并把这些计算添加到计算图中。这些部分对于简单的矩阵计算来说看似有点重，TensorFlow增加这些矩阵操作到计算图进行张量计算。现在看起来这些介绍有些啰嗦，但是这有助于理解后续章节的内容。

1.6 声明操作

现在开始学习TensorFlow计算图的其他操作。

1.6.1 开始

除了标准数值计算外，TensorFlow提供很多其他的操作。在使用之前，按照惯例创建一个计算图会话，代码如下：

```
import tensorflow as tf  
sess = tf.Session()
```

1.6.2 动手做

TensorFlow张量的基本操作有：add（）、sub（）、mul（）和div（）。注意，除特别说明外，这章节所有的操作都是对张量的每个元素进行操作：

1.TensorFlow提供div（）函数的多种变种形式和相关的函数。

2.值得注意的，div（）函数返回值的数据类型与输入数据类型一致。这意味着，在Python 2中，整数除法的实际返回是商的向下取整，即不大于商的最大整数；而Python 3版本中，TensorFlow提供truediv（）函数，其会在除法操作前强制转换整数为浮点数，所以最终的除法结果是浮点数，代码如下：

```
print(sess.run(tf.div(3,4)))
0
print(sess.run(tf.truediv(3,4)))
0.75
```

3.如果要对浮点数进行整数除法，可以使用floordiv（）函数。注意，此函数也返回浮点数结果，但是其会向下舍去小数位到最近的整数。示例如下：

```
print(sess.run(tf.floordiv(3.0,4.0)))
0.0
```

4.另外一个重要的函数是mod（）（取模）。此函数返回除法的余数。示例如下：

```
print(sess.run(tf.mod(22.0, 5.0)))
2.0
```

5.通过cross（）函数计算两个张量间的点积。记住，点积函数只为三维向量定义，所以cross（）函数以两个三维张量作为输入，示例如下：

```
print(sess.run(tf.cross([1., 0., 0.], [0., 1., 0.])))
[ 0.  0.  1.0]
```

6.下面给出数学函数的列表：

abs()	返回输入参数张量的绝对值
ceil()	返回输入参数张量的向上取整结果
cos()	返回输入参数张量的余弦值
exp()	返回输入参数张量的自然常数 e 的指数
floor()	返回输入参数张量的向下取整结果
inv()	返回输入参数张量的倒数
log()	返回输入参数张量的自然对数
maximum()	返回两个输入参数张量中的最大值
minimum()	返回两个输入参数张量中的最小值
neg()	返回输入参数张量的负值
pow()	返回输入参数第一个张量的第二个张量的次幂
round()	返回输入参数张量的四舍五入结果
rsqrt()	返回输入参数张量的平方根的倒数
sign()	根据输入参数张量的符号, 返回 -1、0 或 1
sin()	返回输入参数张量的正弦值
sqrt()	返回输入参数张量的平方根
square()	返回输入参数张量的平方

7. 特殊数学函数：有些用在机器学习中的特殊数学函数值得一提，TensorFlow也有对应的内建函数。除特别说明外，这些函数操作的也是张量的每个元素。

digamma()	普西函数 (Psi 函数), lgamma() 函数的导数
erf()	返回张量的高斯误差函数
erfc()	返回张量的互补误差函数
igamma()	返回下不完全伽马函数
igammac()	返回上不完全伽马函数
lbeta()	返回贝塔函数绝对值的自然对数
lgamma()	返回伽马函数绝对值的自然对数



1.6.3 工作原理

知道在计算图中应用什么函数合适是重要的。大部分情况下，我们关心预处理函数，但也通过组合预处理函数生成许多自定义函数，示例如下：

1.6.4 延伸学习

1.6.4 延伸学习

如果希望（未在上述函数列表中列出的操作）在计算图中增加其他操作，必须创建自定义函数。下面创建一个自定义二次多项式函数， $3x^2-x+10$ ：

1.7 实现激励函数

1.7.1 开始

激励函数是使用所有神经网络算法的必备“神器”。激励函数的目的是为了调节权重和误差。在TensorFlow中，激励函数是作用在张量上的非线性操作。激励函数的使用方法和前面的数学操作相似。激励函数的功能有很多，但其主要是为计算图归一化返回结果而引进的非线性部分。创建一个TensorFlow计算图：

1.7.2 动手做

TensorFlow的激励函数位于神经网络（neural network, nn）库。除了使用TensorFlow内建激励函数外，我们也可以使用TensorFlow操作设计自定义激励函数。导入预定义激励函数，或者在函数中显式调用.nn。这里，选择每个函数显式调用的方法。

1.整流线性单元（Rectifier linear unit, ReLU）是神经网络最常用的非线性函数。其函数为 $\max(0, x)$ ，连续但不平滑。示例如下：

2.有时为了抵消ReLU激励函数的线性增长部分，会在 $\min()$ 函数中嵌入 $\max(0, x)$ ，其在TensorFlow中的实现称作ReLU6，表示为 $\min(\max(0, x), 6)$ 。这是hard-sigmoid函数的变种，计算运行速度快，解决梯度消失（无限趋近于0），这些将在第8章和第9章中详细阐述，使用方式如下：

3.sigmoid函数是最常用的连续、平滑的激励函数。它也被称作逻辑函数（Logistic函数），表示为 $1/(1+\exp(-x))$ 。sigmoid函数由于在机器学习训练过程中反向传播项趋近于0，因此不怎么使用。使用方式如下：



注意，有些激励函数不以0为中心，比如，sigmoid函数。在大部分计算图算法中要求优先使用均值为0的样本数据集。

4.另外一种激励函数是双曲正切函数（hyper tangent, tanh）。双曲正切函数与sigmoid函数相似，但有一点不同：双曲正切函数取值范围为0到1；sigmoid函数取值范围为-1到1。双曲正切函数是双曲正弦与双曲余弦的比值，另外一种写法是 $((\exp(x) - \exp(-x)) / (\exp(x) + \exp(-x)))$ 。使用方式如下：

5.softsign函数也是一种激励函数，表达式为： $x / (\text{abs}(x) + 1)$ 。softsign函数是符号函数的连续估计，使用方式如下：

6.softplus激励函数是ReLU激励函数的平滑版，表达式为： $\log(\exp(x) + 1)$ 。使用方式如下：



注意，当输入增加时，softplus激励函数趋近于无限大，softsign函数趋近于1；当输入减小时，softplus激励函数趋近于0，softsign函数趋近于-1。

7.ELU激励函数（Exponential Linear Unit, ELU）与softplus激励函数相似，不同点在于：当输入无限小

时，ELU激励函数趋近于-1，而softplus激励函数趋近于0。表达式为 $(\exp(x) + 1) \text{ if } x < 0 \text{ else } x$ ，使用方式如下：

1.7.3 工作原理

上面这些激励函数是神经网络引入的非线性部分，并需要知道在什么位置使用激励函数。如果激励函数的取值范围在0和1之间，比如sigmoid激励函数，那计算图输出结果也只能在0到1之间取值。

如果激励函数隐藏在节点之间，就要意识到激励函数作用于传入的张量的影响。如果张量要缩放为均值为0，就需要使用激励函数使得尽可能多的变量在0附近。这暗示我们选用双曲正切（tanh）函数或者softsign函数。

1.7.4 延伸学习

图1-3和图1-4展示了不同激励函数，从中可以看到的激励函数有ReLU、ReLU6、softplus、ELU、sigmoid、softsign和tanh。

图1-3 ReLU、ReLU6、softplus和ELU激励函数

在图1-3中，我们可以看到四种激励函数：ReLU、ReLU6、softplus和ELU。这些激励函数输入值小于0时输出值逐渐变平，输入值大于0时输出值线性增长（除了ReLU6函数有最大值6）。

图1-4 sigmoid、softsign和tanh激励函数

图1-4展示的是sigmoid激励函数、双曲正切（tanh）激励函数和softsign激励函数。这些激励函数都是平滑的、具有S型，注意有两个激励函数有水平渐近线。

1.8 读取数据源

本书中使用样本数据集训练机器学习算法模型，本章简要介绍如何通过TensorFlow和Python访问各种数据源。

1.8.1 开始

在TensorFlow中，有些数据源使用Python内建库，有的需要编写Python脚本下载，还有其他的得手动从网上下载。所有这些数据源都需要联网才能获取到。

1.8.2 动手做

1. 鸢尾花卉数据集（Iris data）。此样本数据是机器学习和统计分析最经典的数据集，包含山鸢尾、变色鸢尾和维吉尼亚鸢尾各自的花萼和花瓣的长度和宽度。总共有150个数据集，每类有50个样本。用Python加载样本数据集时，可以使用Scikit Learn的数据集函数，使用方式如下：

2. 出生体重数据（Birth weight data）。此样本数据集是婴儿出生体重以及母亲和家庭历史人口统计学、医学指标，有189个样本集，包含11个特征变量。使用Python访问的数据的方式：

3. 波士顿房价数据（Boston Housing data）。此样本数据集保存在卡内基梅隆大学机器学习仓库，总共有506个房价样本，包含14个特征变量。使用Python获取数据的方式：

4. MNIST手写体字库：MNIST手写体字库是NIST手写体字库的子样本数据集，网址：<https://yann.lecun.com/exdb/mnist/>。包含70000张0到9的图像，其中60000张标注为训练样本数据集，10000张为测试样本数据集。TensorFlow提供内建函数来访问它，MNIST手写体字库常用来进行图像识别训练。在机器学习中，提供验证样本数据集来预防过拟合是非常重要的，TensorFlow从训练样本数据集中留出5000张图片作为验证样本数据集。这里展示使用Python访问数据的方式：

5. 垃圾短信文本数据集（Spam-ham text data）。通过以下方式访问垃圾短信文本数据：

6. 影评样本数据集。此样本数据集是电影观看者的影评，分为好评和差评，可以在网站<http://www.cs.cornell.edu/people/pabo/movie-review-data/>下载。这里用Python进行数据处理，使用方式如下：

7. CIFAR-10图像数据集。此图像数据集是CIFAR机构发布的8亿张彩色图片（已标注为， 32×32 像素）的子集，总共分10类，60000张图片。50000张图片训练数据集，10000张测试数据集。由于这个图像数据集数据量大，并在本书中以多种方式使用，后面到具体用时再细讲，访问网址为：<http://www.cs.toronto.edu/~kriz/cifar.html>。

8. 莎士比亚著作文本数据集（Shakespeare text data）。此文本数据集是古登堡数字电子书计划提供的免费电子书籍，他们编译了莎士比亚所有著作。用Python访问文本文件的方式如下：

9. 英德句子翻译样本集。此数据集由Tatoeba（在线翻译数据库）发布，ManyThings.org (<http://www.manythings.org>) 整理并提供下载。这里提供英德语句互译的文本文件（你可以通过改变URL，使用你需要的任何语言的文本文件），使用方式如下：

1.8.3 参考

1.9 学习资料

这里提供一些关于TensorFlow使用和学习的链接、文档资料和用例。

TensorFlow资源列表如下：

1. 本书代码可在GitHub获取https://github.com/nfmccleure/tensorflow_cookbook。

2. TensorFlow官方Python API文档地址：https://www.tensorflow.org/api_docs/python。其中包括TensorFlow所有函数、对象和方法的文档和例子。本书当前的TensorFlow版本为r0.8。

3. TensorFlow官方用例相当详细，访问网址：<https://www.tensorflow.org/tutorials/index.html>。包括图像识别模型、Word2Vec、RNN模型和sequence-to-sequence模型，也有些偏微分方程的例子。后续还会不断增加更多实例。

4. TensorFlow官方GitHub仓库：<https://github.com/tensorflow/tensorflow>。你可以查看源代码，甚至包含fork或者clone最新代码。也可以看到最近的issue。

5. TensorFlow在Dockerhub上维护的公开Docker镜像，网址为<https://hub.docker.com/r/tensorflow/tensorflow/>。

6. TensorFlow提供可下载的虚拟机，基于Ubuntu 15.04操作系统安装TensorFlow。这样对于Windows PC用户更容易使用TensorFlow的UNIX版本。

7. Stack Overflow上有TensorFlow标签的知识问答。随着TensorFlow日益流行，这个标签下的问答在不断增长，访问网址为：<http://stackoverflow.com/questions/tagged/TensorFlow>。

8. TensorFlow非常灵活，应用场景广，最常用的是深度学习。为了理解深度学习的基础，数学知识和深度学习开发，Google在线课程Udacity上开课，网址为：<https://www.udacity.com/course/deep-learning--ud730>。

9. TensorFlow也提供一个网站，让你可以可视化查看随着参数和样本数据集的变化对训练神经网络的影响，网址为：<http://playground.tensorflow.org>。

10. 深度学习开山祖师爷Geoffrey Hinton在Coursera上开课教授“机器学习中的神经网络”，网址为：<https://www.coursera.org/learn/neural-networks>。

11. 斯坦福大学提供在线课程“图像识别中卷积神经网络”及其详细的课件，网址为：<http://cs231n.stanford.edu/>。

参考

第2章 TensorFlow进阶

本章将介绍如何使用TensorFlow的关键组件，并串联起来创建一个简单的分类器，评估输出结果。阅读本章你会学到以下知识点：

- 计算图中的操作
- TensorFlow的嵌入Layer
- TensorFlow的多层Layer
- TensorFlow实现损失函数
- TensorFlow实现反向传播
- TensorFlow实现随机训练和批量训练
- TensorFlow实现创建分类器
- TensorFlow实现模型评估

2.1 本章概要

现在我们已经学习完TensorFlow如何创建张量，使用变量和占位符；下面将把这些对象组成一个计算图。基于此，创建一个简单的分类器，并看下性能如何。



本书的所有源代码可以在

GitHub (https://github.com/nfmcclure/tensorflow_cookbook) 下载。

2.2 计算图中的操作

现在可以把这些对象表示成计算图，下面介绍计算图中对象的操作。

2.2.1 开始

导入TensorFlow，创建一个会话，开始一个计算图：

2.2.2 动手做

在这个例子中，我们将结合前面所学的知识，传入一个列表到计算图中的操作，并打印返回值：

- 1.首先，声明张量和占位符。这里，创建一个numpy数组，传入计算图操作：

2.2.3 工作原理

首先，创建数据集和计算图操作，然后传入数据、打印返回值。下面展示计算图（见图2-1）：

图2-1 图中展示了占位符、`x_data`、乘法常量传入乘法操作

2.3 TensorFlow的嵌入Layer

在本节，我们将学习如何在同一个计算图中进行多个乘法操作。

2.3.1 开始

下面我们将用两个矩阵乘以占位符，然后做加法。传入两个矩阵（三维numpy数组）：

2.3.2 动手做

知道数据在传入后是如何改变形状的也是非常重要的。我们将传入两个形状为 3×5 的numpy数组，然后每个矩阵乘以常量矩阵（形状为： 5×1 ），将返回一个形状为 3×1 的矩阵。紧接着再乘以 1×1 的矩阵，返回的结果矩阵仍然为 3×1 。最后，加上一个 3×1 的矩阵，示例如下：

1.首先，创建数据和占位符：

2.接着，创建矩阵乘法和加法中要用到的常量矩阵：

3.现在声明操作，表示成计算图：

4.最后，通过计算图赋值：

2.3.3 工作原理

上面创建的计算图可以用Tensorboard可视化。Tensorboard是TensorFlow的功能，允许用户在图中可视化计算图和值。这些功能是原生的，不像其他机器学习框架。如果想知道这是如何做到的，可参见第11章。图2-2是嵌入层计算图。

2.3.4 延伸学习

在我们通过计算图运行数据之前心里要有个数：声明数据形状，预估操作返回值形状。由于预先不知道或者维度在变化，情况也可能发生变化。为了实现目标，我们指明变化的维度，或者事先不知道的维度设为none。例如，占位符有未知列维度，使用方式如下：

图2-2 在图中可以看到向上传播的数据大小

上面虽然允许打破矩阵乘法规则，但仍然需要遵守——乘以常量矩阵返回值有一致的行数。在计算图中，也可以传入动态的x_data，或者更改形状的x_data，具体细节将在多批量传入数据时讲解。

2.4 TensorFlow的多层Layer

目前，我们已经学完在同一个计算图中进行多个操作，接下来将讲述如何连接传播数据的多层Layer。

2.4.1 开始

本节中，将介绍如何更好地连接多层Layer，包括自定义Layer。这里给出一个例子（数据是生成随机图片数据），以更好地理解不同类型的操作和如何用内建层Layer进行计算。我们对2D图像进行滑动窗口平均，然后通过自定义操作层Layer返回结果。

在这节，我们将会看到TensorFlow的计算图太大，导致无法完整查看。为了解决此问题，将对各层Layer和操作进行层级命名管理。按照惯例，加载numpy和tensorflow模块，创建计算图，代码如下：

```
import tensorflow as tf
import numpy as np
sess = tf.Session()
```

2.4.2 动手做

1.首先，通过numpy创建2D图像， 4×4 像素图片。我们将创建成四维：第一维和最后一维大小为1。注意，TensorFlow的图像函数是处理四维图片的，这四维是：图片数量、高度、宽度和颜色通道。这里是一张图片，单颜色通道，所以设两个维度值为1：

```
x_shape = [1, 4, 4, 1]
x_val = np.random.uniform(size=x_shape)
```

2.下面在计算图中创建占位符。此例中占位符是用来传入图片的，代码如下：

```
x_data = tf.placeholder(tf.float32, shape=x_shape)
```

3.为了创建过滤 4×4 像素图片的滑动窗口，我们将用TensorFlow内建函数conv2d（）（常用来做图像处理）卷积 2×2 形状的常量窗口。conv2d（）函数传入滑动窗口、过滤器和步长。本例将在滑动窗口四个方向上计算，所以在四个方向上都要指定步长。创建一个 2×2 的窗口，每个方向长度为2的步长。为了计算平均值，我们将用常量为0.25的向量与 2×2 的窗口卷积，代码如下：

```
my_filter = tf.constant(0.25, shape=[2, 2, 1, 1])
my_strides = [1, 2, 2, 1]
mov_avg_layer= tf.nn.conv2d(x_data, my_filter, my_strides,
                            padding='SAME', name='Moving'_Avg_
Window')
```



可以使用公式： $\text{Output} = (\text{W}-\text{F}+2\text{P})/\text{S}+1$ 计算卷积层的返回值形状。这里，W是输入形状，F是过滤器形状，P是padding的大小，S是步长形状。

4.注意，我们通过conv2d（）函数的name参数，把这层Layer命名为“Moving_Avg_Window”。

5.现在定义一个自定义Layer，操作滑动窗口平均的 2×2 的返回值。自定义函数将输入张量乘以一个 2×2 的矩阵张量，然后每个元素加1。因为矩阵乘法只计算二维矩阵，所以剪裁图像的多余维度（大小为1）。TensorFlow通过内建函数squeeze（）剪裁。下面是新定义的Layer：

```
def custom_layer(input_matrix):
    input_matrix_sqeezed = tf.squeeze(input_matrix)
    A = tf.constant([[1., 2.], [-1., 3.]])
    b = tf.constant(1., shape=[2, 2])
    temp1 = tf.matmul(A, input_matrix_sqeezed)
```

```
temp = tf.add(temp1, b) # Ax + b  
return(tf.sigmoid(temp))
```

6. 现在把刚刚新定义的Layer加入到计算图中，并且用tf.name_scope() 命名唯一的Layer名字，后续在计算图中可折叠/扩展Custom_Layer层，代码如下：

```
with tf.name_scope('Custom_Layer') as scope:  
    custom_layer1 = custom_layer(mov_avg_layer)
```

7. 为占位符传入4×4像素图片，然后执行计算图，代码如下：

```
print(sess.run(custom_layer1, feed_dict={x_data: x_val}))  
[[ 0.91914582  0.96025133]  
 [ 0.87262219  0.9469803 ]]
```

2.4.3 工作原理

已命名的层级Layer和操作的可视化图看起来更清晰，我们可以折叠和展开已命名的自定义层Layer。在图2-3中，我们可以在左边看到折叠的概略图，在右边看到展开的详细图：

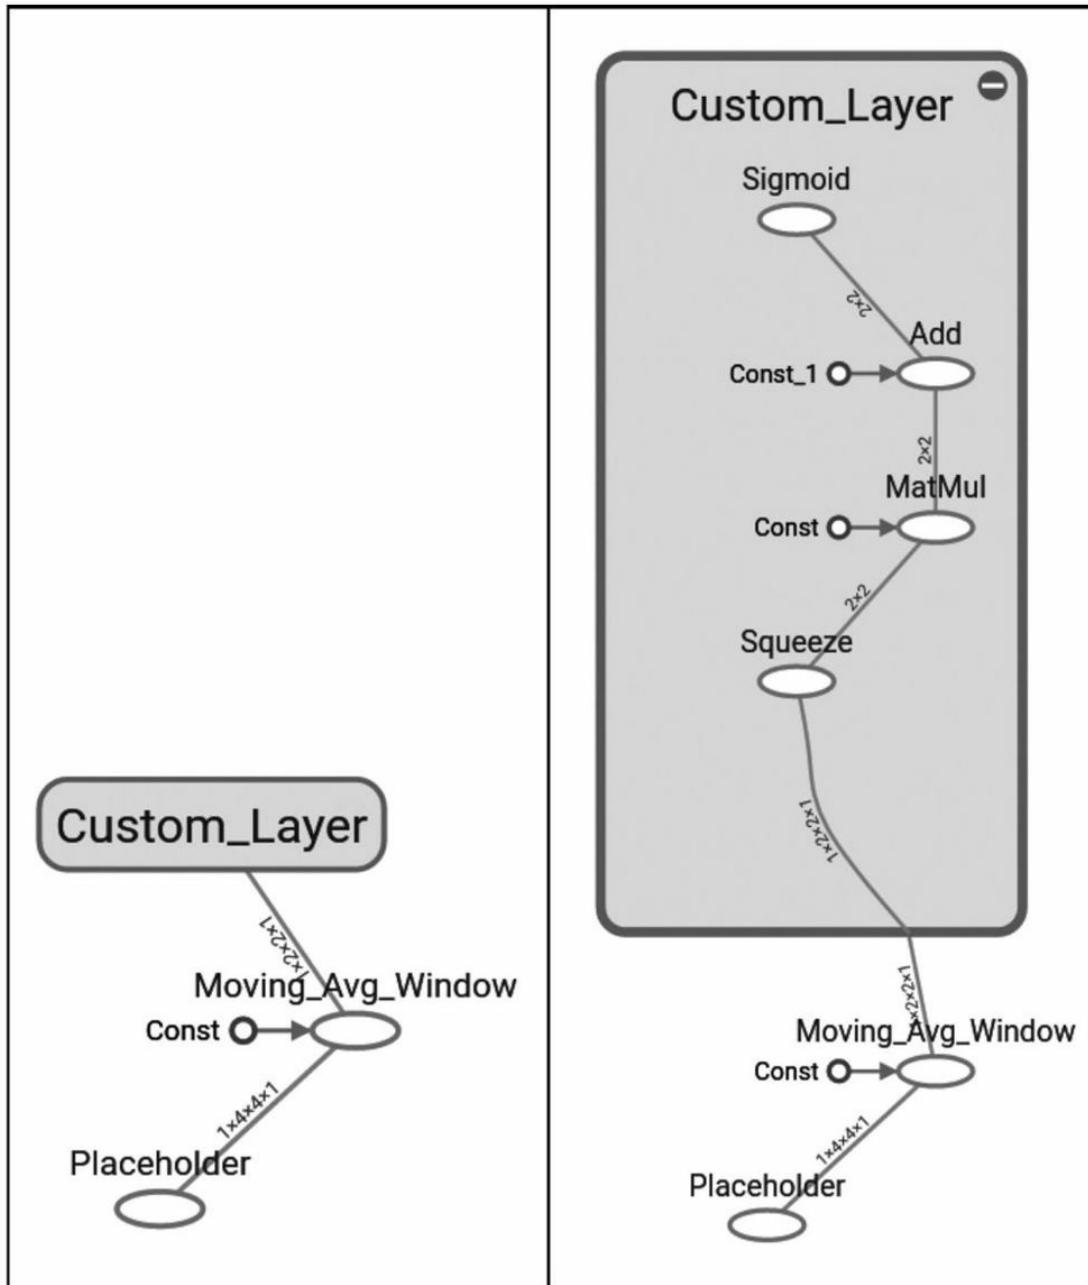


图2-3 两层计算图。第一层是Moving_Avg_Window，第二层是Custom_Layer

2.5 TensorFlow实现损失函数

损失函数（loss function）对机器学习来讲是非常重要的。它们度量模型输出值与目标值（target）间的差值。本节会介绍TensorFlow中实现的各种损失函数。

2.5.1 开始

为了优化机器学习算法，我们需要评估机器学习模型训练输出结果。在TensorFlow中评估输出结果依赖损失函数。损失函数告诉TensorFlow，预测结果相比期望的结果是好是坏。在大部分场景下，我们会有算法模型训练的样本数据集和目标值。损失函数比较预测值与目标值，并给出两者之间的数值化的差值。

本节会介绍TensorFlow能实现的大部分损失函数。

为了比较不同损失函数的区别，我们将会在图表中绘制出来。先创建计算图，然后加载matplotlib（Python的绘图库），代码如下：

```
import matplotlib.pyplot as plt
import tensorflow as tf
```

2.5.2 动手做

首先，将讲解回归算法的损失函数。回归算法是预测连续因变量的。创建预测序列和目标序列作为张量，预测序列是-1到1之间的等差数列，代码如下：

```
x_vals = tf.linspace(-1., 1., 500)  
target = tf.constant(0.)
```

1.L2正则损失函数（即欧拉损失函数）。L2正则损失函数是预测值与目标值差值的平方和。注意，上述例子中目标值为0。L2正则损失函数是非常有用的损失函数，因为它在目标值附近有更好的曲度，机器学习算法利用这点收敛，并且离目标越近收敛越慢，代码如下：

```
l2_y_vals = tf.square(target - x_vals)  
l2_y_out = sess.run(l2_y_vals)
```



TensorFlow有内建的L2正则形式，称为`nn.l2_loss()`。这个函数其实是实际L2正则的一半，换句话说，它是上面`l2_y_vals`的1/2。

2.L1正则损失函数（即绝对值损失函数）。与L2正则损失函数对差值求平方不同的是，L1正则损失函数对差值求绝对值。L1正则在目标值附近不平滑，这会导致算法不能很好地收敛。代码如下：

```
l1_y_vals = tf.abs(target - x_vals)  
l1_y_out = sess.run(l1_y_vals)
```

3.Pseudo-Huber损失函数是Huber损失函数的连续、平滑估计，试图利用L1和L2正则削减极值处的陡峭，使得目标值附近连续。它的表达式依赖参数`delta`。我们将绘图来显示`delta1=0.25`和`delta2=5`的区别，代码如下：

```
delta1 = tf.constant(0.25)  
phuber1_y_vals = tf.mul(tf.square(delta1), tf.sqrt(1. +  
                                              tf.square((target - x_vals)/delta1)) - 1.)  
phuber1_y_out = sess.run(phuber1_y_vals)  
delta2 = tf.constant(5.)  
phuber2_y_vals = tf.mul(tf.square(delta2), tf.sqrt(1. +  
                                              tf.square((target - x_vals)/delta2)) - 1.)  
phuber2_y_out = sess.run(phuber2_y_vals)
```

4. 分类损失函数是用来评估预测分类结果的。

5. 重新给x_vals和target赋值，保存返回值并在下节绘制出来，代码如下：

```
x_vals = tf.linspace(-3., 5., 500)
target = tf.constant(1.)
targets = tf.fill([500], 1.)
```

6. Hinge损失函数主要用来评估支持向量机算法，但有时也用来评估神经网络算法。在本例中是计算两个目标类 (-1, 1) 之间的损失。下面的代码中，使用目标值1，所以预测值离1越近，损失函数值越小：

```
hinge_y_vals = tf.maximum(0., 1. - tf.mul(target, x_vals))
hinge_y_out = sess.run(hinge_y_vals)
```

7. 两类交叉熵损失函数（Cross-entropy loss）有时也作为逻辑损失函数。比如，当预测两类目标0或者1时，希望度量预测值到真实分类值（0或者1）的距离，这个距离经常是0到1之间的实数。为了度量这个距离，我们可以使用信息论中的交叉熵，代码如下：

```
xentropy_y_vals = - tf.mul(target, tf.log(x_vals)) - tf.mul((1. - target), tf.log(1. - x_vals))
xentropy_y_out = sess.run(xentropy_y_vals)
```

8. Sigmoid交叉熵损失函数（Sigmoid cross entropy loss）与上一个损失函数非常类似，有一点不同的是，它先把x_vals值通过sigmoid函数转换，再计算交叉熵损失，代码如下：

```
xentropy_sigmoid_y_vals = tf.nn.sigmoid_cross_entropy_with_
logits(x_vals, targets)
xentropy_sigmoid_y_out = sess.run(xentropy_sigmoid_y_vals)
```

9. 加权交叉熵损失函数（Weighted cross entropy loss）是Sigmoid交叉熵损失函数的加权，对正目标加权。举个例子，我们将正目标加权权重0.5，代码如下：

```
weight = tf.constant(0.5)
xentropy_weighted_y_vals = tf.nn.weighted_cross_entropy_with_
logits(x_vals, targets, weight)
xentropy_weighted_y_out = sess.run(xentropy_weighted_y_vals)
```

10. Softmax交叉熵损失函数（Softmax cross-entropy loss）是作用于非归一化的输出结果，只针对单个目标分类的计算损失。通过softmax函数将输出结果转化成概率分布，然后计算真值概率分布的损失，代码如下：

```
unscaled_logits = tf.constant([[1., -3., 10.]])
target_dist = tf.constant([[0.1, 0.02, 0.88]])
softmax_xentropy = tf.nn.softmax_cross_entropy_with_
logits(unscaled_logits, target_dist)
print(sess.run(softmax_xentropy))
[ 1.16012561]
```

11.稀疏Softmax交叉熵损失函数（Sparse softmax cross-entropy loss）和上一个损失函数类似，它是把目标分类为true的转化成index，而Softmax交叉熵损失函数将目标转成概率分布。代码如下：

```
unscaled_logits = tf.constant([[1., -3., 10.]])
sparse_target_dist = tf.constant([2])
sparse_xentropy = tf.nn.sparse_softmax_cross_entropy_with_
logits(unscaled_logits, sparse_target_dist)
print(sess.run(sparse_xentropy))
[ 0.00012564]
```

2.5.3 工作原理

这里用matplotlib绘制回归算法的损失函数（见图2-4）：

```
x_array = sess.run(x_vals)
plt.plot(x_array, l2_y_out, 'b-', label='L2 Loss')
plt.plot(x_array, l1_y_out, 'r--', label='L1 Loss')
plt.plot(x_array, phuber1_y_out, 'k-.', label='P-Huber Loss (0.25)')
plt.plot(x_array, phuber2_y_out, 'g:', label='P'-Huber Loss (5.0)')
plt.ylim(-0.2, 0.4)
plt.legend(loc='lower right', prop={'size': 11})
plt.show()
```

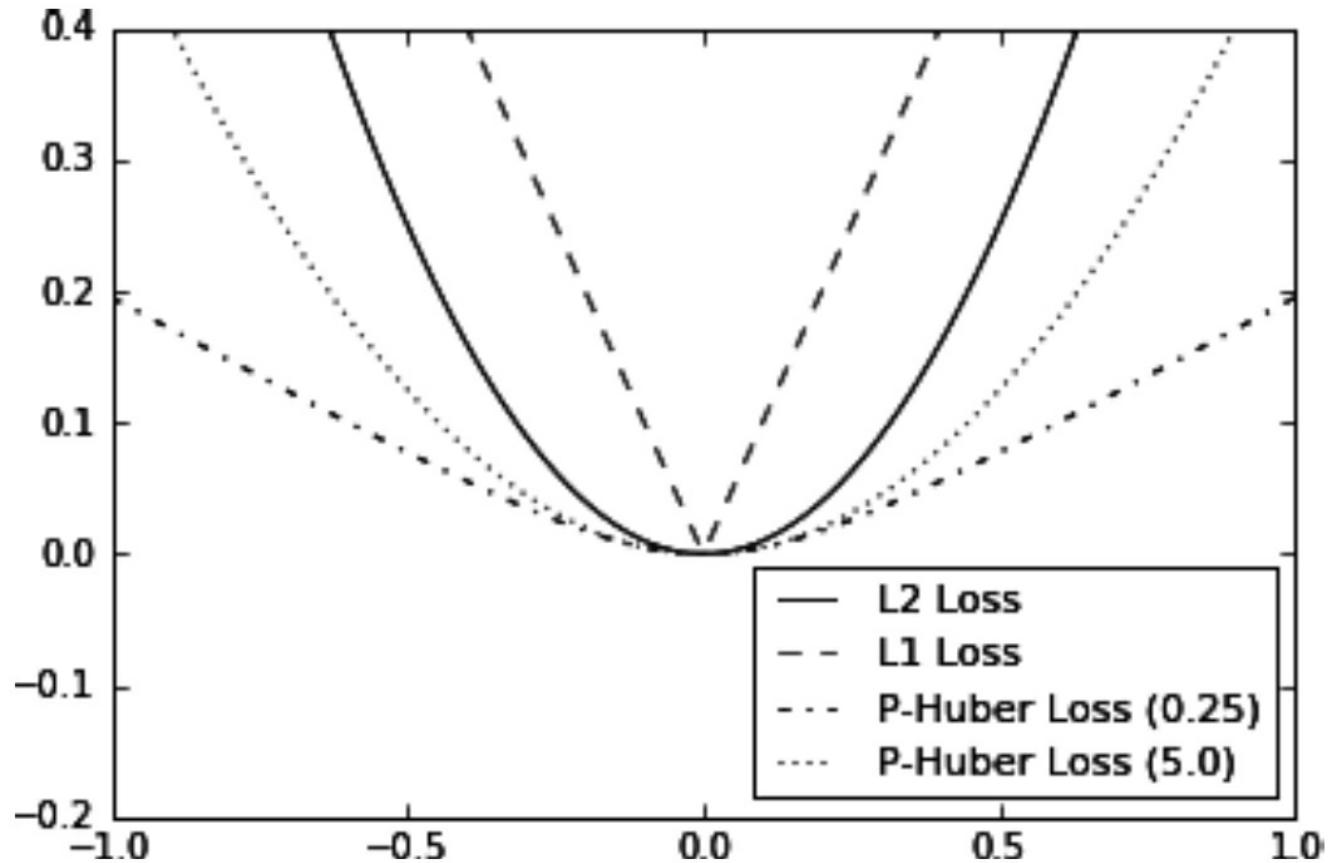


图2-4 各种回归算法的损失函数

下面是用matplotlib绘制各种分类算法损失函数（见图2-5）：

```
x_array = sess.run(x_vals)
plt.plot(x_array, hinge_y_out, 'b-', label='Hinge Loss')
plt.plot(x_array, xentropy_y_out, 'r--', label='Cross Entropy Loss')
plt.plot(x_array, xentropy_sigmoid_y_out, 'k-.', label='Cross Entropy Sigmoid Loss')
plt.plot(x_array, xentropy_weighted_y_out, g:', label='Weighted Cross Entropy Loss (x0.5)')
plt.ylim(-1.5, 3)
plt.legend(loc='lower right', prop={'size': 11})
plt.show()
```

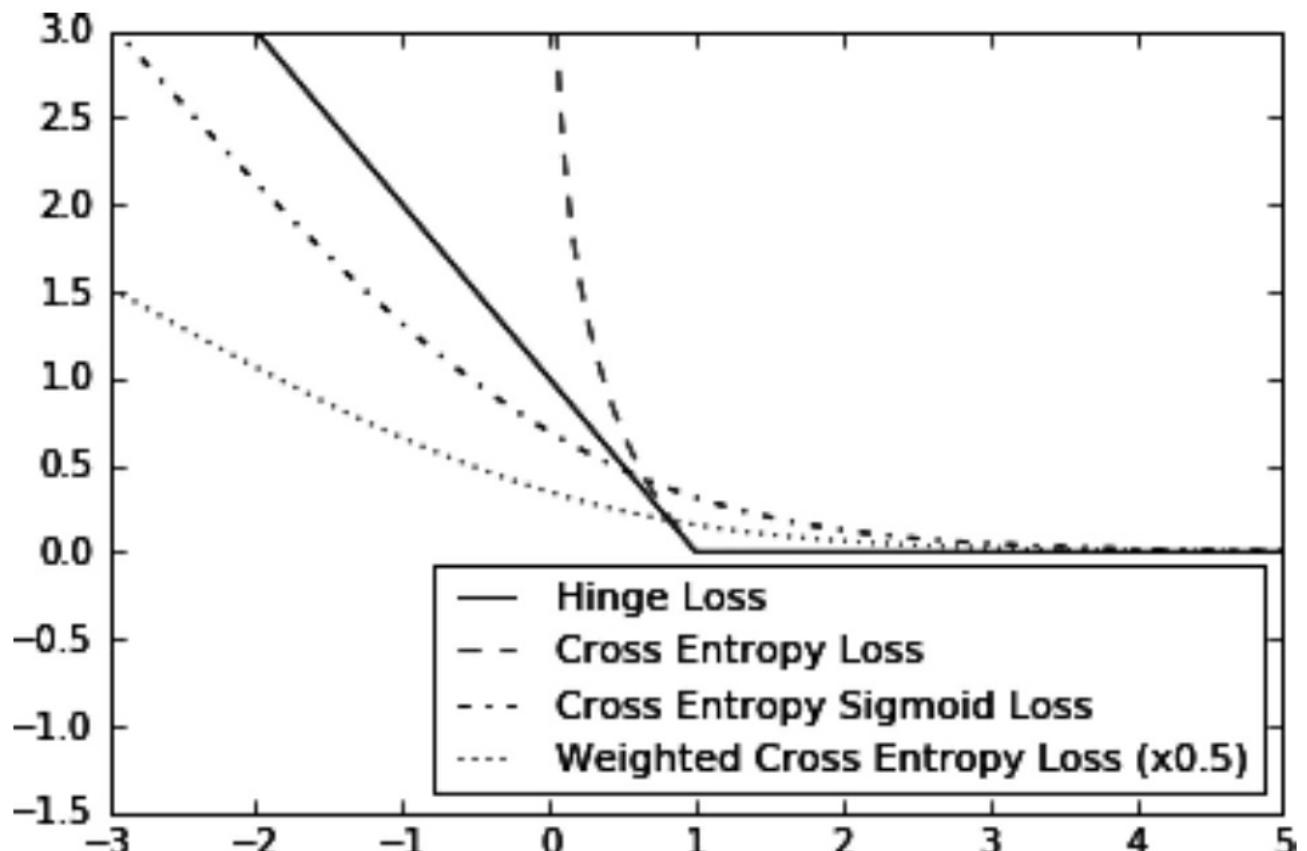


图2-5 各种分类算法的损失函数

2.5.4 延伸学习

下面总结一下前面描述的各种损失函数：

损失函数	使用类型	优 点	缺 点
L2	回归算法	更稳定	缺少健壮
L1	回归算法	更健壮	缺少稳定
Pseudo-Huber	回归算法	更健壮、稳定	参数多
Hinge	分类算法	常用于 SVM 的最大距离	异常值导致无边界损失
Cross-entropy	分类算法	更稳定	缺少健壮，出现无边界损失

其他分类算法的损失函数都需要做交叉熵损失。Sigmoid交叉熵损失函数被用在非归一化逻辑操作，先计算sigmoid，再计算交叉熵。TensorFlow有很好的内建方法来处理数值边界问题。Softmax交叉熵和稀疏Softmax交叉熵都类似。



这里大部分描述的分类算法损失函数是针对二类分类预测，不过也可以通过对每个预测值/目标的交叉熵求和，扩展成多类分类。

也有一些其他指标来评价机器学习模型，这里给出一个列表。

模型指标	描 述
R 平方值 (R-squared)	对简单的线性模型来讲，用于度量因变量的变异中可由自变量解释部分所占的比例
RMSE (平均方差)	对连续模型来讲，平均方差是度量预测的值和观察到的值之差的样本标准差
混淆矩阵 (Confusion matrix)	对分类模型来讲，以矩阵形式将数据集中的记录按照真实的类别与分类模型预测的分类判断两个标准进行分析汇总，其每一列代表预测值，每一行代表的是实际的类别。理想情况下，混淆矩阵是对角矩阵
召回率 (Recall)	对于分类模型来讲，召回率是正类预测为正类数与所有预测正类数的比值
精准度 (Precision)	对于分类模型来讲，精准度是正类预测为正类数与所有实际正类数的比值
F 值 (F-score)	对于分类模型来讲，F 值是召回率和精准度的调和平均数

2.6 TensorFlow实现反向传播

使用TensorFlow的一个优势是，它可以维护操作状态和基于反向传播自动地更新模型变量。本节将介绍如何使用这种优势来训练机器学习模型。

2.6.1 开始

现在开始介绍如何调节模型变量来最小化损失函数。前面已经学习了创建对象和操作，创建度量预测值和目标值之间差值的损失函数。这里将讲解TensorFlow是如何通过计算图来更新变量和最小化损失函数来反向传播误差的。这步将通过声明优化函数（optimization function）来实现。一旦声明好优化函数，TensorFlow将通过它在所有的计算图中解决反向传播的项。当我们传入数据，最小化损失函数，TensorFlow会在计算图中根据状态相应的调节变量。

本节先举个简单的回归算法的例子。从均值为1、标准差为0.1的正态分布中抽样随机数，然后乘以变量A，损失函数为L2正则损失函数。理论上，A的最优值是10，因为生成的样例数据均值是1。

第二个例子是一个简单的二值分类算法。从两个正态分布 ($N(-1, 1)$ 和 $N(3, 1)$) 生成100个数。所有从正态分布 $N(-1, 1)$ 生成的数据标为目标类0；从正态分布 $N(3, 1)$ 生成的数据标为目标类1，模型算法通过sigmoid函数将这些生成的数据转换成目标类数据。换句话讲，模型算法是 $\text{sigmoid}(x+A)$ ，其中，A是要拟合的变量，理论上 $A=-1$ 。假设，两个正态分布的均值分别是 m_1 和 m_2 ，则达到A的取值时，它们通过 $-(m_1+m_2)/2$ 转换成到0等距的值。后面将会在TensorFlow中见证怎样取到相应的值。

同时，指定一个合适的学习率对机器学习算法的收敛是有帮助的。优化器类型也需要指定，前面的两个例子会使用标准梯度下降法，它在TensorFlow中的实现是 `GradientDescentOptimizer()` 函数。

2.6.2 动手做

这里是回归算法例子：

1. 导入Python的数值计算模块，numpy和tensorflow：

```
import numpy as np
import tensorflow as tf
```

2. 创建计算图会话：

```
sess = tf.Session()
```

3. 生成数据，创建占位符和变量A：

```
x_vals = np.random.normal(1, 0.1, 100)
y_vals = np.repeat(10., 100)
x_data = tf.placeholder(shape=[1], dtype=tf.float32)
y_target = tf.placeholder(shape=[1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[1]))
```

4. 增加乘法操作：

```
my_output = tf.mul(x_data, A)
```

5. 增加L2正则损失函数：

```
loss = tf.square(my_output - y_target)
```

6. 在运行之前，需要初始化变量：

```
init = tf.initialize_all_variables()
sess.run(init)
```

7. 现在声明变量的优化器。大部分优化器算法需要知道每步迭代的步长，这距离是由学习率控制的。如果学习率太小，机器学习算法可能耗时很长才能收敛；如果学习率太大，机器学习算法可能会不收敛。相应地导致梯度消失和梯度爆炸问题。学习率对算法的收敛影响较大，我们会在本节结尾探讨。在本节中使用的是标准梯度下降算法，但实际情况应该因问题而异，不同的问题使用不同的优化器算法，具体见2.6.5节中

Sebastian Ruder所写的文章。

```
my_opt = tf.train.GradientDescentOptimizer(learning_rate=0.02)
train_step = my_opt.minimize(loss)
```



选取最优的学习率的理论很多，但真正解决机器学习算法的问题很难。2.6.5节列出了特定算法的学习率选取方法。

8.最后一步是训练算法。我们迭代101次，并且每25次迭代打印返回结果。选择一个随机的x和y，传入计算图中。TensorFlow将自动地计算损失，调整A偏差来最小化损失：

```
for i in range(100):
    rand_index = np.random.choice(100)

    rand_x = [x_vals[rand_index]]
    rand_y = [y_vals[rand_index]]
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})
    if (i+1)%25==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)))
        print('Loss = ' + str(sess.run(loss, feed_dict={x_data: rand_x, y_target: rand_y})))
Here is the output:
Step #25 A = [ 6.23402166]
Loss = 16.3173
Step #50 A = [ 8.50733757]
Loss = 3.56651
Step #75 A = [ 9.37753201]
Loss = 3.03149
Step #100 A = [ 9.80041122]
Loss = 0.0990248
```

9.现在将介绍简单的分类算法例子。如果先重置一下前面的TensorFlow计算图，我们就可以使用相同的TensorFlow脚本继续分类算法的例子。我们试图找到一个优化的转换方式A，它可以把两个正态分布转换到原点，sigmoid函数将正态分布分割成不同的两类。

10.首先，重置计算图，并且重新初始化变量：

```
from tensorflow.python.framework import ops
ops.reset_default_graph()
sess = tf.Session()
```

11.从正态分布 ($N(-1, 1)$, $N(3, 1)$) 生成数据。同时也生成目标标签，占位符和偏差变量A:

```
x_vals = np.concatenate((np.random.normal(-1, 1, 50), np.random.normal(3, 1, 50)))
y_vals = np.concatenate((np.repeat(0., 50), np.repeat(1., 50)))
x_data = tf.placeholder(shape=[1], dtype=tf.float32)
y_target = tf.placeholder(shape=[1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(mean=10, shape=[1]))
```



初始化变量A为10附近的值，远离理论值-1。这样可以清楚地显示算法是如何从10收敛为-1的。

12.增加转换操作。这里不必封装sigmoid函数，因为损失函数中会实现此功能:

```
my_output = tf.add(x_data, A)
```

13.由于指定的损失函数期望批量数据增加一个批量数的维度，这里使用expand_dims() 函数增加维度。下节将讨论如何使用批量变量训练，这次还是一次使用一个随机数据:

```
my_output_expanded = tf.expand_dims(my_output, 0)
y_target_expanded = tf.expand_dims(y_target, 0)
```

14.初始化变量A:

```
init = tf.initialize_all_variables()
sess.run(init)
```

15.声明损失函数，这里使用一个带非归一化logits的交叉熵的损失函数，同时会用sigmoid函数转换。TensorFlow的nn.sigmoid_cross_entropy_with_logits() 函数实现所有这些功能，需要向它传入指定的维度，代码如下:

```
xentropy = tf.nn.sigmoid_cross_entropy_with_logits( my_output_expanded, y_target_expanded)
```

16.如前面回归算法的例子，增加一个优化器函数让TensorFlow知道如何更新和偏差变量：

```
my_opt = tf.train.GradientDescentOptimizer(0.05)
train_step = my_opt.minimize(xentropy)
```

17.最后，通过随机选择的数据迭代几百次，相应地更新变量A。每迭代200次打印出损失和变量A的返回值：

```
for i in range(1400):
    rand_index = np.random.choice(100)
    rand_x = [x_vals[rand_index]]
    rand_y = [y_vals[rand_index]]

    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})
    if (i+1)%200==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)))
        print('Loss = ' + str(sess.run(xentropy, feed_dict={x_
data: rand_x, y_target: rand_y})))
Step #200 A = [ 3.59597969]
Loss = [[ 0.00126199]]
Step #400 A = [ 0.50947344]
Loss = [[ 0.01149425]]
Step #600 A = [-0.50994617]
Loss = [[ 0.14271219]]
Step #800 A = [-0.76606178]
Loss = [[ 0.18807337]]
Step #1000 A = [-0.90859312]
Loss = [[ 0.02346182]]
Step #1200 A = [-0.86169094]
Loss = [[ 0.05427232]]
Step #1400 A = [-1.08486211]
Loss = [[ 0.04099189]]
```

2.6.3 工作原理

作为概括，总结如下几点：

- 1.生成数据。
- 2.初始化占位符和变量。
- 3.创建损失函数。
- 4.定义一个优化器算法。
- 5.最后，通过随机数据样本进行迭代，更新变量。

2.6.4 延伸学习

前面涉及的优化器算法对学习率的选择较敏感。下面给出学习率选择总结：

学习率	优缺点	使用场景
小学习率	收敛慢，但结果精确	若算法不稳定，先降低学习率
大学习率	结果不精确，但收敛快	若算法收敛太慢，可提高学习率

有时，标准梯度下降算法会明显卡顿或者收敛变慢，特别是在梯度为0的附近的点。为了解决此问题，TensorFlow的MomentumOptimizer（）函数增加了一项势能，前一次迭代过程的梯度下降值的倒数。

另外一个可以改变的是优化器的步长，理想情况下，对于变化小的变量使用大步长；而变化迅速的变量使用小步长。这里不会进行数学公式推导，但给出实现这种优点的常用算法：Adagrad算法。此算法考虑整个历史迭代的变量梯度，TensorFlow中相应功能的实现是AdagradOptimizer（）函数。

有时，由于Adagrad算法计算整个历史迭代的梯度，导致梯度迅速变为0。解决这个局限性的是Adadelta算法，它限制使用的迭代次数。TensorFlow中相应功能的实现是AdadeltaOptimizer（）函数。

还有一些其他的优化器算法实现，请阅读TensorFlow官方文档：https://www.tensorflow.org/api_docs/python/train/optimizers。

2.6.5 参考

- ▶ Kingma, D., Jimmy, L. *Adam: A Method for Stochastic Optimization*. ICLR 2015.
<https://arxiv.org/pdf/1412.6980.pdf>
- ▶ Ruder, S. *An Overview of Gradient Descent Optimization Algorithms*. 2016.
<https://arxiv.org/pdf/1609.04747v1.pdf>
- ▶ Zeiler, M. *ADADelta: An Adaptive Learning Rate Method*. 2012. <http://www.matthewzeiler.com/pubs/googleTR2012/googleTR2012.pdf>

2.7 TensorFlow实现随机训练和批量训练

根据上面描述的反向传播算法，TensorFlow更新模型变量。它能一次操作一个数据点，也可以一次操作大量数据。一个训练例子上的操作可能导致比较“古怪”的学习过程，但使用大批量的训练会造成计算成本昂贵。到底选用哪种训练类型对机器学习算法的收敛非常关键。

2.7.1 开始

为了TensorFlow计算变量梯度来让反向传播工作，我们必须度量一个或者多个样本的损失。与前一节所做的相似，随机训练会一次随机抽样训练数据和目标数据对完成训练。另外一个可选项是，一次大批量训练取平均损失来进行梯度计算，批量训练大小可以一次上扩到整个数据集。这里将显示如何扩展前面的回归算法的例子——使用随机训练和批量训练。

导入numpy、matplotlib和tensorflow模块，开始一个计算图会话，代码如下：

```
import matplotlib as plt
import numpy as np
import tensorflow as tf
sess = tf.Session()
```

2.7.2 动手做

1. 开始声明批量大小。批量大小是指通过计算图一次传入多少训练数据：

```
batch_size = 20
```

2. 接下来，声明模型的数据、占位符和变量。这里能做的是改变占位符的形状，占位符有两个维度：第一个维度为None，第二个维度是批量训练中的数据量。我们能显式地设置维度为20，也能设为None。如第一章所述，我们必须知道训练模型中的维度，这会阻止不合法的矩阵操作：

```
x_vals = np.random.normal(1, 0.1, 100)
y_vals = np.repeat(10., 100)
x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[1, 1]))
```

3. 现在在计算图中增加矩阵乘法操作，切记矩阵乘法不满足交换律，所以在`matmul()`函数中的矩阵参数顺序要正确：

```
my_output = tf.matmul(x_data, A)
```

4. 改变损失函数，因为批量训练时损失函数是每个数据点L2损失的平均值。在TensorFlow中通过`reduce_mean()`函数即可实现，代码如下：

```
loss = tf.reduce_mean(tf.square(my_output - y_target))
```

5. 声明优化器，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.02)
train_step = my_opt.minimize(loss)
```

6. 在训练中通过循环迭代优化模型算法。这部分代码与之前不同，因为我们想绘制损失值图与随机训练对比，所以这里初始化一个列表每间隔5次迭代保存损失函数：

```
loss_batch = []
for i in range(100):
    rand_index = np.random.choice(100, size=batch_size)
    rand_x = np.transpose([x_vals[rand_index]])
    rand_y = np.transpose([y_vals[rand_index]])

    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})
    if (i+1)%5==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)))
        temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
        print('Loss = ' + str(temp_loss))
        loss_batch.append(temp_loss)
```

7.迭代100次输出最终返回值。注意，A值现在是二维矩阵：

```
Step #100 A = [[ 9.86720943]]
Loss = 0.
```

2.7.3 工作原理

批量训练和随机训练的不同之处在于它们的优化器方法和收敛。找到一个合适的批量大小是挺难的。为了看清楚两种训练方式的收敛的不同，批量损失的绘图代码见下文。这里是存储随机损失的代码，接着上一小节的代码：

```
loss_stochastic = []
for i in range(100):
    rand_index = np.random.choice(100)
    rand_x = [x_vals[rand_index]]
    rand_y = [y_vals[rand_index]]
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})
    if (i+1)%5==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)))
        temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
        print('Loss = ' + str(temp_loss))
        loss_stochastic.append(temp_loss)
```

绘制回归算法的随机训练损失和批量训练损失（见图2-6），代码如下：

```
plt.plot(range(0, 100, 5), loss_stochastic, 'b-', label='Stochastic
Loss')
plt.plot(range(0, 100, 5), loss_batch, 'r--', label='Batch' Loss,
size=20')

plt.legend(loc='upper right', prop={'size': 11})
plt.show()
```

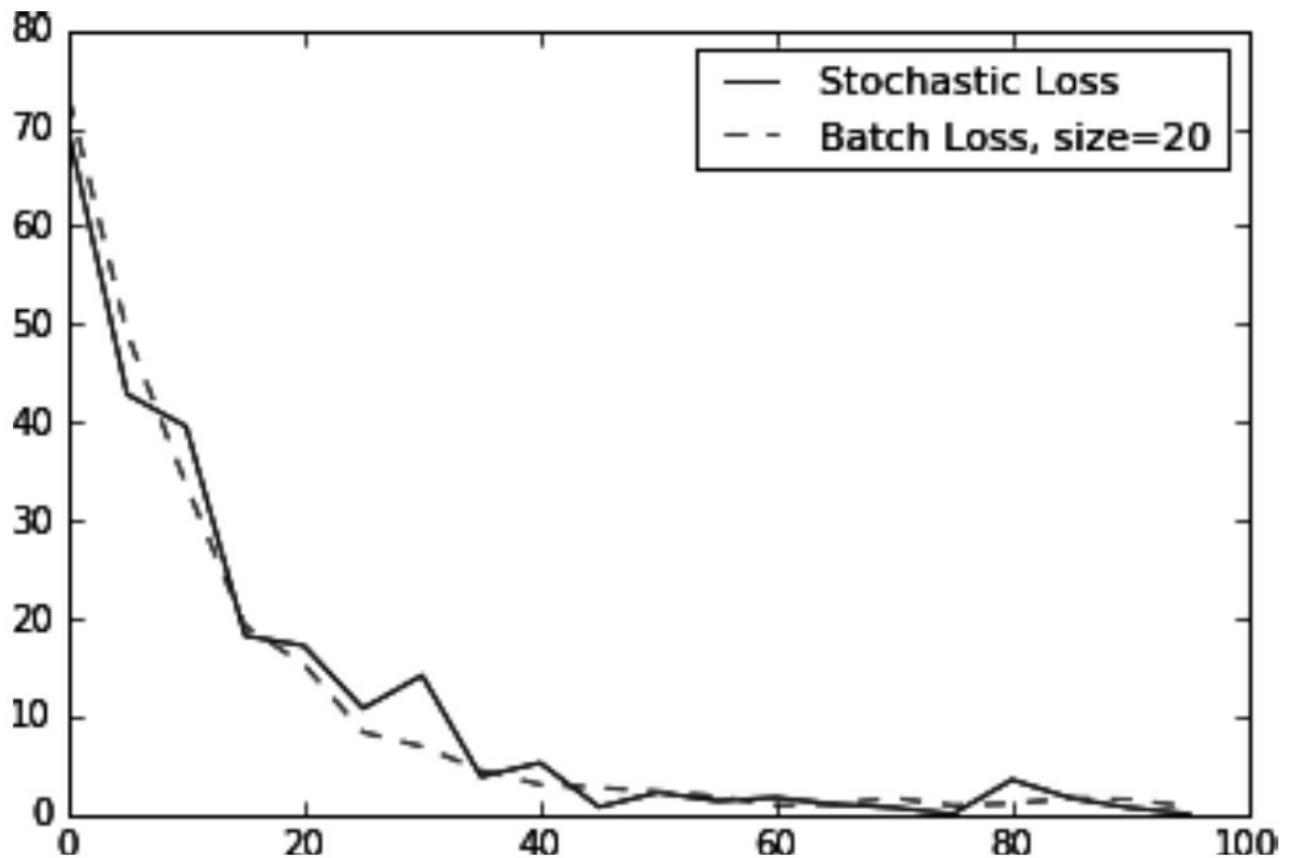


图2-6 迭代100次的随机训练损失和批量训练损失（批量大小为20）图。注意，批量训练损失更平滑，
随机训练损失更不规则

2.7.4 延伸学习

训练类型	优 点	缺 点
随机训练	脱离局部最小	一般需更多次迭代才收敛
批量训练	快速得到最小损失	耗费更多计算资源

2.8 TensorFlow实现创建分类器

在本节中，将结合前面所有的知识点创建一个iris数据集的分类器。

2.8.1 开始

iris数据集详细细节见第1章。加载样本数据集，实现一个简单的二值分类器来预测一朵花是否为山鸢尾。iris数据集有三类花，但这里仅预测是否是山鸢尾。导入iris数据集和工具库，相应地对原数据集进行转换。

2.8.2 动手做

1. 导入相应的工具库，初始化计算图。注意，这里导入matplotlib模块是为了后续绘制结果：

```
import matplotlib.pyplot as plt
import numpy as np

from sklearn import datasets
import tensorflow as tf
sess = tf.Session()
```

2. 导入iris数据集，根据目标数据是否为山鸢尾将其转换成1或者0。由于iris数据集将山鸢尾标记为0，我们将其从0置为1，同时把其他物种标记为0。本次训练只使用两种特征：花瓣长度和花瓣宽度，这两个特征在x-value的第三列和第四列：

```
iris = datasets.load_iris()
binary_target = np.array([1. if x==0 else 0. for x in iris.target])
iris_2d = np.array([[x[2], x[3]] for x in iris.data])
```

3. 声明批量训练大小、数据占位符和模型变量。注意，数据占位符的第一维度设为None：

```
batch_size = 20
x1_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
x2_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[1, 1]))
b = tf.Variable(tf.random_normal(shape=[1, 1]))
```



注意，通过指定`dtype=tf.float32`降低float的字节数，可以提高算法的性能。

4. 定义线性模型。线性模型的表达式为： $x2=x1*A+b$ 。如果找到的数据点在直线以上，则将数据点代入 $x2-x1*A-b$ 计算出的结果大于0；同理找到的数据点在直线以下，则将数据点代入 $x2-x1*A-b$ 计算出的结果小于0。将公式 $x2-x1*A-b$ 传入sigmoid函数，然后预测结果1或者0。TensorFlow有内建的sigmoid损失函数，所以

这里仅仅需要定义模型输出即可，代码如下：

```
my_mult = tf.matmul(x2_data, A)
my_add = tf.add(my_mult, b)
my_output = tf.sub(x1_data, my_add)
```

5.增加TensorFlow的sigmoid交叉熵损失函数sigmoid_cross_entropy_with_logits()，代码如下：

```
xentropy = tf.nn.sigmoid_cross_entropy_with_logits(my_output, y_target)
```

6.声明优化器方法，最小化交叉熵损失。选择学习率为0.05，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.05)
train_step = my_opt.minimize(xentropy)
```

7.创建一个变量初始化操作，然后让TensorFlow执行它，代码如下：

```
init = tf.initialize_all_variables()
sess.run(init)
```

8.现在迭代1000次训练线性模型。传入三种数据：花瓣长度、花瓣宽度和目标变量。每200次迭代打印出变量值，代码如下：

```
for i in range(1000):
    rand_index = np.random.choice(len(iris_2d), size=batch_size)
    rand_x = iris_2d[rand_index]
    rand_x1 = np.array([[x[0]] for x in rand_x])
    rand_x2 = np.array([[x[1]] for x in rand_x])
    rand_y = np.array([[y] for y in binary_target[rand_index]])
    sess.run(train_step, feed_dict={x1_data: rand_x1, x2_data: rand_x2, y_target: rand_y})
    if (i+1)%200==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)) +
', b = ' + str(sess.run(b)))
Step #200 A = [[ 8.67285347]], b = [[-3.47147632]]
Step #400 A = [[ 10.25393486]], b = [[-4.62928772]]
Step #600 A = [[ 11.152668]], b = [[-5.4077611]]
Step #800 A = [[ 11.81016064]], b = [[-5.96689034]]
Step #1000 A = [[ 12.41202831]], b = [[-6.34769201]]
```

9.下面的命令抽取模型变量并绘图，结果图在下一小节展示，代码如下：

```
[[slope]] = sess.run(A)
[[intercept]] = sess.run(b)
x = np.linspace(0, 3, num=50)
ablineValues = []
for i in x:
    ablineValues.append(slope*i+intercept)
setosa_x = [a[1] for i,a in enumerate(iris_2d) if binary_
target[i]==1]
setosa_y = [a[0] for i,a in enumerate(iris_2d) if binary_
target[i]==1]
non_setosa_x = [a[1] for i,a in enumerate(iris_2d) if binary_
target[i]==0]
non_setosa_y = [a[0] for i,a in enumerate(iris_2d) if binary_
target[i]==0]
plt.plot(setosa_x, setosa_y, 'rx', ms=10, mew=2, label='setosa''')
plt.plot(non_setosa_x, non_setosa_y, 'ro', label='Non-setosa')
plt.plot(x, ablineValues, 'b-')
plt.xlim([0.0, 2.7])
plt.ylim([0.0, 7.1])
plt.suptitle('Linear' Separator For I.setosa', fontsize=20)
plt.xlabel('Petal Length')
plt.ylabel('Petal Width')
plt.legend(loc='lower right')
plt.show()
```

2.8.3 工作原理

我们的目的是利用花瓣长度和花瓣宽度的特征在山鸢尾与其他物种间拟合一条直线。绘制所有的数据点和拟合结果，将会看到图2-7。

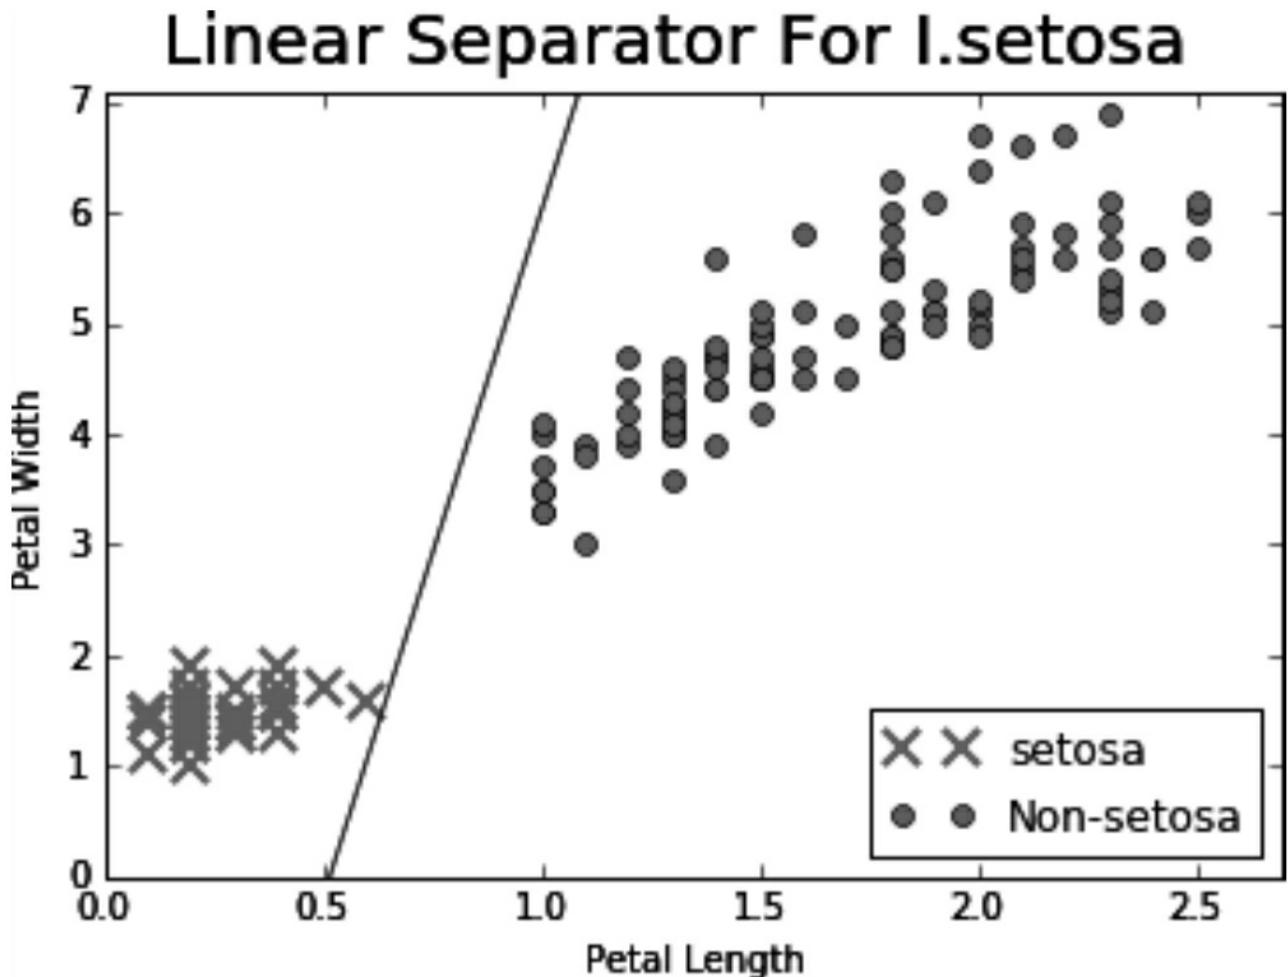


图2-7 山鸢尾和非山鸢尾。实心直线是迭代1000次得到的线性分隔

2.8.4 延伸学习

当前用一条直线分割两类目标并不是最好的模型。第4章将会介绍一种更好的方法来分割两类目标。

2.8.5 参考

关于iris数据集的介绍，可以看维基百科：https://en.wikipedia.org/wiki/Iris_flower_data_set。或者Scikit Learn的iris数据集：http://scikit-learn.org/stable/auto_examples/datasets/plot_iris_dataset.html。

2.9 TensorFlow实现模型评估

学完如何使用TensorFlow训练回归算法和分类算法，我们需要评估模型预测值来评估训练的好坏。

2.9.1 开始

模型评估是非常重要的，随后的每个模型都有模型评估方式。使用TensorFlow时，需要把模型评估加入到计算图中，然后在模型训练完后调用模型评估。

在训练模型过程中，模型评估能洞察模型算法，给出提示信息来调试、提高或者改变整个模型。但是在模型训练中并不是总需要模型评估，我们将展示如何在回归算法和分类算法中使用它。

训练模型之后，需要定量评估模型的性能如何。在理想情况下，评估模型需要一个训练数据集和测试数据集，有时甚至需要一个验证数据集。

想评估一个模型时就得使用大批量数据点。如果完成批量训练，我们可以重用模型来预测批量数据点。但是如果要完成随机训练，就不得不创建单独的评估器来处理批量数据点。



如果在损失函数中使用的模型输出结果经过转换操作，例如，`sigmoid_cross_entropy_with_logits()` 函数，为了精确计算预测结果，别忘了在模型评估中也要进行转换操作。

2.9.2 动手做

回归算法模型用来预测连续数值型，其目标不是分类值而是数字。为了评估这些回归预测值是否与实际目标相符，我们需要度量两者间的距离。这里将重写本章上一小节的回归算法的例子，打印训练过程中的损失，最终评估模型损失。

分类算法模型基于数值型输入预测分类值，实际目标是1和0的序列。我们需要度量预测值与真实值之间的距离。分类算法模型的损失函数一般不容易解释模型好坏，所以通常情况是看下准确预测分类的结果的百分比。这次将使用本章上一小节的分类算法的例子。

2.9.3 工作原理

首先，将展示如何评估简单的回归算法模型，其拟合常数乘法，目标值是10，步骤如下：

1.加载所需的编程库，创建计算图、数据集、变量和占位符。创建完数据后，将它们随机分割成训练数据集和测试数据集。不管算法模型预测的如何，我们都需要测试算法模型，这点相当重要。在训练数据和测试数据上都进行模型评估，以搞清楚模型是否过拟合：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
sess = tf.Session()
x_vals = np.random.normal(1, 0.1, 100)
y_vals = np.repeat(10., 100)
x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
batch_size = 25
train_indices = np.random.choice(len(x_vals), round(len(x_vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]
A = tf.Variable(tf.random_normal(shape=[1, 1]))
```

2.声明算法模型、损失函数和优化器算法。初始化模型变量A，代码如下：

```
my_output = tf.matmul(x_data, A)
loss = tf.reduce_mean(tf.square(my_output - y_target))

init = tf.initialize_all_variables()
sess.run(init)
my_opt = tf.train.GradientDescentOptimizer(0.02)
train_step = my_opt.minimize(loss)
```

3.像以往一样迭代训练模型，代码如下：

```

for i in range(100):
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    rand_x = np.transpose([x_vals_train[rand_index]])
    rand_y = np.transpose([y_vals_train[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})
    if (i+1)%25==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)))
        print('Loss = ' + str(sess.run(loss, feed_dict={x_data: rand_x, y_target: rand_y})))
Step #25 A = [[ 6.39879179]]
Loss = 13.7903
Step #50 A = [[ 8.64770794]]
Loss = 2.53685
Step #75 A = [[ 9.40029907]]
Loss = 0.818259
Step #100 A = [[ 9.6809473]]
Loss = 1.10908

```

4.现在，为了评估训练模型，将打印训练数据集和测试数据集训练的MSE损失函数值，代码如下：

```

mse_test = sess.run(loss, feed_dict={x_data: np.transpose([x_vals_test]), y_target: np.transpose([y_vals_test])})
mse_train = sess.run(loss, feed_dict={x_data: np.transpose([x_vals_train]), y_target: np.transpose([y_vals_train])})
print('MSE' on test:' + str(np.round(mse_test, 2)))
print('MSE' on train:' + str(np.round(mse_train, 2)))
MSE on test:1.35
MSE on train:0.88

```

5.对于分类模型的例子，与前面的例子类似。创建准确率函数（accuracy function），分别调用sigmoid来测试分类是否正确。

6.重新加载计算图，创建数据集、变量和占位符。记住，分割数据集和目标成为训练集和测试集，代码如下：

```

from tensorflow.python.framework import ops
ops.reset_default_graph()
sess = tf.Session()
batch_size = 25
x_vals = np.concatenate((np.random.normal(-1, 1, 50), np.random.
normal(2, 1, 50)))
y_vals = np.concatenate((np.repeat(0., 50), np.repeat(1., 50)))
x_data = tf.placeholder(shape=[1, None], dtype=tf.float32)
y_target = tf.placeholder(shape=[1, None], dtype=tf.float32)

train_indices = np.random.choice(len(x_vals), round(len(x_
vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_
indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]
A = tf.Variable(tf.random_normal(mean=10, shape=[1]))

```

7.在计算图中，增加模型和损失函数，初始化变量，并创建优化器，代码如下：

```

my_output = tf.add(x_data, A)
init = tf.initialize_all_variables()
sess.run(init)
xentropy = tf.reduce_mean(tf.nn.sigmoid_cross_entropy_with_
logits(my_output, y_target))
my_opt = tf.train.GradientDescentOptimizer(0.05)
train_step = my_opt.minimize(xentropy)

```

8.现在进行迭代训练，代码如下：

```
for i in range(1800):
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    rand_x = [x_vals_train[rand_index]]
    rand_y = [y_vals_train[rand_index]]
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})
    if (i+1)%200==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)))
        print('Loss = ' + str(sess.run(xentropy, feed_dict={x_data: rand_x, y_target: rand_y})))
Step #200 A = [ 6.64970636]
Loss = 3.39434
Step #400 A = [ 2.2884655]
Loss = 0.456173
Step #600 A = [ 0.29109824]
Loss = 0.312162
Step #800 A = [-0.20045301]
Loss = 0.241349
Step #1000 A = [-0.33634067]
Loss = 0.376786
Step #1200 A = [-0.36866501]
Loss = 0.271654
Step #1400 A = [-0.3727718]
Loss = 0.294866
Step #1600 A = [-0.39153299]
Loss = 0.202275
Step #1800 A = [-0.36630616]
Loss = 0.358463
```

9.为了评估训练模型，我们创建预测操作。用squeeze（）函数封装预测操作，使得预测值和目标值有相同的维度。然后用equal（）函数检测是否相等，把得到的true或false的boolean型张量转化成float32型，再对其取平均值，得到一个准确度值。我们将用这个函数评估训练模型和测试模型，代码如下：

```

y_prediction = tf.squeeze(tf.round(tf.nn.sigmoid(tf.add(x_data,
A))))
correct_prediction = tf.equal(y_prediction, y_target)
accuracy = tf.reduce_mean(tf.cast(correct_prediction, tf.float32))
acc_value_test = sess.run(accuracy, feed_dict={x_data: [x_vals_
test], y_target: [y_vals_test] })
acc_value_train = sess.run(accuracy, feed_dict={x_data: [x_vals_-
train], y_target: [y_vals_train] })
print('Accuracy' on train set: ' + str(acc_value_train))
print('Accuracy' on test set: ' + str(acc_value_test))
Accuracy on train set: 0.925
Accuracy on test set: 0.95

```

10.模型训练结果，比如准确度、MSE等，将帮助我们评估机器学习模型。因为这是一维模型，能很容易地绘制模型和数据点。用matplotlib绘制两个分开的直方图来可视化机器学习模型和数据点（见图2-8）：

```

A_result = sess.run(A)
bins = np.linspace(-5, 5, 50)
plt.hist(x_vals[0:50], bins, alpha=0.5, label='N' (-1,1) ',
color='white')
plt.hist(x_vals[50:100], bins[0:50], alpha=0.5, label='N' (2,1) ',
color='red')
plt.plot((A_result, A_result), (0, 8), 'k--', linewidth=3,
label='A = ' + str(np.round(A_result, 2)))
plt.legend(loc='upper right')
plt.title('Binary' Classifier, Accuracy=' + str(np.round(acc_
value, 2)))
plt.show()

```

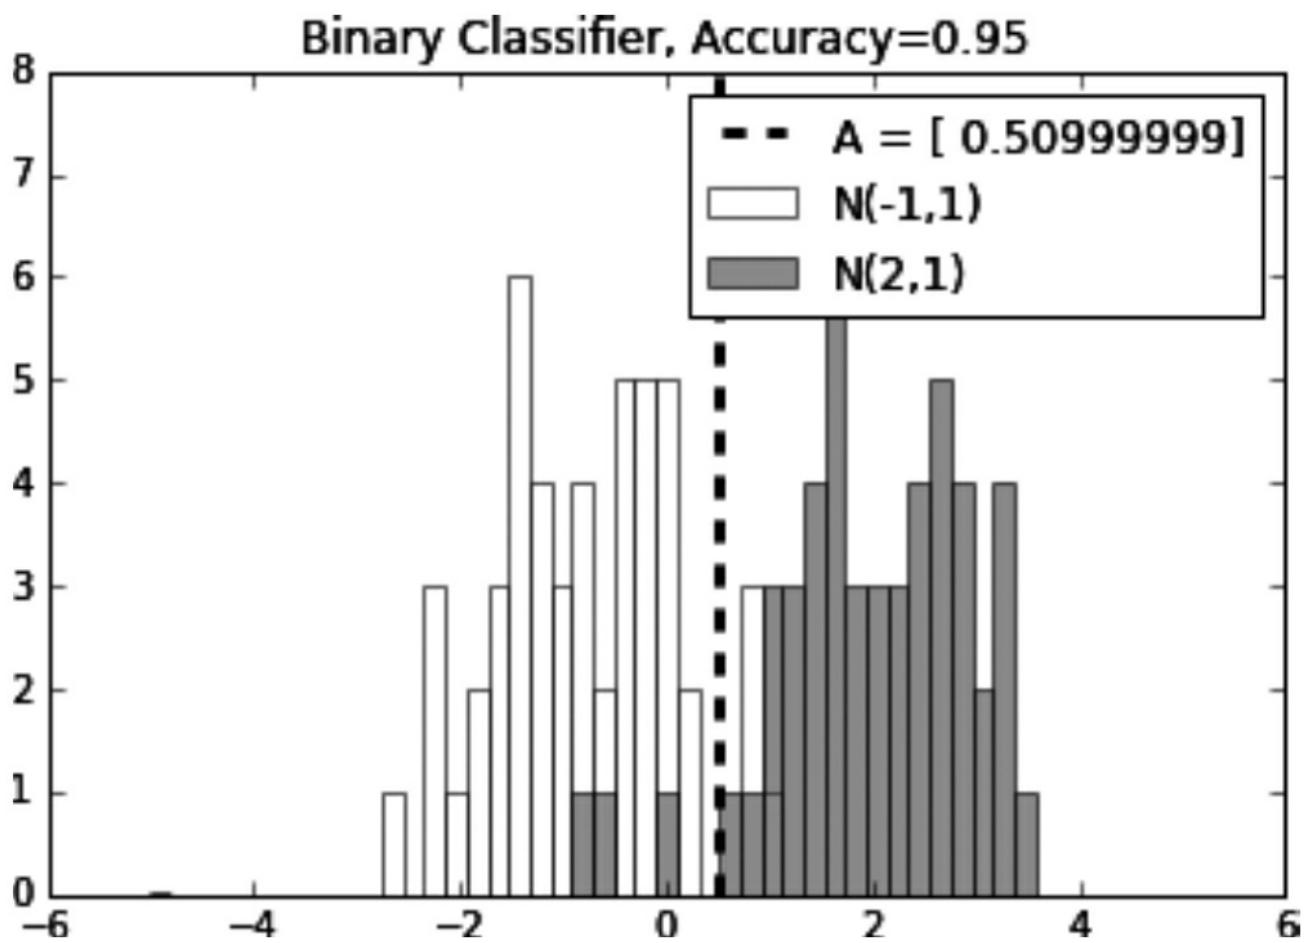


图2-8 模型A和数据点的可视化。两个正态分布（均值分别为-1和2），理论上的最佳分割点是0.5，这里模型结果值（0.50999999）非常接近理论值0.5

第3章 基于TensorFlow的线性回归

本章将介绍TensorFlow是如何工作的，以及如何访问本书的数据集和补充学习资源。学完本章将掌握以下知识点：

- 用TensorFlow求逆矩阵
- 用TensorFlow实现矩阵分解
- 用TensorFlow实现线性回归
- 理解线性回归中的损失函数
- 用TensorFlow实现戴明回归（Deming Regression）
- 用TensorFlow实现Lasso回归和岭回归（Ridge Regression）
- 用TensorFlow实现弹性网络回归（Elastic Net Regression）
- 用TensorFlow实现逻辑回归

3.1 线性回归介绍

线性回归算法是统计分析、机器学习和科学计算中最重要的算法之一，也是最常使用的算法之一，所以需要理解其是如何实现的，以及线性回归算法的各种优点。相对于许多其他算法来讲，线性回归算法是最易解释的。以每个特征的数值直接代表该特征对目标值或者因变量的影响。本章将揭晓线性回归算法的经典实现，然后讲解其在TensorFlow中的实现。记住，本书所有的源代码都可以在GitHub中访问，网址为：https://github.com/nfmccclure/tensorflow_cookbook。

3.2 用TensorFlow求逆矩阵

本节将使用TensorFlow求逆矩阵的方法解决二维线性回归问题。

3.2.1 开始

3.2.1 开始

线性回归算法能表示为矩阵计算， $Ax=b$ 。这里要解决的是用矩阵x来求解系数。注意，如果观测矩阵不是方阵，那求解出的矩阵x为 $x=(A^TA)^{-1}A^Tb$ 。为了更直观地展示这种情况，我们将生成二维数据，用TensorFlow来求解，然后绘制最终结果（见图3-1）。

3.2.2 动手做

1. 导入必要的编程库，初始化计算图，并生成数据，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
sess = tf.Session()
x_vals = np.linspace(0, 10, 100)
y_vals = x_vals + np.random.normal(0, 1, 100)
```

2. 创建后续求逆方法所需的矩阵。创建A矩阵，其为矩阵x_vals_column和ones_column的合并。然后以矩阵y_vals创建b矩阵，代码如下：

```
x_vals_column = np.transpose(np.matrix(x_vals))
ones_column = np.transpose(np.matrix(np.repeat(1, 100)))
A = np.column_stack((x_vals_column, ones_column))
b = np.transpose(np.matrix(y_vals))
```

3. 将A和矩阵转换成张量，代码如下：

```
A_tensor = tf.constant(A)
b_tensor = tf.constant(b)
```

4. 现在，使用TensorFlow的tf.matrix_inverse()方法，代码如下：

```
tA_A = tf.matmul(tf.transpose(A_tensor), A_tensor)
tA_A_inv = tf.matrix_inverse(tA_A)
product = tf.matmul(tA_A_inv, tf.transpose(A_tensor))
solution = tf.matmul(product, b_tensor)
solution_eval = sess.run(solution)
```

5. 从解中抽取系数、斜率和y截距y-intercept，代码如下：

```

slope = solution_eval[0][0]
y_intercept = solution_eval[1][0]
print('slope: ' + str(slope))
print('y_intercept: ' + str(y_intercept))

slope: 0.955707151739
y_intercept: 0.174366829314

best_fit = []
for i in x_vals:
    best_fit.append(slope*i+y_intercept)
plt.plot(x_vals, y_vals, 'o', label='Data')
plt.plot(x_vals, best_fit, 'r-', label='Best fit line',
linewidth=3)
plt.legend(loc='upper left')
plt.show()

```

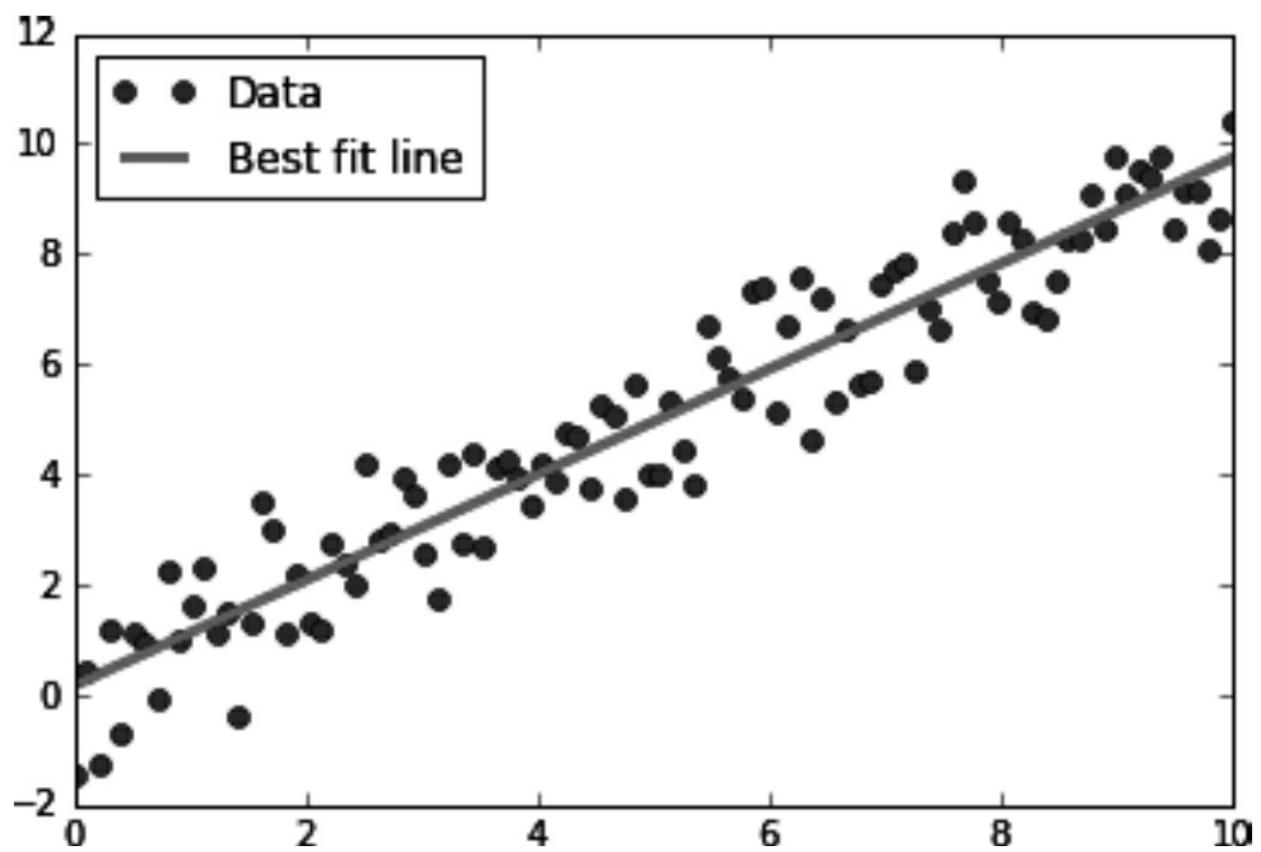


图3-1 通过矩阵求逆方法求解拟合直线和数据点

3.2.3 工作原理

与本书的大部分章节不一样的是，这里的解决方法是通过矩阵操作直接求解结果。大部分TensorFlow算法是通过迭代训练实现的，利用反向传播自动更新模型变量。这里通过实现数据直接求解的方法拟合模型，仅仅是为了说明TensorFlow的灵活用法。

3.3 用TensorFlow实现矩阵分解

本节将用TensorFlow为线性回归算法实现矩阵分解。特别地，我们会使用Cholesky矩阵分解法，相关的函数已在TensorFlow中实现。

3.3.1 开始

在上一小节中实现的求逆矩阵的方法在大部分情况下是低效率的，特别地，当矩阵非常大时效率更低。另外一种实现方法是矩阵分解，此方法使用TensorFlow内建的Cholesky矩阵分解法。用户对分解一个矩阵为多个矩阵的方法感兴趣的原因是，结果矩阵的特性使得其在应用中更高效。Cholesky矩阵分解法把一个矩阵分解为上三角矩阵和下三角矩阵， L 和 L' （ L' 和 L 互为转置矩阵）。求解 $Ax=b$ ，改写成 $LL'x=b$ 。首先求解 $Ly=b$ ，然后求解 $L'x=y$ 得到系数矩阵 x 。

3.3.2 动手做

3.3.2 动手做

1. 导入编程库，初始化计算图，生成数据集。接着获取矩阵A和b，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np

import tensorflow as tf
from tensorflow.python.framework import ops
ops.reset_default_graph()
sess = tf.Session()
x_vals = np.linspace(0, 10, 100)
y_vals = x_vals + np.random.normal(0, 1, 100)
x_vals_column = np.transpose(np.matrix(x_vals))
ones_column = np.transpose(np.matrix(np.repeat(1, 100)))
A = np.column_stack((x_vals_column, ones_column))
b = np.transpose(np.matrix(y_vals))
A_tensor = tf.constant(A)
b_tensor = tf.constant(b)
```

2. 找到方阵的Cholesky矩阵分解， $A^T A$:



注意，TensorFlow的cholesky() 函数仅仅返回矩阵分解的下三角矩阵，因为上三角矩阵是下三角矩阵的转置矩阵。

```
tA_A = tf.matmul(tf.transpose(A_tensor), A_tensor)
L = tf.cholesky(tA_A)
tA_b = tf.matmul(tf.transpose(A_tensor), b)
sol1 = tf.matrix_solve(L, tA_b)
sol2 = tf.matrix_solve(tf.transpose(L), sol1)
```

3. 抽取系数：

```
solution_eval = sess.run(sol2)
slope = solution_eval[0][0]
y_intercept = solution_eval[1][0]
print('slope: ' + str(slope))
print('y_intercept: ' + str(y_intercept))

slope: 0.956117676145
y_intercept: 0.136575513864

best_fit = []
for i in x_vals:
    best_fit.append(slope*i+y_intercept)
plt.plot(x_vals, y_vals, 'o', label='Data')
plt.plot(x_vals, best_fit, 'r-', label='Best fit line',
         linewidth=3)
plt.legend(loc='upper left')
plt.show()
```

3.3.3 工作原理

正如你所看到的，最终求解的结果与前一小节的相似。记住，通过分解矩阵的方法求解有时更高效并且数值稳定（见图3-2）。

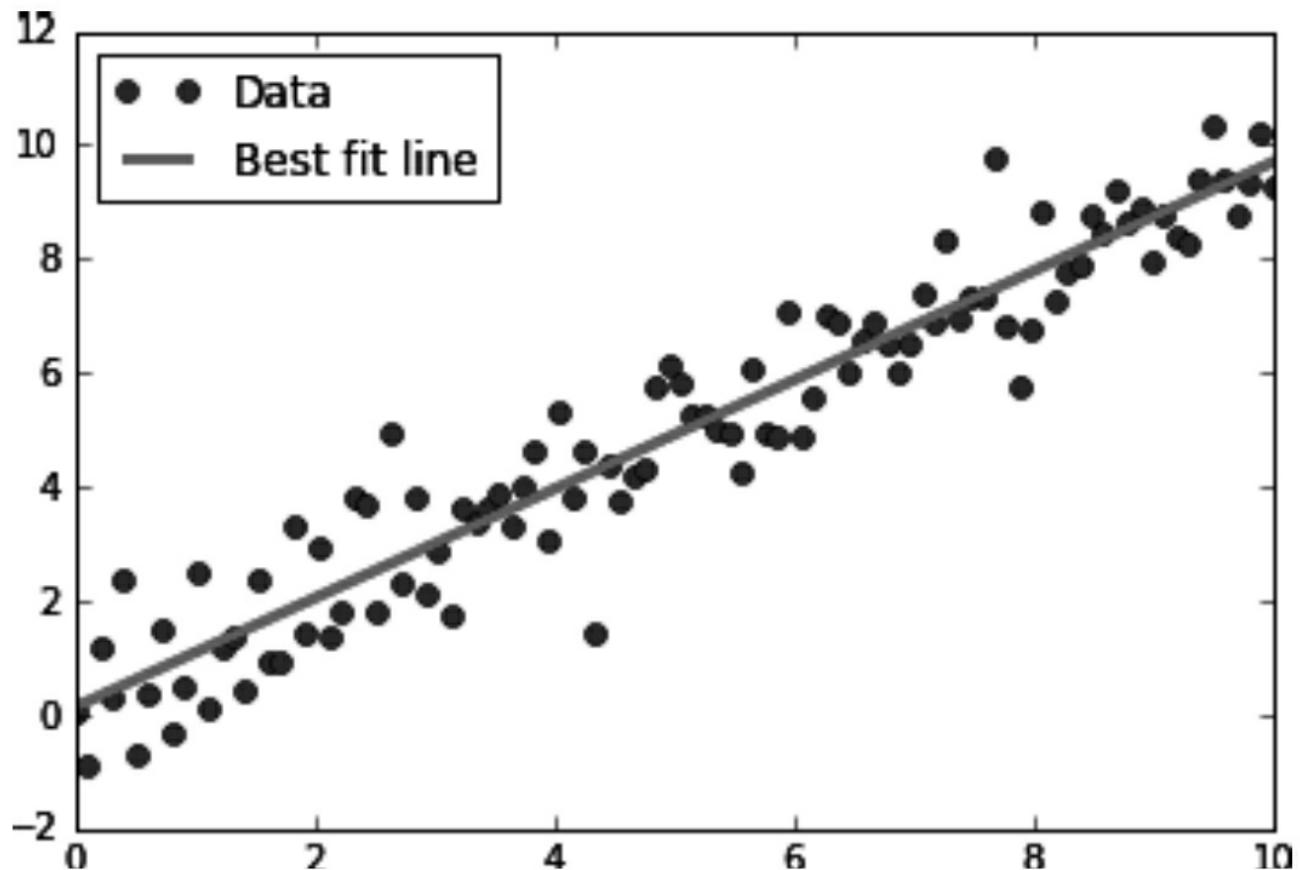


图3-2 通过矩阵分解求解拟合直线和数据点

3.4 用TensorFlow实现线性回归算法

3.4.1 开始

本节将遍历批量数据点并让TensorFlow更新斜率和y截距。这次将使用Scikit Learn的内建iris数据集。特别地，我们将用数据点（x值代表花瓣宽度，y值代表花瓣长度）找到最优直线。选择这两种特征是因为它们具有线性关系，在后续结果中将会看到。下一小节将讲解不同损失函数的影响，本节将使用L2正则损失函数。

3.4.2 动手做

1. 导入必要的编程库，创建计算图，加载数据集，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
from tensorflow.python.framework import ops
ops.reset_default_graph()
sess = tf.Session()
iris = datasets.load_iris()

x_vals = np.array([x[3] for x in iris.data])
y_vals = np.array([y[0] for y in iris.data])
```

2. 声明学习率、批量大小、占位符和模型变量，代码如下：

```
learning_rate = 0.05
batch_size = 25
x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)

y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[1, 1]))
b = tf.Variable(tf.random_normal(shape=[1, 1]))
```

3. 增加线性模型， $y=Ax+b$ 。代码如下：

```
model_output = tf.add(tf.matmul(x_data, A), b)
```

4. 下一步，声明L2损失函数，其为批量损失的平均值。初始化变量，声明优化器。注意，学习率设为0.05。代码如下：

```
loss = tf.reduce_mean(tf.square(y_target - model_output))
init = tf.global_variables_initializer()
sess.run(init)
my_opt = tf.train.GradientDescentOptimizer(learning_rate)
train_step = my_opt.minimize(loss)
```

5. 现在遍历迭代，并在随机选择的批量数据上进行模型训练。迭代100次，每25次迭代输出变量值和损

失值。注意，这里保存每次迭代的损失值，将其用于后续的可视化。代码如下：

```
loss_vec = []
for i in range(100):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = np.transpose([x_vals[rand_index]])
    rand_y = np.transpose([y_vals[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
    loss_vec.append(temp_loss)
    if (i+1)%25==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)) + ' b = ' + str(sess.run(b)))
        print('Loss = ' + str(temp_loss))
Step #25 A = [[ 2.17270374]] b = [[ 2.85338426]]
Loss = 1.08116
Step #50 A = [[ 1.70683455]] b = [[ 3.59916329]]
Loss = 0.796941
Step #75 A = [[ 1.32762754]] b = [[ 4.08189011]]
Loss = 0.466912
Step #100 A = [[ 1.15968263]] b = [[ 4.38497639]]
Loss = 0.281003
```

6.抽取系数，创建最佳拟合直线。代码如下：

```
[slope] = sess.run(A)
[y_intercept] = sess.run(b)
best_fit = []
for i in x_vals:
    best_fit.append(slope*i+y_intercept)
```

7.这里将绘制两幅图。第一幅图（见图3-3）是拟合的直线；第二幅图（见图3-4）是迭代100次的L2正则损失函数。代码如下：

```
plt.plot(x_vals, y_vals, 'o', label='Data Points')
plt.plot(x_vals, best_fit, 'r-', label='Best fit line',
linewidth=3)
plt.legend(loc='upper left')
plt.title('Sepal Length vs Pedal Width')
plt.xlabel('Pedal Width')
plt.ylabel('Sepal Length')
plt.show()

plt.plot(loss_vec, 'k-')
plt.title('L2 Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('L2 Loss')
plt.show()
```

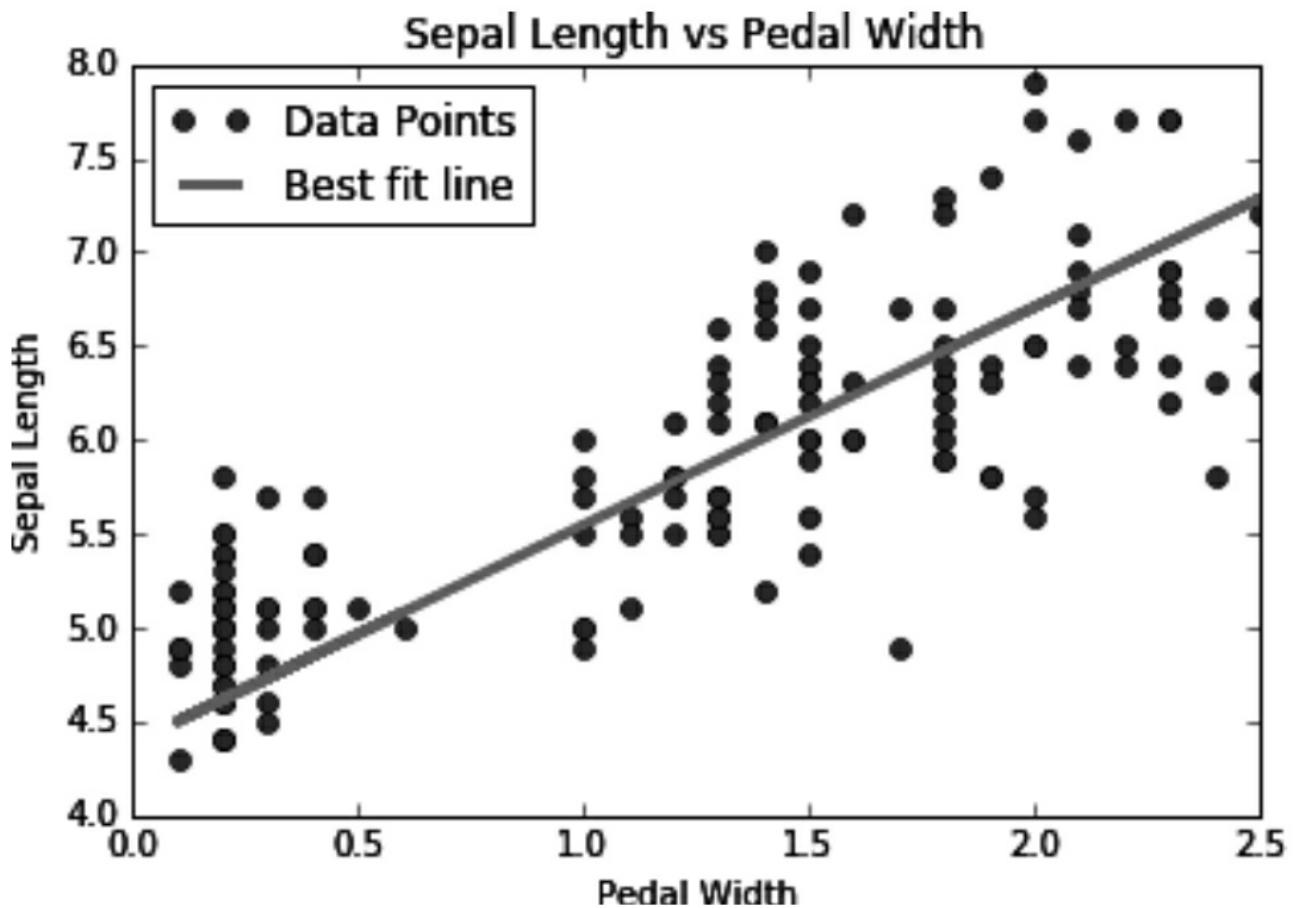


图3-3 iris数据集中的数据点（花瓣长度和花瓣宽度）和TensorFlow拟合的直线

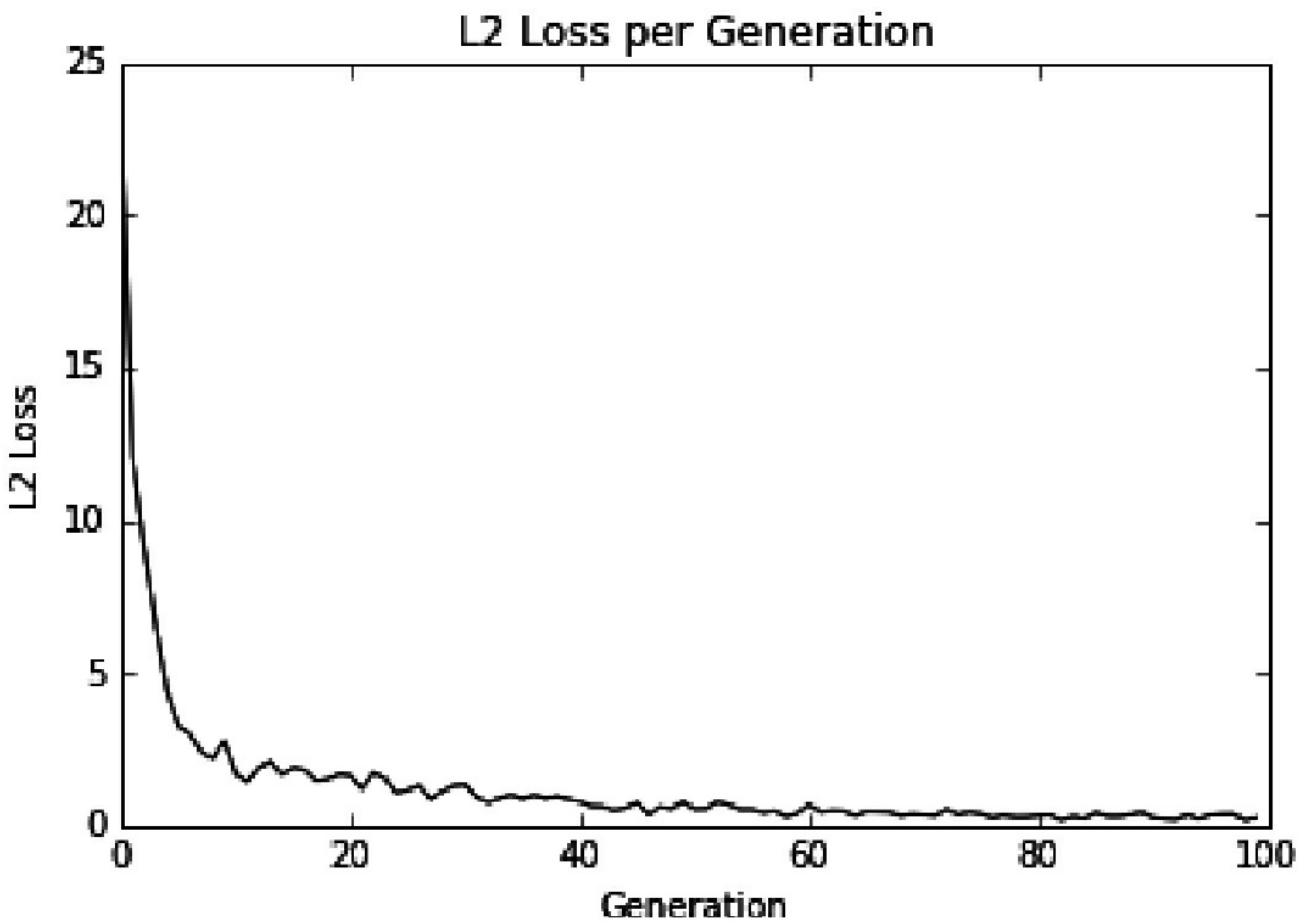


图3-4 L2正则损失。注意，损失函数中的抖动，批量大小越大抖动会减少；批量大小越小抖动会增大



这里很容易看出算法模型是过拟合还是欠拟合。将数据集分割成测试数据集和训练数据集，如果训练数据集的准确度更大，而测试数据集准确度更低，那么该拟合为过拟合；如果在测试数据集和训练数据集上的准确度都一直在增加，那么该拟合是欠拟合，需要继续训练。

3.4.3 工作原理

最优直线并不能保证是最佳拟合的直线。最佳拟合直线的收敛依赖迭代次数、批量大小、学习率和损失函数。最好时刻观察损失函数，它能帮助我们进行问题定位或者超参数调整。

3.5 理解线性回归中的损失函数

理解各种损失函数在算法收敛的影响是非常重要的。这里将展示L1正则和L2正则损失函数对线性回归算法收敛的影响。

3.5.1 开始

这次继续使用上一节中的iris数据集，但是，我们改变损失函数和学习率来观察收敛性的变化。

3.5.2 动手做

1.除了损失函数外，程序的开始与以往一样，导入必要的编程库，创建一个会话，加载数据，创建占位符，定义变量和模型。我们将抽出学习率和模型迭代次数，以便展示调整这些参数的影响。代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
sess = tf.Session()
iris = datasets.load_iris()
x_vals = np.array([x[3] for x in iris.data])
y_vals = np.array([y[0] for y in iris.data])
batch_size = 25
learning_rate = 0.1 # Will not converge with learning rate at 0.4
iterations = 50
x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[1,1]))
b = tf.Variable(tf.random_normal(shape=[1,1]))
model_output = tf.add(tf.matmul(x_data, A), b)
```

2.损失函数改为L1正则损失函数，代码如下：

```
loss_l1 = tf.reduce_mean(tf.abs(y_target - model_output))
```



注意，通过代入式子`tf.reduce_mean(tf.square(y_target-model_output))`可以改回L2正则损失函数。

3.现在继续初始化变量，声明优化器，遍历迭代训练。注意，为了度量收敛性，每次迭代都会保存损失值。代码如下：

```

init = tf.global_variables_initializer()
sess.run(init)
my_opt_l1 = tf.train.GradientDescentOptimizer(learning_rate)
train_step_l1 = my_opt_l1.minimize(loss_l1)
loss_vec_l1 = []
for i in range(iterations):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = np.transpose([x_vals[rand_index]])
    rand_y = np.transpose([y_vals[rand_index]])
    sess.run(train_step_l1, feed_dict={x_data: rand_x, y_target: rand_y})
    temp_loss_l1 = sess.run(loss_l1, feed_dict={x_data: rand_x, y_target: rand_y})
    loss_vec_l1.append(temp_loss_l1)
    if (i+1)%25==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)) + ' b = ' + str(sess.run(b)))
plt.plot(loss_vec_l1, 'k-', label='L1 Loss')
plt.plot(loss_vec_l2, 'r--', label='L2 Loss')
plt.title('L1 and L2 Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('L1 Loss')
plt.legend(loc='upper right')
plt.show()

```

3.5.3 工作原理

当选择了一个损失函数时，也要选择对应的学习率。这里展示了两种解决方法，一种是上一小节的L2正则损失函数，另一种是L1正则损失函数。

如果学习率太小，算法收敛耗时将更长。但是如果学习率太大，算法有可能产生不收敛的问题。下面绘制iris数据的线性回归问题的L1正则和L2正则损失（见图3-5），其中学习率为0.05。

从图3-5中可以看出，当学习率为0.05时，L2正则损失更优，其有更低的损失值。当增加学习率为0.4时，绘制其损失函数（见图3-6）。

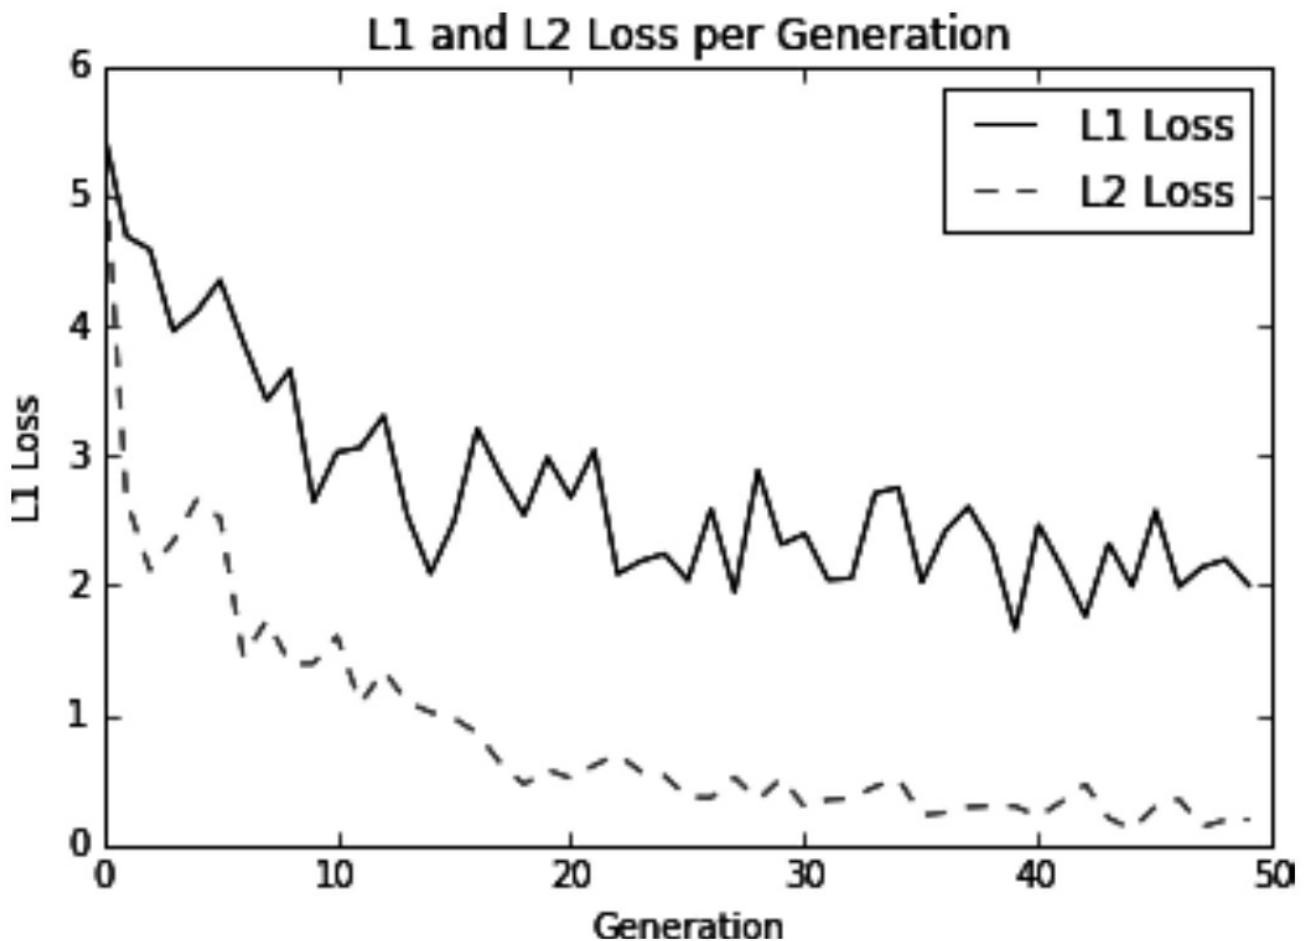


图3-5 iris数据线性回归的L1正则和L2正则损失，学习率为0.05

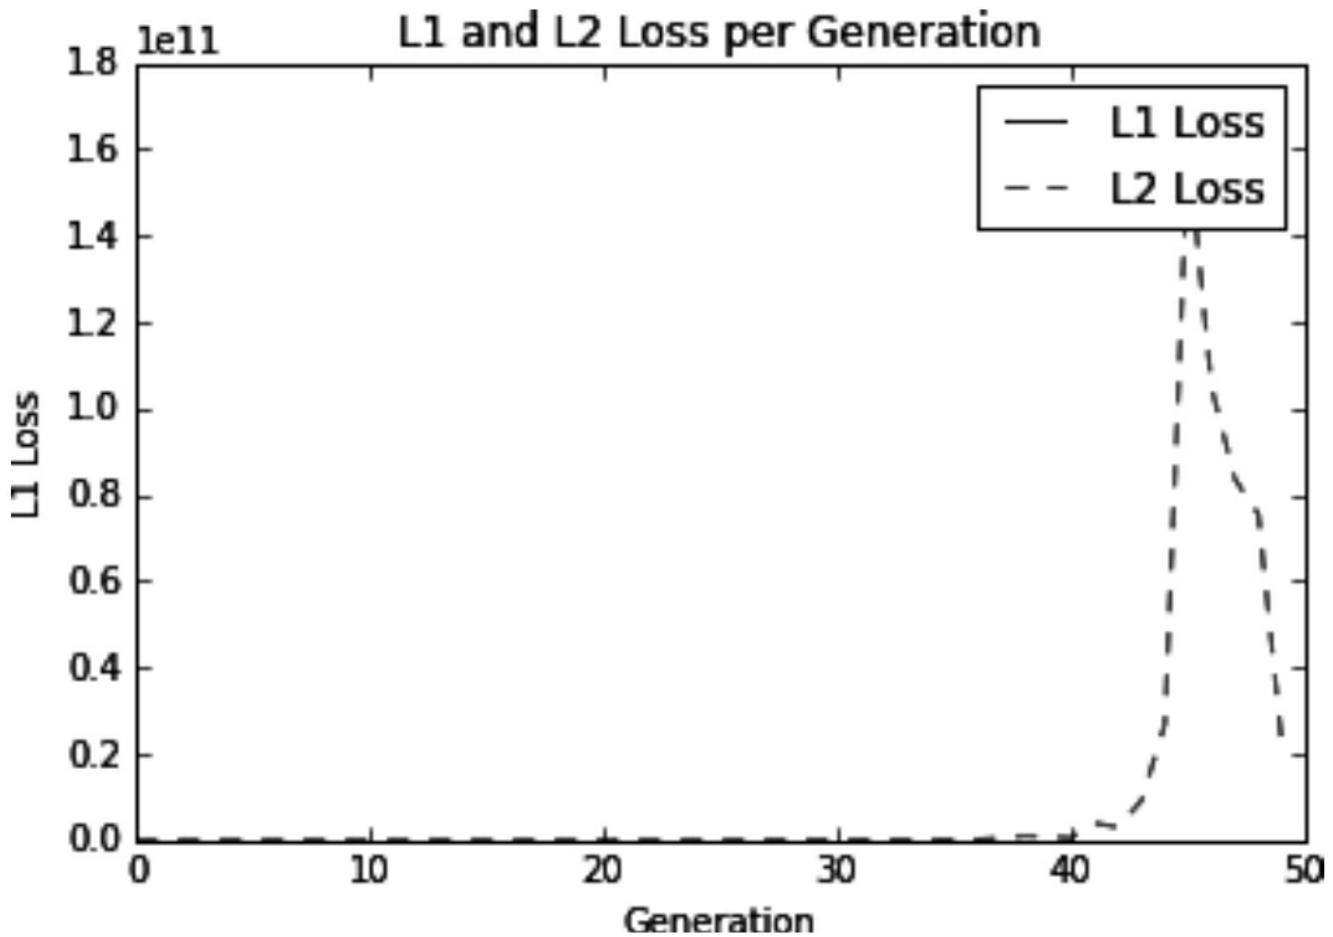


图3-6 iris数据线性回归的L1正则和L2正则损失，学习率为0.4。其中L1正则损失不可见是因为它的y轴值太大

从图3-6中可以发现，学习率大导致L2损失过大，而L1正则损失收敛。

3.5.4 延伸学习

为了更容易地理解上述的情况，这里清晰地展示大学习率和小学习率对L1正则和L2正则损失函数的影响。这里可视化的是L1正则和L2正则损失函数的一维情况，如图3-7所示。

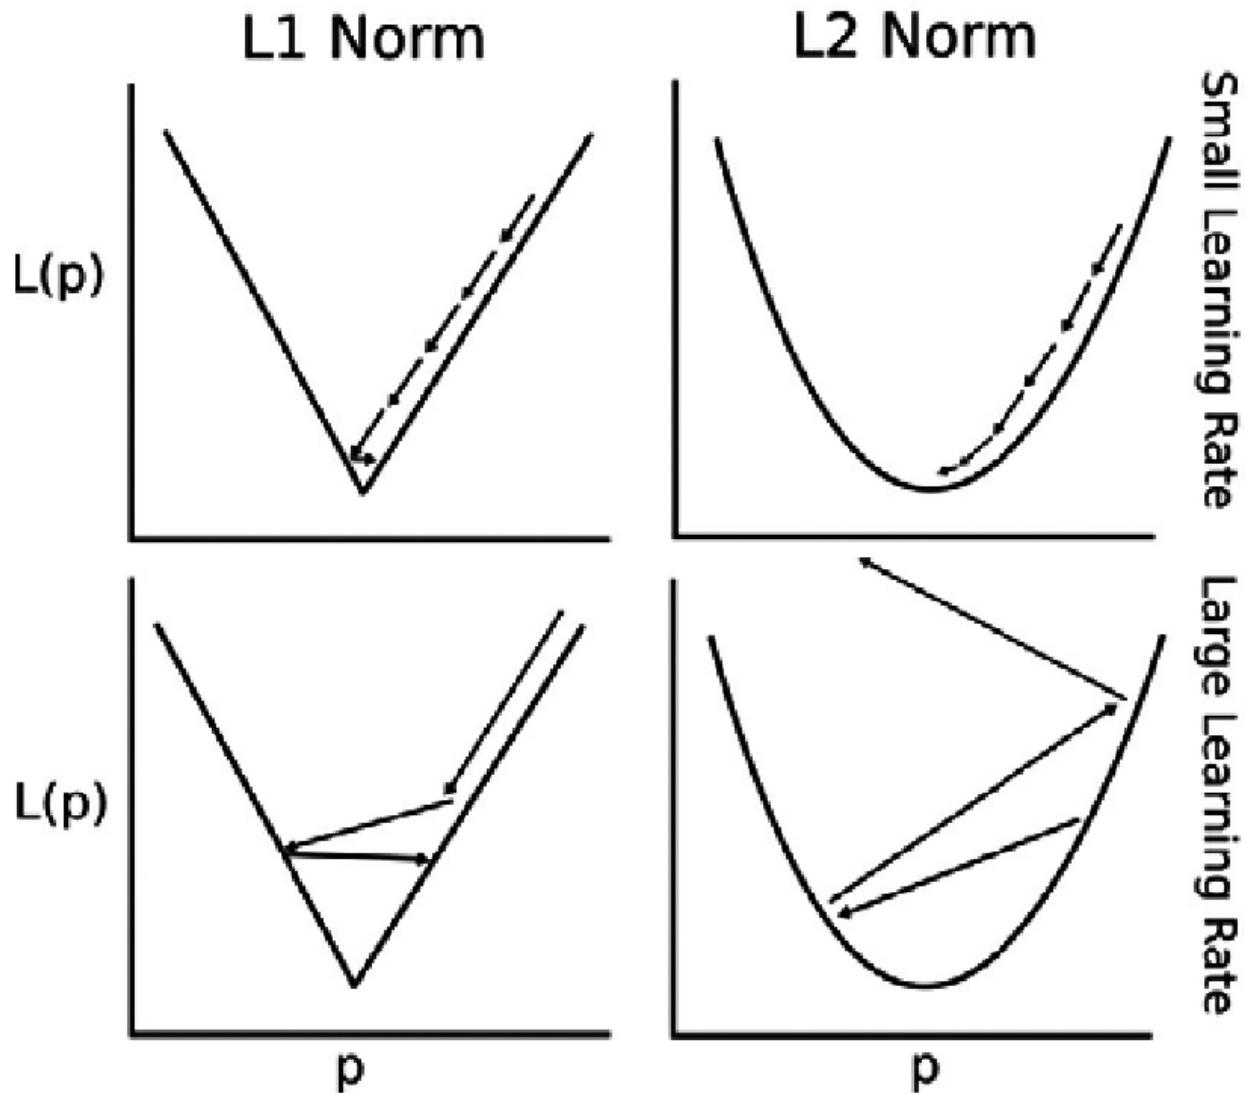


图3-7 L1正则和L2正则损失函数在大学习率和小学习率下的影响

3.6 用TensorFlow实现戴明回归算法

本节将实现戴明回归（total regression），其意味着需要不同的方式来度量模型直线和数据集的数据点间的距离。

3.6.1 开始

如果最小二乘线性回归算法最小化到回归直线的竖直距离（即，平行于y轴方向），则戴明回归最小化到回归直线的总距离（即，垂直于回归直线）。其最小化x值和y值两个方向的误差，具体的对比图如图3-8所示。

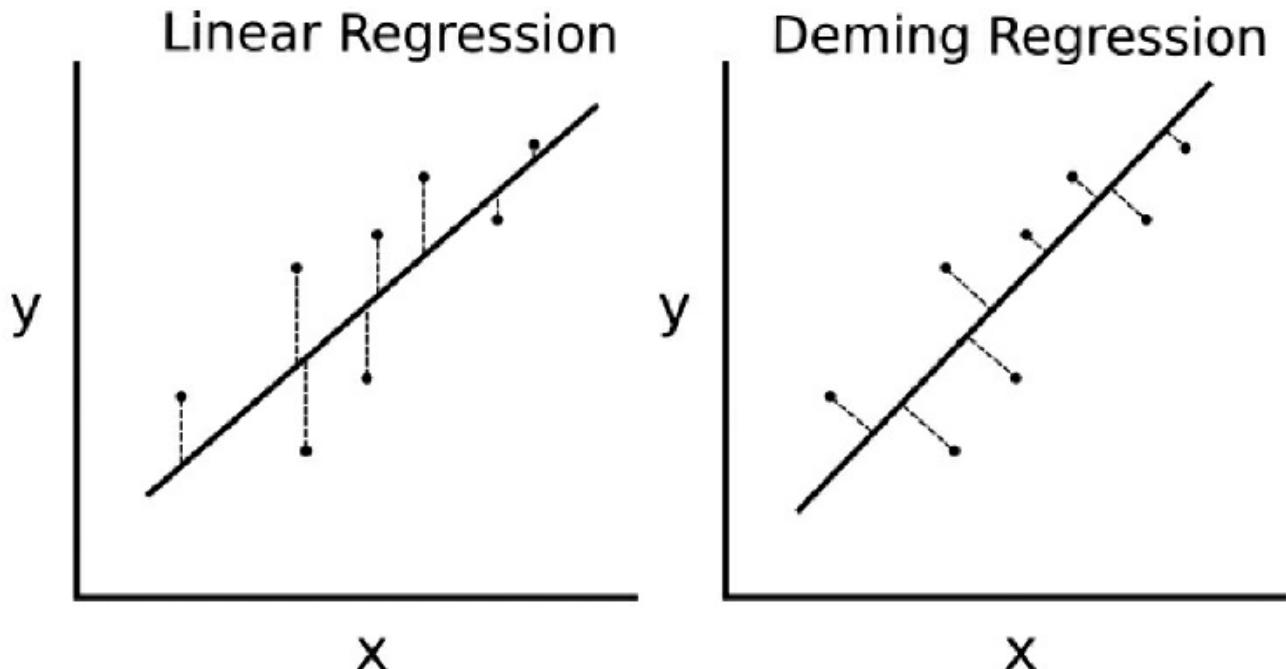


图3-8 线性回归算法和戴明回归算法的区别。左边的线性回归最小化到回归直线的竖直距离；右边的戴明回归最小化到回归直线的总距离

为了实现戴明回归算法，我们修改一下损失函数。线性回归算法的损失函数最小化竖直距离；而这里需要最小化总距离。给定直线的斜率和截距，则求解一个点到直线的垂直距离有已知的几何公式。代入几何公式并使TensorFlow最小化距离。

3.6.2 动手做

3.6.2 动手做

1.除了损失函数外，其他的步骤跟前面的类似。导入必要的编程库，创建一个计算图会话，加载数据集，声明批量大小，创建占位符、变量和模型输出，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
sess = tf.Session()
iris = datasets.load_iris()
x_vals = np.array([x[3] for x in iris.data])
y_vals = np.array([y[0] for y in iris.data])
batch_size = 50
x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[1, 1]))
b = tf.Variable(tf.random_normal(shape=[1, 1]))
model_output = tf.add(tf.matmul(x_data, A), b)
```

2.损失函数是由分子和分母组成的几何公式。给定直线 $y=mx+b$ ，点 (x_0, y_0) ，则求两者间的距离的公式为：

$$d = \frac{|y_0 - (mx_0 + b)|}{\sqrt{m^2 + 1}}$$

```
demming_numerator = tf.abs(tf.sub(y_target, tf.add(tf.matmul(x_data, A), b)))
demming_denominator = tf.sqrt(tf.add(tf.square(A), 1))
loss = tf.reduce_mean(tf.truediv(demming_numerator, demming_denominator))
```

3.现在初始化变量，声明优化器，遍历迭代训练集以得到参数。代码如下：

```

init = tf.global_variables_initializer()
sess.run(init)
my_opt = tf.train.GradientDescentOptimizer(0.1)
train_step = my_opt.minimize(loss)
loss_vec = []
for i in range(250):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = np.transpose([x_vals[rand_index]])
    rand_y = np.transpose([y_vals[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
    loss_vec.append(temp_loss)
    if (i+1)%50==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)) +
' b = ' + str(sess.run(b)))
        print('Loss = ' + str(temp_loss))

```

4.绘制输出结果（见图3-9）的代码如下：

```

[slope] = sess.run(A)
[y_intercept] = sess.run(b)
best_fit = []
for i in x_vals:
    best_fit.append(slope*i+y_intercept)
plt.plot(x_vals, y_vals, 'o', label='Data Points')
plt.plot(x_vals, best_fit, 'r-', label='Best fit line',
linewidth=3)
plt.legend(loc='upper left')
plt.title('Sepal Length vs Pedal Width')
plt.xlabel('Pedal Width')
plt.ylabel('Sepal Length')
plt.show()

```

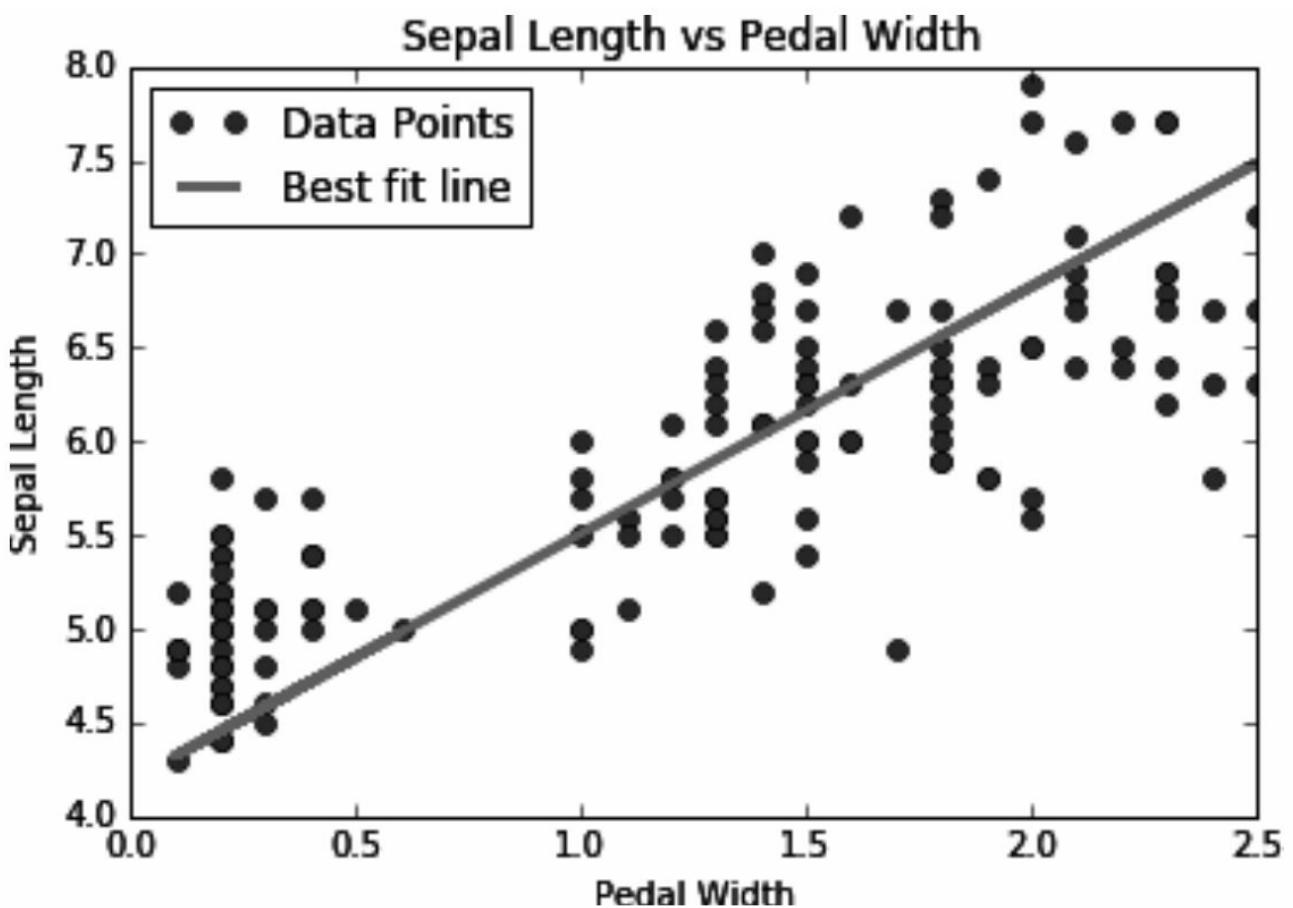


图3-9 iris数据集上戴明回归算法的解

3.6.3 工作原理

本小节的戴明回归算法与线性回归算法得到的结果基本一致。两者之间的关键不同点在于预测值与数据点间的损失函数度量：线性回归算法的损失函数是竖直距离损失；而戴明回归算法是垂直距离损失（到x轴和y轴的总距离损失）。



注意，这里戴明回归算法的实现类型是总体回归（总的最小二乘法误差）。总体回归算法是假设x值和y值的误差是相似的。我们也可以根据不同的理念使用不同的误差来扩展x轴和y轴的距离计算。

3.7 用TensorFlow实现lasso回归和岭回归算法

也有些正则方法可以限制回归算法输出结果中系数的影响，其中最常用的两种正则方法是lasso回归和岭回归。本小节将详细介绍如何实现这两种方法。

3.7.1 开始

lasso回归和岭回归算法跟常规线性回归算法极其相似，有一点不同的是，在公式中增加正则项来限制斜率（或者净斜率）。这样做的主要原因是限制特征对因变量的影响，通过增加一个依赖斜率A的损失函数实现。

对于lasso回归算法，在损失函数上增加一项：斜率A的某个给定倍数。我们使用TensorFlow的逻辑操作，但没有这些操作相关的梯度，而是使用阶跃函数的连续估计，也称作连续阶跃函数，其会在截止点跳跃扩大。一会就可以看到如何使用lasso回归算法。

对于岭回归算法，增加一个L2范数，即斜率系数的L2正则。这个简单的修改将在后续小节介绍。

3.7.2 动手做

1.这次还是使用iris数据集，使用方式跟前面的类似。首先，导入必要的编程库，创建一个计算图会话，加载数据集，声明批量大小，创建占位符、变量和模型输出，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
from tensorflow.python.framework import ops
ops.reset_default_graph()
sess = tf.Session()
iris = datasets.load_iris()
x_vals = np.array([x[3] for x in iris.data])
y_vals = np.array([y[0] for y in iris.data])
batch_size = 50
learning_rate = 0.001
x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[1,1]))
b = tf.Variable(tf.random_normal(shape=[1,1]))
model_output = tf.add(tf.matmul(x_data, A), b)
```

2.增加损失函数，其为改良过的连续阶跃函数，lasso回归的截止点设为0.9。这意味着限制斜率系数不超过0.9，代码如下：

```
lasso_param = tf.constant(0.9)
heavyside_step = tf.truediv(1., tf.add(1., tf.exp(tf.mul(-100.,
tf.sub(A, lasso_param)))))
regularization_param = tf.mul(heavyside_step, 99.)

loss = tf.add(tf.reduce_mean(tf.square(y_target - model_output)),
regularization_param)
```

3.初始化变量和声明优化器，代码如下：

```
init = tf.global_variables_initializer()
sess.run(init)
my_opt = tf.train.GradientDescentOptimizer(learning_rate)
train_step = my_opt.minimize(loss)
```

4.遍历迭代运行一段时间，因为需要一会才会收敛。最后结果显示斜率系数小于0.9，代码如下：

```
loss_vec = []
for i in range(1500):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = np.transpose([x_vals[rand_index]])
    rand_y = np.transpose([y_vals[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
    loss_vec.append(temp_loss[0])
    if (i+1)%300==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)) +
' b = ' + str(sess.run(b)))
        print('Loss = ' + str(temp_loss))
Step #300 A = [[ 0.82512331]] b = [[ 2.30319238]]
Loss = [[ 6.84168959]]
Step #600 A = [[ 0.8200165]] b = [[ 3.45292258]]
Loss = [[ 2.02759886]]
Step #900 A = [[ 0.81428504]] b = [[ 4.08901262]]
Loss = [[ 0.49081498]]
Step #1200 A = [[ 0.80919558]] b = [[ 4.43668795]]
Loss = [[ 0.40478843]]
Step #1500 A = [[ 0.80433637]] b = [[ 4.6360755]]
Loss = [[ 0.23839757]]
```

3.7.3 工作原理

通过在标准线性回归估计的基础上，增加一个连续的阶跃函数，实现lasso回归算法。由于阶跃函数的坡度，我们需要注意步长，因为太大的步长会导致最终不收敛。对于岭回归算法，将在下一节介绍对其的必要修改。

3.7.4 延伸学习

对于岭回归算法，在上一节的代码基础上稍微改变损失函数即可，代码如下：

```
ridge_param = tf.constant(1.)
ridge_loss = tf.reduce_mean(tf.square(A))
loss = tf.expand_dims(tf.add(tf.reduce_mean(tf.square(y_target -
model_output)), tf.mul(ridge_param, ridge_loss)), 0)
```

3.8 用TensorFlow实现弹性网络回归算法

弹性网络回归算法（Elastic Net Regression）是综合lasso回归和岭回归的一种回归算法，通过在损失函数中增加L1和L2正则项。

3.8.1 开始

在学完前面两节之后，可以轻松地实现弹性网络回归算法。本节使用多线性回归的方法实现弹性网络回归算法，以iris数据集为训练数据，用花瓣长度、花瓣宽度和花萼宽度三个特征预测花萼长度。

3.8.2 动手做

1. 导入必要的编程库并初始化一个计算图，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
sess = tf.Session()
```

2. 加载数据集。这次，`x_vals`数据将是三列值的数组，代码如下：

```
iris = datasets.load_iris()
x_vals = np.array([[x[1], x[2], x[3]] for x in iris.data])
y_vals = np.array([y[0] for y in iris.data])
```

3. 声明批量大小、占位符、变量和模型输出。这里唯一不同的是`x_data`占位符的大小为3，代码如下：

```
batch_size = 50
learning_rate = 0.001
x_data = tf.placeholder(shape=[None, 3], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[3, 1]))
b = tf.Variable(tf.random_normal(shape=[1, 1]))
model_output = tf.add(tf.matmul(x_data, A), b)
```

4. 对于弹性网络回归算法，损失函数包含斜率的L1正则和L2正则。创建L1和L2正则项，然后加入到损失函数中，代码如下：

```
elastic_param1 = tf.constant(1.)
elastic_param2 = tf.constant(1.)
l1_a_loss = tf.reduce_mean(tf.abs(A))
l2_a_loss = tf.reduce_mean(tf.square(A))
e1_term = tf.mul(elastic_param1, l1_a_loss)
e2_term = tf.mul(elastic_param2, l2_a_loss)
```

```
loss = tf.expand_dims(tf.add(tf.add(tf.reduce_mean(tf.square(y_target - model_output)), e1_term), e2_term), 0)
```

5.现在初始化变量，声明优化器，然后遍历迭代运行，训练拟合得到系数，代码如下：

```
init = tf.global_variables_initializer()
sess.run(init)
my_opt = tf.train.GradientDescentOptimizer(learning_rate)
train_step = my_opt.minimize(loss)
loss_vec = []
for i in range(1000):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = x_vals[rand_index]
    rand_y = np.transpose([y_vals[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_target: rand_y})
    loss_vec.append(temp_loss[0])
    if (i+1)%250==0:
        print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)) + ' b = ' + str(sess.run(b)))
        print('Loss = ' + str(temp_loss))
```

6.下面是代码运行的输出结果：

```
Step #250 A = [[ 0.42095602]
 [ 0.1055888 ]
 [ 1.77064979]] b = [[ 1.76164341]]
Loss = [ 2.87764359]
Step #500 A = [[ 0.62762028]
 [ 0.06065864]
 [ 1.36294949]] b = [[ 1.87629771]]
Loss = [ 1.8032167]
Step #750 A = [[ 0.67953539]
 [ 0.102514 ]
 [ 1.06914485]] b = [[ 1.95604002]]
Loss = [ 1.33256555]
Step #1000 A = [[ 0.6777274 ]
 [ 0.16535147]
 [ 0.8403284 ]] b = [[ 2.02246833]]
Loss = [ 1.21458709]
```

7.现在能观察到，随着训练迭代后损失函数已收敛（见图3-10），代码如下：

```
plt.plot(loss_vec, 'k-')
plt.title('Loss' per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()
```

3.8.3 工作原理

弹性网络回归算法的实现是多线性回归。我们能发现，增加L1和L2正则项后的损失函数中的收敛变慢。

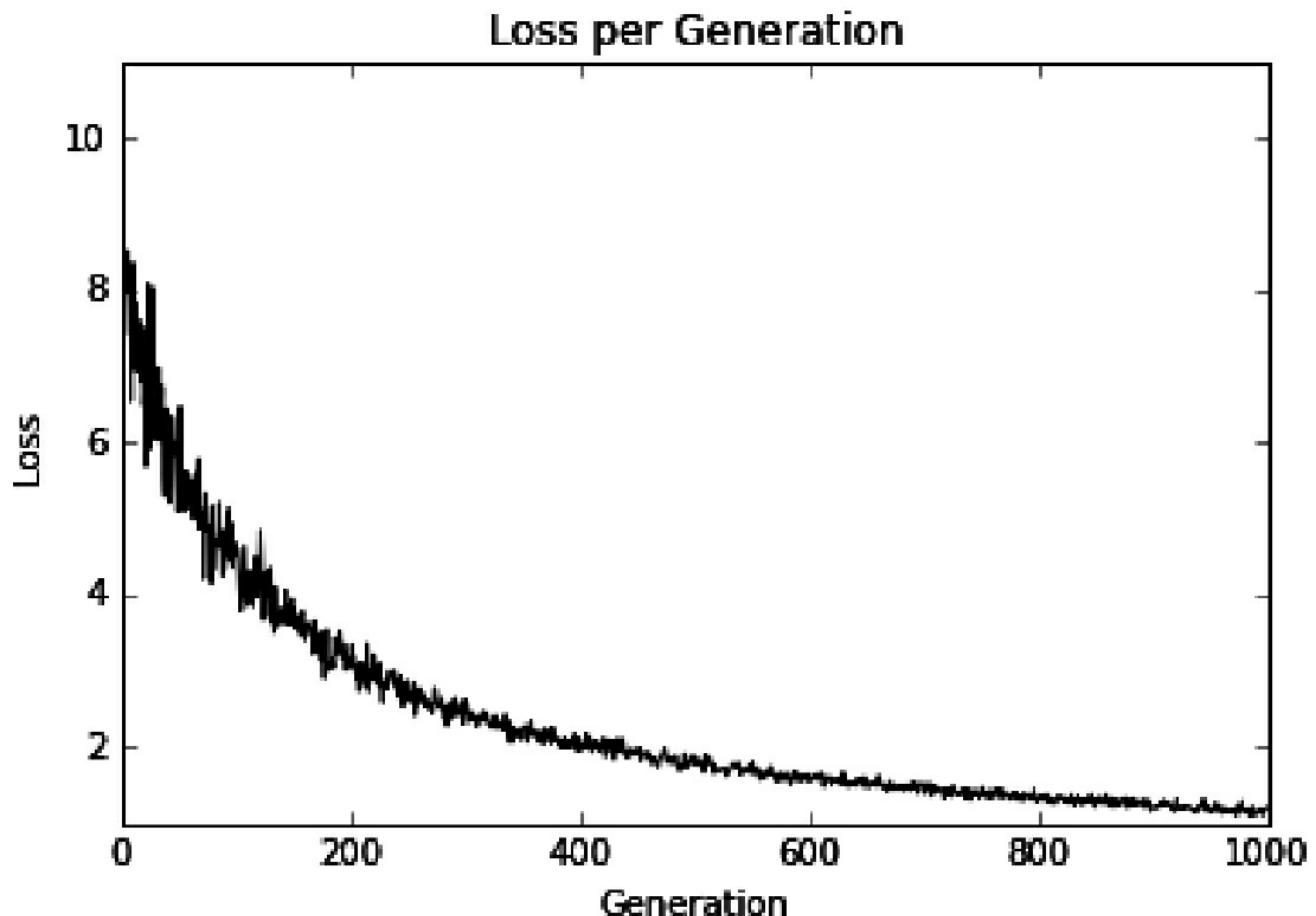


图3-10 弹性网络回归迭代训练1000次的损失图

3.9 用TensorFlow实现逻辑回归算法

本节将实现逻辑回归算法，预测低出生体重的概率。

3.9.1 开始

逻辑回归算法可以将线性回归转换成一个二值分类器。通过sigmoid函数将线性回归的输出缩放到0和1之间。目标值是0或者1代表着一个数据点是否属于某一类。如果预测值在截止值以上，则预测值被标记为“1”类；否则，预测值标为“0”类。在本例中，为方便简单起见，将指定截止值设为0.5。

在本例中使用的低出生体重的数据在马萨诸塞大学安姆斯特分校统计数据仓库（<https://www.umass.edu/statdata/statdata/>）获取。我们将从多个因素来预测低出生体重。

3.9.2 动手做

1. 导入必要的编程库，包括requests模块，因为我们将通过超链接访问低出生体重数据集。初始化一个计算图，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
import requests
from sklearn import datasets
from sklearn.preprocessing import normalize

from tensorflow.python.framework import ops
ops.reset_default_graph()
sess = tf.Session()
```

2. 通过requests模块加载数据集，指定要使用的特征。实际出生体特征和ID两列不需要，代码如下：

```
birthdata_url = 'https://www.umass.edu/statdata/statdata/data/
lowbwt.dat'
birth_file = requests.get(birthdata_url)
birth_data = birth_file.text.split('\r\n')[5:]
birth_header = [x for x in birth_data[0].split(' ') if len(x)>=1]
birth_data = [[float(x) for x in y.split(' ') if len(x)>=1] for y
in birth_data[1:] if len(y)>=1]
y_vals = np.array([x[1] for x in birth_data])
x_vals = np.array([x[2:9] for x in birth_data])
```

3. 分割数据集为测试集和训练集：

```
train_indices = np.random.choice(len(x_vals), round(len(x_
vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_
indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]
```

4. 将所有特征缩放到0和1区间（min-max缩放），逻辑回归收敛的效果更好。下面将归一化特征，代码

如下：

```
def normalize_cols(m):
    col_max = m.max(axis=0)
    col_min = m.min(axis=0)
    return (m-col_min) / (col_max - col_min)

x_vals_train = np.nan_to_num(normalize_cols(x_vals_train))
x_vals_test = np.nan_to_num(normalize_cols(x_vals_test))
```



注意，在缩放数据集前，先分割数据集为测试集和训练集，这是相当重要的。我们要确保训练集和测试集互不影响。如果我们在分割数据集前先缩放，就无法保证它们不相互影响。

5. 声明批量大小、占位符、变量和逻辑模型。这步不需要用sigmoid函数封装输出结果，因为sigmoid操作是包含在内建损失函数中的，代码如下：

```
batch_size = 25
x_data = tf.placeholder(shape=[None, 7], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
A = tf.Variable(tf.random_normal(shape=[7,1]))

b = tf.Variable(tf.random_normal(shape=[1,1]))
model_output = tf.add(tf.matmul(x_data, A), b)
```

6. 声明损失函数，其包含sigmoid函数。初始化变量，声明优化器，代码如下：

```
loss = tf.reduce_mean(tf.nn.sigmoid_cross_entropy_with_
logits(model_output, y_target))
init = tf.global_variables_initializer()
sess.run(init)
my_opt = tf.train.GradientDescentOptimizer(0.01)
train_step = my_opt.minimize(loss)
```

7. 除记录损失函数外，也需要记录分类器在训练集和测试集上的准确度。所以创建一个返回准确度的预测函数，代码如下：

```

prediction = tf.round(tf.sigmoid(model_output))
predictions_correct = tf.cast(tf.equal(prediction, y_target),
tf.float32)
accuracy = tf.reduce_mean(predictions_correct)

```

8.开始遍历迭代训练，记录损失值和准确度，代码如下：

```

loss_vec = []
train_acc = []
test_acc = []
for i in range(1500):
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    rand_x = x_vals_train[rand_index]
    rand_y = np.transpose([y_vals_train[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
    loss_vec.append(temp_loss)
    temp_acc_train = sess.run(accuracy, feed_dict={x_data: x_vals_
train, y_target: np.transpose([y_vals_train])})
    train_acc.append(temp_acc_train)
    temp_acc_test = sess.run(accuracy, feed_dict={x_data: x_vals_-
test, y_target: np.transpose([y_vals_test])})
    test_acc.append(temp_acc_test)

```

9.绘制损失和准确度，代码如下：

```

plt.plot(loss_vec, 'k-')
plt.title('Cross Entropy Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Cross Entropy Loss')
plt.show()
plt.plot(train_acc, 'k-', label='Train Set Accuracy')
plt.plot(test_acc, 'r--', label='Test Set Accuracy')
plt.title('Train' and Test Accuracy')
plt.xlabel('Generation')
plt.ylabel('Accuracy')

plt.legend(loc='lower right')
plt.show()

```

3.9.3 工作原理

这里是迭代过程中的损失，以及训练集和测试集的准确度。数据集只有189个观测值，但训练集和测试集的准确度图由于数据集的随机分割将会变化，如图3-11和图3-12所示。

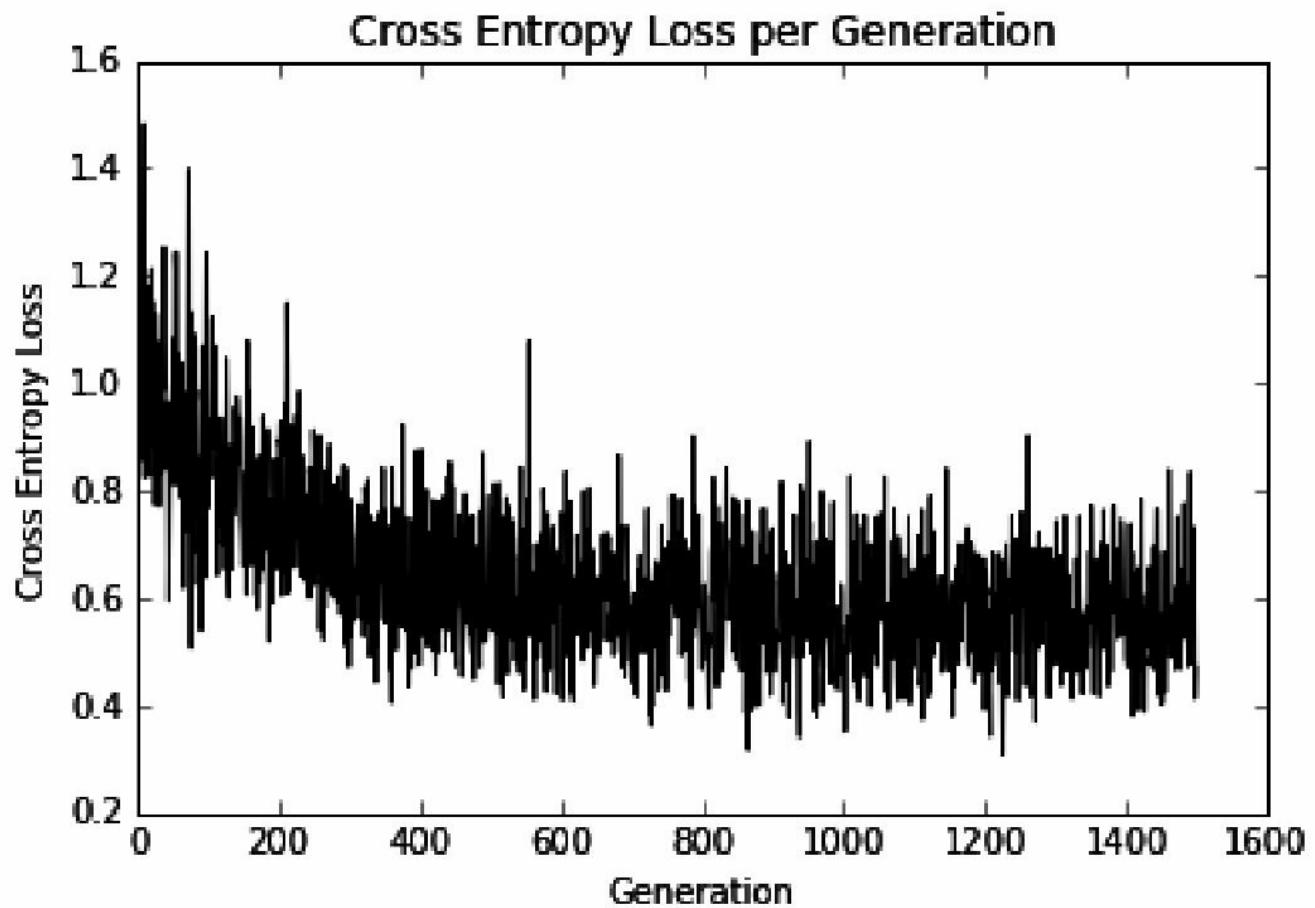


图3-11 迭代1500次的交叉熵损失图

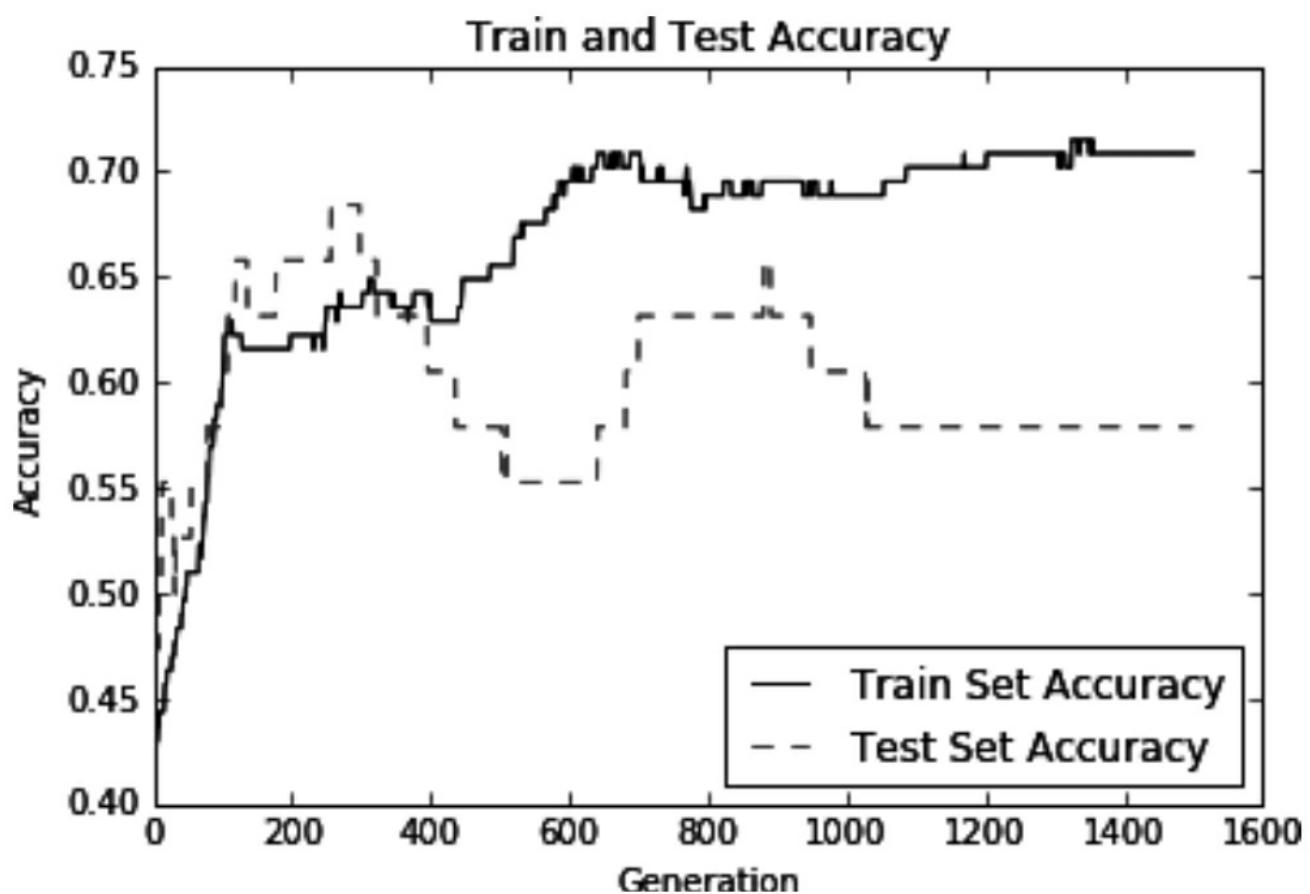


图3-12 迭代1500次的测试集和训练集的准确度图

第4章 基于TensorFlow的支持向量机

本章将详细介绍TensorFlow中支持向量机算法的使用、实现和评估。学完本章将掌握以下知识点：

- 线性支持向量机的使用
- 弱化为线性回归
- TensorFlow上核函数的使用
- TensorFlow实现非线性支持向量机
- TensorFlow实现多类支持向量机



注意，上一章介绍的逻辑回归算法和本章的大部分支持向量机算法都是二值预测。

逻辑回归算法试图找到回归直线来最大化距离（概率）；而支持向量机算法也试图最小化误差，最大化两类之间的间隔。一般来说，如果一个问题的训练集中有大量特征，则建议用逻辑回归或者线性支持向量机算法；如果训练集的数量更大，或者数据集是非线性可分的，则建议使用带高斯核的支持向量机算法。

记住，本章的所有代码在GitHub (https://github.com/nfmccleure/tensorflow_cookbook) 可以获取。

4.1 支持向量机简介

4.1.1 支持向量机简介

支持向量机算法是一种二值分类器方法（见图4-1）。基本的观点是，找到两类之间的一个线性可分的直线（或者超平面）。首先假设二分类目标是-1或者1，代替前面章节中的0或者1目标值。有许多条直线可以分割两类目标，但是我们定义分割两类目标有最大距离的直线为最佳线性分类器。

得到一个超平面，公式如下：

$$Ax - b = 0$$

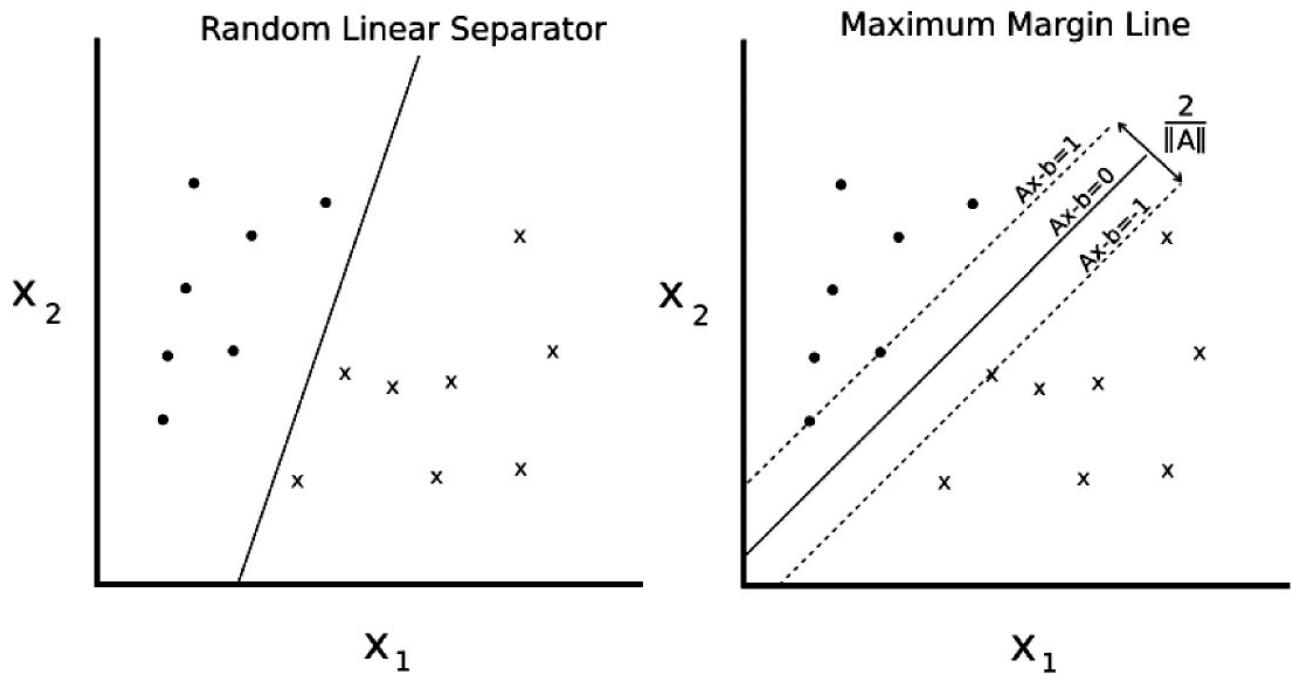


图4-1 假设两类分离的目标，“o”和“x”，找到两类目标间的线性分类器等式。左边显示有许多条线分离两类目标；右边显示最大间隔的直线，此时为最小化系数A的L2正则

其中， A 是斜率向量， x 是输入向量。最大间隔的宽度为2除以 A 的L2范数。对于这个公式有很多种证明方式，但是，从几何观点来看，这是二维数据点到一条直线的垂直距离。

对于线性可分的二值分类数据集，为了最大化间隔，我们最小化 A 的L2范数 $\|A\|$ 。最小化也必须服从以下约束：

$$y_i(Ax_i - b) \geq 1 \quad \forall i$$

上述的约束确保所有相关分类的数据点都在分割线的同一侧。

因为不是所有的数据集都是线性可分的，我们引入跨分割线的数据点的损失函数函数。对于n个数据点，引入soft margin损失函数，公式如下：

$$\frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i(Ax_i - b)) + a \|A\|^2$$

注意，如果数据点分割正确，乘积 $y_i (Ax_i - b)$ 总是大于1。这意味着损失函数左边项等于0，这时对损失函数有影响的仅仅只有间隔大小。

上述损失函数寻求一个线性可分的直线，但是也允许有些点跨越间隔直线，这取决于a值，当a值很大，模型会倾向于尽量将样本分割开；a值越小，会有更多的跨越边界的点存在。

在本章中，将建立一个soft margin支持向量机，展示如何将其扩展应用到非线性的场景和多分类目标。

4.2 线性支持向量机的使用

本节将从iris数据集创建一个线性分类器。如前所述，用花萼宽度和花萼长度的特征可以创建一个线性二值分类器来预测是否为山鸢尾花。

4.2.1 开始

4.2.1 开始

为了在TensorFlow上实现一个soft margin支持向量机，我们将实现特殊的损失函数，公式如下：

$$\frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i(Ax_i - b)) + a \|A\|^2$$

其中， A 是斜率向量， b 是截距， x_i 是输入向量， y_i 是实际分类（-1或者1）。 a 是软分类器的正则参数。

4.2.2 动手做

1. 导入必要的编程库，包括导入scikit learn的datasets库来访问iris数据集，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
```



安装scikit learn可使用：`$pip install -U scikit-learn`。注意，也可以使用Anaconda来安装。

2. 创建一个计算图会话，加载需要的数据集。注意，加载iris数据集的第一列和第四列特征变量，其为花萼长度和花萼宽度。加载目标变量时，山鸢尾花为1，否则为-1，代码如下：

```
sess = tf.Session()

iris = datasets.load_iris()
x_vals = np.array([[x[0], x[3]] for x in iris.data])
y_vals = np.array([1 if y==0 else -1 for y in iris.target])
```

3. 分割数据集为训练集和测试集。我们将评估训练集和测试集训练的准确度，因为我们知道这个数据集是线性可分的，所以期待在两个数据集上得到100%的准确度，代码如下：

```
train_indices = np.random.choice(len(x_vals), round(len(x_vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]
```

4. 设置批量大小、占位符和模型变量。对于这个支持向量机算法，我们希望用非常大的批量大小来帮助其收敛。可以想象一下，非常小的批量大小会使得最大间隔线缓慢跳动。在理想情况下，也应该缓慢减小学

习率，但是这已经足够了。A变量的形状是 2×1 ，因为有花萼长度和花萼宽度两个变量，代码如下：

```
batch_size = 100

x_data = tf.placeholder(shape=[None, 2], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)

A = tf.Variable(tf.random_normal(shape=[2, 1]))
b = tf.Variable(tf.random_normal(shape=[1, 1]))
```

5. 声明模型输出。对于正确分类的数据点，如果数据点是山鸢尾花，则返回的数值大于或者等于1；否则返回的数值小于或者等于-1，代码如下：

```
model_output = tf.sub(tf.matmul(x_data, A), b)
```

6. 声明最大间隔损失函数。首先，我们将声明一个函数来计算向量的L2范数。接着增加间隔参数 α 。声明分类器损失函数，并把前面两项加在一起，代码如下：

```
l2_norm = tf.reduce_sum(tf.square(A))

alpha = tf.constant([0.1])

classification_term = tf.reduce_mean(tf.maximum(0., tf.sub(1.,
tf.mul(model_output, y_target)))) 

loss = tf.add(classification_term, tf.mul(alpha, l2_norm))
```

7. 声明预测函数和准确度函数，用来评估训练集和测试集训练的准确度，代码如下：

```
prediction = tf.sign(model_output)
accuracy = tf.reduce_mean(tf.cast(tf.equal(prediction, y_target),
tf.float32))
```

8. 声明优化器函数，并初始化模型变量，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.01)
train_step = my_opt.minimize(loss)

init = tf.initialize_all_variables()
sess.run(init)
```

9. 开始遍历迭代训练模型，记录训练集和测试集训练的损失和准确度，代码如下：

```

loss_vec = []
train_accuracy = []
test_accuracy = []
for i in range(500):
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    rand_x = x_vals_train[rand_index]
    rand_y = np.transpose([y_vals_train[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})

    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_target: rand_y})
    loss_vec.append(temp_loss)

    train_acc_temp = sess.run(accuracy, feed_dict={x_data: x_vals_train, y_target: np.transpose([y_vals_train])})
    train_accuracy.append(train_acc_temp)

    test_acc_temp = sess.run(accuracy, feed_dict={x_data: x_vals_test, y_target: np.transpose([y_vals_test])})
    test_accuracy.append(test_acc_temp)

if (i+1)%100==0:
    print('Step #' + str(i+1) + ' A = ' + str(sess.run(A)) + ' b = ' + str(sess.run(b)))
    print('Loss = ' + str(temp_loss))

```

10.训练过程中前面脚本的输出结果如下：

```

Step #100 A = [[-0.10763293]
[-0.65735245]] b = [[-0.68752676]]
Loss = [ 0.48756418]
Step #200 A = [[-0.0650763 ]
[-0.89443302]] b = [[-0.73912662]]
Loss = [ 0.38910741]
Step #300 A = [[-0.02090022]
[-1.12334013]] b = [[-0.79332656]]
Loss = [ 0.28621092]
Step #400 A = [[ 0.03189624]
[-1.34912157]] b = [[-0.8507266]]
Loss = [ 0.22397576]
Step #500 A = [[ 0.05958777]
[-1.55989814]] b = [[-0.9000265]]
Loss = [ 0.20492229]

```

11.为了绘制输出结果图，需要抽取系数，分割x_vals为山鸢尾花（I.setosa）和非山鸢尾花（non-I.setosa），代码如下：

```

[[a1], [a2]] = sess.run(A)
[[b]] = sess.run(b)
slope = -a2/a1
y_intercept = b/a1

x1_vals = [d[1] for d in x_vals]

best_fit = []
for i in x1_vals:
    best_fit.append(slope*i+y_intercept)

setosa_x = [d[1] for i,d in enumerate(x_vals) if y_vals[i]==1]
setosa_y = [d[0] for i,d in enumerate(x_vals) if y_vals[i]==1]
not_setosa_x = [d[1] for i,d in enumerate(x_vals) if y_
vals[i]==-1]
not_setosa_y = [d[0] for i,d in enumerate(x_vals) if y_
vals[i]==-1]

```

12.下面是代码绘制数据的线性分类器、准确度和损失图（见图4-2），代码如下：

```
plt.plot(setosa_x, setosa_y, 'o', label='I. setosa')
plt.plot(not_setosa_x, not_setosa_y, 'x', label='Non-setosa')
plt.plot(x1_vals, best_fit, 'r-', label='Linear Separator',
linewidth=3)
plt.ylim([0, 10])
plt.legend(loc='lower right')
plt.title('Sepal Length vs Pedal Width')
plt.xlabel('Pedal Width')
plt.ylabel('Sepal Length')
plt.show()
```

```
plt.plot(train_accuracy, 'k-', label='Training Accuracy')
plt.plot(test_accuracy, 'r--', label='Test Accuracy')
plt.title('Train and Test Set Accuracies')
plt.xlabel('Generation')
plt.ylabel('Accuracy')
plt.legend(loc='lower right')
plt.show()
```

```
plt.plot(loss_vec, 'k-')
plt.title('Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()
```



使用TensorFlow实现SVD算法可能导致每次运行的结果不尽相同。原因包括训练集和测试集的随机分割，每批训练的批量大小不同，在理想情况下每次迭代后学习率缓慢减小。

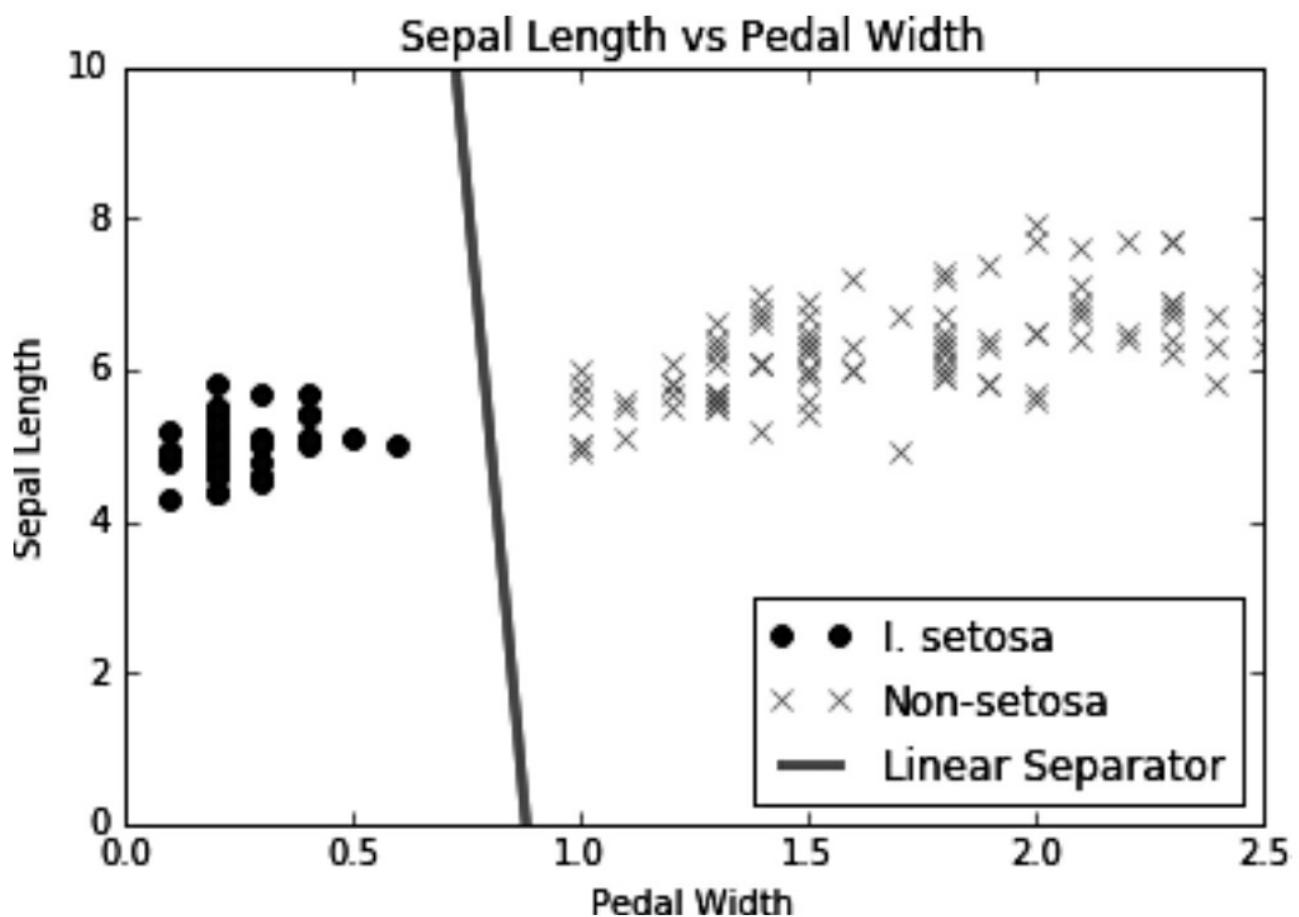


图4-2 线性支持向量机拟合

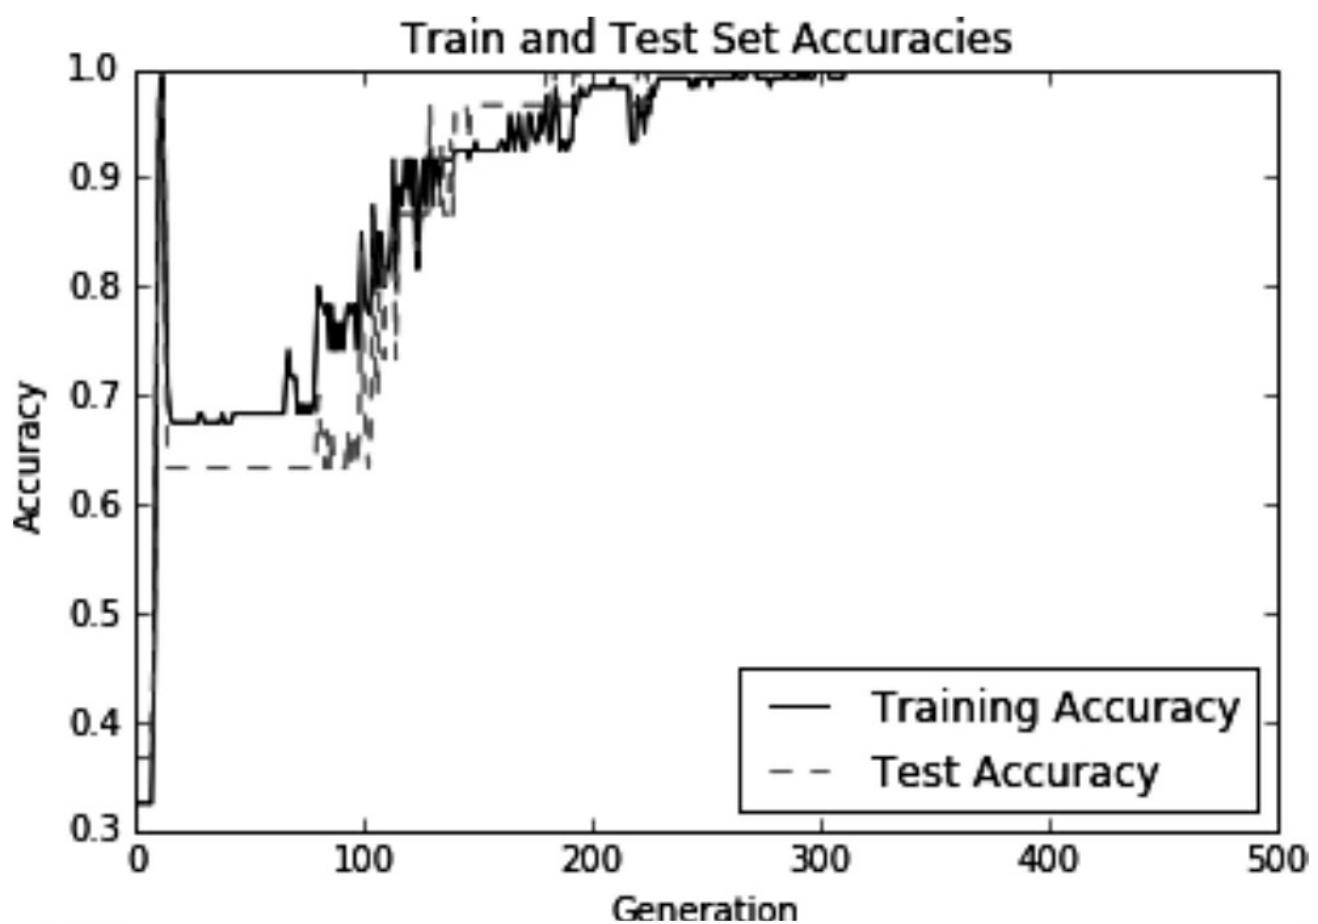


图4-3 训练集和测试集迭代的准确度。由于两类目标是线性可分的，得到准确度是100%

从图4-3中可以看出，训练集和测试集迭代训练。由于两类目标是线性可分的，我们得到准确度是100%。迭代500次的最大间隔如图4-4所示。

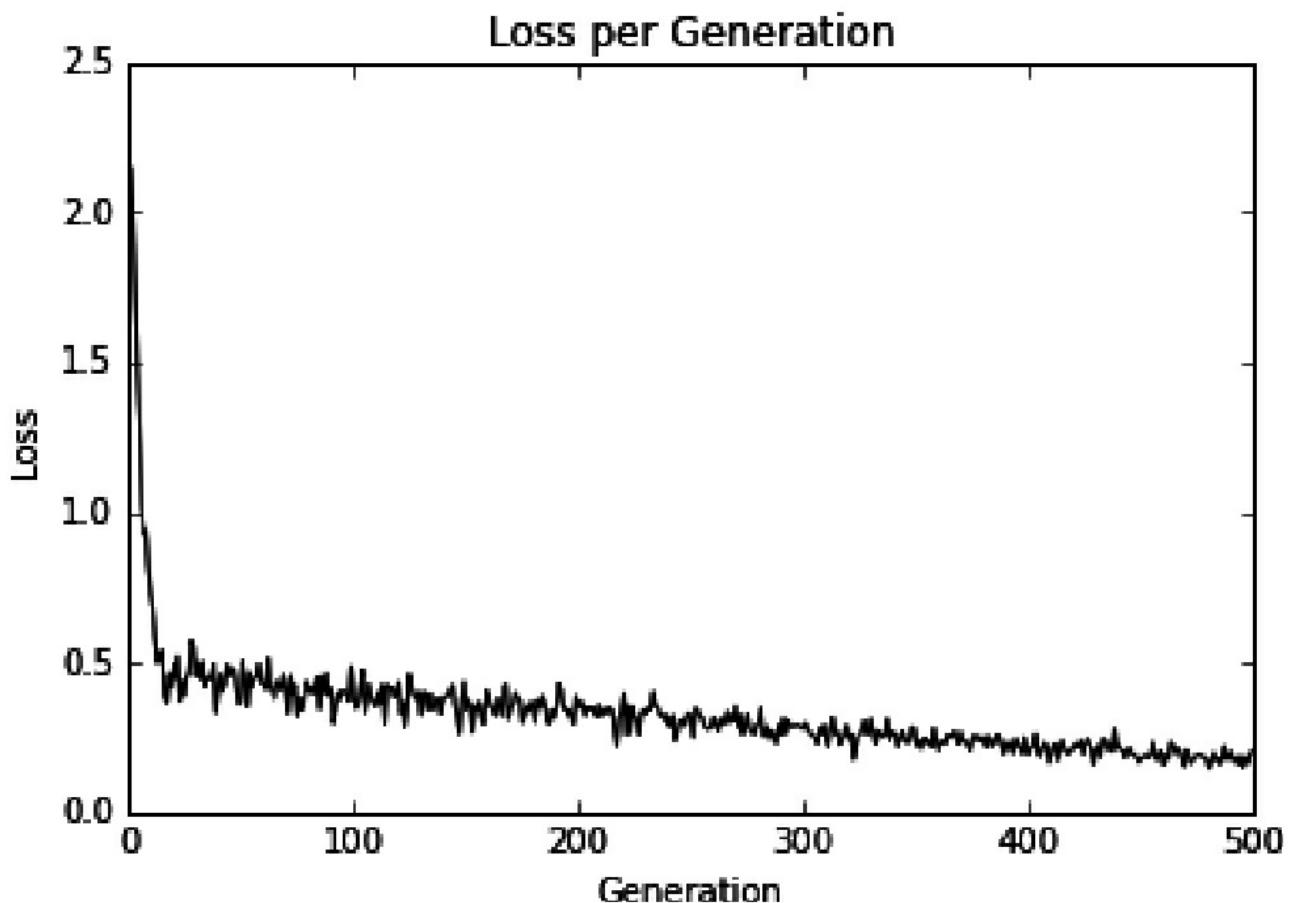


图4-4 迭代500次的最大间隔图

4.2.3 工作原理

本节使用最大间隔损失函数实现了线性支持向量机算法模型。

4.3 弱化为线性回归

支持向量机可以用来拟合线性回归。本节将展示如何在TensorFlow实现支持向量机用来拟合线性回归。

4.3.1 开始

4.3.1 开始

相同的最大间隔（maximum margin）的概念应用到线性回归拟合。代替最大化分割两类目标是，最大化分割包含大部分的数据点（ x, y ）。我们将用相同的iris数据集，展示用刚才的概念来进行花萼长度与花瓣宽度之间的线性拟合。

相关的损失函数类似于 $\max(0, |y_i - (Ax_i + b)| - \epsilon)$ 。 ϵ 这里，是间隔宽度的一半，这意味着如果一个数据点在该区域，则损失等于0。

4.3.2 动手做

1. 导入必要的编程库，创建一个计算图会话，加载iris数据集。然后分割数据集为训练集和测试集，并且可视化相应的损失函数，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
sess = tf.Session()
iris = datasets.load_iris()
x_vals = np.array([x[3] for x in iris.data])
y_vals = np.array([y[0] for y in iris.data])
train_indices = np.random.choice(len(x_vals), round(len(x_vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]
```



对于这个例子，我们分割数据集为训练集和测试集。有时也经常分割为三个数据集，还包括验证集。我们用验证集验证训练过的模型是否过拟合。

2. 声明批量大小、占位符和变量，创建线性模型，代码如下：

```
batch_size = 50

x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)

A = tf.Variable(tf.random_normal(shape=[1,1]))
b = tf.Variable(tf.random_normal(shape=[1,1]))

model_output = tf.add(tf.matmul(x_data, A), b)
```

3. 声明损失函数。该损失函数如前所述，实现时=0.5。注意，是损失函数的一部分，其允许soft margin

代替hard margin，代码如下：

```
epsilon = tf.constant([0.5])
loss = tf.reduce_mean(tf.maximum(0., tf.sub(tf.abs(tf.sub(model_
output, y_target)), epsilon)))
```

4. 创建一个优化器，初始化变量，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.075)
train_step = my_opt.minimize(loss)

init = tf.initialize_all_variables()
sess.run(init)
```

5. 现在开始200次迭代训练，保存训练集和测试集损失函数，后续用来绘图，代码如下：

```
train_loss = []
test_loss = []
for i in range(200):
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    rand_x = np.transpose([x_vals_train[rand_index]])
    rand_y = np.transpose([y_vals_train[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})

    temp_train_loss = sess.run(loss, feed_dict={x_data: np.transpose([x_vals_train]), y_target: np.transpose([y_vals_train])})
    train_loss.append(temp_train_loss)
    temp_test_loss = sess.run(loss, feed_dict={x_data: np.transpose([x_vals_test]), y_target: np.transpose([y_vals_test])})
    test_loss.append(temp_test_loss)
    if (i+1)%50==0:
        print('-----')
        print('Generation: ' + str(i))
        print('A = ' + str(sess.run(A)) + ' b = ' + str(sess.run(b)))
        print('Train Loss = ' + str(temp_train_loss))
        print('Test Loss = ' + str(temp_test_loss))
```

6. 下面是迭代训练输出结果：

```

Generation: 50
A = [[ 2.20651722]] b = [[ 2.71290684]]
Train Loss = 0.609453
Test Loss = 0.460152
-----
Generation: 100
A = [[ 1.6440177]] b = [[ 3.75240564]]
Train Loss = 0.242519
Test Loss = 0.208901
-----
Generation: 150
A = [[ 1.27711761]] b = [[ 4.3149066]]
Train Loss = 0.108192
Test Loss = 0.119284
-----
Generation: 200
A = [[ 1.05271816]] b = [[ 4.53690529]]
Train Loss = 0.0799957
Test Loss = 0.107551

```

7.现在抽取系数，获取最佳拟合直线的截距。为了后续绘图，这里也获取间隔宽度值，代码如下：

```

[[slope]] = sess.run(A)
[[y_intercept]] = sess.run(b)
[width] = sess.run(epsilon)

best_fit = []
best_fit_upper = []
best_fit_lower = []
for i in x_vals:
    best_fit.append(slope*i+y_intercept)
    best_fit_upper.append(slope*i+y_intercept+width)
    best_fit_lower.append(slope*i+y_intercept-width)

```

8.最后，绘制数据点和拟合直线，以及训练集和测试集损失，代码如下（对应的图见图4-5）：

```

plt.plot(x_vals, y_vals, 'o', label='Data Points')
plt.plot(x_vals, best_fit, 'r-', label='SVM Regression Line',
linewidth=3)
plt.plot(x_vals, best_fit_upper, 'r--', linewidth=2)
plt.plot(x_vals, best_fit_lower, 'r--', linewidth=2)
plt.ylim([0, 10])
plt.legend(loc='lower right')
plt.title('Sepal Length vs Pedal Width')
plt.xlabel('Pedal Width')
plt.ylabel('Sepal Length')
plt.show()

plt.plot(train_loss, 'k-', label='Train Set Loss')
plt.plot(test_loss, 'r--', label='Test Set Loss')
plt.title('L2 Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('L2 Loss')
plt.legend(loc='upper right')
plt.show()

```

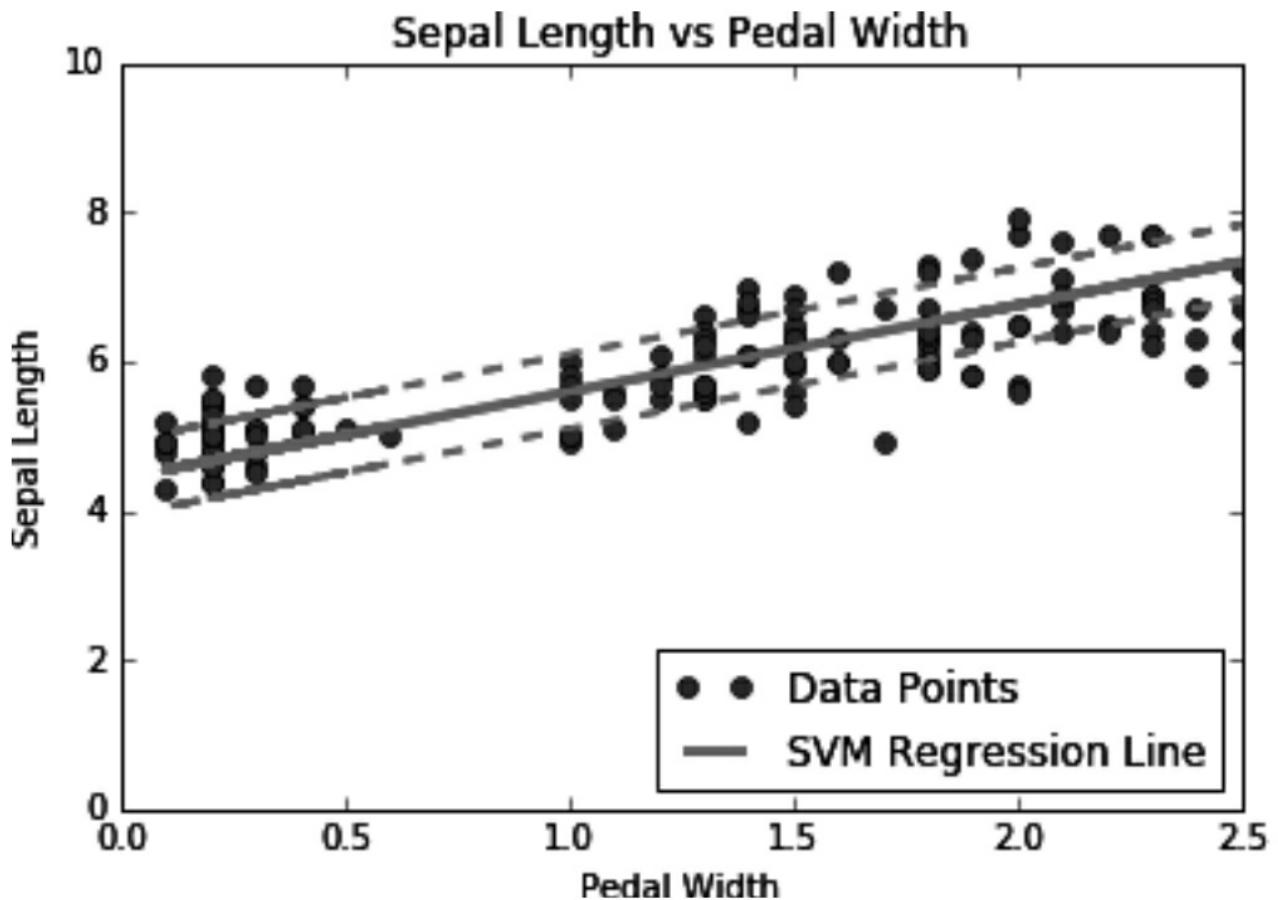


图4-5 基于iris数据集（花萼长度和花瓣宽度）的支持向量机回归，间隔宽度为0.5

图4-6是模型训练迭代中训练集和测试集的训练损失：

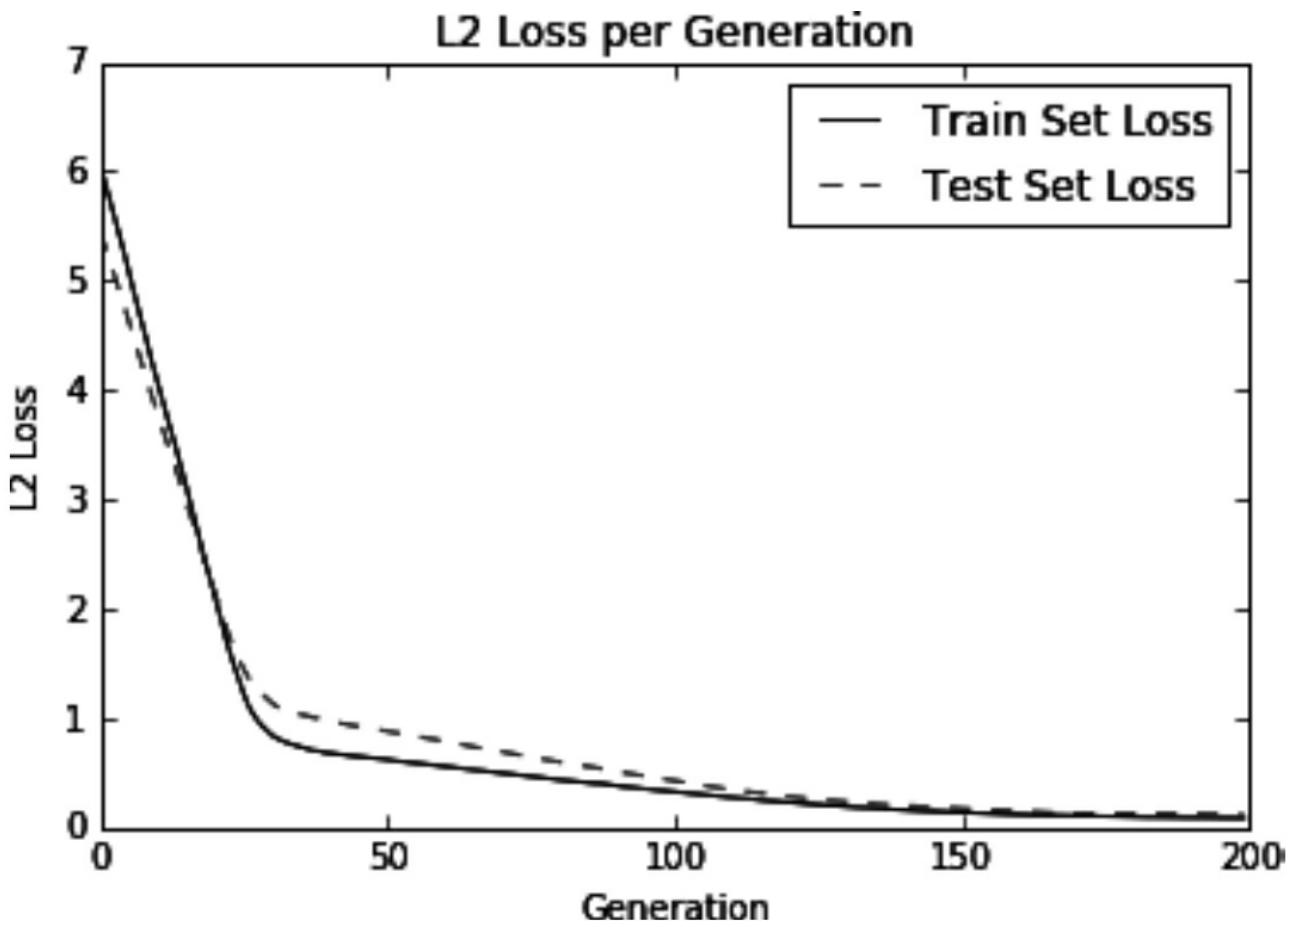


图4-6 每次迭代的支持向量机回归的损失值（训练集和测试集）

4.3.3 工作原理

直观地讲，我们认为SVM回归算法试图把更多的数据点拟合到直线两边 2ϵ 宽度的间隔内。这时拟合的直线对于 ϵ 参数更有意义。如果选择太小的 ϵ 值，SVM回归算法在间隔宽度内不能拟合更多的数据点；如果选择太大的 ϵ 值，将有许多条直线能够在间隔宽度内拟合所有的数据点。作者更倾向于选取更小的 ϵ 值，因为在间隔宽度附近的数据点比远处的数据点贡献更少的损失。

4.4 TensorFlow上核函数的使用

上节介绍的是用SVM算法线性分割数据集。如果想分割非线性数据集，该如何改变线性分类器映射到数据集？答案是，改变SVM损失函数中的核函数。本节将详细阐述如何调整核函数，并且分割非线性可分的数据集。

4.4.1 开始

4.4.1 开始

我们将介绍支持向量机算法中核函数的使用。在4.2节中，采用特殊损失函数来解决soft margin问题。另外一种解决soft margin的方法是对偶优化问题，线性支持向量机问题的对偶表达式为：

$$\max \sum_{i=1}^n b_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i b_i (x_i \cdot x_j) y_j b_j$$

其中：

$$\sum_{i=1}^n b_i y_i = 0 \text{ 和 } 0 \leq b_i \leq \frac{1}{2ny}$$

上述表达式中，模型变量是向量 b 。在理想情况下， b 向量是稀疏向量，iris数据集相关的支持向量仅仅取1和-1附近的值。数据点向量以 x_i 表示，目标值（1或者-1）以 y_i 表示。

在前述方程里的核函数是点积， $x_i \cdot x_j$ ，其为线性核函数。该核函数是以数据点（i, j）的点积填充的矩阵。

替代数据点间的点积，可以将其扩展到更复杂的函数更高维度。这看似不怎么复杂，但是如果选择函数 k ，其需满足如下条件：

$$k(x_i, x_j) = \varphi(x_i) \cdot \varphi(x_j)$$

这里， k 称为核函数。最广为人知的核函数之一是高斯核函数（也称为，径向基核函数或者RBF核函数），该核函数用下面的方程描述：

$$k(x_i, x_j) = e^{-y} \|x_i - x_j\|^2$$

为了用该核函数预测，假设观测数据点 p_i ，代入上述核函数等式中：

$$k(x_i, p_j) = e^{-y} \|x_i - p_j\|^2$$

在本节中，我们将讨论如何实现高斯核函数。注意，这里将用合适的线性核函数实现来替代。为了显示高斯核函数比线性核函数更合适，使用的数据集是程序生成的模拟数据。

4.4.2 动手做

1. 导入必要的编程库，创建一个计算图会话，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
sess = tf.Session()
```

2. 生成模拟数据。生成的数据是两个同心圆数据，每个不同的环代表不同的类，确保只有类-1或者1。为了让绘图方便，这里将每类数据分成x值和y值，代码如下：

```
(x_vals, y_vals) = datasets.make_circles(n_samples=500, factor=.5,
noise=.1)
y_vals = np.array([1 if y==1 else -1 for y in y_vals])
class1_x = [x[0] for i,x in enumerate(x_vals) if y_vals[i]==1]
class1_y = [x[1] for i,x in enumerate(x_vals) if y_vals[i]==1]
class2_x = [x[0] for i,x in enumerate(x_vals) if y_vals[i]==-1]
class2_y = [x[1] for i,x in enumerate(x_vals) if y_vals[i]==-1]
```

3. 声明批量大小、占位符，创建模型变量b。对于SVM算法，为了让每次迭代训练不波动，得到一个稳定的训练模型，这时批量大小得取值更大。注意，本例为预测数据点声明有额外的占位符。最后创建彩色的网格来可视化不同的区域代表不同的类别，代码如下：

```
batch_size = 250
x_data = tf.placeholder(shape=[None, 2], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
prediction_grid = tf.placeholder(shape=[None, 2], dtype=tf.float32)
b = tf.Variable(tf.random_normal(shape=[1,batch_size]))
```

4. 创建高斯核函数。该核函数用矩阵操作来表示，代码如下：

```

gamma = tf.constant(-50.0)
dist = tf.reduce_sum(tf.square(x_data), 1)
dist = tf.reshape(dist, [-1,1])
sq_dists = tf.add(tf.sub(dist, tf.mul(2., tf.matmul(x_data,
tf.transpose(x_data)))), tf.transpose(dist)))
my_kernel = tf.exp(tf.mul(gamma, tf.abs(sq_dists)))

```



注意，在sq_dists中应用广播加法和减法操作。

线性核函数可以表示为： my_kernel=tf.matmul (x_data, tf.transpose (x_data)) 。

5. 声明在本节一开始提到的对偶问题。为了最大化，这里采用最小化损失函数的负数： tf.neg () ， 代码如下：

```

model_output = tf.matmul(b, my_kernel)
first_term = tf.reduce_sum(b)
b_vec_cross = tf.matmul(tf.transpose(b), b)
y_target_cross = tf.matmul(y_target, tf.transpose(y_target))
second_term = tf.reduce_sum(tf.mul(my_kernel, tf.mul(b_vec_cross,
y_target_cross)))
loss = tf.neg(tf.sub(first_term, second_term))

```

6. 创建预测函数和准确度函数。先创建一个预测核函数，类似于步骤4，但用预测数据点的核函数代替步骤4中用模拟数据点的核函数。预测值是模型输出的符号函数值，代码如下：

```

rA = tf.reshape(tf.reduce_sum(tf.square(x_data), 1), [-1,1])
rB = tf.reshape(tf.reduce_sum(tf.square(prediction_grid), 1), [-1,1])

pred_sq_dist = tf.add(tf.sub(rA, tf.mul(2., tf.matmul(x_data,
tf.transpose(prediction_grid)))), tf.transpose(rB)))
pred_kernel = tf.exp(tf.mul(gamma, tf.abs(pred_sq_dist)))

prediction_output = tf.matmul(tf.mul(tf.transpose(y_target), b),
pred_kernel)
prediction = tf.sign(prediction_output-tf.reduce_mean(prediction_output))
accuracy = tf.reduce_mean(tf.cast(tf.equal(tf.squeeze(prediction),
tf.squeeze(y_target)), tf.float32))

```



为了实现线性预测核函数，将预测核函数改为：`pred_kernel=tf.matmul(x_data, tf.transpose(prediction_grid))`。

7. 创建优化器函数，初始化所有的变量，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.001)
train_step = my_opt.minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)
```

8. 开始迭代训练。这里会记录每次迭代的损失向量和批量训练的准确度。当计算准确度时，需要为三个占位符赋值，其中，`x_data`数据会被赋值两次来得到数据点的预测值，代码如下：

```
loss_vec = []
batch_accuracy = []
for i in range(500):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = x_vals[rand_index]
    rand_y = np.transpose([y_vals[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})

    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_target: rand_y})
    loss_vec.append(temp_loss)

    acc_temp = sess.run(accuracy, feed_dict={x_data: rand_x,
                                             y_target: rand_y,
                                             prediction_
grid:rand_x})
    batch_accuracy.append(acc_temp)

    if (i+1)%100==0:
        print('Step #' + str(i+1))
        print('Loss = ' + str(temp_loss))
```

9. 输出结果如下：

```
Step #100
Loss = -28.0772

Step #200
Loss = -3.3628
Step #300
Loss = -58.862
Step #400
Loss = -75.1121
Step #500
Loss = -84.8905
```

10.为了能够在整个数据空间可视化分类返回结果，我们将创建预测数据点的网格，并在其上进行预测，代码如下：

```
x_min, x_max = x_vals[:, 0].min() - 1, x_vals[:, 0].max() + 1
y_min, y_max = x_vals[:, 1].min() - 1, x_vals[:, 1].max() + 1
xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.02),
                      np.arange(y_min, y_max, 0.02))
grid_points = np.c_[xx.ravel(), yy.ravel()]
[grid_predictions] = sess.run(prediction, feed_dict={x_data:
rand_x,
y_target:
rand_y,
prediction_
grid: grid_points})
grid_predictions = grid_predictions.reshape(xx.shape)
```

11.下面绘制预测结果、批量准确度和损失函数：

```
plt.contourf(xx, yy, grid_predictions, cmap=plt.cm.Paired,
alpha=0.8)
plt.plot(class1_x, class1_y, 'ro', label='Class 1')
plt.plot(class2_x, class2_y, 'kx', label='Class -1')
plt.legend(loc='lower right')
plt.ylim([-1.5, 1.5])
plt.xlim([-1.5, 1.5])
plt.show()

plt.plot(batch_accuracy, 'k-', label='Accuracy')
plt.title('Batch Accuracy')
plt.xlabel('Generation')
plt.ylabel('Accuracy')
plt.legend(loc='lower right')
plt.show()

plt.plot(loss_vec, 'k-')
plt.title('Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()
```

12.简单扼要，这里只显示训练结果图（见图4-7和图4-8），不过也可以分开运行绘图代码展示其他效果。

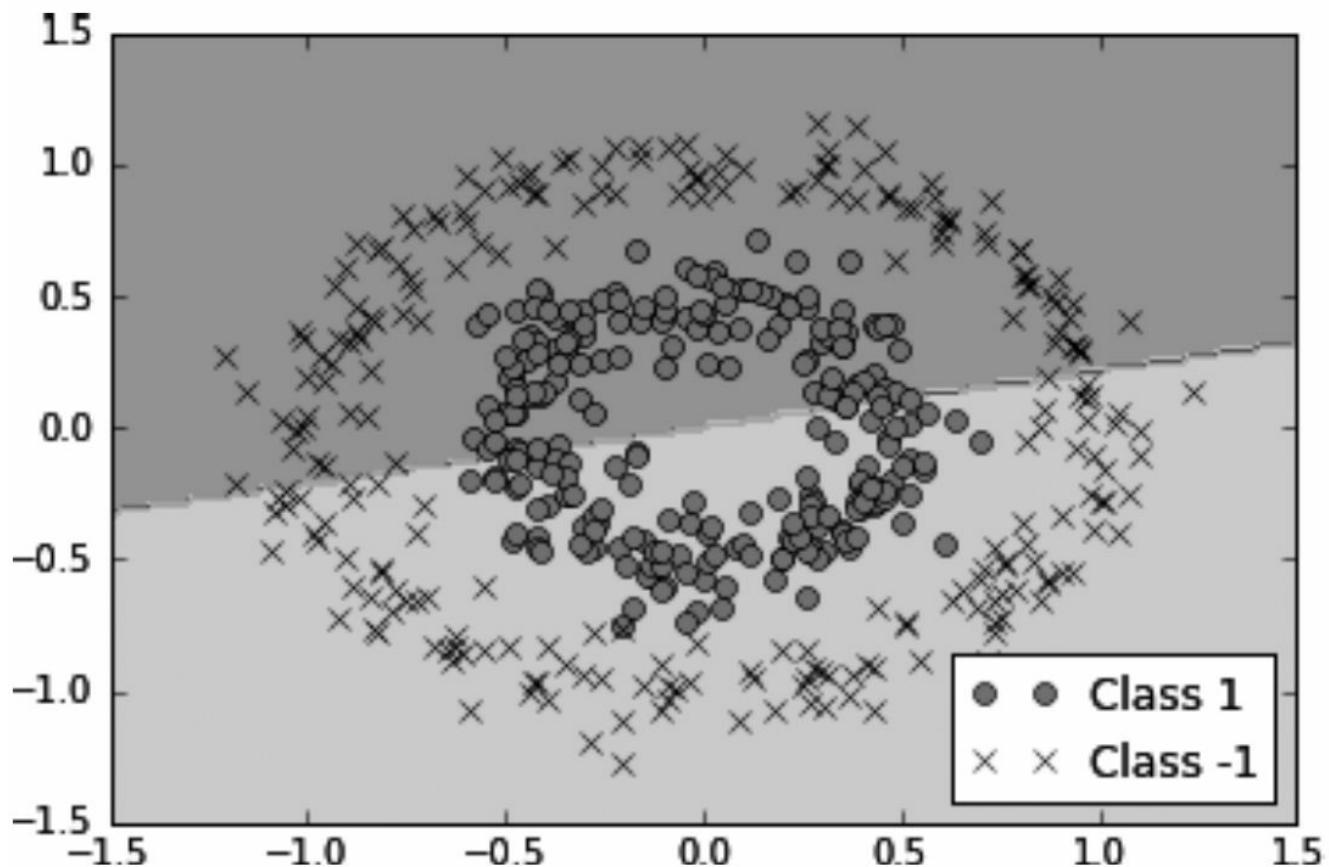


图4-7 使用线性支持向量机在非线性可分的数据集上进行分割

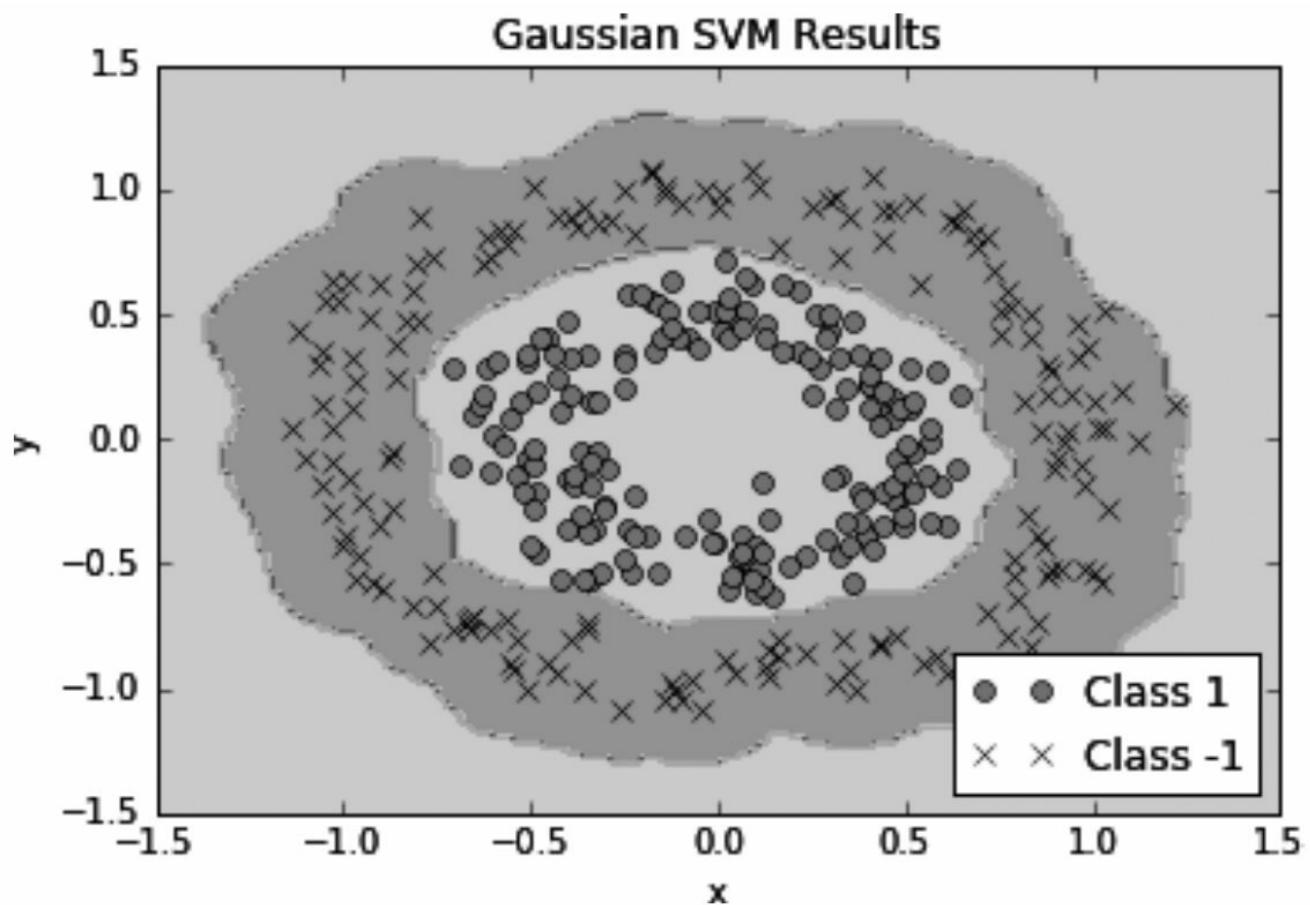


图4-8 使用非线性的高斯核函数SVM在非线性可分的数据集上进行分割

图4-7展示的是在非线性可分的数据集上进行线性SVM训练。

图4-8展示的是非线性可分的数据集上进行非线性的高斯核函数SVM训练。

4.4.3 工作原理

上述的代码里有两个重要的部分：如何为SVM对偶优化问题完成核函数和损失函数。我们已经实现了线性核函数和高斯核函数，其中高斯核函数能够分割非线性数据集。

我们也应该注意到高斯核函数中有一个参数——`gamma`。该参数控制数据集分割的弯曲部分的影响程度，一般情况下选择较小值，但是也严重依赖于数据集。在理想情况下，`gamma`值是通过统计技术（比如，交叉验证）来确定的。

4.4.4 延伸学习

有许多核函数可以实现，下面是常用的非线性核函数列表：

·齐次多项式核函数：

$$k(x_i, x_j) = (x_i \cdot x_j)^d$$

·非齐次多项式核函数：

$$k(x_i, x_j) = (x_i \cdot x_j + 1)^d$$

·双曲正切核函数：

$$k(x_i, x_j) = \tanh(ax_i \cdot x_j + k)$$

4.5 用TensorFlow实现非线性支持向量机

本节将会应用非线性核函数来分割数据集。

4.5.1 开始

本节使用前面实现的高斯核函数SVM来分割真实数据集。我们将加载iris数据集，创建一个山鸢尾花(I.setosa)的分类器。后面将会看到各种gamma值对分类器的影响。

4.5.2 动手做

1. 导入必要的编程库，包括scikit learn的datasets模块。scikit learn的datasets模块可以加载iris数据集。然后建立一个计算图会话，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
sess = tf.Session()
```

2. 加载iris数据集，抽取花萼长度和花瓣宽度，分割每类的x_vals值和y_vals值，代码如下：

```
iris = datasets.load_iris()
x_vals = np.array([[x[0], x[3]] for x in iris.data])
y_vals = np.array([1 if y==0 else -1 for y in iris.target])
class1_x = [x[0] for i,x in enumerate(x_vals) if y_vals[i]==1]
class1_y = [x[1] for i,x in enumerate(x_vals) if y_vals[i]==1]
class2_x = [x[0] for i,x in enumerate(x_vals) if y_vals[i]==-1]
class2_y = [x[1] for i,x in enumerate(x_vals) if y_vals[i]==-1]
```

3. 声明批量大小（偏向于更大批量大小）、占位符和模型变量b，代码如下：

```
batch_size = 100

x_data = tf.placeholder(shape=[None, 2], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
prediction_grid = tf.placeholder(shape=[None, 2], dtype=tf.float32)

b = tf.Variable(tf.random_normal(shape=[1,batch_size]))
```

4. 声明高斯核函数。该核函数依赖gamma值，在本节末尾将展示不同的gamma值对分类器的影响，代码如下：

```

gamma = tf.constant(-10.0)
dist = tf.reduce_sum(tf.square(x_data), 1)
dist = tf.reshape(dist, [-1,1])
sq_dists = tf.add(tf.sub(dist, tf.mul(2., tf.matmul(x_data,
tf.transpose(x_data)))), tf.transpose(dist)))
my_kernel = tf.exp(tf.mul(gamma, tf.abs(sq_dists)))

```

We now compute the loss for the dual optimization problem, as follows:

```

model_output = tf.matmul(b, my_kernel)
first_term = tf.reduce_sum(b)
b_vec_cross = tf.matmul(tf.transpose(b), b)
y_target_cross = tf.matmul(y_target, tf.transpose(y_target))
second_term = tf.reduce_sum(tf.mul(my_kernel, tf.mul(b_vec_cross,
y_target_cross)))
loss = tf.neg(tf.sub(first_term, second_term))

```

5.为了使用SVM进行预测，创建一个预测核函数。然后声明一个准确度函数，其为正确分类的数据点的百分比，代码如下：

```

rA = tf.reshape(tf.reduce_sum(tf.square(x_data), 1), [-1,1])
rB = tf.reshape(tf.reduce_sum(tf.square(prediction_grid), 1), [-1,1])
pred_sq_dist = tf.add(tf.sub(rA, tf.mul(2., tf.matmul(x_data,
tf.transpose(prediction_grid)))), tf.transpose(rB)))
pred_kernel = tf.exp(tf.mul(gamma, tf.abs(pred_sq_dist)))

prediction_output = tf.matmul(tf.mul(tf.transpose(y_target), b),
pred_kernel)
prediction = tf.sign(prediction_output - tf.reduce_mean(prediction_output))
accuracy = tf.reduce_mean(tf.cast(tf.equal(tf.squeeze(prediction),
tf.squeeze(y_target)), tf.float32))

```

6.声明优化器函数，初始化变量，代码如下：

```

my_opt = tf.train.GradientDescentOptimizer(0.01)
train_step = my_opt.minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)

```

7.现在开始迭代训练。迭代300次，并保存损失值和批量准确度，代码如下：

```

loss_vec = []
batch_accuracy = []

for i in range(300):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = x_vals[rand_index]
    rand_y = np.transpose([y_vals[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})

    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
    loss_vec.append(temp_loss)

    acc_temp = sess.run(accuracy, feed_dict={x_data: rand_x,
y_target: rand_y,
prediction_
grid:rand_x})
    batch_accuracy.append(acc_temp)

```

8.为了绘制决策边界（Decision Boundary），我们创建一个数据点（x，y）的网格，评估预测函数，代码如下：

```

x_min, x_max = x_vals[:, 0].min() - 1, x_vals[:, 0].max() + 1
y_min, y_max = x_vals[:, 1].min() - 1, x_vals[:, 1].max() + 1
xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.02),
                     np.arange(y_min, y_max, 0.02))
grid_points = np.c_[xx.ravel(), yy.ravel()]
[grid_predictions] = sess.run(prediction, feed_dict={x_data:
rand_x,
y_target:
rand_y,
prediction_
grid: grid_points})
grid_predictions = grid_predictions.reshape(xx.shape)

```

9.为了简明扼要，这里仅仅显示如何绘制决策边界。对于gamma值的影响和绘图将在下一节介绍，代码如下：

```
plt.contourf(xx, yy, grid_predictions, cmap=plt.cm.Paired,
alpha=0.8)
plt.plot(class1_x, class1_y, 'ro', label='I. setosa')
plt.plot(class2_x, class2_y, 'kx', label='Non setosa')
plt.title('Gaussian SVM Results on Iris Data')
plt.xlabel('Pedal Length')
plt.ylabel('Sepal Width')
plt.legend(loc='lower right')
plt.ylim([-0.5, 3.0])
plt.xlim([3.5, 8.5])
plt.show()
```

4.5.3 工作原理

这里是四种不同的gamma值（1, 10, 25, 100），山鸢尾花（I.setosa）的分类器结果图，如图4-9所示。注意，gamma值越大，每个数据点对分类边界的影响就越大。

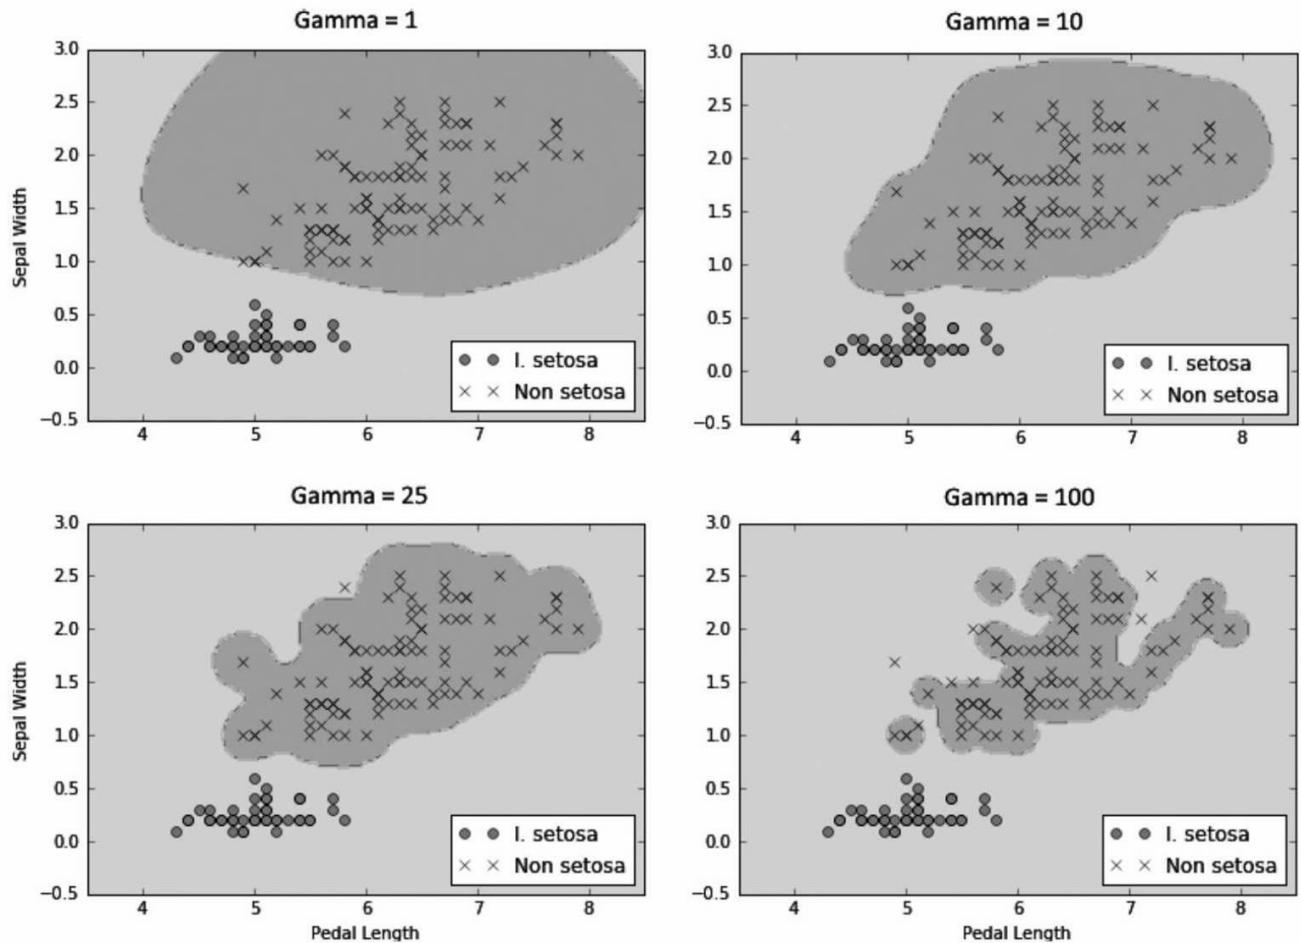


图4-9 不同gamma值的山鸢尾花（I.setosa）的分类器结果图，采用高斯核函数的SVM

4.6 用TensorFlow实现多类支持向量机

我们也能用SVM分类多类目标。在本节中，将详细展示一个多类支持向量机分类器训练iris数据集来分类三种花。

4.6.1 开始

SVM算法最初是为二值分类问题设计的，但是也可以通过一些策略使得其能进行多类分类。主要的两种策略是：一对多（one versus all）方法；一对一（one versus one）方法。

一对一方法是在任意两类样本之间设计创建一个二值分类器，然后得票最多的类别即为该未知样本的预测类别。但是当类别（k类）很多的时候，就必须创建 $k! / (k-2)! 2!$ 个分类器，计算的代价还是相当大的。

另外一种实现多类分类器的方法是一对多，其为每类创建一个分类器。最后的预测类别是具有最大SVM间隔的类别。本小节将实现该方法。

我们将加载iris数据集，使用高斯核函数的非线性多类SVM模型。iris数据集含有三个类别，山鸢尾、变色鸢尾和维吉尼亚鸢尾（I.setosa、I.virginica和I.versicolor），我们将为它们创建三个高斯核函数SVM来预测。

4.6.2 动手做

1. 导入必要的编程库，创建一个计算图，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
sess = tf.Session()
```

2. 加载iris数据集并为每类分离目标值。因为我们想绘制结果图，所以只使用花萼长度和花瓣宽度两个特征。为了便于绘图，也会分离x值和y值，代码如下：

```
iris = datasets.load_iris()
x_vals = np.array([[x[0], x[3]] for x in iris.data])
y_vals1 = np.array([1 if y==0 else -1 for y in iris.target])
y_vals2 = np.array([1 if y==1 else -1 for y in iris.target])
y_vals3 = np.array([1 if y==2 else -1 for y in iris.target])
y_vals = np.array([y_vals1, y_vals2, y_vals3])
class1_x = [x[0] for i,x in enumerate(x_vals) if iris.
target[i]==0]
class1_y = [x[1] for i,x in enumerate(x_vals) if iris.
target[i]==0]
class2_x = [x[0] for i,x in enumerate(x_vals) if iris.
target[i]==1]
class2_y = [x[1] for i,x in enumerate(x_vals) if iris.
target[i]==1]
class3_x = [x[0] for i,x in enumerate(x_vals) if iris.
target[i]==2]
class3_y = [x[1] for i,x in enumerate(x_vals) if iris.
target[i]==2]
```

3. 与4.5节最大的不同是，数据集的维度在变化，从单类目标分类到三类目标分类。我们将利用矩阵传播和reshape技术一次性计算所有的三类SVM。注意，由于一次性计算所有分类，y_target占位符的维度是[3, None]，模型变量b初始化大小为[3, batch_size]，代码如下：

```

batch_size = 50

x_data = tf.placeholder(shape=[None, 2], dtype=tf.float32)
y_target = tf.placeholder(shape=[3, None], dtype=tf.float32)
prediction_grid = tf.placeholder(shape=[None, 2], dtype=tf.float32)

b = tf.Variable(tf.random_normal(shape=[3, batch_size]))

```

4.计算高斯核函数。因为该核函数只依赖x_data，所以代码与4.5节没有区别，代码如下：

```

gamma = tf.constant(-10.0)
dist = tf.reduce_sum(tf.square(x_data), 1)
dist = tf.reshape(dist, [-1, 1])
sq_dists = tf.add(tf.sub(dist, tf.mul(2., tf.matmul(x_data,
tf.transpose(x_data)))), tf.transpose(dist)))
my_kernel = tf.exp(tf.mul(gamma, tf.abs(sq_dists)))

```

5.最大的变化是批量矩阵乘法。最终的结果是三维矩阵，并且需要传播矩阵乘法。所以数据矩阵和目标矩阵需要预处理，比如 $x^T \cdot x$ 操作需额外增加一个维度。这里创建一个函数来扩展矩阵维度，然后进行矩阵转置，接着调用TensorFlow的tf.batch_matmul() 函数，代码如下：

```

def reshape_matmul(mat):
    v1 = tf.expand_dims(mat, 1)
    v2 = tf.reshape(v1, [3, batch_size, 1])
    return(tf.batch_matmul(v2, v1))

```

6.计算对偶损失函数，代码如下：

```

model_output = tf.matmul(b, my_kernel)
first_term = tf.reduce_sum(b)
b_vec_cross = tf.matmul(tf.transpose(b), b)
y_target_cross = reshape_matmul(y_target)

second_term = tf.reduce_sum(tf.mul(my_kernel, tf.mul(b_vec_cross,
y_target_cross)), [1, 2])
loss = tf.reduce_sum(tf.neg(tf.sub(first_term, second_term)))

```

7.现在创建预测核函数。要当心reduce_sum() 函数，这里我们并不想聚合三个SVM预测，所以需要通过第二个参数告诉TensorFlow求和哪几个，代码如下：

```
rA = tf.reshape(tf.reduce_sum(tf.square(x_data), 1), [-1,1])
rB = tf.reshape(tf.reduce_sum(tf.square(prediction_grid), 1), [-1,1])
pred_sq_dist = tf.add(tf.sub(rA, tf.mul(2., tf.matmul(x_data,
tf.transpose(prediction_grid)))), tf.transpose(rB))
pred_kernel = tf.exp(tf.mul(gamma, tf.abs(pred_sq_dist)))
```

8. 实现预测核函数后，我们创建预测函数。与4.5节不同的是，不再对模型输出进行`sign()`运算。因为这里实现的是一对多方法，所以预测值是分类器有最大返回值的类别。使用TensorFlow的内建函数`argmax()`来实现该功能，代码如下：

```
prediction_output = tf.matmul(tf.mul(y_target,b), pred_kernel)
prediction = tf.argmax(prediction_output-tf.expand_dims(tf.
reduce_mean(prediction_output,1), 1), 0)
accuracy = tf.reduce_mean(tf.cast(tf.equal(prediction,
tf.argmax(y_target,0)), tf.float32))
```

9. 准备好核函数、损失函数和预测函数后，该声明优化器函数和初始化变量了，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.01)
train_step = my_opt.minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)
```

10. 该算法收敛得相当快，所以迭代训练的次数不要超过100次，代码如下：

```

loss_vec = []
batch_accuracy = []
for i in range(100):
    rand_index = np.random.choice(len(x_vals), size=batch_size)
    rand_x = x_vals[rand_index]
    rand_y = y_vals[:,rand_index]
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})

    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
    loss_vec.append(temp_loss)

    acc_temp = sess.run(accuracy, feed_dict={x_data: rand_x, y_
target: rand_y, prediction_grid:rand_x})
    batch_accuracy.append(acc_temp)

if (i+1)%25==0:
    print('Step #' + str(i+1))
    print('Loss = ' + str(temp_loss))

Step #25
Loss = -2.8951
Step #50
Loss = -27.9612
Step #75
Loss = -26.896
Step #100
Loss = -30.2325

```

11. 创建数据点的预测网格，运行预测函数，代码如下：

```

x_min, x_max = x_vals[:, 0].min() - 1, x_vals[:, 0].max() + 1
y_min, y_max = x_vals[:, 1].min() - 1, x_vals[:, 1].max() + 1
xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.02),
                      np.arange(y_min, y_max, 0.02))
grid_points = np.c_[xx.ravel(), yy.ravel()]
grid_predictions = sess.run(prediction, feed_dict={x_data: rand_x,
                                                 y_target:
rand_y,
                                                 prediction_
grid: grid_points})
grid_predictions = grid_predictions.reshape(xx.shape)

```

12. 绘制训练结果、批量准确度和损失函数（见图4-10）。为了简便，只显示训练结果：

```
plt.contourf(xx, yy, grid_predictions, cmap=plt.cm.Paired,
alpha=0.8)

plt.plot(class1_x, class1_y, 'ro', label='I. setosa')
plt.plot(class2_x, class2_y, 'kx', label='I. versicolor')
plt.plot(class3_x, class3_y, 'gv', label='I. virginica')
plt.title('Gaussian SVM Results on Iris Data')
plt.xlabel('Pedal Length')
plt.ylabel('Sepal Width')
plt.legend(loc='lower right')
plt.ylim([-0.5, 3.0])
plt.xlim([3.5, 8.5])
plt.show()

plt.plot(batch_accuracy, 'k-', label='Accuracy')
plt.title('Batch Accuracy')
plt.xlabel('Generation')
plt.ylabel('Accuracy')
plt.legend(loc='lower right')
plt.show()

plt.plot(loss_vec, 'k-')
plt.title('Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()
```

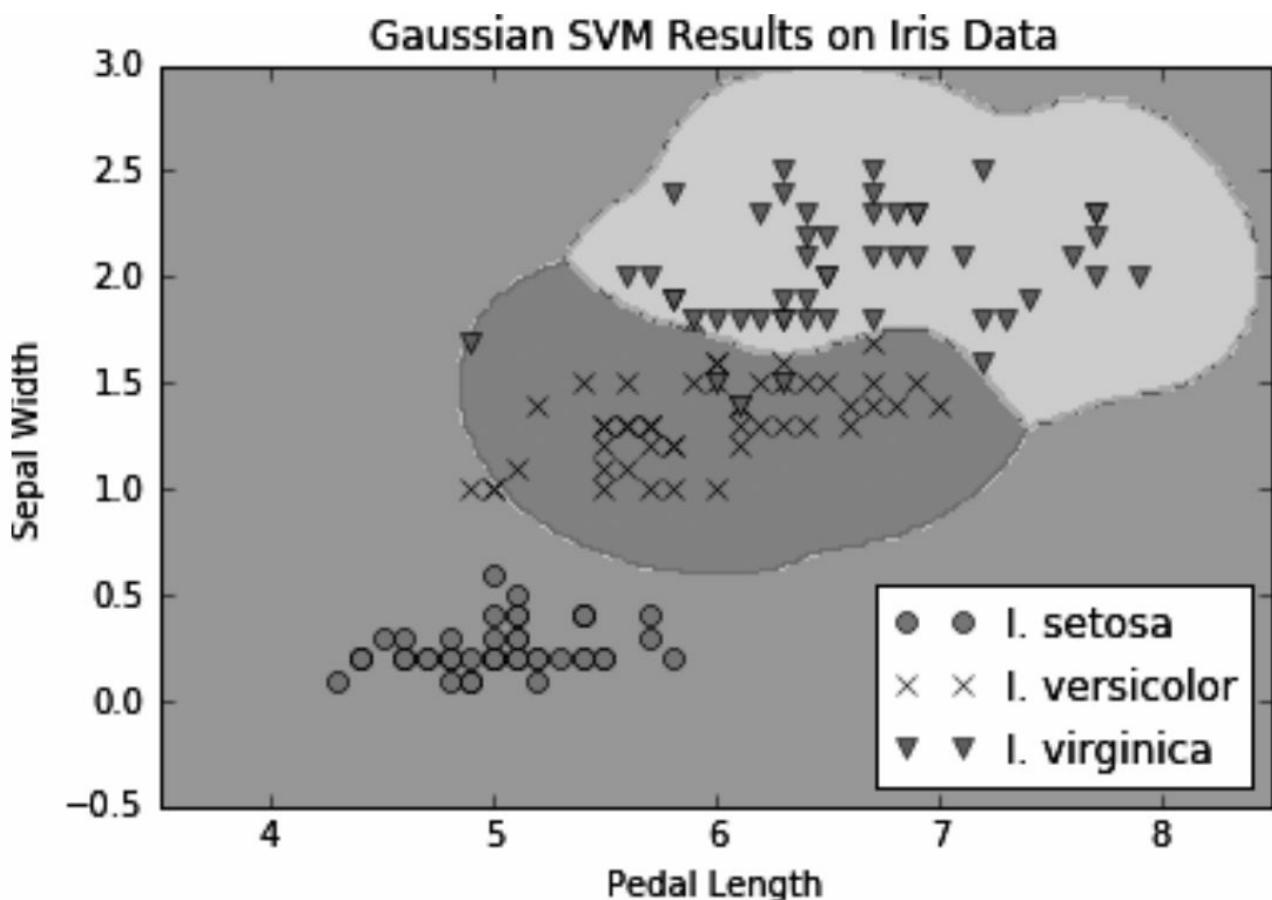


图4-10 山鸢尾花（I. Setosa）非线性高斯SVM模型的多分类（三类）结果，其中gamma值为10

4.6.3 工作原理

本节的重点是改变SVM算法一次性优化三类SVM模型。模型参数 b 通过增加一个维度来计算三个模型。我们可以看到，使用TensorFlow内建功能可以轻松扩展算法到多类的相似算法。

第5章 最近邻域法

本章主要关注最近邻域法，以及在TensorFlow中如何实现该算法。首先介绍最近邻域法和不同形式的实现方法，然后在本章结尾处将最近邻域法应用于地址匹配和图像识别中。学完本章将掌握以下知识点：

- 最近邻域法的使用
- 如何度量文本距离
- TensorFlow实现混合距离
- TensorFlow实现地址匹配
- TensorFlow实现图像识别

注意，本章的代码可以在GitHub (https://github.com/nfmccleure/tensorflow_cookbook) 上访问。

5.1 最近邻域法介绍

5.1.1 最近邻域法介绍

最近邻域算法的思想很简单，其先将训练集看作训练模型，然后基于新数据点与训练集的距离来预测新数据点。最直观的最近邻域算法是让预测值与最接近的训练数据集作为同一类。但是大部分样本数据集包含一定程度的噪声，更通用的方法是k个邻域的加权平均，该方法称为k最近邻域法（k-nearest neighbor, k-NN）。

假设样本训练集 (x_1, x_2, \dots, x_n) ，对应的目标值 (y_1, y_2, \dots, y_n) ，通过最近邻域法预测数据点 z 。预测的实际方法取决于我们是想做回归训练（连续型 y_i ）还是分类训练（离散型 y_i ）。

对于离散型分类目标，预测值由到预测数据点的加权距离的最大投票方案决定，公式如下：

$$f(z) = \max_j \sum_{i=1}^k \varphi(d_{ij}) I_{ij}$$

其中，预测函数 $f(z)$ 是所有分类 j 上的最大加权值。预测数据点到训练数据点 i 的加权距离用 $\varphi(d_{ij})$ 表示。 I_{ij} 是指示函数，表示数据点 i 是否属于分类 j 。

对于连续回归训练目标，预测值是所有 k 个最近邻域数据点到预测数据点的加权平均，公式如下：

$$f(z) = \frac{1}{k} \sum_{i=1}^k \varphi(d_i)$$

明显地，预测值严重依赖距离度量 (d) 方式的选择。常用的距离度量是L1范数和L2范数。公式如下：

$$d_{L1}(x_i, x_j) = |x_i - x_j| = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \dots$$

$$d_{L2}(x_i, x_j) = \|x_i - x_j\| = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2 + \dots}$$

距离度量方式可选择性广，但是在本节，将使用L1范数和L2范数，也会使用编辑距离和文本距离。

我们也需要选择如何加权距离。最直观的方式是用距离本身来加权，即加权权重为1。考虑到更近的数据点对预测数据点的预测值影响应该更小，因而最通用的加权方式是距离的归一化倒数。下一节将实现该方法。



注意，k-NN算法是一种聚合的方法。对于回归算法来说，需要计算邻域的加权平均距离，因而预测值将比实际目标值的特征更平缓。影响的程度将取决于k值，该值是算法中的邻域的个数。

5.2 最近邻域法的使用

本小节开始介绍最近邻域法的实现，并应用到房价的预测。也许这是学习最近邻域法最好的方式，因为我们将处理数值化的特征和连续型目标。

5.2.1 开始

为了展示在TensorFlow中如何运用最近邻域法预测，我们将进行波士顿房价数据集训练。这里将利用几个特征的函数来预测平均邻域房价。

我们将从训练好的模型的训练数据集中找到预测数据点的最近邻域，并对实际值进行加权平均。

5.2.2 动手做

1. 导入必要的编程库，创建一个计算图会话。我们将使用Python的requests模块，从UCI机器学习仓库加载所需的波士顿房价数据集，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf

import requests

sess = tf.Session()
```

2. 使用requests模块加载数据集，代码如下：

```
housing_url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/housing/housing.data'
housing_header = ['CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX', 'PTRATIO', 'B', 'LSTAT', 'MEDV']
cols_used = ['CRIM', 'INDUS', 'NOX', 'RM', 'AGE', 'DIS', 'TAX', 'PTRATIO', 'B', 'LSTAT']
num_features = len(cols_used)
# Request data
housing_file = requests.get(housing_url)
# Parse Data
housing_data = [[float(x) for x in y.split(' ') if len(x)>=1] for y in housing_file.text.split('\n') if len(y)>=1]
```

3. 分离数据集为特征依赖的数据集和特征无关的数据集。我们将预测最后一个变量——MEDV，该值为一组房价中的平均值。由于非相关特征或者二值特征，在本例中不使用ZN、CHAS和RAD这几个特征，代码如下：

```

y_vals = np.transpose([np.array([y[13] for y in housing_data])])
x_vals = np.array([[x for i,x in enumerate(y) if housing_header[i]
in cols_used] for y in housing_data])

x_vals = (x_vals - x_vals.min(0)) / x_vals.ptp(0)

```

4. 分离x_vals值和y_vals值为训练数据集和测试数据集。随机选择80%的行作为训练集，剩下的20%数据行作为测试集，代码如下：

```

train_indices = np.random.choice(len(x_vals), round(len(x_
vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_
indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]

```

5. 声明k值和批量大小：

```

k = 4
batch_size=len(x_vals_test)

```

6. 声明占位符。注意，本例中没有训练模型变量，算法模型完全是通过训练集决定的，代码如下：

```

x_data_train = tf.placeholder(shape=[None, num_features],
dtype=tf.float32)
x_data_test = tf.placeholder(shape=[None, num_features], dtype=tf.
float32)
y_target_train = tf.placeholder(shape=[None, 1], dtype=tf.float32)

y_target_test = tf.placeholder(shape=[None, 1], dtype=tf.float32)

```

7. 为批量测试集创建距离函数，这里使用L1范数距离，代码如下：

```

distance = tf.reduce_sum(tf.abs(tf.sub(x_data_train, tf.expand_
dims(x_data_test,1))), reduction_indices=2)

```



注意，L2范数距离函数也经常使用，代码为：

```
distance = tf.sqrt(tf.reduce_sum(tf.square(tf.
sub(x_data_train, tf.expand_dims(x_data_test, 1))), ,
reduction_indices=1))
```

8. 创建预测函数。在本例中，将使用`top_k()` 函数，其以张量的方式返回最大值的值和索引。因为需要找到最小距离的索引，所以将对最大距离取负。声明预测函数和目标值的均方误差（MSE），代码如下：

```
top_k_xvals, top_k_indices = tf.nn.top_k(tf.neg(distance), k=k)
x_sums = tf.expand_dims(tf.reduce_sum(top_k_xvals, 1), 1)
x_sums_repeated = tf.matmul(x_sums, tf.ones([1, k], tf.float32))
x_val_weights = tf.expand_dims(tf.div(top_k_xvals, x_sums_
repeated), 1)

top_k_yvals = tf.gather(y_target_train, top_k_indices)
prediction = tf.squeeze(tf.batch_matmul(x_val_weights, top_k_
yvals), squeeze_dims=[1])
mse = tf.div(tf.reduce_sum(tf.square(tf.sub(prediction, y_target_
test))), batch_size)
```

9. 进行测试，代码如下：

```
num_loops = int(np.ceil(len(x_vals_test) / batch_size))

for i in range(num_loops):
    min_index = i * batch_size
    max_index = min((i+1) * batch_size, len(x_vals_train))
    x_batch = x_vals_test[min_index:max_index]
    y_batch = y_vals_test[min_index:max_index]
    predictions = sess.run(prediction, feed_dict={x_data_train: x_vals_train, x_data_test: x_batch, y_target_train: y_vals_train, y_target_test: y_batch})
    batch_mse = sess.run(mse, feed_dict={x_data_train: x_vals_train, x_data_test: x_batch, y_target_train: y_vals_train, y_target_test: y_batch})

    print('Batch #' + str(i+1) + ' MSE: ' + str(np.round(batch_mse, 3)))
```

Batch #1 MSE: 23.153

10. 下面通过直方图（见图5-1）来比较实际值和预测值。因为本例使用的是平均方法，所以在预测目标值最大和最小极值时遇到问题，代码如下：

```

bins = np.linspace(5, 50, 45)

plt.hist(predictions, bins, alpha=0.5, label='Prediction')
plt.hist(y_batch, bins, alpha=0.5, label='Actual')
plt.title('Histogram of Predicted and Actual Values')
plt.xlabel('Med Home Value in $1,000s')
plt.ylabel('Frequency')
plt.legend(loc='upper right')
plt.show()

```

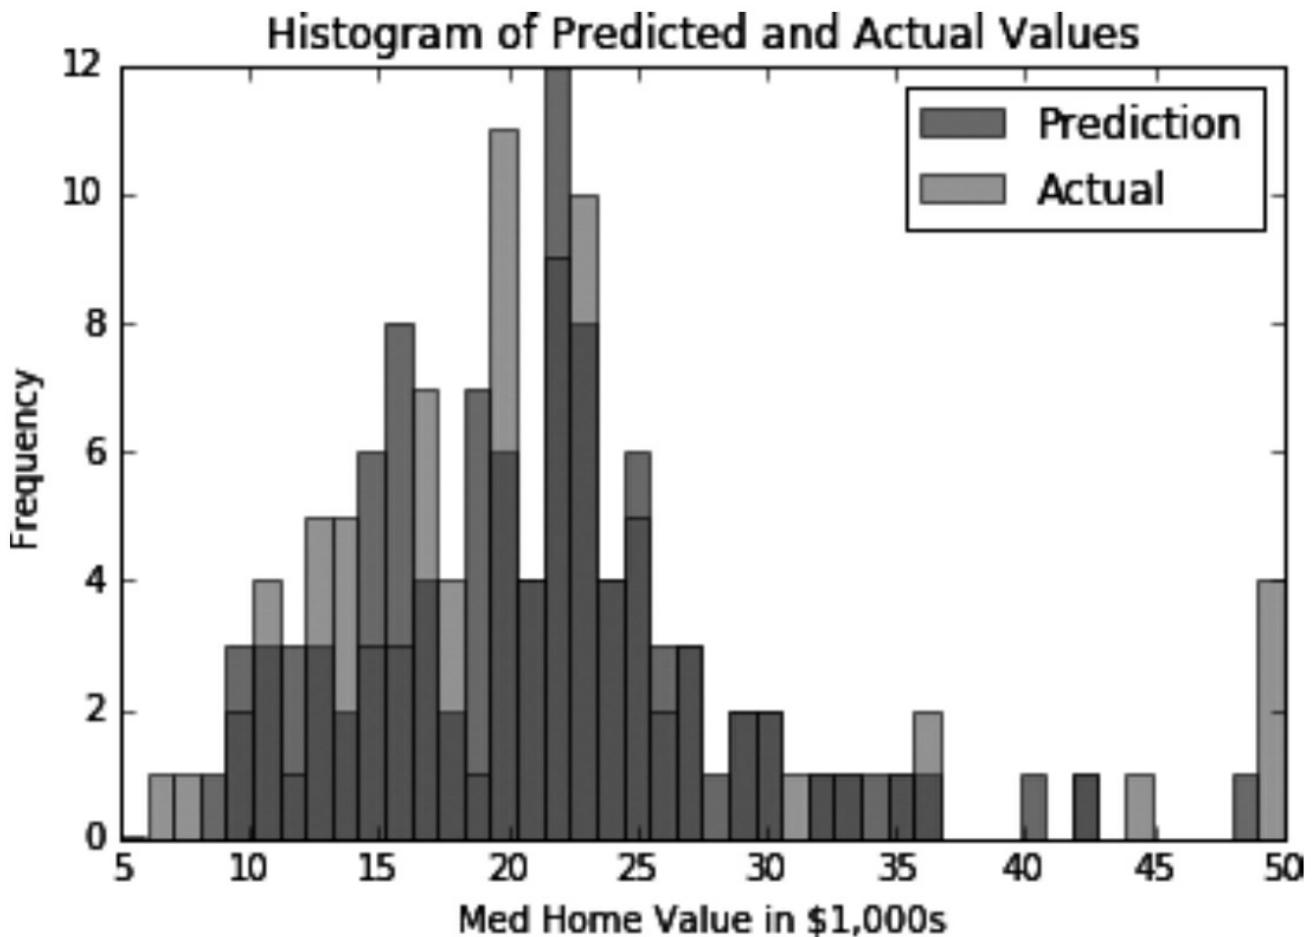


图5-1 预测值和实际值对比的直方图 (k-NN算法, 其中k=4)

11.k的取值是个难点。对于图5-1中的预测，我们选用k=4进行模型训练。选取该值的原因是，通过交叉验证，其使得MSE最低。如果使用交叉验证来选取多个k值对比，我们将看到k=4时，MSE值最小，见图5-2。同时，也值得绘制预测值随k值变化的预测方差，因为其可以显示平均更多的邻域数据点时预测方差也会减小。

5.2.3 工作原理

在最近邻域算法中，模型是训练数据集，所以在训练模型中没有任何变量训练。只有一个参数k，通过交叉验证法最小化MSE来确定。

5.2.4 延伸学习

对于k-NN算法的权重，我们选择的是距离的本身。另外也有一些其他的权重选取方法，常用平方距离的倒数作为权重。

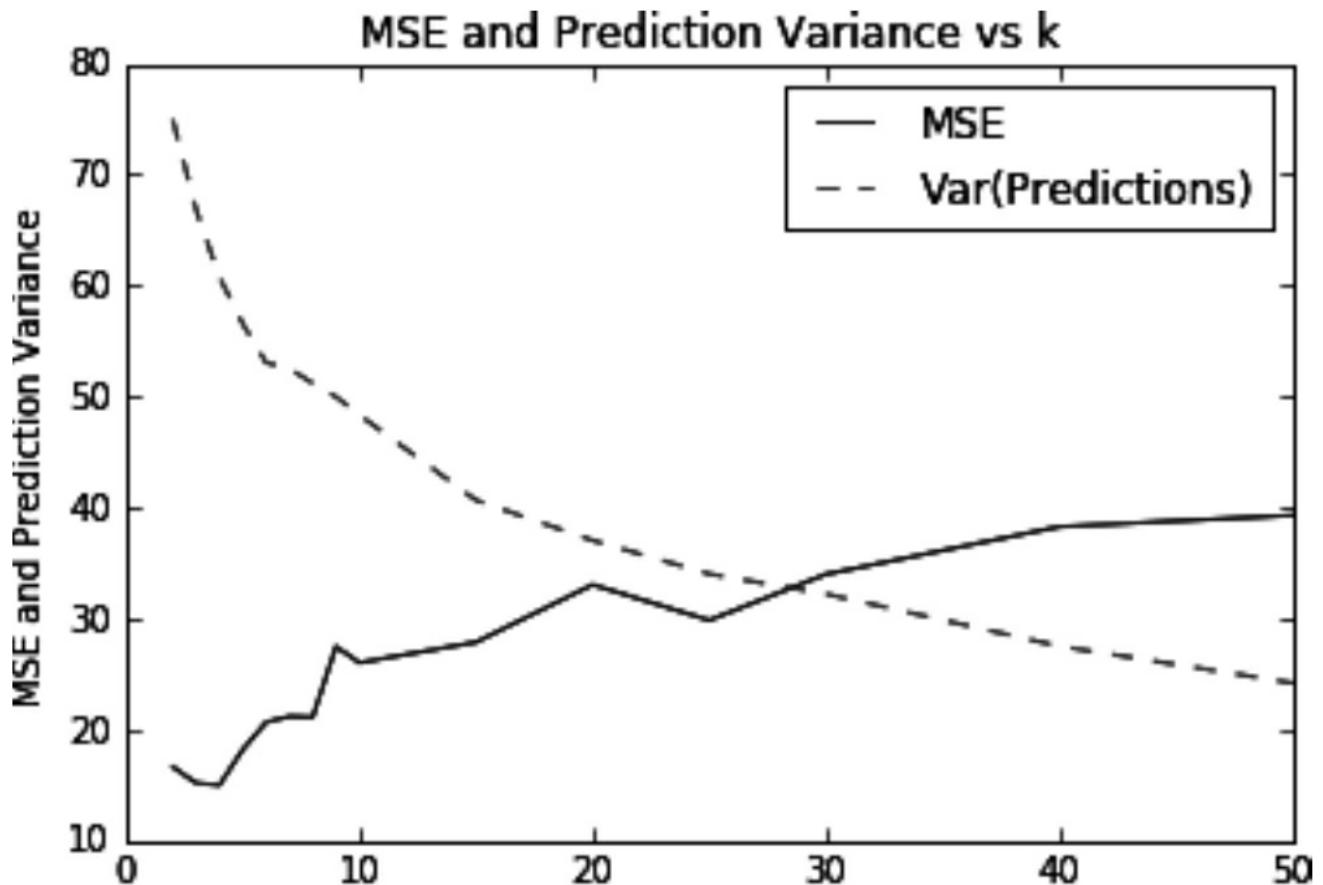


图5-2 随k值变化的k-NN预测的MSE值。我们也绘制测试集预测值的预测方差。注意，随着k值增大，
预测方差变小

5.3 如何度量文本距离

除了处理数值外，最近邻域法还广泛应用于其他领域。只要有方法来度量距离，即可应用最近邻域算法。本节将介绍如何使用TensorFlow度量文本距离。

5.3.1 开始

本节将展示如何使用TensorFlow的文本距离度量——字符串间的编辑距离（Levenshtein距离）。这将对后续章节扩展最近邻域法很有帮助。

Levenshtein距离是指由一个字符串转换成另一个字符串所需的最少编辑操作次数。允许的编辑操作包括插入一个字符，删除一个字符和将一个字符替换成另一个字符。本节将使用TensorFlow的内建函数`edit_distance()`求解Levenshtein距离。本节将展示该函数的使用，后续章节会有应用。



注意，TensorFlow的内建函数`edit_distance()`仅仅接受稀疏张量。因此，我们得把字符串转换成稀疏张量。

5.3.2 动手做

1.加载TensorFlow，初始化一个计算图会话，代码如下：

```
import tensorflow as tf
sess = tf.Session()
```

2.展示如何计算两个单词'bear'和'beer'间的编辑距离。用Python的list（）函数创建字符串list，然后将list映射为一个三维稀疏矩阵。TensorFlow的tf.SparseTensor（）函数需指定字符索引、矩阵形状和张量中的非零值。编辑距离计算时，指定normalize=False表示计算总的编辑距离；指定normalize=True表示计算归一化编辑距离，通过编辑距离除以第二个单词的长度进行归一化，代码如下：



TensorFlow文档把两个字符串处理为参考字符串（hypothesis）和真实字符串

（ground truth）。本例标记为h张量和t张量。

```
hypothesis = list('bear')
truth = list('beers')
h1 = tf.SparseTensor([[0,0,0], [0,0,1], [0,0,2], [0,0,3]],
                     hypothesis, [1,1,1])
t1 = tf.SparseTensor([[0,0,0], [0,0,1], [0,0,2], [0,0,3], [0,0,4]],
                     truth, [1,1,1])

print(sess.run(tf.edit_distance(h1, t1, normalize=False)))
```

3.编辑距离计算结果如下：

[[2.]]



TensorFlow的SparseTensorValue（）函数是创建稀疏张量的方法，要传入所需创建的稀疏张量的索引、值和形状大小。

4.下面演示比较两个单词bear和beer与另一个单词beers。为了做比较，需要重复beers使得比较的单词有相同的数据，代码如下：

```
hypothesis2 = list('bearbeer')
truth2 = list('beersbeers')
h2 = tf.SparseTensor([[0,0,0], [0,0,1], [0,0,2], [0,0,3], [0,1,0],
[0,1,1], [0,1,2], [0,1,3]], hypothesis2, [1,2,4])
t2 = tf.SparseTensor([[0,0,0], [0,0,1], [0,0,2], [0,0,3], [0,0,4],
[0,1,0], [0,1,1], [0,1,2], [0,1,3], [0,1,4]], truth2, [1,2,5])

print(sess.run(tf.edit_distance(h2, t2, normalize=True)))
```

5.结果如下：

```
[[ 0.4000001  0.2      ]]
```

6.下面介绍一个例子，讲解另外一种更有效地比较一个单词集合与单个单词的方法。事先为参考字符串（hypothesis）和真实字符串（ground）创建索引和字符列表，代码如下：

```
hypothesis_words = ['bear', 'bar', 'tensor', 'flow']
truth_word = ['beers']

num_h_words = len(hypothesis_words)
h_indices = [[xi, 0, yi] for xi, x in enumerate(hypothesis_words)
for yi, y in enumerate(x)]
h_chars = list(''.join(hypothesis_words))
h3 = tf.SparseTensor(h_indices, h_chars, [num_h_words, 1, 1])
truth_word_vec = truth_word * num_h_words
t_indices = [[xi, 0, yi] for xi, x in enumerate(truth_word_vec) for
yi, y in enumerate(x)]
t_chars = list(''.join(truth_word_vec))
t3 = tf.SparseTensor(t_indices, t_chars, [num_h_words, 1, 1])

print(sess.run(tf.edit_distance(h3, t3, normalize=True)))
```

7.结果如下：

```
[ [ 0.40000001]
[ 0.60000002]
[ 0.80000001]
[ 1. ]]
```

8. 展示如何用占位符来计算两个单词列表间的编辑距离。基本思路是一样的，不同的是现在用 SparseTensorValue() 替代先前的稀疏张量。首先，创建一个函数，该函数根据单词列表，输出稀疏张量，代码如下：

```
def create_sparse_vec(word_list):
    num_words = len(word_list)
    indices = [[xi, 0, yi] for xi,x in enumerate(word_list) for yi,y in enumerate(x)]
    chars = list(''.join(word_list))
    return(tf.SparseTensorValue(indices, chars, [num_words,1,1]))
```



```
hyp_string_sparse = create_sparse_vec(hypothesis_words)
truth_string_sparse = create_sparse_vec(truth_word*len(hypothesis_words))
```



```
hyp_input = tf.sparse_placeholder(dtype=tf.string)
truth_input = tf.sparse_placeholder(dtype=tf.string)
```



```
edit_distances = tf.edit_distance(hyp_input, truth_input,
normalize=True)
```



```
feed_dict = {hyp_input: hyp_string_sparse,
            truth_input: truth_string_sparse}
```



```
print(sess.run(edit_distances, feed_dict=feed_dict))
```

9. 输出结果如下：

```
[ [ 0.40000001]
[ 0.60000002]
[ 0.80000001]
[ 1. ]]
```

5.3.3 工作原理

本节展示了使用TensorFlow计算文本距离的几种方法。这对文本特征数据进行最近邻域法训练非常有帮助。本章后续的地址匹配应用中也会用到这些方法。

5.3.4 延伸学习

这里讨论一下文本距离的度量方式，下面是各种文本距离的定义，假设字符串s1和s2。

名 称	描 述	公 式
汉明距离 (Hamming distance)	两个等长字符串中对应位置的不同字符的个数	$D(s_1, s_2) = \sum_i I_i$, 其中 I 是等长字符串的指示函数
余弦距离 (Cosine distance)	不同 k-gram 的点积除以不同 k-gram 的 L2 范数	$D(s_1, s_2) = 1 - \frac{k(s_1) \cdot k(s_2)}{\ k(s_1)\ \ k(s_2)\ }$
Jaccard 距离 (Jaccard distance)	两个字符串中相同字符数除以所有字符数	$D(s_1, s_2) = \frac{ s_1 \cap s_2 }{ s_1 \cup s_2 }$

5.4 用TensorFlow实现混合距离计算

当处理的数据观测点有多种特征时，我们应该意识到不同的特征应该用不同的归一化方式来缩放。本节将用此思路来优化房价预测值。

5.4.1 开始

扩展最近邻域法进行多维度缩放。在本例中，我们将展示如何扩展多变量的距离函数。特别地，我们将扩展距离函数为特征变量的函数。

加权距离函数的关键是使用加权权重矩阵。包含矩阵操作的距离函数的表达式如下：

$$D(x, y) = \sqrt{(x - y)^T A (x - y)}$$

其中，A是对角权重矩阵。

在本节中，我们将试着优化波士顿房价数据集的MSE。该数据集的特征维度不同，所以缩放后的距离函数对最近邻域法有利。

5.4.2 动手做

1. 导入必要的编程库，创建一个计算图会话，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
import requests
sess = tf.Session()
```

2. 加载数据集，存储为numpy数组。再次提醒，我们只使用某些列来预测，不使用id变量或者方差非常小的变量，代码如下：

```
housing_url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/housing/housing.data'
housing_header = ['CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX', 'PTRATIO', 'B', 'LSTAT', 'MEDV']
cols_used = ['CRIM', 'INDUS', 'NOX', 'RM', 'AGE', 'DIS', 'TAX', 'PTRATIO', 'B', 'LSTAT']
num_features = len(cols_used)
housing_file = requests.get(housing_url)
housing_data = [[float(x) for x in y.split(' ') if len(x)>=1] for y in housing_file.text.split('\n') if len(y)>=1]
y_vals = np.transpose([np.array([y[13] for y in housing_data])])
x_vals = np.array([[x for i,x in enumerate(y) if housing_header[i] in cols_used] for y in housing_data])
```

3. 用min-max缩放法缩放x_vals值到0和1之间，代码如下：

```
x_vals = (x_vals - x_vals.min(0)) / x_vals.ptp(0)
```

4. 创建对角权重矩阵，该矩阵提供归一化的距离度量，其值为特征的标准差，代码如下：

```
weight_diagonal = x_vals.std(0)
weight_matrix = tf.cast(tf.diag(weight_diagonal), dtype=tf.float32)
```

5. 分割数据集为训练集和测试集。声明k值，该值为最近邻域的数量。设置批量大小为测试集大小，代码如下：

```

train_indices = np.random.choice(len(x_vals), round(len(x_vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]
k = 4
batch_size=len(x_vals_test)

```

6. 声明所需的占位符。占位符有四个，分别是训练集和测试集的x值输入和y目标输入，代码如下：

```

x_data_train = tf.placeholder(shape=[None, num_features], dtype=tf.float32)
x_data_test = tf.placeholder(shape=[None, num_features], dtype=tf.float32)
y_target_train = tf.placeholder(shape=[None, 1], dtype=tf.float32)
y_target_test = tf.placeholder(shape=[None, 1], dtype=tf.float32)

```

7. 声明距离函数。为了使可读性更好，我们将距离函数分解。注意，本例需要tf.tile函数为权重矩阵指定batch_size维度扩展。使用batch_matmul()函数进行批量矩阵乘法，代码如下：

```

subtraction_term = tf.sub(x_data_train, tf.expand_dims(x_data_test, 1))
first_product = tf.batch_matmul(subtraction_term, tf.tile(tf.expand_dims(weight_matrix, 0), [batch_size, 1, 1]))
second_product = tf.batch_matmul(first_product,
tf.transpose(subtraction_term, perm=[0, 2, 1]))
distance = tf.sqrt(tf.batch_matrix_diag_part(second_product))

```

8. 计算完每个测试数据点的距离，需要返回k-NN法的前k个最近邻域（使用tf.nn.top_k()函数）。因为tf.nn.top_k()函数返回最大值，而我们需要的是最小距离，所以转换成返回距离负值的最大值。然后将前k个最近邻域的距离进行加权平均做预测，代码如下：

```

top_k_xvals, top_k_indices = tf.nn.top_k(tf.neg(distance), k=k)
x_sums = tf.expand_dims(tf.reduce_sum(top_k_xvals, 1), 1)
x_sums_repeated = tf.matmul(x_sums, tf.ones([1, k], tf.float32))
x_val_weights = tf.expand_dims(tf.div(top_k_xvals, x_sums_repeated), 1)
top_k_yvals = tf.gather(y_target_train, top_k_indices)
prediction = tf.squeeze(tf.batch_matmul(x_val_weights, top_k_yvals), squeeze_dims=[1])

```

9.计算预测值的MSE，评估训练模型，代码如下：

```
mse = tf.div(tf.reduce_sum(tf.square(tf.sub(prediction, y_target_test))), batch_size)
```

10.遍历迭代训练批量测试数据，每次迭代计算其MSE，代码如下：

```
num_loops = int(np.ceil(len(x_vals_test)/batch_size))
for i in range(num_loops):
    min_index = i*batch_size
    max_index = min((i+1)*batch_size, len(x_vals_train))
    x_batch = x_vals_test[min_index:max_index]
    y_batch = y_vals_test[min_index:max_index]
    predictions = sess.run(prediction, feed_dict={x_data_train: x_vals_train, x_data_test: x_batch, y_target_train: y_vals_train, y_target_test: y_batch})
    batch_mse = sess.run(mse, feed_dict={x_data_train: x_vals_train, x_data_test: x_batch, y_target_train: y_vals_train, y_target_test: y_batch})
    print('Batch #' + str(i+1) + ' MSE: ' + str(np.round(batch_mse, 3)))
```

11.输出结果如下：

Batch #1 MSE: 21.322

12.为了最终对比，我们绘制测试数据集的房价分布和测试集上的预测值的分布（见图5-3），代码如

下：

```
bins = np.linspace(5, 50, 45)
plt.hist(predictions, bins, alpha=0.5, label='Prediction')
plt.hist(y_batch, bins, alpha=0.5, label='Actual')

plt.title('Histogram of Predicted and Actual Values')
plt.xlabel('Med Home Value in $1,000s')
plt.ylabel('Frequency')
plt.legend(loc='upper right')
plt.show()
```

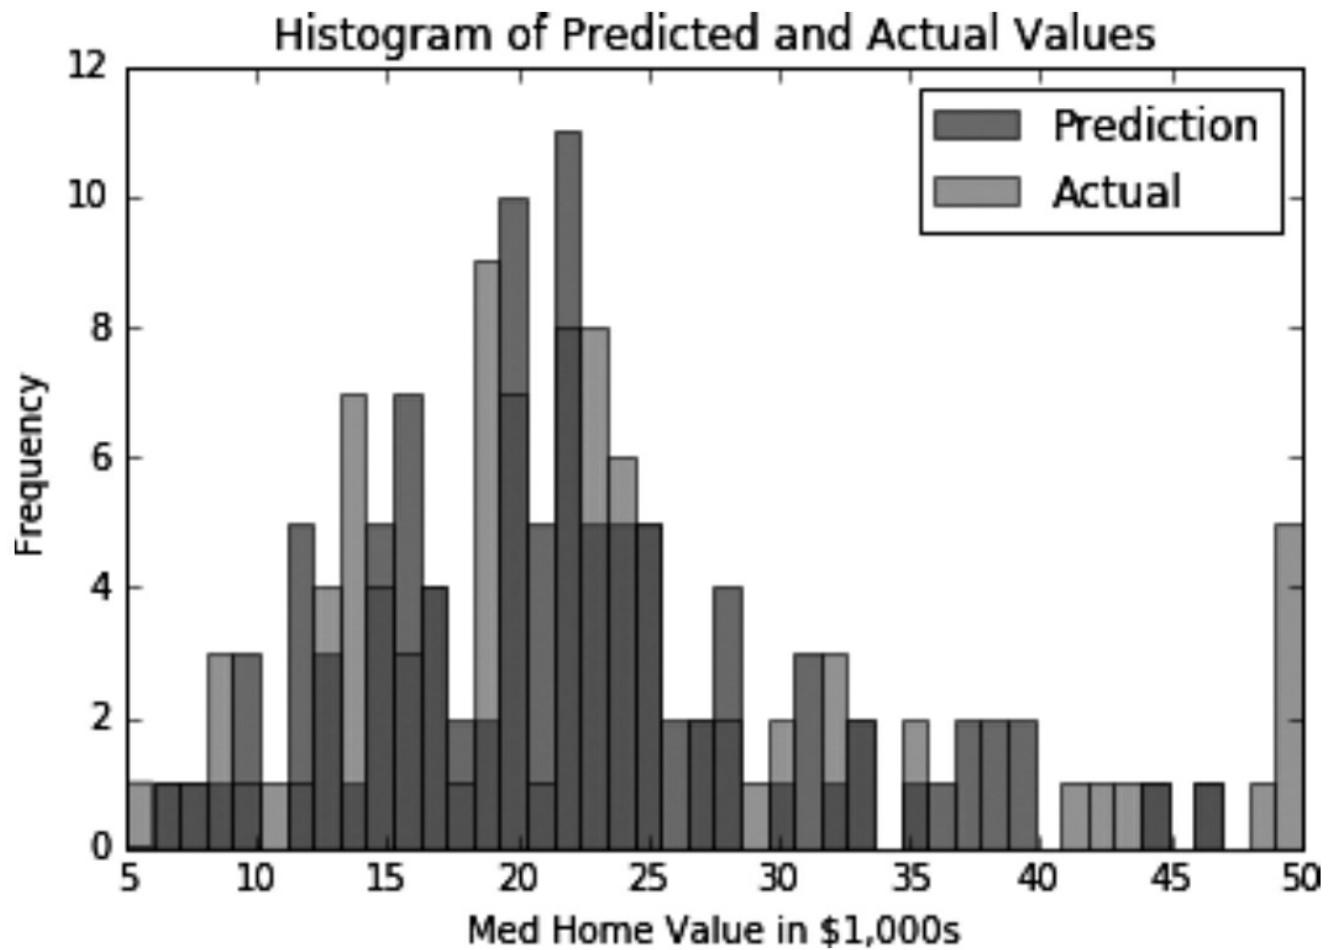


图5-3 波士顿房价的预测值和实际值的分布直方图。本图中对特征进行了距离缩放

5.4.3 工作原理

通过对特征的距离进行缩放，减小测试数据集的MSE。本例中使用的是特征的标准差因子来缩放距离函数，并且对top k邻域进行加权平均作为距离函数来进行房价预测。

5.4.4 延伸学习

缩放因子可以加强或者减弱最近邻域距离计算中特征的权重，这更符合实际特征的作用。

5.5 用TensorFlow实现地址匹配

学完数值距离和文本距离，现在我们将花点时间结合两者来度量既包含文本特征又包含数值特征的数据观测点间的距离。

5.5.1 开始

最近邻域算法应用在地址匹配上是非常有效的。地址匹配是一种记录匹配，其匹配的地址涉及多个数据集。在地址匹配中，地址中有许多打印错误，不同的城市或者不同的邮政编码，但是指向同一个地址。使用最近邻域算法综合地址信息的数值部分和字符部分可以帮助鉴定实际相同的地址。

本例将生成两个模拟数据集，每个数据集包含街道地址和邮政编码。其中，有一个数据集的街道地址有大量的打印错误。我们将准确的地址数据集作为“金标准”，为每个有打印错误的地址返回一个最接近的地址，采用综合字符距离（街道）和数值距离（邮政编码）的距离函数度量地址间的相似程度。

代码的第一部分是生成模拟数据集。第二部分是训练测试数据集，从训练数据集中返回最接近的地址。

5.5.2 动手做

1.先导入必要的编程库，代码如下：

```
import random
import string
import numpy as np
import tensorflow as tf
```

2.创建参考数据集。为了显示简洁的输出，每个数据集仅仅由10个地址组成，不过更多数据量也适用，代码如下：

```
n = 10
street_names = ['abbey', 'baker', 'canal', 'donner', 'elm']
street_types = ['rd', 'st', 'ln', 'pass', 'ave']
rand_zips = [random.randint(65000,65999) for i in range(5)]
numbers = [random.randint(1, 9999) for i in range(n)]
streets = [random.choice(street_names) for i in range(n)]
street_suffs = [random.choice(street_types) for i in range(n)]
zips = [random.choice(rand_zips) for i in range(n)]
full_streets = [str(x) + ' ' + y + ' ' + z for x,y,z in
zip(numbers, streets, street_suffs)]
reference_data = [list(x) for x in zip(full_streets,zips)]
```

3.为了创建一个测试数据集，我们需要一个随机创建“打印错误”的字符串函数，然后返回结果字符串，代码如下：

```
def create_typo(s, prob=0.75):
    if random.uniform(0,1) < prob:
        rand_ind = random.choice(range(len(s)))
        s_list = list(s)
        s_list[rand_ind]=random.choice(string.ascii_lowercase)
        s = ''.join(s_list)
    return(s)

typo_streets = [create_typo(x) for x in streets]
typo_full_streets = [str(x) + ' ' + y + ' ' + z for x,y,z in
zip(numbers, typo_streets, street_suffs)]
test_data = [list(x) for x in zip(typo_full_streets,zips)]
```

4. 初始化一个计算图会话，声明所需的占位符。本例需要四个占位符，每个测试集和参考集需一个地址和邮政编码占位符，代码如下：

```
sess = tf.Session()
test_address = tf.sparse_placeholder(dtype=tf.string)
test_zip = tf.placeholder(shape=[None, 1], dtype=tf.float32)
ref_address = tf.sparse_placeholder(dtype=tf.string)
ref_zip = tf.placeholder(shape=[None, n], dtype=tf.float32)
```

5. 声明数值的邮政编码距离和地址字符串的编辑距离，代码如下：

```
zip_dist = tf.square(tf.sub(ref_zip, test_zip))
address_dist = tf.edit_distance(test_address, ref_address,
normalize=True)
```

6. 把邮政编码距离和地址距离转换成相似度。当两个输入完全一致时该相似度为1；当它们完全不一致时为0。对于邮政编码相似度，其计算方式为：最大邮政编码减去该邮政编码，然后除以邮政编码范围（即最大邮政编码减去最小邮政编码的差值）。对于地址相似度，其值已经是0到1之间的值，所以直接用1减去其编辑距离大小，代码如下：

```
zip_max = tf.gather(tf.squeeze(zip_dist), tf.argmax(zip_dist, 1))
zip_min = tf.gather(tf.squeeze(zip_dist), tf.argmin(zip_dist, 1))
zip_sim = tf.div(tf.sub(zip_max, zip_dist), tf.sub(zip_max, zip_min))
address_sim = tf.sub(1., address_dist)
```

7. 结合上面两个相似度函数，并对其进行加权平均。在本例中，地址和邮政编码的权重设为相等（即，各为0.5），但我们也可以根据每个特征的信誉度来调整权重，然后返回参考集最大相似度的索引，代码如下：

```
address_weight = 0.5
zip_weight = 1. - address_weight
weighted_sim = tf.add(tf.transpose(tf.mul(address_weight, address_sim)), tf.mul(zip_weight, zip_sim))
top_match_index = tf.argmax(weighted_sim, 1)
```

8. 为了在TensorFlow中使用编辑距离，我们必须把地址字符串转换成稀疏向量。在本章前面的小节中，我们创建过下面的函数来进行稀疏矩阵的转换，代码如下：

```

def sparse_from_word_vec(word_vec):
    num_words = len(word_vec)
    indices = [[xi, 0, yi] for xi,x in enumerate(word_vec) for
yi,y in enumerate(x)]
    chars = list(''.join(word_vec))
    # Now we return our sparse vector
    return(tf.SparseTensorValue(indices, chars, [num_words,1,1]))

```

9. 分离参考集中的地址和邮政编码，然后在遍历迭代训练中为占位符赋值，代码如下：

```

reference_addresses = [x[0] for x in reference_data]
reference_zips = np.array([[x[1] for x in reference_data]])

```

10. 利用步骤8中创建的函数将参考地址转换为稀疏矩阵，代码如下：

```
sparse_ref_set = sparse_from_word_vec(reference_addresses)
```

11. 遍历循环测试集的每项，返回参考集中最接近项的索引，打印出测试集和参考集的每项。正如下面所看到的，模拟数据集训练的结果不错，代码如下：

```

for i in range(n):
    test_address_entry = test_data[i][0]
    test_zip_entry = [[test_data[i][1]]]

    # Create sparse address vectors
    test_address_repeated = [test_address_entry] * n
    sparse_test_set = sparse_from_word_vec(test_address_repeated)

    feeddict={test_address: sparse_test_set,
              test_zip: test_zip_entry,
              ref_address: sparse_ref_set,
              ref_zip: reference_zips}

    best_match = sess.run(top_match_index, feed_dict=feeddict)
    best_street = reference_addresses[best_match]
    [best_zip] = reference_zips[0][best_match]
    [[test_zip_]] = test_zip_entry
    print('Address: ' + str(test_address_entry) + ', ' +
str(test_zip_))
    print('Match : ' + str(best_street) + ', ' + str(best_
zip))

```

12. 输出结果如下：

Address: 8659 beker ln, 65463
Match : 8659 baker ln, 65463
Address: 1048 eanal ln, 65681
Match : 1048 canal ln, 65681
Address: 1756 vaker st, 65983
Match : 1756 baker st, 65983
Address: 900 abbjy pass, 65983
Match : 900 abbey pass, 65983
Address: 5025 canal rd, 65463
Match : 5025 canal rd, 65463
Address: 6814 elh st, 65154
Match : 6814 elm st, 65154
Address: 3057 cagal ave, 65463
Match : 3057 canal ave, 65463
Address: 7776 iaker ln, 65681
Match : 7776 baker ln, 65681
Address: 5167 caker rd, 65154
Match : 5167 baker rd, 65154
Address: 8765 donnor st, 65154
Match : 8765 donner st, 65154

5.5.3 工作原理

解决地址匹配问题时会遇到很多困难，比如，权重大小和如何归一化距离，这些都得根据实际数据选择解决方法。可能处理地址的方法与刚才的方法不同。比如，把街道地址细化成省市、城市、街道地址和街道号码。处理数值地址部分时，我们可以将其看成数字（数值距离）或者字符（编辑距离），这都取决于如何选择。注意，如果考虑人为输入或者电脑输入错误，我们也可以用编辑距离函数来处理邮政编码。

为了感受“打印错误”对结果的影响，我们鼓励读者去调整“打印错误”的字符串函数来增加“打印错误”的数量或者错误出现的频率，增加数据样本集的大小来查看算法的效果。

5.6 用TensorFlow实现图像识别

5.6.1 开始

最近邻域算法也常用于图像识别。图像识别届的“Hello World”数据集是MNIST手写数字样本数据集。后续的章节会使用该数据集进行各种神经网络图像识别算法训练，这也和非神经网络算法的结果进行对比。

MNIST手写数字样本数据集由上万张 28×28 像素、已标注的图片组成。虽然该数据集不大，但是其包含有784个特征可供最近邻域算法训练。我们将计算这类分类问题的最近邻域预测，选用最近k邻域（本例中， $k=4$ ）模型。

5.6.2 动手做

1. 导入必要的编程库。注意，导入PIL（Python Image Library）模块绘制预测输出结果。TensorFlow中有内建的函数加载MNIST手写数字样本数据集，代码如下：

```
import random
import numpy as np
import tensorflow as tf
import matplotlib.pyplot as plt
from PIL import Image
from tensorflow.examples.tutorials.mnist import input_data
```

2. 创建一个计算图会话，加载MNIST手写数字数据集，并指定one-hot编码，代码如下：

```
sess = tf.Session()
mnist = input_data.read_data_sets("MNIST_data/", one_hot=True)
```



one-hot编码是分类类别的数值化，这样更有利于后续的数值计算。本例包含10个类别（数字0到9），采用长度为10的0-1向量表示。例如，类别“0”表示为向量：1, 0, 0, 0, 0, 0, 0, 0, 0, 0，类别“1”表示为向量：0, 1, 0, 0, 0, 0, 0, 0, 0, 0，等等。

3. 由于MNIST手写数字数据集较大，直接计算成千上万个输入的784个特征之间的距离是比较困难的，所以本例会抽样成小数据集进行训练。对测试集也进行抽样处理，为了后续绘图方便，选择测试集数量可以被6整除。我们将绘制最后批次的6张图片来查看效果，代码如下：

```
train_size = 1000
test_size = 102
rand_train_indices = np.random.choice(len(mnist.train.images),
train_size, replace=False)
rand_test_indices = np.random.choice(len(mnist.test.images), test_
size, replace=False)
x_vals_train = mnist.train.images[rand_train_indices]
x_vals_test = mnist.test.images[rand_test_indices]
y_vals_train = mnist.train.labels[rand_train_indices]
y_vals_test = mnist.test.labels[rand_test_indices]
```

4. 声明k值和批量大小：

```
k = 4  
batch_size=6
```

5.现在在计算图中开始初始化占位符，并赋值，代码如下：

```
x_data_train = tf.placeholder(shape=[None, 784], dtype=tf.float32)  
x_data_test = tf.placeholder(shape=[None, 784], dtype=tf.float32)  
y_target_train = tf.placeholder(shape=[None, 10], dtype=tf.  
float32)  
y_target_test = tf.placeholder(shape=[None, 10], dtype=tf.float32)
```

6.声明距离度量函数。本例使用L1范数（即绝对值）作为距离函数，代码如下：

```
distance = tf.reduce_sum(tf.abs(tf.sub(x_data_train, tf.expand_  
dims(x_data_test, 1))), reduction_indices=2)
```



注意，我们也可以把距离函数定义为L2范数。对应的代码为：

```
distance=tf.sqrt (tf.reduce_sum (tf.square (tf.sub (x_data_train, tf.expand_dims (x_data_test, 1) ) ) ,  
reduction_indices=1) )。
```

7.找到最接近的top k图片和预测模型。在数据集的one-hot编码索引上进行预测模型计算，然后统计发生的数据量，代码如下：

```
top_k_xvals, top_k_indices = tf.nn.top_k(tf.neg(distance), k=k)  
prediction_indices = tf.gather(y_target_train, top_k_indices)  
count_of_predictions = tf.reduce_sum(prediction_indices,  
reduction_indices=1)  
prediction = tf.argmax(count_of_predictions, dimension=1)
```

8.在测试集上遍历迭代运行，计算预测值，并将结果存储，代码如下：

```
num_loops = int(np.ceil(len(x_vals_test)/batch_size))  
test_output = []  
actual_vals = []  
for i in range(num_loops):
```

```

min_index = i*batch_size
max_index = min((i+1)*batch_size, len(x_vals_train))
x_batch = x_vals_test[min_index:max_index]
y_batch = y_vals_test[min_index:max_index]
predictions = sess.run(prediction, feed_dict={x_data_train: x_vals_train, x_data_test: x_batch,
                                              y_target_train: y_vals_train, y_target_test: y_batch})
test_output.extend(predictions)
actual_vals.extend(np.argmax(y_batch, axis=1))

```

9.现在已经保存了实际值和预测返回值，下面计算模型训练准确度。不过该结果会因为测试数据集和训练数据集的随机抽样而变化，但是其准确度约为80%~90%，代码如下：

```

accuracy = sum([1./test_size for i in range(test_size) if test_output[i]==actual_vals[i]])
print('Accuracy on test set: ' + str(accuracy))
Accuracy on test set: 0.833333333333325

```

10.绘制最后批次的计算结果（见图5-4），代码如下：

```

actuals = np.argmax(y_batch, axis=1)
Nrows = 2
Ncols = 3
for i in range(len(actuals)):
    plt.subplot(Nrows, Ncols, i+1)
    plt.imshow(np.reshape(x_batch[i], [28,28]), cmap='Greys_r')
    plt.title('Actual: ' + str(actuals[i]) + ' Pred: ' +
str(predictions[i]), fontsize=10)
    frame = plt.gca()
    frame.axes.get_xaxis().set_visible(False)
    frame.axes.get_yaxis().set_visible(False)

```

Actual: 7 Pred: 7



Actual: 9 Pred: 7



Actual: 3 Pred: 5



Actual: 4 Pred: 4



Actual: 5 Pred: 5



Actual: 4 Pred: 4



图5-4 最近邻域算法预测的最后批次的六张图片。我们能看到，并不是每张图片都获得到正确的结果

5.6.3 工作原理

假设有足够的计算时间和计算资源，我们能让训练数据集和测试数据集足够大。该方法可以增加准确度，也是预防过拟合的最普通的方法之一。并且最近邻域算法说明了理想的k值需进一步选择，k值的选择一般通过在数据集上进行交叉验证获得。

5.6.4 延伸学习

我们也能使用最近邻域算法评估用户书写的数字，具体见代码仓库
(https://github.com/nfmcclure/tensorflow_cookbook)。

本章讨论了如何使用kNN算法进行回归训练和分类。也列举了各种距离函数的使用方法，以及如何混合使用各种函数。我们鼓励读者开发更多不同的距离度量函数、权重和k值来提高算法的准确度。

第6章 神经网络算法

在本章中，我们将介绍神经网络算法及其在TensorFlow中的实现。后续大部分章节会基于神经网络算法，所以学习如何在TensorFlow中实现神经网络算法非常重要。我们将从介绍神经网络的基本概念讲起，之后介绍多层神经网络算法，在最后一节，将创建一个神经网络来学习井字棋。

通过本章的学习，你将掌握以下知识点：

- 实现门函数
- 使用门函数和激励函数
- TensorFlow实现单层神经网络
- TensorFlow实现神经网络常见层
- 使用多层神经网络
- 线性预测模型的优化
- TensorFlow基于神经网络实现井字棋

读者可以在代码仓库（https://github.com/nfmccleure/tensorflow_cookbook）获取本章的所有代码。

6.1 神经网络算法基础

神经网络算法在识别图像和语音、识别手写、理解文本、图像分割、对话系统、自动驾驶等领域不断打破纪录。上述这些应用将在后续章节中讲解，神经网络算法是一种简单易实现的、很重要的机器学习算法。

神经网络算法的概念已出现几十年，但是它仅仅在最近由于计算能力（计算处理、算法效率和数据集大小）的提升能训练大规模网络才获得新的发展。

神经网络算法是对输入数据矩阵进行一系列的基本操作。这些操作通常包括非线性函数的加法和乘法，在3.9节中有所使用。逻辑回归算法是斜率与特征点积求和后进行非线性sigmoid函数计算。神经网络算法表达形式更通用，允许任意形式的基本操作和非线性函数的结合，包括绝对值、最大值、最小值等。

神经网络算法的一个重要的“黑科技”是“反向传播”。反向传播是一种基于学习率和损失函数返回值来更新模型变量的过程。我们在第3章和第4章中使用反向传播方法来更新模型变量。

神经网络算法另外一个重要的特性是非线性激励函数。因为大部分神经网络算法仅仅是加法操作和乘法操作的结合，所以它们不能进行非线性数据样本集的模型训练。为了解决该问题，我们在神经网络算法中使用非线性激励函数，这将使得神经网络算法能够解决大部分非线性的问题。

记住，如前面见过的大部分算法，神经网络算法对所选择的超参数是敏感的。在本章中，我们将看到不同的学习率、损失函数和优化对模型训练的影响。

这里有一些神经网络算法的深入学习资料。

关于反向传播的文章“Efficient BackProp”，Yann LeCun等著，PDF版地址：<http://yann.lecun.com/exdb/publis/pdf/lecun-98b.pdf>。

斯坦福大学课程CS231，《Convolutional Neural Networks for Visual Recognition》，课件地址：<http://cs231n.stanford.edu/>。

斯坦福大学课程CS224d，《Deep Learning for Natural Language Processing》，课件地址：<http://cs224d.stanford.edu/>。

MIT出版的《Deep Learning》，Goodfellow等著，地址：<http://www.deeplearningbook.org>。

在线书籍《Neural Networks and Deep Learning》，Michael Nielsen著，地址：<http://neuralnetworksanddeeplearning.com/>。

Andrej Karpathy用程序的方式介绍神经网络算法，其JavaScript例子称为“A Hacker's Guide to Neural Networks”，地址：<http://karpathy.github.io/neuralnets/>。

Ian Goodfellow、Yoshua Bengio和Aaron Courville总结的深度学习笔记《Deep Learning for Beginners》，地址：<http://randomkek.github.io/deep/deeplearning.html>。

6.2 用TensorFlow实现门函数

神经网络算法的基本概念之一是门操作。本节以乘法操作作为门操作开始，接着介绍嵌套的门操作。

6.2.1 开始

第一个实现的操作门是 $f(x) = a \cdot x$ 。为了优化该门操作，我们声明a输入作为变量，x输入作为占位符。这意味着TensorFlow将改变a的值，而不是x的值。我们将创建损失函数，度量输出结果和目标值之间的差值，这里的目标值是50。

第二个实现的嵌套操作门是 $f(x) = a \cdot x + b$ 。我们声明a和b为变量，x为占位符。向目标值50优化输出结果。有趣的是第二个例子的解决方法不是唯一的。许多模型变量的组合使得输出结果为50。在神经网络算法中，我们不太关心模型变量的中间值，而把关注点放在预期的输出结果上。

想象一下，计算图中的操作门，图6-1是上述两个例子的门操作的描述。

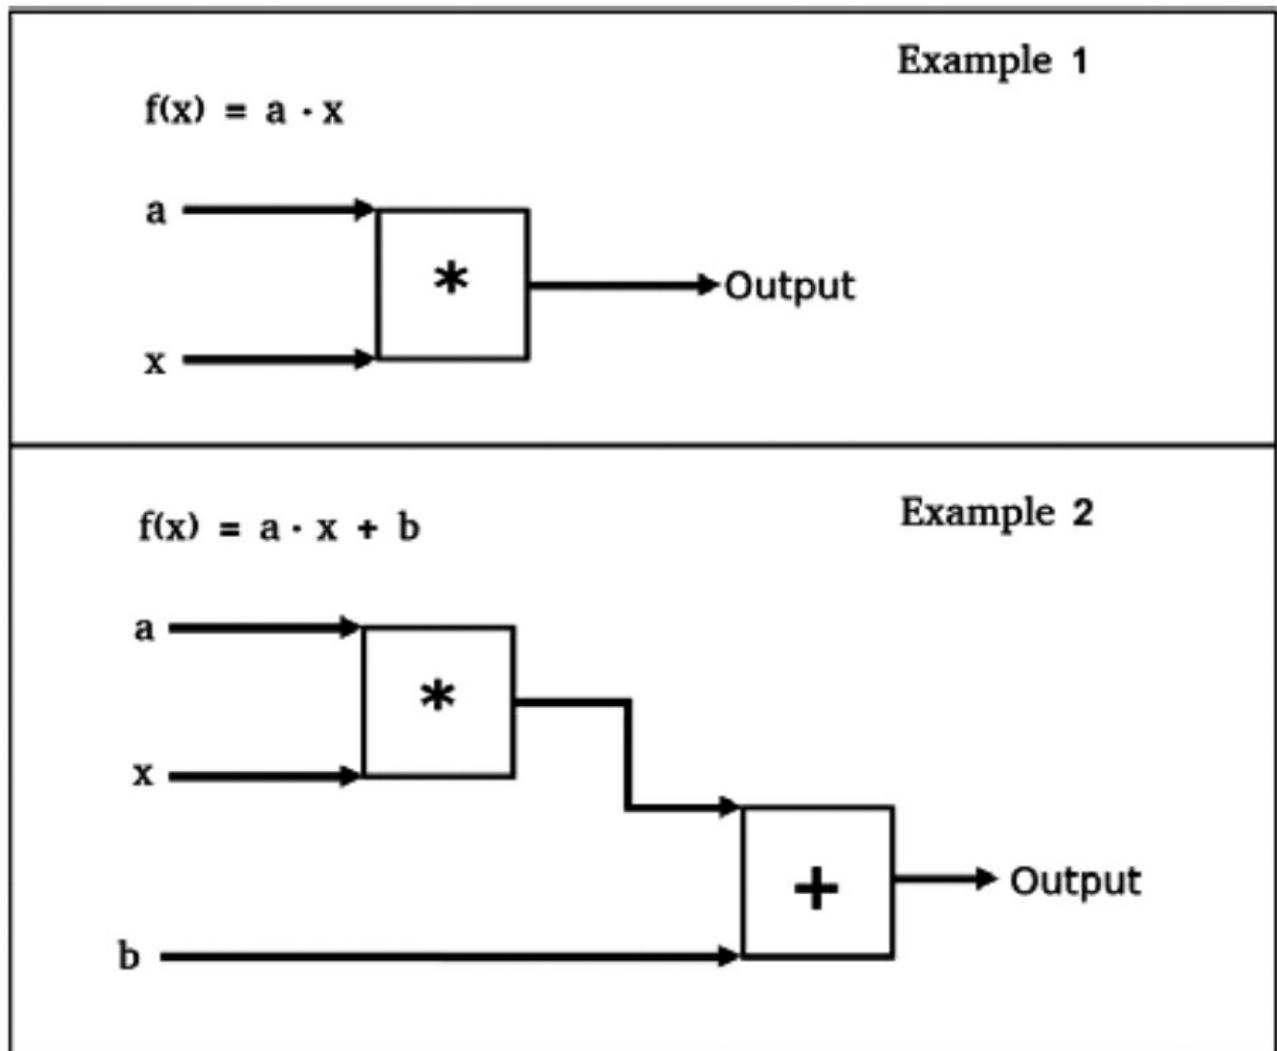


图6-1 两个操作门

6.2.2 动手做

为了在TensorFlow中实现第一个门操作 $f(x) = a \cdot x$ ，并训练输出结果50，具体的步骤如下。

1.加载TensorFlow模块，创建一个计算图会话，代码如下：

```
import tensorflow as tf
sess = tf.Session()
```

2.声明模型变量、输入数据集和占位符。本例输入数据为5，所以乘法因子为10，可以得到50的预期值（ $5 \times 10 = 50$ ），代码如下：

```
a = tf.Variable(tf.constant(4.))
x_val = 5.
x_data = tf.placeholder(dtype=tf.float32)
```

3.增加操作到计算图中，代码如下：

```
multiplication = tf.mul(a, x_data)
```

4.声明损失函数：输出结果与预期目标值（50）之间的L2距离函数，代码如下：

```
loss = tf.square(tf.sub(multiplication, 50.))
```

5.初始化模型变量，声明标准梯度下降优化算法，代码如下：

```
init = tf.initialize_all_variables()
sess.run(init)
my_opt = tf.train.GradientDescentOptimizer(0.01)
train_step = my_opt.minimize(loss)
```

6.优化模型输出结果。连续输入值5，反向传播损失函数来更新模型变量以达到值10，代码如下：

```
print('Optimizing a Multiplication Gate Output to 50.')
for i in range(10):
    sess.run(train_step, feed_dict={x_data: x_val})
    a_val = sess.run(a)
    mult_output = sess.run(multiplication, feed_dict={x_data: x_val})
    print(str(a_val) + ' * ' + str(x_val) + ' = ' + str(mult_output))
```

7.输出结果如下：

```
Optimizing a Multiplication Gate Output to 50.  
7.0 * 5.0 = 35.0  
8.5 * 5.0 = 42.5  
9.25 * 5.0 = 46.25  
9.625 * 5.0 = 48.125  
9.8125 * 5.0 = 49.0625  
9.90625 * 5.0 = 49.5312  
9.95312 * 5.0 = 49.7656  
9.97656 * 5.0 = 49.8828  
9.98828 * 5.0 = 49.9414  
9.99414 * 5.0 = 49.9707
```

8.对两个嵌套操作的例子 $f(x) = a \cdot x + b$, 也执行上述相同的步骤。

9.开始第二个例子，不同在于本例中包含两个模型变量：a和b，代码如下：

```
from tensorflow.python.framework import ops  
ops.reset_default_graph()  
sess = tf.Session()  
  
a = tf.Variable(tf.constant(1.))  
b = tf.Variable(tf.constant(1.))  
x_val = 5.  
x_data = tf.placeholder(dtype=tf.float32)  
  
two_gate = tf.add(tf.mul(a, x_data), b)  
  
loss = tf.square(tf.sub(two_gate, 50.))  
  
my_opt = tf.train.GradientDescentOptimizer(0.01)  
train_step = my_opt.minimize(loss)  
  
init = tf.initialize_all_variables()  
sess.run(init)
```

10.优化模型变量，训练输出结果，以达到预期目标值50，代码如下：

```

print ('\nOptimizing Two Gate Output to 50.')
for i in range(10):
    # Run the train step
    sess.run(train_step, feed_dict={x_data: x_val})
    # Get the a and b values
    a_val, b_val = (sess.run(a), sess.run(b))
    # Run the two-gate graph output
    two_gate_output = sess.run(two_gate, feed_dict={x_data: x_val})
    print(str(a_val) + ' * ' + str(x_val) + ' + ' + str(b_val) + ' = ' + str(two_gate_output))

```

11.输出结果如下：

```

Optimizing Two Gate Output to 50.
5.4 * 5.0 + 1.88 = 28.88
7.512 * 5.0 + 2.3024 = 39.8624
8.52576 * 5.0 + 2.50515 = 45.134
9.01236 * 5.0 + 2.60247 = 47.6643
9.24593 * 5.0 + 2.64919 = 48.8789
9.35805 * 5.0 + 2.67161 = 49.4619
9.41186 * 5.0 + 2.68237 = 49.7417
9.43769 * 5.0 + 2.68754 = 49.876
9.45009 * 5.0 + 2.69002 = 49.9405
9.45605 * 5.0 + 2.69121 = 49.9714

```



这里需要注意的是，第二个例子的解决方法不是唯一的。这在神经网络算法中不太重要，因为所有的参数是根据减小损失函数来调整的。最终的解决方案依赖于a和b的初始值。如果它们是随机初始化的，而不是1，我们将会看到每次迭代的模型变量的输出结果并不相同。

6.2.3 工作原理

通过TensorFlow的隐式后向传播达到计算门操作的优化。TensorFlow维护模型操作和变量，调整优化算法和损失函数。

我们能扩展操作门，选定哪一个输入是变量，哪一个输入是数据。因为TensorFlow将调整所有的模型变量来最小化损失函数，而不是调整数据，数据输入声明为占位符。

维护计算图中的状态，以及每次训练迭代自动更新模型变量的隐式能力是TensorFlow具有的优势特征之一，该能力让TensorFlow威力无穷。

6.3 使用门函数和激励函数

现在我们已经学会了链接这些操作门函数，接下来将使用激励函数来运行计算图输出结果。本节会介绍常用的激励函数。

6.3.1 开始

本节将比较两种不同的激励函数：sigmoid激励函数和ReLU激励函数。简单回忆一下这两个激励函数的表达式：

$$\text{sigmoid}(x) = \frac{1}{1 + e^x}$$

$$\text{ReLU}(x) = \max(0, x)$$

在本例中，我们将创建两个相同结构的单层神经网络，有一点不同的是：一个通过sigmoid激励函数赋值；另外一个则通过ReLU激励函数赋值。损失函数使用L2范数距离函数（输出结果与0.75的差值）。我们将从正态分布数据集（Normal (mean=2, sd=0.1)）中随机抽取批量数据，优化输出结果达到预期值0.75。

6.3.2 动手做

1. 导入必要的编程库，初始化一个计算图会话。对于学习在TensorFlow中如何设置随机种子而言，这也是一個很好的例子。这里将使用TensorFlow和Numpy模块的随机数生成器。对于相同的随机种子集，我们应该能够复现，代码如下：

```
import tensorflow as tf
import numpy as np
import matplotlib.pyplot as plt
sess = tf.Session()
tf.set_random_seed(5)
np.random.seed(42)
```

2. 声明批量大小、模型变量、数据集和占位符。在计算图中为两个相似的神经网络模型（仅激励函数不同）传入正态分布数据，代码如下：

```
batch_size = 50
a1 = tf.Variable(tf.random_normal(shape=[1, 1]))
b1 = tf.Variable(tf.random_uniform(shape=[1, 1]))
a2 = tf.Variable(tf.random_normal(shape=[1, 1]))
b2 = tf.Variable(tf.random_uniform(shape=[1, 1]))
x = np.random.normal(2, 0.1, 500)
x_data = tf.placeholder(shape=[None, 1], dtype=tf.float32)
```

3. 声明两个训练模型，即sigmoid激励模型和ReLU激励模型，代码如下：

```
sigmoid_activation = tf.sigmoid(tf.add(tf.matmul(x_data, a1), b1))
relu_activation = tf.nn.relu(tf.add(tf.matmul(x_data, a2), b2))
```

4. 损失函数都采用模型输出和预期值0.75之间的差值的L2范数平均，代码如下：

```
loss1 = tf.reduce_mean(tf.square(tf.sub(sigmoid_activation, 0.75)))
loss2 = tf.reduce_mean(tf.square(tf.sub(relu_activation, 0.75)))
```

5. 声明优化算法，初始化变量，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.01)
train_step_sigmoid = my_opt.minimize(loss1)
train_step_relu = my_opt.minimize(loss2)
init = tf.initialize_all_variables()
sess.run(init)
```

6. 遍历迭代训练模型，每个模型迭代750次。保存损失函数输出和激励函数的返回值，以便后续绘图，代码如下：

```
loss_vec_sigmoid = []
loss_vec_relu = []
activation_sigmoid = []
activation_relu = []
for i in range(750):
    rand_indices = np.random.choice(len(x), size=batch_size)
    x_vals = np.transpose([x[rand_indices]])
    sess.run(train_step_sigmoid, feed_dict={x_data: x_vals})
    sess.run(train_step_relu, feed_dict={x_data: x_vals})

    loss_vec_sigmoid.append(sess.run(loss1, feed_dict={x_data: x_vals}))
    loss_vec_relu.append(sess.run(loss2, feed_dict={x_data: x_vals}))

    activation_sigmoid.append(np.mean(sess.run(sigmoid_activation,
feed_dict={x_data: x_vals})))
    activation_relu.append(np.mean(sess.run(rectu_activation, feed_
dict={x_data: x_vals})))
```

7. 下面是绘制损失函数和激励函数的代码，所绘图像见图6-2：

```

plt.plot(activation_sigmoid, 'k-', label='Sigmoid Activation')
plt.plot(activation_relu, 'r--', label='Relu Activation')
plt.ylim([0, 1.0])
plt.title('Activation Outputs')
plt.xlabel('Generation')
plt.ylabel('Outputs')
plt.legend(loc='upper right')
plt.show()

plt.plot(loss_vec_sigmoid, 'k-', label='Sigmoid Loss')
plt.plot(loss_vec_relu, 'r--', label='Relu Loss')
plt.ylim([0, 1.0])
plt.title('Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.legend(loc='upper right')
plt.show()

```

两个神经网络模型具有相似的结构和预期值0.75，只有激励函数不同（分别是sigmoid和ReLU激励函数）。从图6-3中可以看出，带有ReLU激励函数的神经网络比sigmoid激励函数的神经网络向0.75收敛得更快。

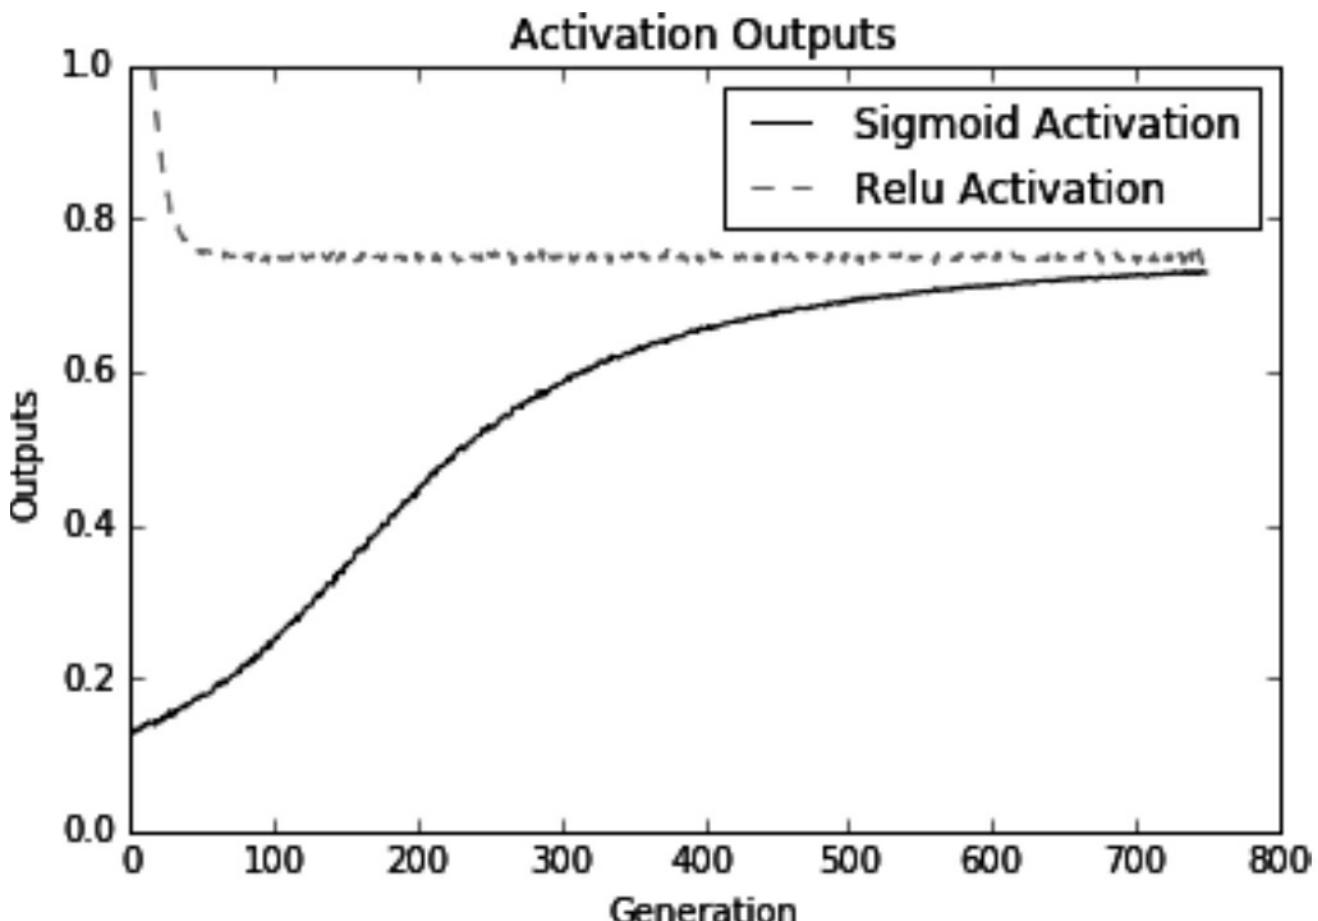


图6-2 带有sigmoid和ReLU激励函数的神经网络输出结果对比

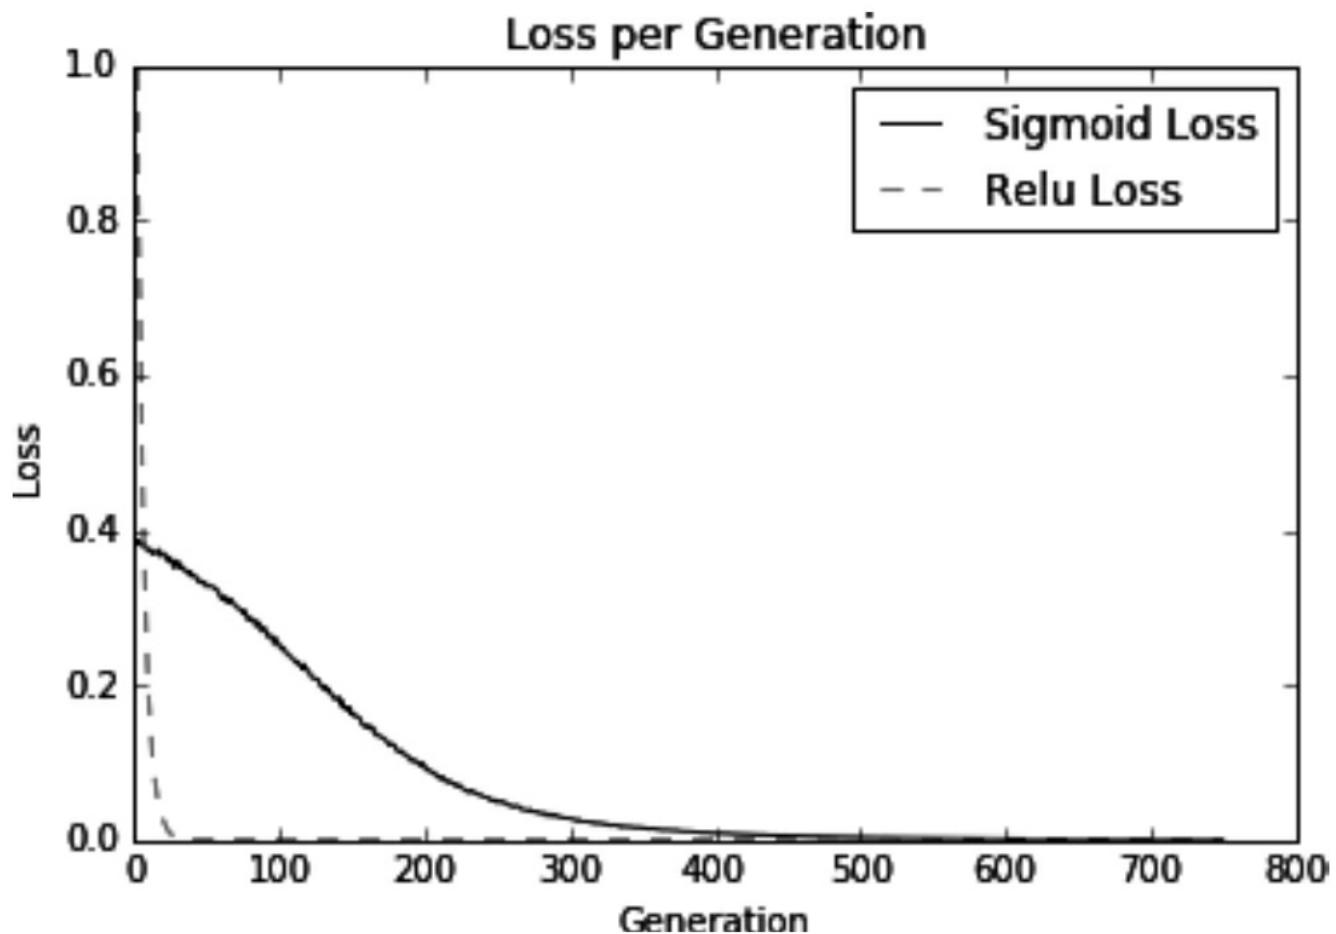


图6-3 带有sigmoid和ReLU激励函数的神经网络的损失函数值对比。注意ReLU损失在迭代初期急剧下降

6.3.3 工作原理

基于ReLU激励函数的形式，它将比sigmoid激励函数返回更多的0值。我们认为该行为是一种稀疏性的，稀疏性导致收敛速度加快，但是损失了一部分梯度控制的能力。相反，sigmoid激励函数具有良好的梯度控制，不会出现ReLU激励函数那样的极值。sigmoid激励函数和ReLU激励函数的对比如下表所示。

激励函数	优点	缺点
Sigmoid 激励函数	输出的极值很少	收敛太慢
ReLU 激励函数	快速收敛	返回结果中容易出现极值

6.3.4 延伸学习

在本节中，我们比较了神经网络算法的ReLU激励函数和sigmoid激励函数。神经网络算法常用的其他激励函数还有很多，但是整体可以归纳成两类：第一类是形状类似sigmoid的激励函数，包括反正切激励函数、双曲正切函数、阶跃激励函数等；第二类是形状类似ReLU的激励函数，包括softplus激励函数、leak ReLU激励函数等。本节讨论的两类激励函数的大部分比较结果也适用于所在的同分类激励函数。然而，注意激励函数的选择对于神经网络算法的收敛是非常关键的。

6.4 用TensorFlow实现单层神经网络

我们已经实现了神经网络算法应用到真实数据集上的大部分操作，本节将实现一个单层神经网络（层即为神经网络中的神经元），并在Iris数据集上进行模型训练。

6.4.1 开始

在本节中，我们将实现一个单隐藏层的神经网络算法。理解全联接神经网络算法主要是基于矩阵乘法的，这一点是相当重要的。并且，数据集和矩阵的维度对于算法模型正确有序地运行是非常关键的。

由于本例是一个回归算法问题，所以将使用均方误差作为损失函数。

6.4.2 动手做

1. 创建计算图会话，导入必要的编程库，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn import datasets
```

2. 加载Iris数据集，存储花萼长度作为目标值，然后开始一个计算图会话，代码如下：

```
iris = datasets.load_iris()
x_vals = np.array([x[0:3] for x in iris.data])
y_vals = np.array([x[3] for x in iris.data])
sess = tf.Session()
```

3. 因为数据集比较小，我们设置一个种子使得返回结果可复现，代码如下：

```
seed = 2
tf.set_random_seed(seed)
np.random.seed(seed)
```

4. 为了准备数据集，我们创建一个80-20分的训练集和测试集。通过min-max缩放法正则化x特征值为0到1之间，代码如下：

```

train_indices = np.random.choice(len(x_vals), round(len(x_vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]
def normalize_cols(m):
    col_max = m.max(axis=0)
    col_min = m.min(axis=0)
    return (m-col_min) / (col_max - col_min)

x_vals_train = np.nan_to_num(normalize_cols(x_vals_train))
x_vals_test = np.nan_to_num(normalize_cols(x_vals_test))

```

5.现在为数据集和目标值声明批量大小和占位符，代码如下：

```

batch_size = 50
x_data = tf.placeholder(shape=[None, 3], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)

```

6.这一步相当重要，声明有合适形状的模型变量。我们能声明隐藏层为任意大小，本例中设置为有五个隐藏节点，代码如下：

```

hidden_layer_nodes = 5
A1 = tf.Variable(tf.random_normal(shape=[3,hidden_layer_nodes]))
b1 = tf.Variable(tf.random_normal(shape=[hidden_layer_nodes]))
A2 = tf.Variable(tf.random_normal(shape=[hidden_layer_nodes,1]))
b2 = tf.Variable(tf.random_normal(shape=[1]))

```

7.分两步声明训练模型：第一步，创建一个隐藏层输出；第二步，创建训练模型的最后输出，代码如下：



注意，本例中的模型有三个特征、五个隐藏节点和一个输出结果值。

```

hidden_output = tf.nn.relu(tf.add(tf.matmul(x_data, A1), b1))
final_output = tf.nn.relu(tf.add(tf.matmul(hidden_output, A2),
                               b2))

```

8.这里定义均方误差作为损失函数，代码如下：

```
loss = tf.reduce_mean(tf.square(y_target - final_output))
```

9.声明优化算法，初始化模型变量，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.005)
train_step = my_opt.minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)
```

10.遍历迭代训练模型。我们也初始化两个列表（list）存储训练损失和测试损失。在每次迭代训练时，随机选择批量训练数据来拟合模型，代码如下：

```
# First we initialize the loss vectors for storage.
loss_vec = []
test_loss = []
for i in range(500):
    # First we select a random set of indices for the batch.
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    # We then select the training values
    rand_x = x_vals_train[rand_index]
    rand_y = np.transpose([y_vals_train[rand_index]])
    # Now we run the training step
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})
    # We save the training loss
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_
target: rand_y})
    loss_vec.append(np.sqrt(temp_loss))

    # Finally, we run the test-set loss and save it.
    test_temp_loss = sess.run(loss, feed_dict={x_data: x_vals_
test, y_target: np.transpose([y_vals_test])})
    test_loss.append(np.sqrt(test_temp_loss))
    if (i+1)%50==0:
        print('Generation: ' + str(i+1) + '. Loss = ' + str(temp_
loss))
```

11.使用matplotlib绘制损失函数的代码如下，所绘图像如图6-4所示：

```
plt.plot(loss_vec, 'k-', label='Train Loss')
plt.plot(test_loss, 'r--', label='Test Loss')
plt.title('Loss (MSE) per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.legend(loc='upper right')
plt.show()
```

6.4.3 工作原理

可视化神经网络算法模型，如图6-5所示。

6.4.4 延伸学习

注意，我们通过可视化测试集和训练集的损失函数可以判定训练数据集上的模型训练是否过拟合，也可以发现测试集的损失函数比训练集更平滑，主要有两个原因：第一个是，训练集的数据批量大小比测试集小（虽然小得不太多）；第二个是，模型训练是在训练集上进行的，所以测试集对模型变量没有影响。

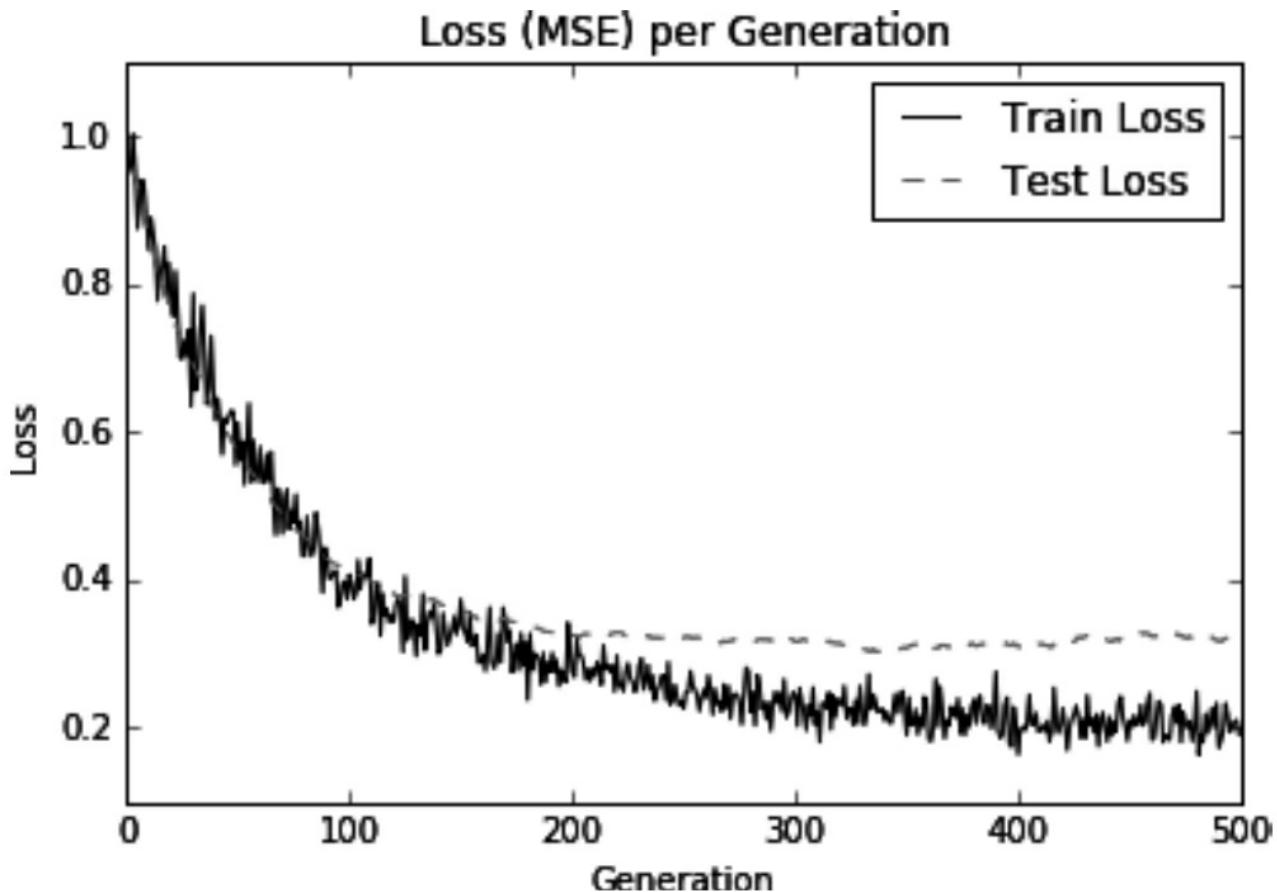


图6-4 训练集和测试集的损失函数（MSE）绘图。注意，在200次迭代训练后会出现轻微的过拟合，因为测试集MSE没有丢失特征，但是训练集MSE会剔除特征

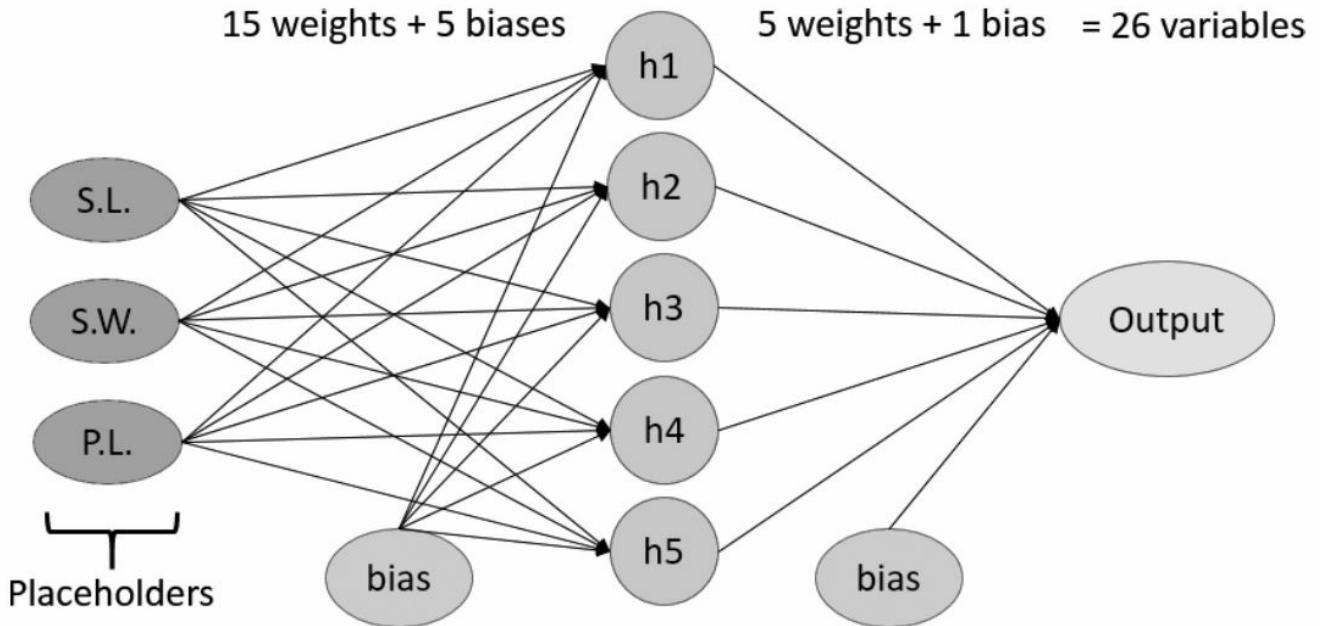


图6-5 神经网络算法模型可视化，其中隐藏层包含五个隐藏节点。我们传入三个值：花萼长度（S.L.）、花萼宽度（S.W）和花瓣长度（P.L）。目标值是花瓣宽度。总共将有26个模型变量

6.5 用TensorFlow实现神经网络常见层

本节将介绍如何实现常见层，包括卷积层（convolutional layer）和池化层（maxpool layer）。在上一节，我们实现了全联接层，本小节将扩展到其他层。

6.5.1 开始

我们已经研究了如何连接数据输入和全联接的隐藏层。TensorFlow中有许多内建函数的多种类型的层，其中最流行的层是卷积层和池化层。我们将展示如何在输入数据和全联接的数据上创建和使用这些层。首先，我们来介绍如何在一维数据上使用这些层，然后是在二维数据上使用它们。

神经网络算法的层能以任意形式组合，最常用的使用方法是用卷积层和全联接层来创建特征。如果我们有许多特征，常用的处理方法是采用池化层。在这些层之后常常引入激励函数。卷积神经网络（CNN）算法（见第8章），经常会包括卷积层、池化层、激励函数，等等。

6.5.2 动手做

刚开始，先以一维数据为例。我们将生成一维随机数据。

1. 导入需要的编程库，创建计算图会话，代码如下：

```
import tensorflow as tf
import numpy as np
sess = tf.Session()
```

2. 初始化数据，该数据为NumPy数组，长度为25。创建传入数据的占位符，代码如下：

```
data_size = 25
data_1d = np.random.normal(size=data_size)
x_input_1d = tf.placeholder(dtype=tf.float32, shape=[data_size])
```

3. 定义一个卷积层的函数。接着声明一个随机过滤层，创建一个卷积层，代码如下：



注意，许多TensorFlow的层函数是为四维数据设计的（ $4D=[batch\ size, width, height, channels]$ ）。我们需要调整输入数据和输出数据，包括扩展维度和降维。在本例中，批量大小为1，宽度为1，高度为25，颜色通道为1。为了扩展维度，使用`expand_dims()`函数；降维使用`squeeze()`函数。卷积层的输出结果的维度公式为 $output_size= (W-F+2P) / S + 1$ ，其中W为输入数据维度，F为过滤层大小，P是padding大小，S是步长大小。

```

def conv_layer_1d(input_1d, my_filter):
    # Make 1d input into 4d
    input_2d = tf.expand_dims(input_1d, 0)
    input_3d = tf.expand_dims(input_2d, 0)
    input_4d = tf.expand_dims(input_3d, 3)
    # Perform convolution
    convolution_output = tf.nn.conv2d(input_4d, filter=my_filter,
strides=[1,1,1,1], padding="VALID")
    # Now drop extra dimensions
    conv_output_1d = tf.squeeze(convolution_output)
    return(conv_output_1d)

my_filter = tf.Variable(tf.random_normal(shape=[1,5,1,1]))
my_convolution_output = conv_layer_1d(x_input_1d, my_filter)

```

4. TensorFlow的激励函数默认是逐个元素进行操作。这意味着，在部分层中使用激励函数。下面创建一个激励函数并初始化：

```

def activation(input_1d):
    return(tf.nn.relu(input_1d))
my_activation_output = activation(my_convolution_output)

```

5. 声明一个池化层函数，该函数在一维向量的移动窗口上创建池化层函数。对于本例，其宽度为5，代码如下：



TensorFlow的池化层函数的参数与卷积层函数参数非常相似。但是它没有过滤层，只有形状、步长和padding选项。因为我们的窗口宽度为5，并且具有valid padding（即非零padding），所以输出数组将有4或者 $2 \cdot \text{floor}(5/2)$ 项。

```

def max_pool(input_1d, width):
    # First we make the 1d input into 4d.
    input_2d = tf.expand_dims(input_1d, 0)
    input_3d = tf.expand_dims(input_2d, 0)
    input_4d = tf.expand_dims(input_3d, 3)
    # Perform the max pool operation
    pool_output = tf.nn.max_pool(input_4d, ksize=[1, 1, width, 1],
strides=[1, 1, 1, 1], padding='VALID')
    pool_output_1d = tf.squeeze(pool_output)
    return(pool_output_1d)
my_maxpool_output = max_pool(my_activation_output, width=5)

```

6.最后一层连接的是全联接层。创建一个函数，该函数输入一维数据，输出值的索引。记住一维数组做矩阵乘法需要提前扩展为二维，代码如下：

```

def fully_connected(input_layer, num_outputs):
    # Create weights
    weight_shape = tf.squeeze(tf.pack([tf.shape(input_layer),
[num_outputs]]))
    weight = tf.random_normal(weight_shape, stddev=0.1)
    bias = tf.random_normal(shape=[num_outputs])
    # Make input into 2d
    input_layer_2d = tf.expand_dims(input_layer, 0)
    # Perform fully connected operations
    full_output = tf.add(tf.matmul(input_layer_2d, weight), bias)
    # Drop extra dimensions
    full_output_1d = tf.squeeze(full_output)
    return(full_output_1d)

my_full_output = fully_connected(my_maxpool_output, 5)

```

7.初始化所有的变量，运行计算图打印出每层的输出结果，代码如下：

```

init = tf.initialize_all_variables()
sess.run(init)
feed_dict = {x_input_1d: data_1d}
# Convolution Output
print('Input = array of length 25')

```

```
print('Convolution w/filter, length = 5, stride size = 1, results  
in an array of length 21:')  
print(sess.run(my_convolution_output, feed_dict=feed_dict))  
# Activation Output  
print('\nInput = the above array of length 21')  
print('ReLU element wise returns the array of length 21')  
print(sess.run(my_activation_output, feed_dict=feed_dict))  
# Maxpool Output  
print('\nInput = the above array of length 21')  
print('MaxPool, window length = 5, stride size = 1, results in the  
array of length 17')  
print(sess.run(my_maxpool_output, feed_dict=feed_dict))  
# Fully Connected Output  
print('\nInput = the above array of length 17')  
print('Fully connected layer on all four rows with five  
outputs')  
print(sess.run(my_full_output, feed_dict=feed_dict))
```

8.输出结果如下：

```

Input = array of length 25
Convolution w/filter, length = 5, stride size = 1, results in an
array of length 21:
[-0.91608119  1.53731811 -0.7954089   0.5041104   1.88933098
 -1.81099761  0.56695032  1.17945457 -0.66252393 -1.90287709
  0.87184119  0.84611893 -5.25024986 -0.05473572  2.19293165
 -4.47577858 -1.71364677  3.96857905 -2.0452652  -1.86647367
 -0.12697852]

Input = the above array of length 21
ReLU element wise returns the array of length 21:
[ 0.          1.53731811  0.          0.5041104   1.88933098
  0.          0.          1.17945457  0.          0.
  0.87184119  0.84611893  0.          0.          2.19293165
  0.          0.          3.96857905  0.          0.
  0.          ]
Input = the above array of length 21
MaxPool, window length = 5, stride size = 1, results in the array
of length 17:
[ 1.88933098  1.88933098  1.88933098  1.88933098  1.88933098
  1.17945457  1.17945457  1.17945457  0.87184119  0.87184119
  2.19293165  2.19293165  2.19293165  3.96857905  3.96857905
  3.96857905  3.96857905]

Input = the above array of length 17
Fully connected layer on all four rows with five outputs:
[ 1.23588216 -0.42116445  1.44521213  1.40348077 -0.79607368]

```



神经网络对于一维数据非常重要。时序数据集、信号处理数据集和一些文本嵌入数
据集都是一维数据，会频繁使用到神经网络算法。

下面开始在二维数据集上进行层函数操作：

1.重置计算图会话，代码如下：

```

ops.reset_default_graph()
sess = tf.Session()

```

2.初始化输入数组为 10×10 的矩阵，然后初始化计算图的占位符，代码如下：

```
data_size = [10, 10]
data_2d = np.random.normal(size=data_size)
x_input_2d = tf.placeholder(dtype=tf.float32, shape=data_size)
```

3. 声明一个卷积层函数。因为数据集已经具有高度和宽度了，这里仅需再扩展两维（批量大小为1，颜色通道为1）即可使用卷积conv2d（）函数。本例将使用一个随机的 2×2 过滤层，两个方向上的步长和valid padding（非零padding）。由于输入数据是 10×10 ，因此卷积输出为 5×5 。具体代码如下：

```
def conv_layer_2d(input_2d, my_filter):
    # First, change 2d input to 4d
    input_3d = tf.expand_dims(input_2d, 0)
    input_4d = tf.expand_dims(input_3d, 3)
    # Perform convolution
    convolution_output = tf.nn.conv2d(input_4d, filter=my_filter,
    strides=[1, 2, 2, 1], padding="VALID")
    # Drop extra dimensions
    conv_output_2d = tf.squeeze(convolution_output)
    return(conv_output_2d)

my_filter = tf.Variable(tf.random_normal(shape=[2, 2, 1, 1]))
my_convolution_output = conv_layer_2d(x_input_2d, my_filter)
```

4. 激励函数是针对逐个元素的，现创建激励函数并初始化，代码如下：

```
def activation(input_2d):
    return(tf.nn.relu(input_2d))
my_activation_output = activation(my_convolution_output)
```

5. 本例的池化层与一维数据例子中的相似，有一点不同的是，我们需要声明池化层移动窗口的宽度和高度。这里将与二维卷积层一样，将扩展池化层为二维，代码如下：

```

def max_pool(input_2d, width, height):
    # Make 2d input into 4d
    input_3d = tf.expand_dims(input_2d, 0)
    input_4d = tf.expand_dims(input_3d, 3)
    # Perform max pool
    pool_output = tf.nn.max_pool(input_4d, ksize=[1, height,
width, 1], strides=[1, 1, 1, 1], padding='VALID')
    # Drop extra dimensions
    pool_output_2d = tf.squeeze(pool_output)
    return(pool_output_2d)

my_maxpool_output = max_pool(my_activation_output, width=2,
height=2)

```

6.本例中的全联接层也与一维数据的输出相似。注意，全联接层的二维输入看作一个对象，为了实现每项连接到每个输出，我们打平二维矩阵，然后在做矩阵乘法时再扩展维度，代码如下：

```

def fully_connected(input_layer, num_outputs):
    # Flatten into 1d
    flat_input = tf.reshape(input_layer, [-1])
    # Create weights
    weight_shape = tf.squeeze(tf.pack([tf.shape(flat_input), [num_
outputs]]))
    weight = tf.random_normal(weight_shape, stddev=0.1)
    bias = tf.random_normal(shape=[num_outputs])
    # Change into 2d
    input_2d = tf.expand_dims(flat_input, 0)
    # Perform fully connected operations
    full_output = tf.add(tf.matmul(input_2d, weight), bias)
    # Drop extra dimensions
    full_output_2d = tf.squeeze(full_output)
    return(full_output_2d)

my_full_output = fully_connected(my_maxpool_output, 5)

```

7.初始化变量，创建一个赋值字典，代码如下：

```

init = tf.initialize_all_variables()
sess.run(init)

feed_dict = {x_input_2d: data_2d}

```

8.打印每层的输出结果，代码如下：

```
# Convolution Output
print('Input = [10 X 10] array')
print('2x2 Convolution, stride size = [2x2], results in the [5x5]
array:')
print(sess.run(my_convolution_output, feed_dict=feed_dict))
# Activation Output
print('\nInput = the above [5x5] array')
print('ReLU element wise returns the [5x5] array:')
print(sess.run(my_activation_output, feed_dict=feed_dict))
# Max Pool Output
print('\nInput = the above [5x5] array')
print('MaxPool, stride size = [1x1], results in the [4x4]
array:')
print(sess.run(my_maxpool_output, feed_dict=feed_dict))
# Fully Connected Output
print('\nInput = the above [4x4] array')
print('Fully connected layer on all four rows with five
outputs:')
print(sess.run(my_full_output, feed_dict=feed_dict))
```

9.输出结果如下：

```
Input = [10 X 10] array
2x2 Convolution, stride size = [2x2], results in the [5x5] array:
[[ 0.37630892 -1.41018617 -2.58821273 -0.32302785  1.18970704]
 [-4.33685207  1.97415686  1.0844903 -1.18965471  0.84643292]
 [ 5.23706436  2.46556497 -0.95119286  1.17715418  4.1117816 ]
 [ 5.86972761  1.2213701   1.59536231  2.66231227  2.28650784]
 [-0.88964868 -2.75502229   4.3449688  2.67776585 -2.23714781]]

Input = the above [5x5] array
ReLU element wise returns the [5x5] array:
[[ 0.37630892  0.          0.          0.          1.18970704]
 [ 0.          1.97415686  1.0844903  0.          0.84643292]
 [ 5.23706436  2.46556497  0.          1.17715418  4.1117816 ]
 [ 5.86972761  1.2213701   1.59536231  2.66231227  2.28650784]
 [ 0.          0.          4.3449688  2.67776585  0.          ]]

Input = the above [5x5] array
MaxPool, stride size = [1x1], results in the [4x4] array:
[[ 1.97415686  1.97415686  1.0844903  1.18970704]
 [ 5.23706436  2.46556497  1.17715418  4.1117816 ]
 [ 5.86972761  2.46556497  2.66231227  4.1117816 ]
 [ 5.86972761  4.3449688   4.3449688  2.67776585]]]

Input = the above [4x4] array
Fully connected layer on all four rows with five outputs:
[-0.6154139  -1.96987963 -1.88811922  0.20010889  0.32519674]
```

6.5.3 工作原理

我们学习了如何在一维数据集和二维数据集上使用TensorFlow的卷积层和池化层。不管输入数据集的形状，最后的输出结果都是相同维度的。这现实了神经网络算法层的灵活性。本节也让我们理解了，神经网络操作中形状和大小的重要性。

6.6 用TensorFlow实现多层神经网络

本节将多层神经网络应用到实际场景中，预测低出生体重数据集。

6.6.1 开始

截至目前，我们学习了如何创建神经网络和层，我们将运用该方法在低出生体重数据集上预测婴儿出生体重。我们将创建一个包含三个隐藏层的神经网络。低出生体重数据集包括实际的出生体重和是否超过2500克的标记。在本例中，我们将预测出生体重（回归预测），然后看最后分类结果的准确度（模型能够鉴别出生体重是否超过2500克）。

6.6.2 动手做

1. 导入必要的编程库，初始化计算图会话，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import requests
import numpy as np
sess = tf.Session()
```

2. 使用requests模块从网站加载数据集，然后分离出需要的特征数据和目标值，代码如下：

```
birthdata_url = 'https://www.umass.edu/statdata/statdata/data/
lowbwt.dat'
birth_file = requests.get(birthdata_url)
birth_data = birth_file.text.split('\r\n')[5:]
birth_header = [x for x in birth_data[0].split(' ') if len(x)>=1]
birth_data = [[float(x) for x in y.split(' ') if len(x)>=1] for y
in birth_data[1:] if len(y)>=1]
y_vals = np.array([x[10] for x in birth_data])
cols_of_interest = ['AGE', 'LWT', 'RACE', 'SMOKE', 'PTL', 'HT',
'UI', 'FTV']
x_vals = np.array([[x[ix] for ix, feature in enumerate(birth_
header) if feature in cols_of_interest] for x in birth_data])
```

3. 为了后面可以复现，为NumPy和TensorFlow设置随机种子，然后声明批量大小，代码如下：

```
seed = 3
tf.set_random_seed(seed)
np.random.seed(seed)
batch_size = 100
```

4. 分割数据集为80-20的训练集和测试集，然后使用min-max方法归一化输入特征数据为0到1之间，代码如下：

```

train_indices = np.random.choice(len(x_vals), round(len(x_vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]

def normalize_cols(m):
    col_max = m.max(axis=0)
    col_min = m.min(axis=0)
    return (m-col_min) / (col_max - col_min)

x_vals_train = np.nan_to_num(normalize_cols(x_vals_train))
x_vals_test = np.nan_to_num(normalize_cols(x_vals_test))

```



归一化输入特征数据是常用的特征转化方法，对神经网络算法特别有帮助。如果样本数据集是以0到1为中心的，它将有利于激励函数操作的收敛。

5.因为有多个层含有相似的变量初始化，因此我们将创建一个初始化函数，该函数可以初始化加权权重和偏置，代码如下：

```

def init_weight(shape, st_dev):
    weight = tf.Variable(tf.random_normal(shape, stddev=st_dev))
    return(weight)

def init_bias(shape, st_dev):
    bias = tf.Variable(tf.random_normal(shape, stddev=st_dev))
    return(bias)

```

6.初始化占位符。本例中将有八个输入特征数据和一个输出结果（出生体重，单位：克），代码如下：

```

x_data = tf.placeholder(shape=[None, 8], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)

```

7.全联接层将在三个隐藏层中使用三次，为了避免代码上的重复，我们将创建一个层函数来初始化算法

模型，代码如下：

```
def fully_connected(input_layer, weights, biases):
    layer = tf.add(tf.matmul(input_layer, weights), biases)
    return(tf.nn.relu(layer))
```

8.现在创建算法模型。对于每一层（包括输出层），我们将初始化一个权重矩阵、偏置矩阵和全联接层。在本例中，三个隐藏层的大小分别为25、10和3，代码如下：



本例中使用的算法模型需要拟合522个变量。下面来看下这个数值是如何计算的？

输入数据集和第一隐藏层之间有225 ($8 \times 25 + 25$) 个变量，继续用这种方式计算隐藏层并加在一起有522 ($225 + 260 + 33 + 4$) 个变量。很明显，这比之前在逻辑回归算法中的9个变量要多得多。

```
# Create second layer (25 hidden nodes)
weight_1 = init_weight(shape=[8, 25], st_dev=10.0)
bias_1 = init_bias(shape=[25], st_dev=10.0)
layer_1 = fully_connected(x_data, weight_1, bias_1)

# Create second layer (10 hidden nodes)
weight_2 = init_weight(shape=[25, 10], st_dev=10.0)
bias_2 = init_bias(shape=[10], st_dev=10.0)
layer_2 = fully_connected(layer_1, weight_2, bias_2)

# Create third layer (3 hidden nodes)
weight_3 = init_weight(shape=[10, 3], st_dev=10.0)
bias_3 = init_bias(shape=[3], st_dev=10.0)
layer_3 = fully_connected(layer_2, weight_3, bias_3)

# Create output layer (1 output value)
weight_4 = init_weight(shape=[3, 1], st_dev=10.0)
bias_4 = init_bias(shape=[1], st_dev=10.0)
final_output = fully_connected(layer_3, weight_4, bias_4)
```

9. 使用L1范数损失函数（绝对值），声明优化器（Adam优化器）和初始化变量，代码如下：

```
loss = tf.reduce_mean(tf.abs(y_target - final_output))
my_opt = tf.train.AdamOptimizer(0.05)
train_step = my_opt.minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)
```



本例中为Adam优化器选择的学习率为0.05，有研究建议设置更低的学习率可以产生更好的结果。在本节中，我们使用比较大的学习率是为了数据集的一致性和快速收敛。

10. 迭代训练模型200次。下面的代码也包括存储训练损失和测试损失，选择随机批量大小和每25次迭代就打印状态，代码如下：

```
# Initialize the loss vectors
loss_vec = []
test_loss = []
for i in range(200):
    # Choose random indices for batch selection
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    # Get random batch
    rand_x = x_vals_train[rand_index]
    rand_y = np.transpose([y_vals_train[rand_index]])
    # Run the training step
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})
    # Get and store the train loss
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_target: rand_y})
    loss_vec.append(temp_loss)
    # Get and store the test loss
    test_temp_loss = sess.run(loss, feed_dict={x_data: x_vals_test, y_target: np.transpose([y_vals_test])})
    test_loss.append(test_temp_loss)
    if (i+1)%25==0:
        print('Generation: ' + str(i+1) + '. Loss = ' + str(temp_loss))
```

11.输出结果如下:

```
Generation: 25. Loss = 5922.52
Generation: 50. Loss = 2861.66
Generation: 75. Loss = 2342.01
Generation: 100. Loss = 1880.59
Generation: 125. Loss = 1394.39
Generation: 150. Loss = 1062.43
Generation: 175. Loss = 834.641
Generation: 200. Loss = 848.54
```

12.使用matplotlib模块绘制训练损失和测试损失的代码，所绘图像见图6-6:

```
plt.plot(loss_vec, 'k-', label='Train Loss')
plt.plot(test_loss, 'r--', label='Test Loss')
plt.title('Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.legend(loc='upper right')
plt.show()
```

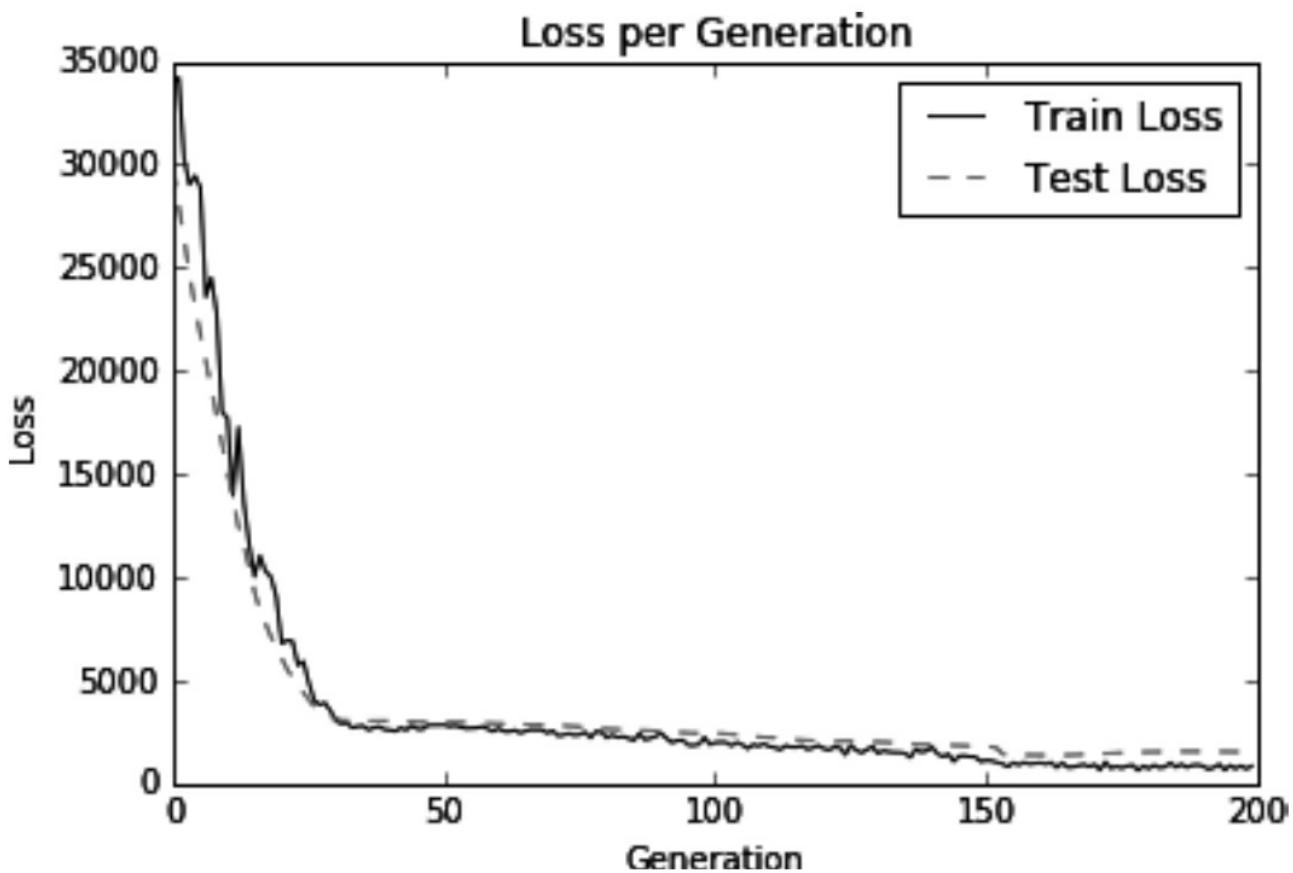


图6-6 神经网络算法模型训练预测出生体重的训练集损失和测试集损失图（单位：克）。注意，在30次迭代训练后会获得较好的模型

13.现在我们想比较预测出生体重结果和前面章节的逻辑结果。在第3章的逻辑回归算法中，我们在迭代上千次后得到了大约60%的精确度。为了在这里做比较，我们将输出训练集/测试集的回归结果，然后传入一个指示函数（判断是否大于2500克），将回归结果转换成分类结果。下面的代码将证明本例模型的准确度：

```
actuals = np.array([x[1] for x in birth_data])
test_actuals = actuals[test_indices]
train_actuals = actuals[train_indices]
test_preds = [x[0] for x in sess.run(final_output, feed_dict={x_data: x_vals_test})]
train_preds = [x[0] for x in sess.run(final_output, feed_dict={x_data: x_vals_train})]
test_preds = np.array([1.0 if x<2500.0 else 0.0 for x in test_preds])
```

```
train_preds = np.array([1.0 if x<2500.0 else 0.0 for x in train_
preds])
# Print out accuracies
test_acc = np.mean([x==y for x,y in zip(test_preds, test_
actuals)])
train_acc = np.mean([x==y for x,y in zip(train_preds, train_
actuals)])
print('On predicting the category of low birthweight from
regression output (<2500g):')
print('Test Accuracy: {}'.format(test_acc))
print('Train Accuracy: {}'.format(train_acc))
```

14.准确度的结果如下：

```
Test Accuracy: 0.5526315789473685
Train Accuracy: 0.6688741721854304
```

6.6.3 工作原理

在本节中，我们创建一个回归神经网络模型，该模型有三个全联接隐藏层，并用该模型预测低出生体重数据集。与逻辑结果预测出生体重是否大于2500克相比，我们得到了相似的结果，并且迭代的次数更少。在下一节中，我们将通过多层逻辑神经网络算法来优化逻辑回归算法模型。

6.7 线性预测模型的优化

在上一节中，我们注意到需拟合的参数数量远超线性模型。在本节中，我们试图用神经网络算法模型来优化低出生体重的逻辑模型。

6.7.1 开始

加载低出生体重样本数据集，使用一个带两个隐藏层的全联接层的神经网络，并采用sigmoid激励函数来拟合低出生体重的概率。

6.7.2 动手做

1. 导入必要的编程库，初始化计算图会话，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
import requests
sess = tf.Session()
```

2. 加载低出生体重数据集，并对其进行抽取和归一化。有一点不同的是，本例中将使用低出生体重指示变量作为目标值，而不是实际出生体重，代码如下：

```
birthdata_url = 'https://www.umass.edu/statdata/statdata/data/
lowbwt.dat'
birth_file = requests.get(birthdata_url)
birth_data = birth_file.text.split('\r\n')[5:]
birth_header = [x for x in birth_data[0].split(' ') if len(x)>=1]
birth_data = [[float(x) for x in y.split(' ') if len(x)>=1] for y
in birth_data[1:] if len(y)>=1]
y_vals = np.array([x[1] for x in birth_data])
x_vals = np.array([x[2:9] for x in birth_data])
train_indices = np.random.choice(len(x_vals), round(len(x_
vals)*0.8), replace=False)
test_indices = np.array(list(set(range(len(x_vals))) - set(train_-
indices)))
x_vals_train = x_vals[train_indices]
x_vals_test = x_vals[test_indices]
y_vals_train = y_vals[train_indices]
y_vals_test = y_vals[test_indices]

def normalize_cols(m):
    col_max = m.max(axis=0)
    col_min = m.min(axis=0)
    return (m-col_min) / (col_max - col_min)

x_vals_train = np.nan_to_num(normalize_cols(x_vals_train))
x_vals_test = np.nan_to_num(normalize_cols(x_vals_test))
```

3. 声明批量大小和占位符，代码如下：

```

batch_size = 90
x_data = tf.placeholder(shape=[None, 7], dtype=tf.float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)

```

4. 我们声明函数来初始化算法模型中的变量和层。为了创建一个更好的逻辑层，我们需要创建一个返回输入层的逻辑层的函数。换句话说，我们需要使用全联接层，返回每层的sigmoid值。注意，损失函数包括最终的sigmoid函数，所以我们指定最后一层不必返回输出的sigmoid值，代码如下：

```

def init_variable(shape):
    return(tf.Variable(tf.random_normal(shape=shape)))
# Create a logistic layer definition
def logistic(input_layer, multiplication_weight, bias_weight,
activation = True):
    linear_layer = tf.add(tf.matmul(input_layer, multiplication_
weight), bias_weight)

    if activation:
        return(tf.nn.sigmoid(linear_layer))
    else:
        return(linear_layer)

```

5. 声明神经网络的三层（两个隐藏层和一个输出层）。我们为每层初始化一个权重矩阵和偏置矩阵，并定义每层的操作，代码如下：

```

# First logistic layer (7 inputs to 14 hidden nodes)
A1 = init_variable(shape=[7,14])
b1 = init_variable(shape=[14])
logistic_layer1 = logistic(x_data, A1, b1)
# Second logistic layer (14 hidden inputs to 5 hidden nodes)
A2 = init_variable(shape=[14,5])
b2 = init_variable(shape=[5])
logistic_layer2 = logistic(logistic_layer1, A2, b2)
# Final output layer (5 hidden nodes to 1 output)
A3 = init_variable(shape=[5,1])
b3 = init_variable(shape=[1])
final_output = logistic(logistic_layer2, A3, b3, activation=False)

```

6. 声明损失函数（本例使用的是交叉熵损失函数）和优化算法，并初始化变量，代码如下：

```

# Create loss function
loss = tf.reduce_mean(tf.nn.sigmoid_cross_entropy_with_logits(
final_output, y_target))
# Declare optimizer
my_opt = tf.train.AdamOptimizer(learning_rate = 0.002)
train_step = my_opt.minimize(loss)
# Initialize variables
init = tf.initialize_all_variables()
sess.run(init)

```



交叉熵是度量概率之间的距离。这里度量确定值（0或者1）和模型概率值（ $0 < x < 1$ ）之间的差值。在TensorFlow中实现的交叉熵是用函数sigmoid()内建的。采用超参数调优对于寻找最好的损失函数、学习率和优化算法是相当重要的，但是为了本节示例的简洁性，这里不介绍超参数调优。

7.为了评估和比较算法模型，创建计算图预测操作和准确度操作。这使得我们可以传入测试集并计算准确度，代码如下：

```

prediction = tf.round(tf.nn.sigmoid(final_output))
predictions_correct = tf.cast(tf.equal(prediction, y_target),
tf.float32)
accuracy = tf.reduce_mean(predictions_correct)

```

8.准备开始遍历迭代训练模型。本例将训练1500次，并为后续绘图保存模型的损失函数和训练集/测试集准确度，代码如下：

```

# Initialize loss and accuracy vectors
loss_vec = []
train_acc = []
test_acc = []

```

```
for i in range(1500):
    # Select random indicies for batch selection
    rand_index = np.random.choice(len(x_vals_train), size=batch_size)
    # Select batch
    rand_x = x_vals_train[rand_index]
    rand_y = np.transpose([y_vals_train[rand_index]])
    # Run training step
    sess.run(train_step, feed_dict={x_data: rand_x, y_target: rand_y})
    # Get training loss
    temp_loss = sess.run(loss, feed_dict={x_data: rand_x, y_target: rand_y})
    loss_vec.append(temp_loss)
    # Get training accuracy
    temp_acc_train = sess.run(accuracy, feed_dict={x_data: x_vals_train, y_target: np.transpose([y_vals_train])})
    train_acc.append(temp_acc_train)
    # Get test accuracy
    temp_acc_test = sess.run(accuracy, feed_dict={x_data: x_vals_test, y_target: np.transpose([y_vals_test])})
    test_acc.append(temp_acc_test)
    if (i+1)%150==0:
        print('Loss = ' + str(temp_loss))
```

9.输出结果如下：

```
LOSS = 0.696393
LOSS = 0.591708
LOSS = 0.59214
LOSS = 0.505553
LOSS = 0.541974
LOSS = 0.512707
LOSS = 0.590149
LOSS = 0.502641
LOSS = 0.518047
LOSS = 0.502616
```

10.下面的代码块展示如何用matplotlib模块绘制交叉熵损失函数和测试集/训练集准确度：

```
# Plot loss over time
plt.plot(loss_vec, 'k-')
plt.title('Cross Entropy Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Cross Entropy Loss')
plt.show()

# Plot train and test accuracy
plt.plot(train_acc, 'k-', label='Train Set Accuracy')
plt.plot(test_acc, 'r--', label='Test Set Accuracy')
plt.title('Train and Test Accuracy')
plt.xlabel('Generation')

plt.ylabel('Accuracy')
plt.legend(loc='lower right')
plt.show()
```

从图6-7可以看出，大约迭代50次，我们得到了较好的训练模型。随着继续迭代训练，我们发现后续的

迭代并没有获得较大的效果提升。

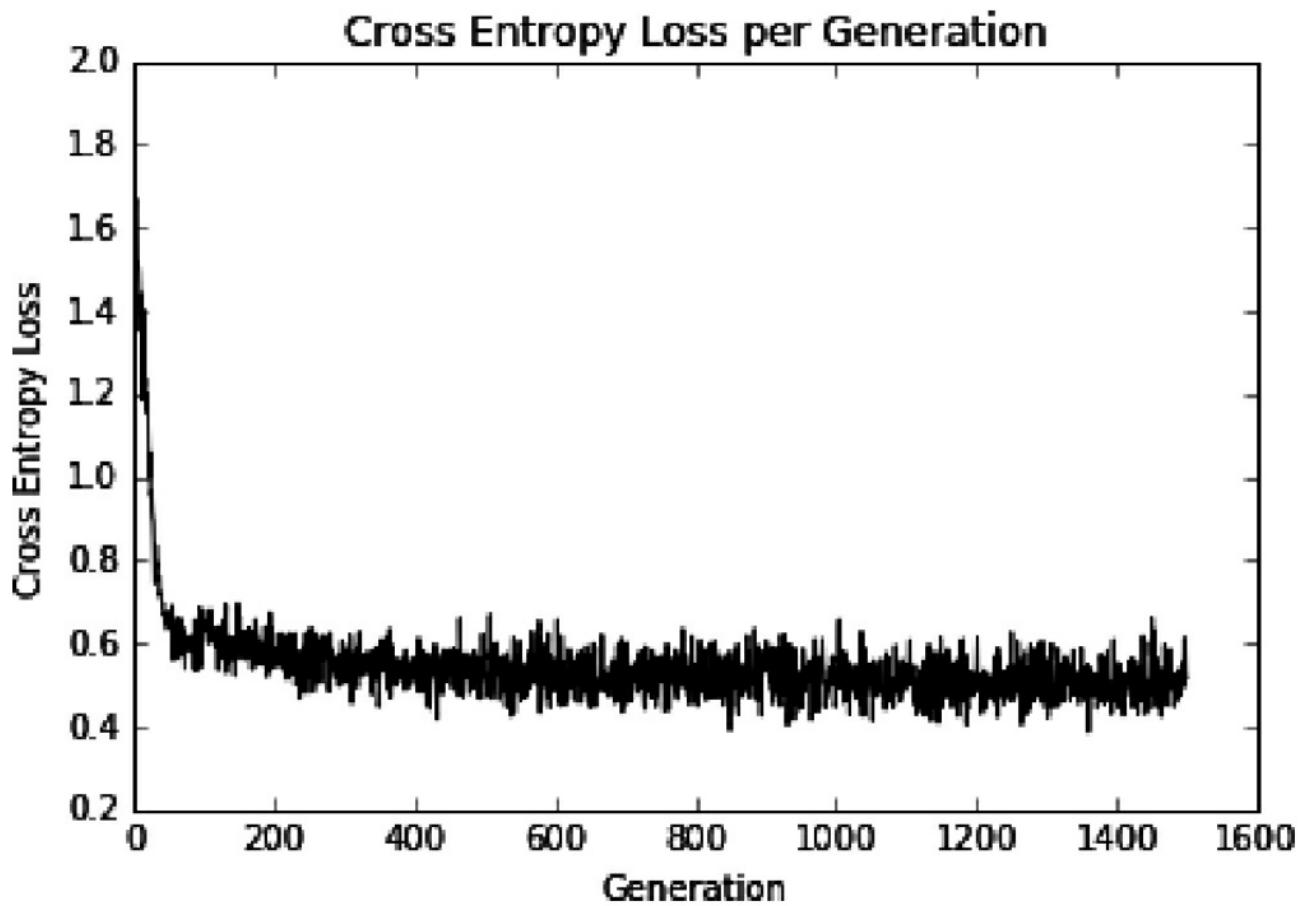


图6-7 迭代训练1500次的损失函数图

从图6-8可以发现，该模型训练很快就得到了较好的模型。

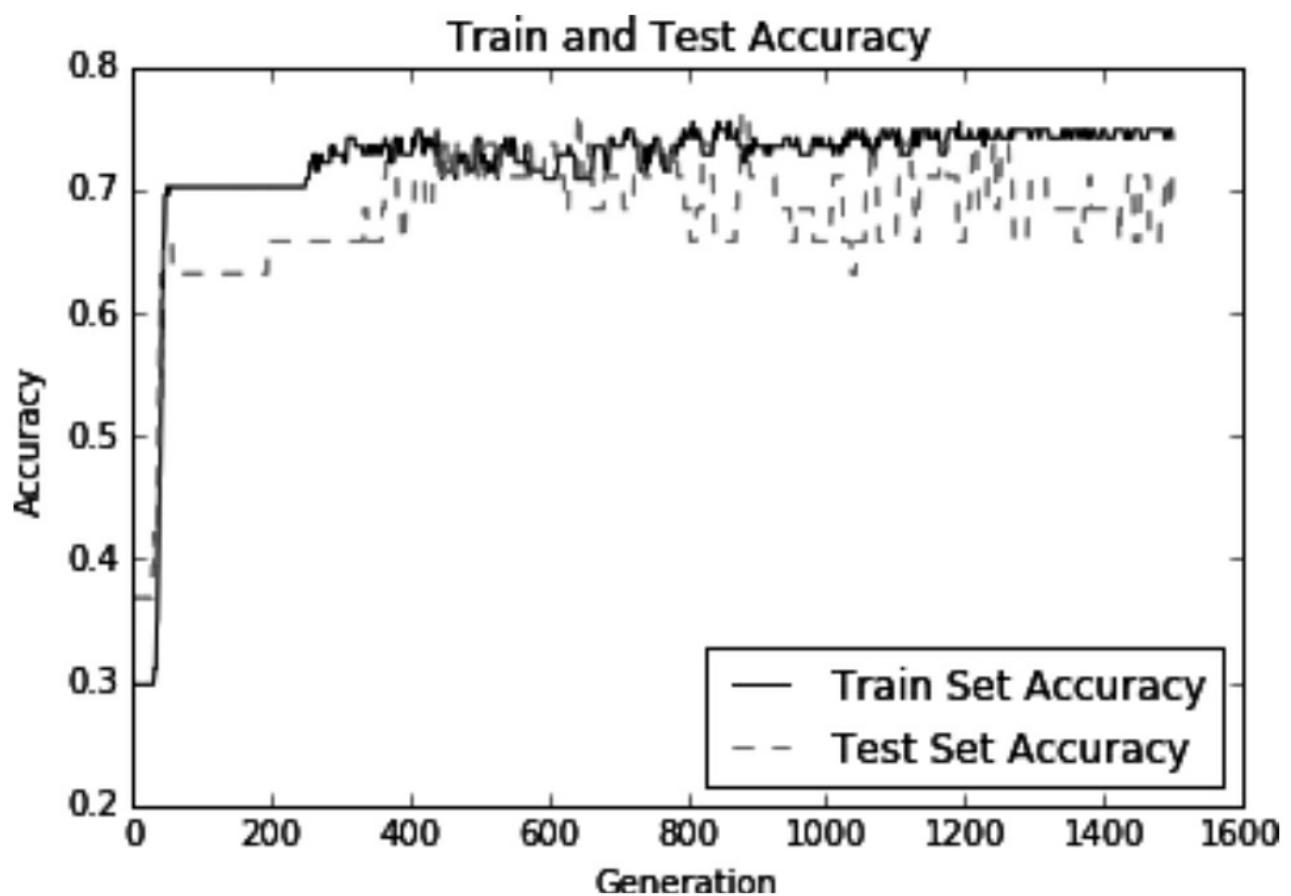


图6-8 训练集和测试集的准确度图

6.7.3 工作原理

使用神经网络训练模型数据有利有弊。神经网络算法模型比先前的算法模型收敛得更快，并在某些场景下更准确，但是同时也要付出代价：我们需要训练更多的模型变量，并且极有可能过拟合。我们从图6-8中就可以发现，训练集的准确度在持续地缓慢增加，然而测试集的准确度有时轻微增加，有时会减小。

为了解决欠拟合的问题，我们可以增加训练模型的深度或者迭代训练的次数。为了解决过拟合的问题，我们可以增加更多的数据或者使用正则化技术。

另外，要注意的一点是，神经网络算法模型变量并不像线性模型那样具有可解释性。神经网络算法模型的系数比线性模型更难解释其在算法模型中的特征意义。

6.8 用TensorFlow基于神经网络实现井字棋

为了展示如何应用神经网络算法模型，我们将使用神经网络来学习优化井字棋（Tic Tac Toe）。明确井字棋是一种决策性游戏，并且走棋步骤优化是确定的。

6.8.1 开始

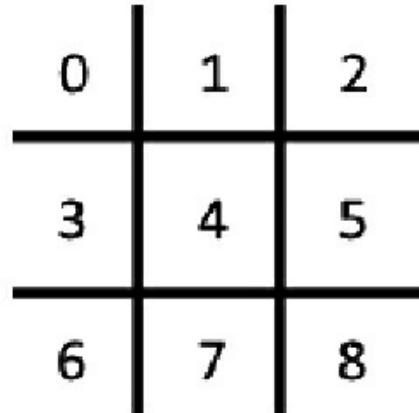
为了训练神经网络模型，我们有一系列优化的不同的走棋棋谱，棋谱基于棋盘位置列表和对应的最佳落子点。考虑到棋盘的对称性，通过只关心不对称的棋盘位置来简化棋盘。井字棋的非单位变换（考虑几何变换）可以通过90度、180度、270度、Y轴对称和X轴对称旋转获得。如果这个假设成立，我们使用一系列的棋盘位置列表和对应的最佳落子点，应用两个随机变换，然后赋值给神经网络算法模型学习。



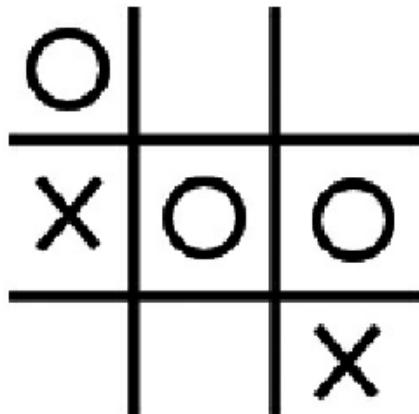
井字棋是一种决策类游戏，注意，先下者要么赢，要么继续走棋。我们希望能训练一个算法模型给出最佳走棋，使得棋局继续。

在本例中，棋盘走棋一方“ \times ”用“1”表示，对手“O”用“-1”表示，空格棋用“0”表示。图6-9展示了棋盘的表示方式和走棋：

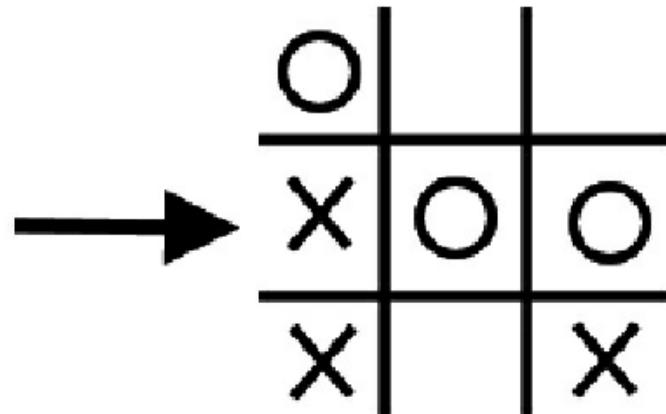
Board Position Indices



Sample Board



Sample Response



[-1,0,0,1,-1,-1,0,0,1]

6

图6-9 展示棋盘和走棋的表示方式。注意， $\times=1$, $O=-1$, 空格棋为0。棋盘位置索引的起始位置标为0

除了计算模型损失之外，我们将用两种方法来检测算法模型的性能：第一种检测方法是，从训练集中移除一个位置，然后优化走棋。这能看出神经网络算法模型能否生成以前未有过的走棋（即该走棋不在训练集中）；第二种评估的方法是，直接实战井字棋游戏看是否能赢。

不同的棋盘位置列表和对应的最佳落子点数据在

GitHub (https://github.com/nfmcclure/tensorflow_cookbook/tree/master/06_Neural_Networks/08_Learning_Tic_Tac_Toe) 中可以查看。

6.8.2 动手做

1. 导入必要的编程库，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import csv
import random
import numpy as np
import random
```

2. 声明训练模型的批量大小，代码如下：

```
batch_size = 50
```

3. 为了让棋盘看起来更清楚，我们创建一个井字棋的打印函数，代码如下：

```
def print_board(board):
    symbols = ['O', ' ', 'X']
    board_plus1 = [int(x) + 1 for x in board]
    print(' ' + symbols[board_plus1[0]] + ' | ' + symbols[board_plus1[1]] + ' | ' + symbols[board_plus1[2]])
    print(' _____')
    print(' ' + symbols[board_plus1[3]] + ' | ' + symbols[board_plus1[4]] + ' | ' + symbols[board_plus1[5]])
    print(' _____')
    print(' ' + symbols[board_plus1[6]] + ' | ' + symbols[board_plus1[7]] + ' | ' + symbols[board_plus1[8]])
```

4. 创建get_symmetry() 函数，返回变换之后的新棋盘和最佳落子点，代码如下：

```
def get_symmetry(board, response, transformation):
    """
    :param board: list of integers 9 long:
        opposing mark = -1
        friendly mark = 1
        empty space = 0
    :param transformation: one of five transformations on a board:
        rotate180, rotate90, rotate270, flip_v, flip_h
    :return: tuple: (new_board, new_response)
    """

    if transformation == 'rotate180':
        new_response = 8 - response

        return(board[::-1], new_response)

    elif transformation == 'rotate90':
        new_response = [6, 3, 0, 7, 4, 1, 8, 5, 2].index(response)
        tuple_board = list(zip(*[board[6:9], board[3:6],
                                board[0:3]]))

        return([value for item in tuple_board for value in item],
               new_response)

    elif transformation == 'rotate270':
        new_response = [2, 5, 8, 1, 4, 7, 0, 3, 6].index(response)
        tuple_board = list(zip(*[board[0:3], board[3:6],
                                board[6:9]]))[:-1]

        return([value for item in tuple_board for value in item],
               new_response)

    elif transformation == 'flip_v':
        new_response = [6, 7, 8, 3, 4, 5, 0, 1, 2].index(response)
        return(board[6:9] + board[3:6] + board[0:3], new_response)

    elif transformation == 'flip_h':
        # flip_h = rotate180, then flip_v
        new_response = [2, 1, 0, 5, 4, 3, 8, 7, 6].index(response)
        new_board = board[::-1]
        return(new_board[6:9] + new_board[3:6] + new_board[0:3],
               new_response)

    else:
        raise ValueError('Method not implemented.')
```

5. 棋盘位置列表和对应的最佳落子点数据位于.csv文件中。我们将创建get_moves_from_csv()函数来加载文件中的棋盘和最佳落子点数据，并保存成元组，代码如下：

```
def get_moves_from_csv(csv_file):
    """
    :param csv_file: csv file location containing the boards w/
responses
    :return: moves: list of moves with index of best response
    """
    moves = []
    with open(csv_file, 'rt') as csvfile:
        reader = csv.reader(csvfile, delimiter=',')
        for row in reader:
            moves.append(([int(x) for x in row[0:9]], int(row[9])))
    return(moves)
```

6. 创建一个get_rand_move()函数，返回一个随机变换棋盘和落子点，代码如下：

```
def get_rand_move(moves, rand_transforms=2):
    # This function performs random transformations on a board.
    (board, response) = random.choice(moves)
    possible_transforms = ['rotate90', 'rotate180', 'rotate270',
    'flip_v', 'flip_h']
    for i in range(rand_transforms):
        random_transform = random.choice(possible_transforms)
        (board, response) = get_symmetry(board, response, random_
transform)
    return(board, response)
```

7. 初始化计算图会话，加载数据文件，创建训练集，代码如下：

```
sess = tf.Session()
moves = get_moves_from_csv('base_tic_tac_toe_moves.csv')
# Create a train set:
train_length = 500
train_set = []
for t in range(train_length):
    train_set.append(get_rand_move(moves))
```

8. 前面提到，我们将从训练集中移除一个棋盘位置和对应的最佳落子点，来看训练的模型是否可以生成最佳走棋。下面棋盘的最佳落子点是棋盘位置索引为6的位置，代码如下：

```
test_board = [-1, 0, 0, 1, -1, -1, 0, 0, 1]
train_set = [x for x in train_set if x[0] != test_board]
```

9. 创建init_weights() 函数和model() 函数，分别实现初始化模型变量和模型操作。注意，模型中并没有包含softmax() 激励函数，因为softmax() 激励函数会在损失函数中出现，代码如下：

```
def init_weights(shape):
    return(tf.Variable(tf.random_normal(shape)))

def model(X, A1, A2, bias1, bias2):
    layer1 = tf.nn.sigmoid(tf.add(tf.matmul(X, A1), bias1))
    layer2 = tf.add(tf.matmul(layer1, A2), bias2)
    return(layer2)
```

10. 声明占位符、变量和模型，代码如下：

```
X = tf.placeholder(dtype=tf.float32, shape=[None, 9])
Y = tf.placeholder(dtype=tf.int32, shape=[None])
A1 = init_weights([9, 81])
bias1 = init_weights([81])
A2 = init_weights([81, 9])
bias2 = init_weights([9])
model_output = model(X, A1, A2, bias1, bias2)
```

11. 声明算法模型的损失函数，该函数是最后输出的逻辑变换的平均softmax值。然后声明训练步长和优化器。为了将来可以和训练好的模型对局，我们还需要创建预测操作，代码如下：

```
loss = tf.reduce_mean( tf.nn.sparse_softmax_cross_entropy_with_
logits(model_output, Y))
train_step = tf.train.GradientDescentOptimizer(0.025).
minimize(loss)
prediction = tf.argmax(model_output, 1)
```

12. 初始化变量，遍历迭代训练神经网络模型，代码如下：

```

# Initialize variables
init = tf.initialize_all_variables()
sess.run(init)
loss_vec = []
for i in range(10000):
    # Select random indices for batch
    rand_indices = np.random.choice(range(len(train_set)), batch_size, replace=False)
    # Get batch
    batch_data = [train_set[i] for i in rand_indices]
    x_input = [x[0] for x in batch_data]
    y_target = np.array([y[1] for y in batch_data])
    # Run training step
    sess.run(train_step, feed_dict={X: x_input, Y: y_target})
    # Get training loss
    temp_loss = sess.run(loss, feed_dict={X: x_input, Y: y_target})
    loss_vec.append(temp_loss)
    if i%500==0:
        print('iteration ' + str(i) + ' Loss: ' + str(temp_loss))

```

13.绘制模型训练的损失函数，代码如下（对应的图见图6-10）：

```

plt.plot(loss_vec, 'k-', label='Loss')
plt.title('Loss (MSE) per Generation')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()

```

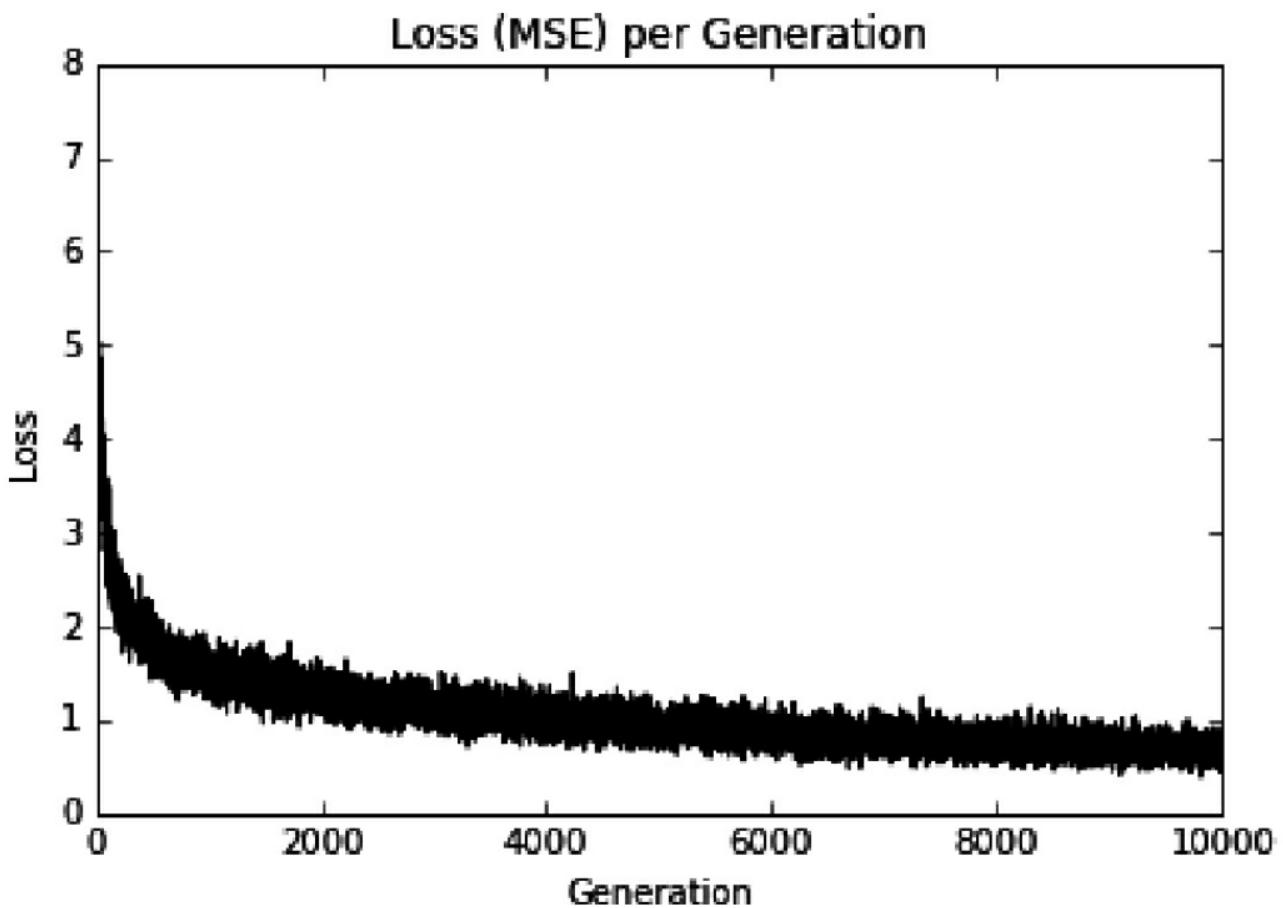


图6-10 迭代10000次训练的井字棋模型的损失函数图

下面绘制模型训练的损失函数：

1.为了测试模型，将展示如何在测试棋盘（从训练集中移除的数据）使用。我们希望看到模型能生成预测落子点的索引，并且索引值为6。在大部分情况下，模型都会成功预测，代码如下：

```
test_boards = [test_board]
feed_dict = {x: test_boards}
logits = sess.run(model_output, feed_dict=feed_dict)
predictions = sess.run(prediction, feed_dict=feed_dict)
print(predictions)
```

2.输出结果如下：

[6]

3.为了能够评估训练模型，我们计划和训练好的模型进行对局。为了实现该功能，我们创建一个函数来检测是否赢了棋局，这样程序才能在该结束的时间喊停，代码如下：

```

def check(board):
    wins = [[0,1,2], [3,4,5], [6,7,8], [0,3,6], [1,4,7], [2,5,8],
[0,4,8], [2,4,6]]
    for i in range(len(wins)):
        if board[wins[i][0]]==board[wins[i][1]]==board[wins[i]
[2]]==1.:
            return(1)
        elif board[wins[i][0]]==board[wins[i][1]]==board[wins[i]
[2]]== -1.:
            return(-1)
    return(0)

```

4.现在遍历迭代，同训练模型进行对局。起始棋盘为空棋盘，即为全0值；然后询问棋手要在哪个位置落棋子，即输入0-8的索引值；接着将其传入训练模型进行预测。对于模型的走棋，我们获得了多个可能的预测。最后显示井字棋游戏的样例。对于该游戏来说，我们发现训练的模型表现得并不理想，代码如下：

```

game_tracker = [0., 0., 0., 0., 0., 0., 0., 0., 0.]
win_logical = False
num_moves = 0
while not win_logical:
    player_index = input('Input index of your move (0-8): ')
    num_moves += 1
    # Add player move to game
    game_tracker[int(player_index)] = 1.

    # Get model's move by first getting all the logits for each
    index
    [potential_moves] = sess.run(model_output, feed_dict={x:
[game_tracker]})

    # Now find allowed moves (where game tracker values = 0.0)
    allowed_moves = [ix for ix,x in enumerate(game_tracker) if
x==0.0]

    # Find best move by taking argmax of logits if they are in
    allowed moves
    model_move = np.argmax([x if ix in allowed_moves else -999.0
for ix,x in enumerate(potential_moves)])

```

```
# Add model move to game
game_tracker[int(model_move)] = -1.
print('Model has moved')
print_board(game_tracker)
# Now check for win or too many moves
if check(game_tracker)==1 or num_moves>=5:
    print('Game Over!')
    win_logical = True
```

5.人机交互的输出结果如下：

Input index of your move (0-8): 4

Model has moved

o		

		x

Input index of your move (0-8): 6

Model has moved

o		

		x

x		

Input index of your move (0-8): 2

Model has moved

o		
x		x

o		x

x		

Game Over!

6.8.3 工作原理

我们训练一个神经网络模型来玩井字棋游戏，该模型需要传入棋盘位置，其中棋盘的位置是用一个九维向量来表示的。然后预测最佳落子点。我们需要赋值可能的井字棋棋盘，应用随机转换来增加训练集的大小。

为了测试算法模型，我们移除一个棋盘位置列表和对应的最佳落子点，然后看训练模型能否生成预测的最佳落棋点。最后，我们也和训练模型进行对局，但是结果并不理想，我们仍然需要尝试不同的架构和训练方法来提高效果。

第7章 自然语言处理

本章将介绍TensorFlow在文本处理中的使用。先介绍“词袋”的工作原理和“词袋”的使用方法，然后讲解更高级的词嵌入方法，比如，Word2Vec和Doc2Vec。

- 词袋的使用
- TensorFlow实现TF-IDF算法
- TensorFlow实现skip-gram模型
- TensorFlow实现CBOW词嵌入模型
- 使用TensorFlow的Word2Vec预测
- TensorFlow实现基于Doc2Vec的情感分析

注意，读者可以在Github上找到本章的所有代码，网址：<https://github.com/nfmccclure/tensorflow-cookbook>。

7.1 文本处理介绍

到目前为止，我们介绍的机器学习算法都是应用到数值输入。如果我们想应用到文本处理，就必须找到一种方法将文本转化成数字。有许多方法可以实现该功能，这里我们将介绍一些常用的方法。

假设要处理一句话，TensorFlow让这类机器学习变得简单，我们可以把单词转换成易观察的有序的数字。一句话转换成12345。然后当我们看到一个新的句子，机器学习很容易将其翻译成3405，用0代表不能识别的单词。在前面的两个例子中，我们把词汇限制为6个数字。对于长文本，我们可以根据所需选择单词数，一般选择的单词是使用频率高的词汇，并用0标注其他任意单词。

如果单词learning用数字4表示，单词makes用数字2表示，那很容易地认为单词learning是单词makes的两倍。因为我们不期望两个单词之间有数值关系，所以我们假设这些数字仅仅代表分类，而不具有数值关系。

另一个问题是，两句话的长度不一样。我们的算法模型期望的输入是相同长度的语句。为了解决这个问题，我们把句子转成一个稀疏向量。该稀疏向量的规则是，如果对应索引上的单词存在，则对应的索引位置的值为1。

TensorFlow	makes	machine	learning	easy
1	2	3	4	5

`first_sentence = [0, 1, 1, 1, 1, 1]`

Machine	learning	is	easy
3	4	0	5

`second_sentence = [1, 0, 0, 1, 1, 1]`

这种方法的缺点是损失了语句中单词顺序的特征。TensorFlow makes machine learning easy和machine learning makes TensorFlow easy，不同的两句话却具有相同句子稀疏向量。

值得注意的是，这些向量的长度是相等的，并且与我们所选的词汇一致。一般情况下，我们会选择非常大的词汇量，所以这些句子向量非常稀疏。刚介绍的这种词嵌入方法称为“词袋”，下一节将会介绍。

另外一个缺点是，单词is和TensorFlow具有相同的数值化索引值1。但是我们很明显地看到单词is要比单词TensorFlow的重要性弱。

我们将在本章中阐述不同的词嵌入方法，试图解决上面的问题。下面先来看下“词袋”的实现。

7.2 词袋的使用

本节展示如何使用TensorFlow的“词袋”嵌入。“词袋”嵌入映射的原理在上一节已经讲过，这里只展示如何使用“词袋”嵌入来进行垃圾短信的预测。

7.2.1 开始

为了阐述在文本数据集上如何使用“词袋”，我们将使用UCI机器学习数据库中的垃圾短信文本数据集（<https://archive.ics.uci.edu/ml/datasets/SWS+Spam+Collection>）该垃圾短信数据集中有正常短信和垃圾短信。我们将下载该数据集，存储好以备后用。然后用“词袋”的方法处理，预测一条文本是否为垃圾短信。我们将使用不含隐藏层的逻辑模型来训练“词袋”，采用批量大小为1的随机训练，并计算留存的测试集的准确度。

7.2.2 动手做

对于本例，首先获取数据集，归一化和分割文本数据，运行词嵌入函数，训练逻辑函数来预测垃圾短信。

1. 导入必要的编程库。本例中需要.zip文件库来解压从UCI机器学习数据库中下载的.zip文件，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import os
import numpy as np
import csv
import string
import requests
import io
from zipfile import ZipFile
from tensorflow.contrib import learn
sess = tf.Session()
```

2. 为了让脚本运行时不用每次都去下载文本数据，我们将下载文件存储，并检查之前是否保存过。该步骤避免了文本数据的重复下载。下载完文本数据集后，抽取输入数据和目标数据，并调整目标值（垃圾短信（spam）置为1，正常短信（ham）置为0）。具体代码如下：

```

save_file_name = os.path.join('temp', 'temp_spam_data.csv')
if os.path.isfile(save_file_name):
    text_data = []
    with open(save_file_name, 'r') as temp_output_file:
        reader = csv.reader(temp_output_file)
        for row in reader:
            text_data.append(row)
else:
    zip_url = 'http://archive.ics.uci.edu/ml/machine-learning-
databases/00228/smsspamcollection.zip'
    r = requests.get(zip_url)
    z = ZipFile(io.BytesIO(r.content))
    file = z.read('SMSSpamCollection')
    # Format Data
    text_data = file.decode()
    text_data = text_data.encode('ascii', errors='ignore')
    text_data = text_data.decode().split('\n')
    text_data = [x.split('\t') for x in text_data if len(x)>=1]

    # And write to csv
    with open(save_file_name, 'w') as temp_output_file:
        writer = csv.writer(temp_output_file)
        writer.writerows(text_data)
texts = [x[1] for x in text_data]
target = [x[0] for x in text_data]
# Relabel 'spam' as 1, 'ham' as 0
target = [1 if x=='spam' else 0 for x in target]

```

3.为了减小词汇量大小，我们对文本进行规则化处理。移除文本中大小写和数字的影响，代码如下：

```

# Convert to lower case
texts = [x.lower() for x in texts]
# Remove punctuation
texts = [''.join(c for c in x if c not in string.punctuation) for
x in texts]
# Remove numbers
texts = [''.join(c for c in x if c not in '0123456789') for x in
texts]
# Trim extra whitespace
texts = [' '.join(x.split()) for x in texts]

```

4.计算最长句子大小。我们使用文本数据集的文本长度直方图（见图7-1），并取最佳截止点（本例中取值为25个单词），代码如下：

```

# Plot histogram of text lengths
text_lengths = [len(x.split()) for x in texts]
text_lengths = [x for x in text_lengths if x < 50]
plt.hist(text_lengths, bins=25)
plt.title('Histogram of # of Words in Texts')
sentence_size = 25
min_word_freq = 3

```

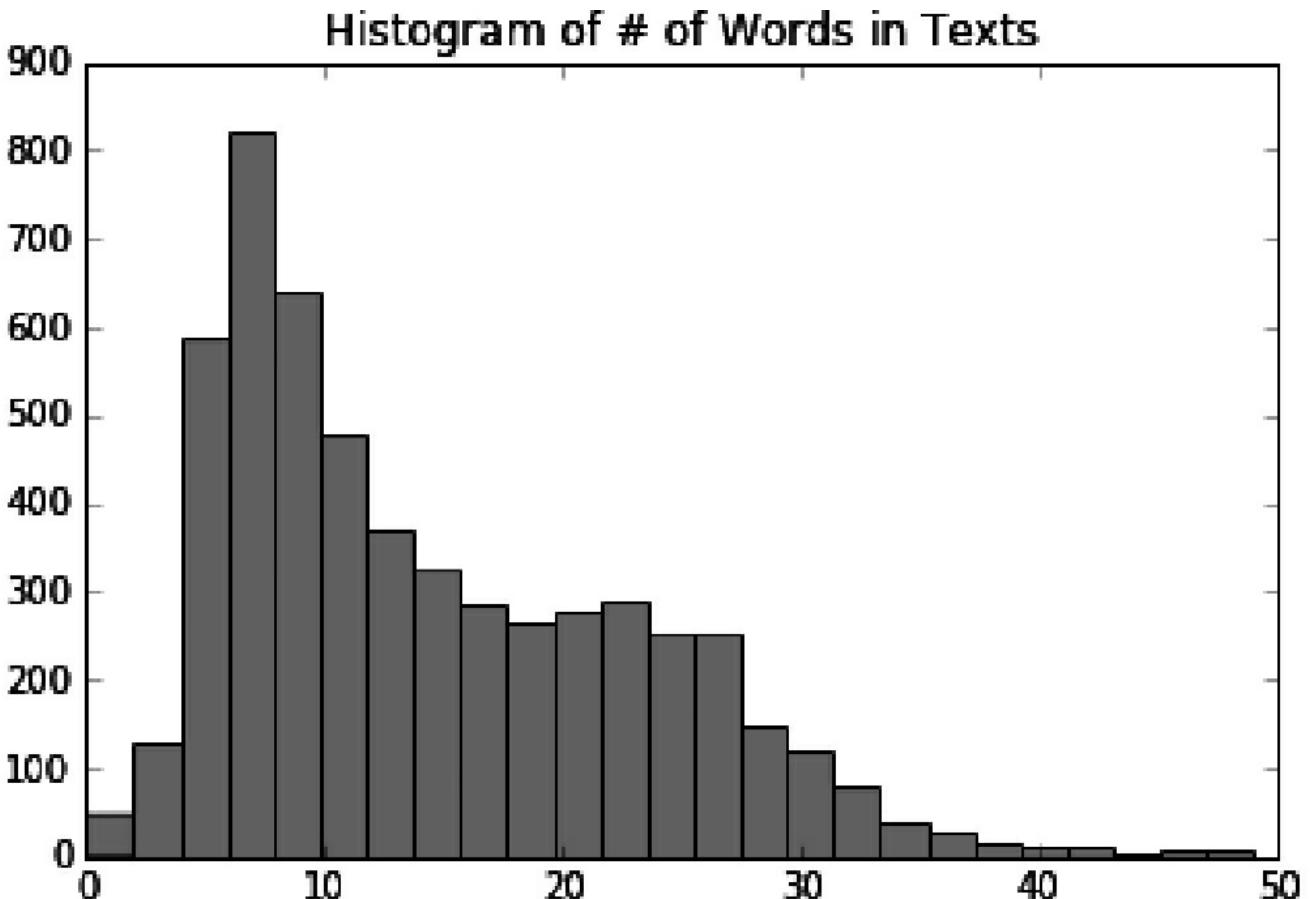


图7-1 文本数据中的单词数的直方图。我们用该直方图选出最大单词长度。本例设为25个单词，但是
也可以设为30或者40

5.TensorFlow自带分词器VocabularyProcessor()，该函数位于learn.preprocessing库，代码如下：

```

vocab_processor = learn.preprocessing.
VocabularyProcessor(sentence_size, min_frequency=min_word_freq)
vocab_processor.fit_transform(texts)
embedding_size = len(vocab_processor.vocabulary_)

```

6.分割数据集为训练集和测试集，代码如下：

```

train_indices = np.random.choice(len(texts),
round(len(texts)*0.8), replace=False)
test_indices = np.array(list(set(range(len(texts))) - set(train_
indices)))
texts_train = [x for ix, x in enumerate(texts) if ix in train_
indices]
texts_test = [x for ix, x in enumerate(texts) if ix in test_
indices]
target_train = [x for ix, x in enumerate(target) if ix in train_
indices]
target_test = [x for ix, x in enumerate(target) if ix in test_
indices]

```

7. 声明词嵌入矩阵。将句子单词转成索引，再将索引转成one-hot向量，该向量为单位矩阵。我们使用该矩阵为每个单词查找稀疏向量，并加入到词稀疏向量，代码如下：

```
identity_mat = tf.diag(tf.ones(shape=[embedding_size]))
```

8. 因为最后要进行逻辑回归预测垃圾短信的概率，所以我们需要声明逻辑回归变量。然后声明占位符，注意x_data输入占位符是整数类型，因为它被用来查找单位矩阵的行索引，而TensorFlow要求其为整数类型，代码如下：

```

A = tf.Variable(tf.random_normal(shape=[embedding_size, 1]))
b = tf.Variable(tf.random_normal(shape=[1, 1]))
# Initialize placeholders
x_data = tf.placeholder(shape=[sentence_size], dtype=tf.int32)
y_target = tf.placeholder(shape=[1, 1], dtype=tf.float32)

```

9. 使用TensorFlow的嵌入查找函数来映射句子中的单词为单位矩阵的one-hot向量。然后把前面的词向量求和，代码如下：

```
x_embed = tf.nn.embedding_lookup(identity_mat, x_data)
x_col_sums = tf.reduce_sum(x_embed, 0)
```

10. 有了每个句子的固定长度的句子向量之后，我们进行逻辑回归训练。声明逻辑回归算法模型。因为一次做一个数据点的随机训练，所有扩展输入数据的维度，并进行线性回归操作。记住，TensorFlow中的损失函数已经包含了sigmoid激励函数，所以我们不需要在输出时加入激励函数，代码如下：

```
x_col_sums_2D = tf.expand_dims(x_col_sums, 0)
model_output = tf.add(tf.matmul(x_col_sums_2D, A), b)
```

11. 声明训练模型的损失函数、预测函数和优化器，代码如下：

```

loss = tf.reduce_mean(tf.nn.sigmoid_cross_entropy_with_
logits(model_output, y_target))
# Prediction operation
prediction = tf.sigmoid(model_output)
# Declare optimizer
my_opt = tf.train.GradientDescentOptimizer(0.001)
train_step = my_opt.minimize(loss)

```

12.接下来初始化计算图中的变量，代码如下：

```

init = tf.initialize_all_variables()
sess.run(init)

```

13.开始迭代训练。TensorFlow的内建函数vocab_processor.fit()是一个符合本例的生成器。我们将使用该函数来进行随机训练逻辑回归模型。为了得到准确度的趋势，我们保留最近50次迭代的平均值。如果只绘制当前值，我们会依赖预测训练数据点是否正确而得到1或者0的值，代码如下：

```

loss_vec = []
train_acc_all = []
train_acc_avg = []
for ix, t in enumerate(vocab_processor.fit_transform(texts_train)):
    y_data = [[target_train[ix]]]

    sess.run(train_step, feed_dict={x_data: t, y_target: y_data})

    temp_loss = sess.run(loss, feed_dict={x_data: t, y_target: y_data})
    loss_vec.append(temp_loss)

    if (ix+1)%10==0:
        print('Training Observation #' + str(ix+1) + ': Loss = ' +
str(temp_loss))

    # Keep trailing average of past 50 observations accuracy
    # Get prediction of single observation
    [[temp_pred]] = sess.run(prediction, feed_dict={x_data:t, y_
target:y_data})
    # Get True/False if prediction is accurate
    train_acc_temp = target_train[ix]==np.round(temp_pred)
    train_acc_all.append(train_acc_temp)
    if len(train_acc_all) >= 50:
        train_acc_avg.append(np.mean(train_acc_all[-50:]))

```

14.训练结果如下：

```
Starting Training Over 4459 Sentences.  
Training Observation #10: Loss = 5.45322  
Training Observation #20: Loss = 3.58226  
Training Observation #30: Loss = 0.0  
Training Observation #4430: Loss = 1.84636  
Training Observation #4440: Loss = 1.46626e-05  
Training Observation #4450: Loss = 0.045941
```

15.为了得到测试集的准确度，我们重复处理过程，对测试文本只进行预测操作，而不进行训练操作，

代码如下：

```
print('Getting Test Set Accuracy')  
test_acc_all = []  
  
for ix, t in enumerate(vocab_processor.fit_transform(texts_test)):  
    y_data = [[target_test[ix]]]  
  
    if (ix+1)%50==0:  
        print('Test Observation #' + str(ix+1))  
  
        # Keep trailing average of past 50 observations accuracy  
        # Get prediction of single observation  
        [[temp_pred]] = sess.run(prediction, feed_dict={x_data:t, y_  
target:y_data})  
        # Get True/False if prediction is accurate  
        test_acc_temp = target_test[ix]==np.round(temp_pred)  
        test_acc_all.append(test_acc_temp)  
print('\nOverall Test Accuracy: {}'.format(np.mean(test_acc_all)))  
Getting Test Set Accuracy For 1115 Sentences.  
Test Observation #10  
Test Observation #20  
Test Observation #30  
Test Observation #1000  
Test Observation #1050  
Test Observation #1100  
Overall Test Accuracy: 0.8035874439461883
```

7.2.3 工作原理

在本例中，我们处理垃圾短信文本数据。使用TensorFlow的词汇处理函数来创建标准的词汇和句子向量，该句子向量是文本单词向量的总和。我们在逻辑回归算法模型中进行句子向量的训练，预测垃圾短信获得了大约80%的准确度。

7.2.4 延伸学习

值得注意的是本例中限制句子长度的动机。本例限制文本大小为25个单词。这是“词袋”的最佳实践，因为文本长度影响到预测结果。想象一下，如果我们发现一个单词预测为正常短信，然后该单词出现许多次，那就变成垃圾短信了。

事实上，这在数据不均衡的情况下最普遍。在数据不均衡的情况下，垃圾短信变得很难找到，而正常短信很容易发现。由于这个事实，我们创建的词汇就会严重倾斜到正常短信数据这边。如果我们不限制文本长度，那发垃圾短信者会利用这一点，创建很长的文本，而长文本触发逻辑回归模型中非垃圾短信因素的概率更高。

下一节试图以词频来更好地解决该问题。

7.3 用TensorFlow实现TF-IDF算法

因为我们为每个单词选择词嵌入，所以可能需要调整某些特定单词的权重。在这种策略下，应提高有用词汇的权重，降低常用单词或者无意义单词的权重。本节将展示使用该方法的词嵌入。

7.3.1 开始

TF-IDF（Text Frequency-Inverse Document Frequency）算法表示为词频和逆文档频率的乘积。

上一节介绍了“词袋”的方法，其为句子中每个单词出现一次就分配一个值“1”。这可能不是太理想的方法，每类句子（前面的例子中分垃圾短信和非垃圾短信）可能有相同频率的the、and和其他的单词。但是Viagra和sale这类词可能在判断短信是否为垃圾短信时应该增加权重。

首先，我们考虑词频。词频是某个单词在文档中出现的频率。词频（TF）的目的是找到每个单词的权重：

$$w_{tf-idf} = w_{tf} \cdot \log\left(\frac{1}{w_{df}}\right)$$

但是the和andx之类的单词在每个文档中出现的频率都很高，我们需要降低这些单词的权重。所以，用词频（TF）乘以逆文档频率（其为所有包含该单词的文档频率的倒数）即可找到重要的单词。但是因为语料库往往数量巨大，普遍的做法是对文档频率求log。这样就得到每个单词在每个文档中的TF-IDF公式：

$$w_{tf-idf} = w_{tf} \cdot \log\left(\frac{1}{w_{df}}\right)$$

其中， w_{tf} 是文档的词频， w_{df} 是包含该单词的所有文档的总频率。TF-IDF值高代表着单词在文档中的重要性。

创建TF-IDF向量要求向内存加载所有的文本数据进，并在开始训练模型之前计算每个单词发生的次数。由于该原因，我们将使用scikit-learn创建TF-IDF向量，但是采用TensorFlow拟合逻辑回归模型。

7.3.2 动手做

1.导入必要的编程库。本例中会导入scikit-learn的TF-IDF处理模块处理文本数据集，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import csv
import numpy as np
import os
import string
import requests
import io
import nltk
from zipfile import ZipFile
from sklearn.feature_extraction.text import TfidfVectorizer
```

2.创建一个计算图会话，声明批量大小和词汇的最大长度，代码如下：

```
sess = tf.Session()
batch_size= 200
max_featurtes = 1000
```

3.加载文本数据集。可以从网站下载或者从上次保存的temp文件夹加载，代码如下：

```

save_file_name = os.path.join('temp', 'temp_spam_data.csv')
if os.path.isfile(save_file_name):
    text_data = []
    with open(save_file_name, 'r') as temp_output_file:
        reader = csv.reader(temp_output_file)
        for row in reader:
            text_data.append(row)
else:
    zip_url = 'http://archive.ics.uci.edu/ml/machine-learning-
databases/00228/smsspamcollection.zip'
    r = requests.get(zip_url)
    z = ZipFile(io.BytesIO(r.content))
    file = z.read('SMSSpamCollection')
    # Format Data
    text_data = file.decode()
    text_data = text_data.encode('ascii', errors='ignore')
    text_data = text_data.decode().split('\n')
    text_data = [x.split('\t') for x in text_data if len(x)>=1]

    # And write to csv
    with open(save_file_name, 'w') as temp_output_file:
        writer = csv.writer(temp_output_file)
        writer.writerows(text_data)
texts = [x[1] for x in text_data]
target = [x[0] for x in text_data]
# Relabel 'spam' as 1, 'ham' as 0
target = [1. if x=='spam' else 0. for x in target]

```

4. 声明词汇大小。在本例中也会将所有字符转成小写，剔除标点符号和数字，代码如下：

```

# Lower case
texts = [x.lower() for x in texts]
# Remove punctuation
texts = [''.join(c for c in x if c not in string.punctuation) for
x in texts]
# Remove numbers
texts = [''.join(c for c in x if c not in '0123456789') for x in
texts]
# Trim extra whitespace
texts = [' '.join(x.split()) for x in texts]

```

5. 为了使用scikit-learn的TF-IDF处理函数，我们需要输入切分好的语句（即将句子切分为相关的单词）。nltk包可以提供非常棒的分词器来实现分词功能，代码如下：

```

def tokenizer(text):
    words = nltk.word_tokenize(text)
    return words
# Create TF-IDF of texts
tfidf = TfidfVectorizer(tokenizer=tokenizer, stop_words='english',
max_features=max_features)
sparse_tfidf_texts = tfidf.fit_transform(texts)

```

6. 分割数据集为训练集和测试集，代码如下：

```

train_indices = np.random.choice(sparse_tfidf_texts.shape[0],
round(0.8*sparse_tfidf_texts.shape[0]), replace=False)3test_
indices = np.array(list(set(range(sparse_tfidf_texts.shape[0])) -
set(train_indices)))
texts_train = sparse_tfidf_texts[train_indices]
texts_test = sparse_tfidf_texts[test_indices]
target_train = np.array([x for ix, x in enumerate(target) if ix in
train_indices])
target_test = np.array([x for ix, x in enumerate(target) if ix in
test_indices])

```

7. 声明逻辑回归模型的变量和数据集的占位符，代码如下：

```

A = tf.Variable(tf.random_normal(shape=[max_features,1]))
b = tf.Variable(tf.random_normal(shape=[1,1]))
# Initialize placeholders
x_data = tf.placeholder(shape=[None, max_features], dtype=tf.
float32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)

```

8. 声明算法模型操作和损失函数。注意，逻辑回归算法的sigmoid部分是在损失函数中实现的，代码如下：

```

model_output = tf.add(tf.matmul(x_data, A), b)
loss = tf.reduce_mean(tf.nn.sigmoid_cross_entropy_with_
logits(model_output, y_target))

```

9. 为计算图增加预测函数和准确度函数（可以让我们看到模型训练中训练集和测试集的准确度），代码如下：

```

prediction = tf.round(tf.sigmoid(model_output))
predictions_correct = tf.cast(tf.equal(prediction, y_target),
tf.float32)
accuracy = tf.reduce_mean(predictions_correct)

```

10. 声明优化器，初始化计算图中的变量，代码如下：

```
my_opt = tf.train.GradientDescentOptimizer(0.0025)
train_step = my_opt.minimize(loss)
# Intitialize Variables
init = tf.initialize_all_variables()
sess.run(init)
```

11. 遍历迭代训练模型10000次，记录测试集和训练集损失，以及每迭代100次的准确度，然后每迭代500次就打印状态信息，代码如下：

```

train_loss = []
test_loss = []
train_acc = []
test_acc = []
i_data = []
for i in range(10000):
    rand_index = np.random.choice(texts_train.shape[0],
size=batch_size)
    rand_x = texts_train[rand_index].todense()
    rand_y = np.transpose([target_train[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})

    # Only record loss and accuracy every 100 generations
    if (i+1)%100==0:
        i_data.append(i+1)
        train_loss_temp = sess.run(loss, feed_dict={x_data:
rand_x, y_target: rand_y})
        train_loss.append(train_loss_temp)

        test_loss_temp = sess.run(loss, feed_dict={x_data: texts_
test.todense(), y_target: np.transpose([target_test])})
        test_loss.append(test_loss_temp)

        train_acc_temp = sess.run(accuracy, feed_dict={x_data:
rand_x, y_target: rand_y})
        train_acc.append(train_acc_temp)

        test_acc_temp = sess.run(accuracy, feed_dict={x_data:
texts_test.todense(), y_target: np.transpose([target_test])})
        test_acc.append(test_acc_temp)
    if (i+1)%500==0:
        acc_and_loss = [i+1, train_loss_temp, test_loss_temp,
train_acc_temp, test_acc_temp]
        acc_and_loss = [np.round(x,2) for x in acc_and_loss]
        print('Generation # {}. Train Loss (Test Loss): {:.2f} ({:.2f}). Train Acc (Test Acc): {:.2f} ({:.2f})'.format(*acc_and_
loss))

```

12.输出结果如下：

```
Generation # 500. Train Loss (Test Loss): 0.69 (0.73). Train Acc  
(Test Acc): 0.62 (0.57)  
Generation # 1000. Train Loss (Test Loss): 0.62 (0.63). Train Acc  
(Test Acc): 0.68 (0.66)  
...  
Generation # 9500. Train Loss (Test Loss): 0.39 (0.45). Train Acc  
(Test Acc): 0.89 (0.85)  
Generation # 10000. Train Loss (Test Loss): 0.48 (0.45). Train Acc  
(Test Acc): 0.84 (0.85)
```

13.绘制训练集和测试集的准确度和损失函数（见图7-2和图7-3）：

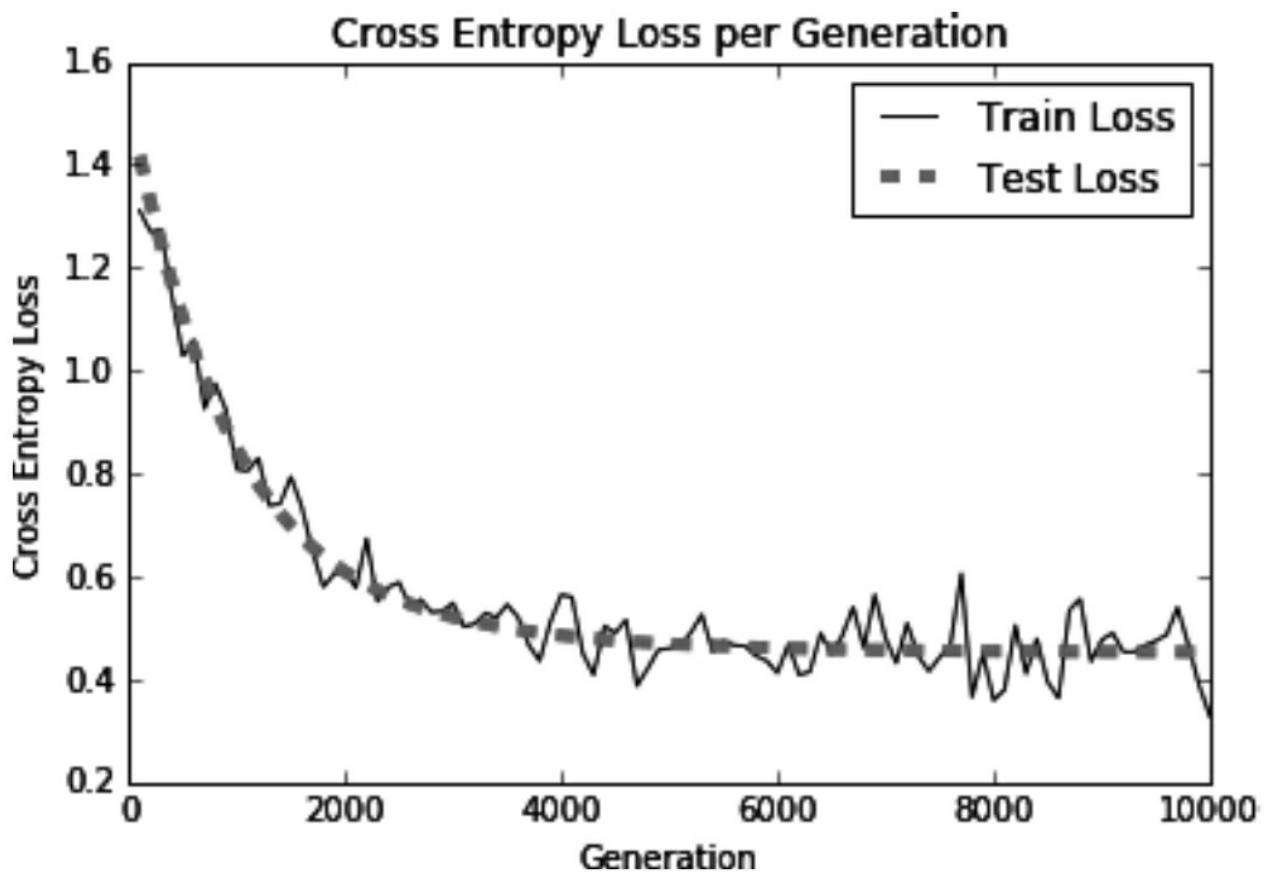


图7-2 逻辑回归模型计算TF-IDF值的交叉熵损失图

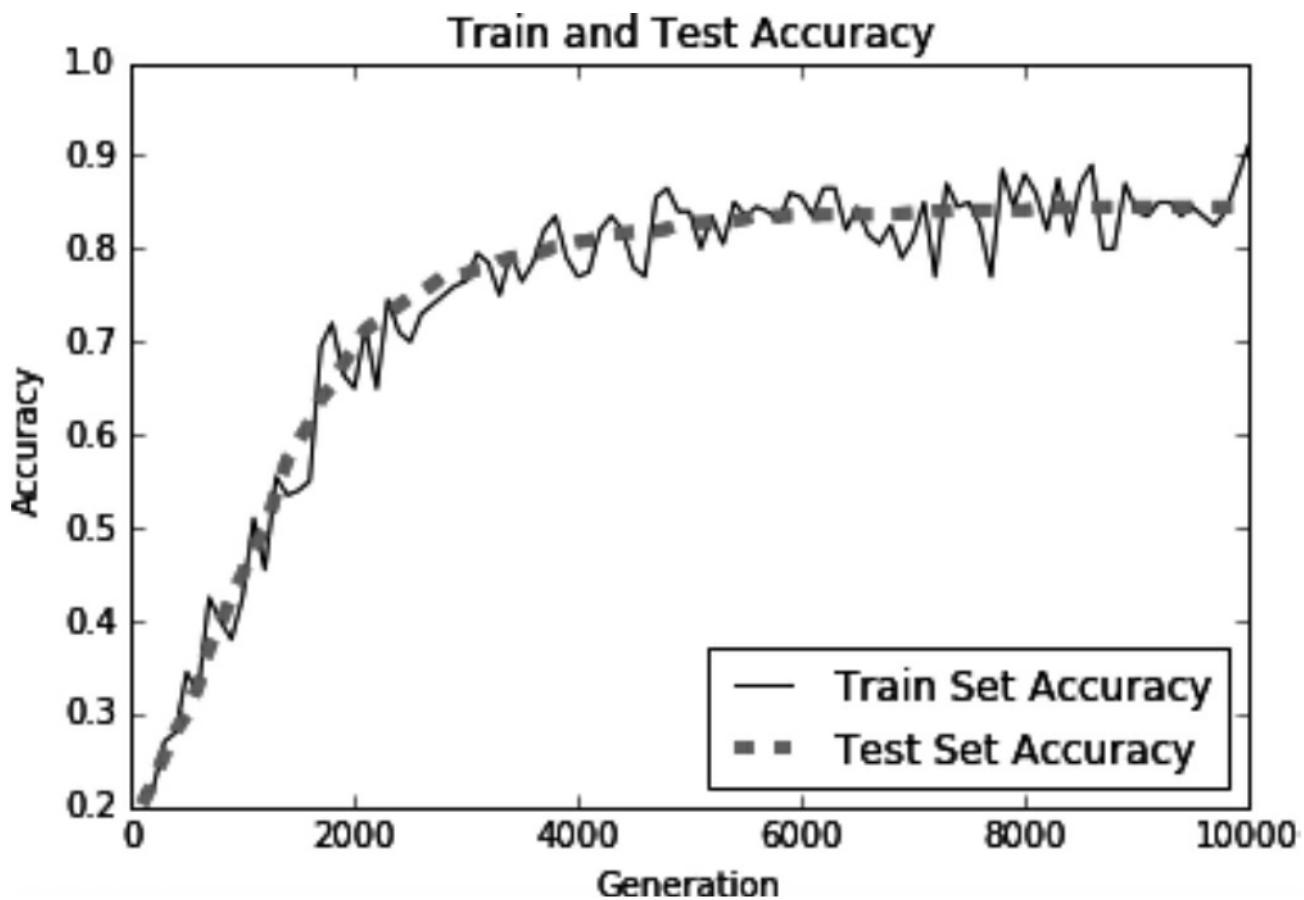


图7-3 逻辑回归模型计算TF-IDF值的训练集和测试集准确度图

7.3.3 工作原理

使用TF-IDF值来进行模型训练，其预测函数的准确度由上一节“词袋”方法的80%提高到90%。我们采用scikit-learn的TF-IDF处理函数并用TF-IDF值进行逻辑回归模型训练。

7.3.4 延伸学习

本节解决了单词重要性的问题，但是没有解决单词顺序的问题。“词袋”方法和TF-IDF方法都未考虑句子中单词的顺序这一特征。下一节引入的Word2Vec技术试图解决该问题。

7.4 用TensorFlow实现skip-gram模型

在上一节中，我们已经描述了训练模型前的词嵌套。使用神经网络算法可以得到训练过程中词嵌套向量。本节将阐述的方法称为skip-gram嵌套。

7.4.1 开始

在前一节中，我们在创建词向量时未考虑相关单词顺序特征。在2013年早期，就职于Google的Tomas Mikolov和另一些研究者发表了一篇论文（<https://arxiv.org/abs/1301.3781>），并创建了一种词向量方法来解决该问题，该方法被命名为Word2Vec。

基本的思路是创建词向量来表现单词上下文关系。我们寻找如何理解互相关联的单词。下面是单词如何嵌套的例子：

$$\text{king} - \text{man} + \text{woman} = \text{queen}$$

$$\text{India pale ale} - \text{hops} + \text{malt} = \text{stout}$$

如果仅仅考虑每个单词位置之间的关系，那么我们可以得到数值化的表示。如果分析大量连续文档，我们可以看到，单词king、man和queen是紧密联系的。如果已知man和woman语义相关联，那我们可以得出单词man和king的关系就如同单词woman和queen的关系。

为了找到这种词嵌套，我们使用神经网络算法预测输入单词的上下文相关的单词。我们也可以很简单地将其转化成给出一个上下文相关的单词集合来预测目标单词。我们先讲解第一种方法，不过在Word2Vec程序中都有实现。第一种给出目标单词进行上下文相关单词的预测，称为skip-gram模型（见图7-4）。在下一节中，我们将实现另外一种方法，从上下文相关单词集合中预测目标单词，该方法称为“连续词袋”（continuous bag of words，CBOW）方法：

本节将使用康奈尔大学的电影影评数据集（<http://www.cs.cornell.edu/people/pabo/movie-review-data/>）来实现skip-gram模型。

7.4.2 动手做

本节将创建几个辅助函数：加载数据函数、归一化文本函数、生成词汇表函数和生成批量数据函数。在实现这些函数之后，我们开始训练词向量。我们不预测任何目标变量，而是拟合词向量。

1. 导入必要的编程库，开始一个计算图会话，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import numpy as np
import random
import os
import string
import requests
import collections
import io
import tarfile
import urllib.request
from nltk.corpus import stopwords
sess = tf.Session()
```

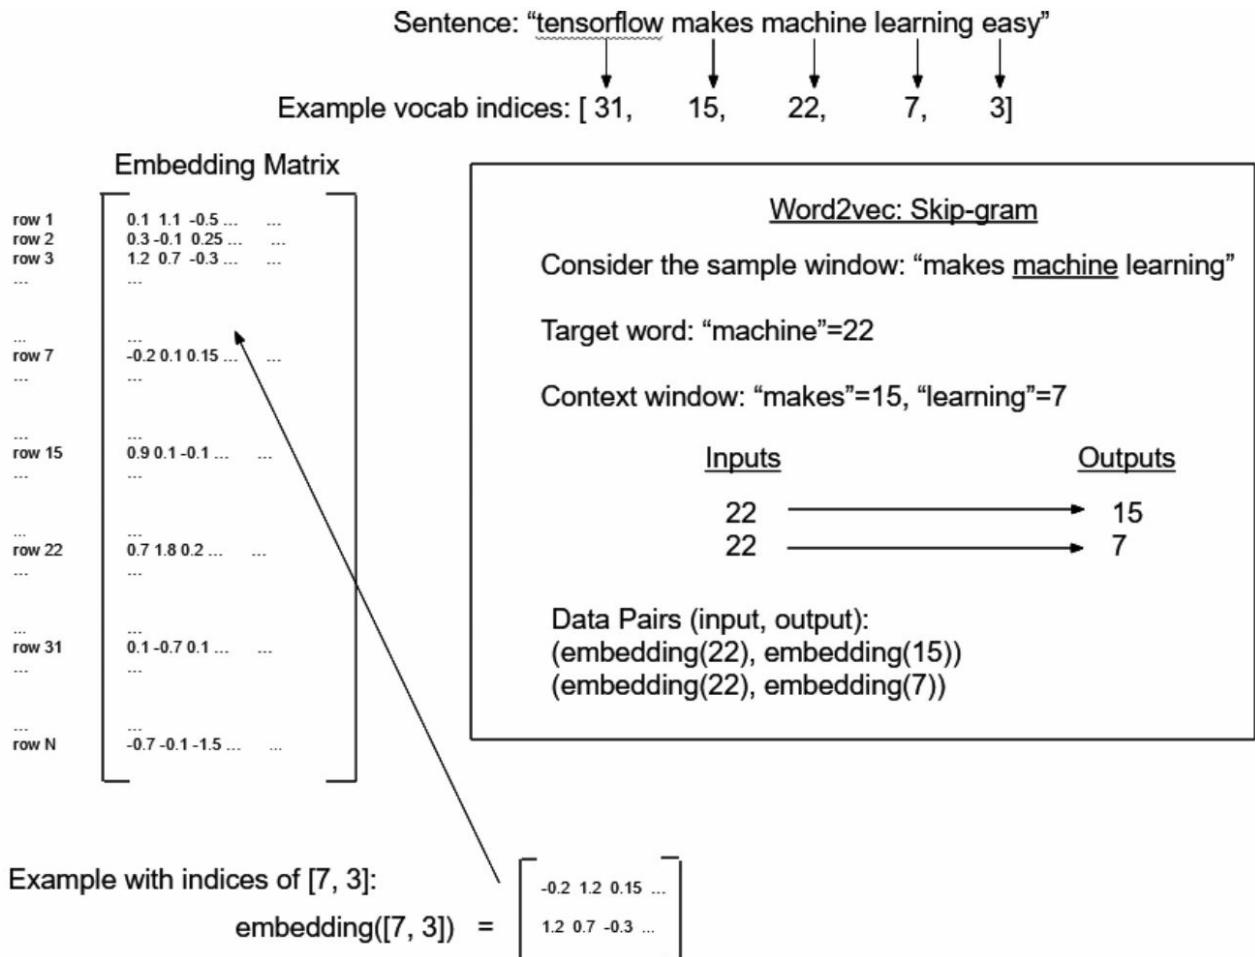


图7-4 Word2Vec中的skip-gram模型。skip-gram模型从目标单词中预测上下文窗口大小（两边宽度均为1）内的单词

2. 声明一些模型参数。一次将查找50对词嵌套（批量大小）。每个单词的嵌套大小是一个长度为200的向量，并且仅仅考虑频次为10000的单词（其他单词分类为“unknown”）。我们将迭代训练50000次，每迭代500次打印损失函数。然后声明一个num_sampled变量，该变量将在损失函数中使用，具体解释见下文。我们还需要声明skip-gram模型上下文窗口大小，本例中窗口大小设为2，即将查找目标单词两边各两个上下文单词。我们使用Python的nltk包做“停词”步骤。为了检测词向量的性能，选择一些常用的电影影评单词，每迭代2000次训练打印最近邻域单词。具体代码如下：

```
batch_size = 50
embedding_size = 200
vocabulary_size = 10000
generations = 50000
print_loss_every = 500
num_sampled = int(batch_size/2)
window_size = 2
stops = stopwords.words('english')
print_valid_every = 2000
valid_words = ['cliche', 'love', 'hate', 'silly', 'sad']
```

3. 声明数据加载函数，该函数会在下载数据前先检测是否已下载过该数据集，如果已下载过，将直接从磁盘加载数据，代码如下：

```
def load_movie_data():
    save_folder_name = 'temp'
    pos_file = os.path.join(save_folder_name, 'rt-polarity.pos')
    neg_file = os.path.join(save_folder_name, 'rt-polarity.neg')
    # Check if files are already downloaded
    if os.path.exists(save_folder_name):
        pos_data = []
        with open(pos_file, 'r') as temp_pos_file:
            for row in temp_pos_file:
                pos_data.append(row)
        neg_data = []
        with open(neg_file, 'r') as temp_neg_file:
            for row in temp_neg_file:
                neg_data.append(row)
    else: # If not downloaded, download and save
        movie_data_url = 'http://www.cs.cornell.edu/people/pabo/
movie-review-data/rt-polaritydata.tar.gz'
        stream_data = urllib.request.urlopen(movie_data_url)
        tmp = io.BytesIO()
        while True:
            s = stream_data.read(16384)
            if not s:
                break
            tmp.write(s)
        stream_data.close()
        tmp.seek(0)
        tar_file = tarfile.open(fileobj=tmp, mode="r:gz")
        pos = tar_file.extractfile('rt-polaritydata/rt-polarity.
pos')
        neg = tar_file.extractfile('rt-polaritydata/rt-polarity.
neg')
        # Save pos/neg reviews
        pos_data = []
        for line in pos:
            pos_data.append(line.decode('ISO-8859-1').
encode('ascii',errors='ignore').decode())
        neg_data = []
        for line in neg:
```

```

        neg_data.append(line.decode('ISO-8859-1').
encode('ascii',errors='ignore').decode())
    tar_file.close()
    # Write to file
    if not os.path.exists(save_folder_name):
        os.makedirs(save_folder_name)
    # Save files
    with open(pos_file, "w") as pos_file_handler:
        pos_file_handler.write(''.join(pos_data))
    with open(neg_file, "w") as neg_file_handler:
        neg_file_handler.write(''.join(neg_data))
texts = pos_data + neg_data
target = [1]*len(pos_data) + [0]*len(neg_data)
return(texts, target)
texts, target = load_movie_data()

```

4. 创建归一化文本函数。该函数输入一列字符串，转换大小字符，移除标点符号，移除数字，去除多余的空白字符，并移除“停词”，代码如下：

```

def normalize_text(texts, stops):
    # Lower case
    texts = [x.lower() for x in texts]
    # Remove punctuation
    texts = [''.join(c for c in x if c not in string.punctuation)
for x in texts]
    # Remove numbers
    texts = [''.join(c for c in x if c not in '0123456789') for x
in texts]
    # Remove stopwords
    texts = [' '.join([word for word in x.split() if word not in
(stops)]) for x in texts]
    # Trim extra whitespace
    texts = [' '.join(x.split()) for x in texts]

    return(texts)
texts = normalize_text(texts, stops)

```

5. 为了确保所有电影影评的有效性，我们将检查其中的影评长度。可以强制影评长度为三个单词或者更长长度的单词，代码如下：

```
target = [target[ix] for ix, x in enumerate(texts) if len(x.split()) > 2]
texts = [x for x in texts if len(x.split()) > 2]
```

6. 构建词汇表，创建函数来建立一个单词字典（该单词词典是单词和单词数对）。词频不够的单词（即标记为unknown的单词）标记为RARE，代码如下：

```
def build_dictionary(sentences, vocabulary_size):
    # Turn sentences (list of strings) into lists of words
    split_sentences = [s.split() for s in sentences]
    words = [x for sublist in split_sentences for x in sublist]
    # Initialize list of [word, word_count] for each word,
    # starting with unknown
    count = [['RARE', -1]]
    # Now add most frequent words, limited to the N-most frequent
    # (N=vocabulary size)
    count.extend(collections.Counter(words).most_common(vocabulary_size-1))
    # Now create the dictionary
    word_dict = {}
    # For each word, that we want in the dictionary, add it, then
    # make it the value of the prior dictionary length
    for word, word_count in count:
        word_dict[word] = len(word_dict)
    return(word_dict)
```

7. 创建一个函数将一系列的句子转化成单词索引列表，并将单词索引列表传入嵌套寻找函数，代码如下：

```

def text_to_numbers(sentences, word_dict):
    # Initialize the returned data
    data = []
    for sentence in sentences:
        sentence_data = []
        # For each word, either use selected index or rare word
index
        for word in sentence:
            if word in word_dict:
                word_ix = word_dict[word]
            else:
                word_ix = 0
            sentence_data.append(word_ix)
        data.append(sentence_data)
    return(data)

```

8. 创建单词字典，转换句子列表为单词索引列表，代码如下：

```

word_dictionary = build_dictionary(texts, vocabulary_size)
word_dictionary_rev = dict(zip(word_dictionary.values(), word_
dictionary.keys()))
text_data = text_to_numbers(texts, word_dictionary)

```

9. 从预处理的单词词典中，查找第二步中选择的验证单词的索引，代码如下：

```
valid_examples = [word_dictionary[x] for x in valid_words]
```

10. 创建函数返回skip-gram模型的批量数据。我们希望在单词对上训练模型，该单词对中第一个单词为训练输入（即窗口中央的目标单词）；另一个单词为窗口中所选的单词。例如，句子“the cat in the hat”，如果in为目标单词，那么该例句的上下文窗口大小为2的单词对（输入单词，输出单词）为：（the, in），（cat, in），（the, in），（hat, in）。具体代码如下：

```

def generate_batch_data(sentences, batch_size, window_size,
method='skip_gram'):
    # Fill up data batch

```

```

batch_data = []
label_data = []
while len(batch_data) < batch_size:
    # select random sentence to start
    rand_sentence = np.random.choice(sentences)
    # Generate consecutive windows to look at
    window_sequences = [rand_sentence[max((ix-window_size),0):(ix+window_size+1)] for ix, x in enumerate(rand_sentence)]
        # Denote which element of each window is the center word
        # of interest
        label_indices = [ix if ix<window_size else window_size for ix,x in enumerate(window_sequences)]

    # Pull out center word of interest for each window and
    # create a tuple for each window
    if method=='skip_gram':
        batch_and_labels = [(x[y], x[:y] + x[(y+1):]) for x,y
in zip(window_sequences, label_indices)]
            # Make it into a big list of tuples (target word,
            # surrounding word)
            tuple_data = [(x, y_) for x,y in batch_and_labels for
y_ in y]
    else:
        raise ValueError('Method {} not implemented
yet.'.format(method))

    # extract batch and labels
    batch, labels = [list(x) for x in zip(*tuple_data)]
    batch_data.extend(batch[:batch_size])
    label_data.extend(labels[:batch_size])
# Trim batch and label at the end
batch_data = batch_data[:batch_size]
label_data = label_data[:batch_size]

# Convert to numpy array
batch_data = np.array(batch_data)
label_data = np.transpose(np.array([label_data]))

return(batch_data, label_data)

```

11. 初始化嵌套矩阵，声明占位符和嵌套查找函数，代码如下：

```

embeddings = tf.Variable(tf.random_uniform([vocabulary_size,
    embedding_size], -1.0, 1.0))
# Create data/target placeholders
x_inputs = tf.placeholder(tf.int32, shape=[batch_size])
y_target = tf.placeholder(tf.int32, shape=[batch_size, 1])
valid_dataset = tf.constant(valid_examples, dtype=tf.int32)

# Lookup the word embedding:
embed = tf.nn.embedding_lookup(embeddings, x_inputs)

```

12.softmax损失函数是用来实现多类分类问题常见的损失函数，上一节中其计算预测错误单词分类的损失。因为本例中目标是10000个不同的分类，所以会导致稀疏性非常高。稀疏性会导致算法模型拟合或者收敛的问题。为了解决该问题，我们使用噪声对比损失函数（noise-contrastive error, NCE）。NCE损失函数将问题转换成一个二值预测，预测单词分类和随机噪声。`num_sampled`参数控制多少个批量转换为随机噪声。具体代码如下：

```

nce_weights = tf.Variable(tf.truncated_normal([vocabulary_size,
    embedding_size], stddev=1.0 / np.sqrt(embedding_size)))
nce_biases = tf.Variable(tf.zeros([vocabulary_size]))
loss = tf.reduce_mean(tf.nn.nce_loss(nce_weights, nce_biases,
embed,
y_target, num_sampled, vocabulary_size))

```

13.创建函数寻找验证单词周围的单词。我们将计算验证单词集和所有词向量之间的余弦相似度，打印出每个验证单词最接近的单词，代码如下：

```

norm = tf.sqrt(tf.reduce_sum(tf.square(embeddings), 1, keep_
dims=True))
normalized_embeddings = embeddings / norm
valid_embeddings = tf.nn.embedding_lookup(normalized_embeddings,
valid_dataset)
similarity = tf.matmul(valid_embeddings, normalized_embeddings,
transpose_b=True)

```

14.声明优化器函数，初始化模型变量，代码如下：

```

optimizer = tf.train.GradientDescentOptimizer(learning_rate=1.0).
minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)

```

15.迭代训练词嵌套，打印出损失函数和验证单词集单词的最接近的单词，代码如下：

```

loss_vec = []
loss_x_vec = []
for i in range(generations):
    batch_inputs, batch_labels = generate_batch_data(text_data,
batch_size, window_size)
    feed_dict = {x_inputs : batch_inputs, y_target : batch_labels}
    # Run the train step
    sess.run(optimizer, feed_dict=feed_dict)
    # Return the loss
    if (i+1) % print_loss_every == 0:
        loss_val = sess.run(loss, feed_dict=feed_dict)
        loss_vec.append(loss_val)
        loss_x_vec.append(i+1)
        print("Loss at step {} : {}".format(i+1, loss_val))

    # Validation: Print some random words and top 5 related words
    if (i+1) % print_valid_every == 0:
        sim = sess.run(similarity, feed_dict=feed_dict)
        for j in range(len(valid_words)):

            valid_word = word_dictionary_rev[valid_examples[j]]
            top_k = 5 # number of nearest neighbors
            nearest = (-sim[j, :]).argsort() [1:top_k+1]
            log_str = "Nearest to {}".format(valid_word)
            for k in range(top_k):
                close_word = word_dictionary_rev[nearest[k]]
                log_str = "%s %s," % (log_str, close_word)
            print(log_str)

```

16.输出结果如下:

```

Loss at step 500 : 13.387781143188477
Loss at step 1000 : 7.240757465362549
Loss at step 49500 : 0.9395825862884521
Loss at step 50000 : 0.30323168635368347
Nearest to cliche: walk, intrigue, brim, eileen, dumber,
Nearest to love: plight, fiction, complete, lady, bartleby,
Nearest to hate: style, throws, players, fearlessness, astringent,
Nearest to silly: delivers, meow, regain, nicely, anger,
Nearest to sad: dizzying, variety, existing, environment, tunney,

```

7.4.3 工作原理

在电影影评文本集上通过skip-gram方法训练完Word2Vec模型。下载数据集，把单词转换为单词字典，并使用索引数字作为嵌套查找。最后训练预测每个单词最接近的单词。

7.4.4 延伸学习

乍一看，我们期望的验证单词集最接近的单词是同义词。但是这种情况在一个句子中是不常见的，因为一个句子中的每个单词周围的单词都很少出现同义词。我们得到的是数据集中每个单词的同义词的预测。

为了使用单词嵌套，我们必须将其保存和重用。下一节，我们将实现CBOW词嵌入（嵌套）模型。

7.5 用TensorFlow实现CBOW词嵌入模型

本节将实现word2Vec的CBOW方法。该方法和skip-gram方法相似，有一点不同的是给一个上下文相关的单词集合来预测目标单词。

7.5.1 开始

在上一个例子中，我们把上下文窗口的单词和目标单词组成输入和输出对，但是在CBOW模型中，我们把上下文窗口的单词嵌套放在一起，预测目标单词嵌套，如图7-5所示。

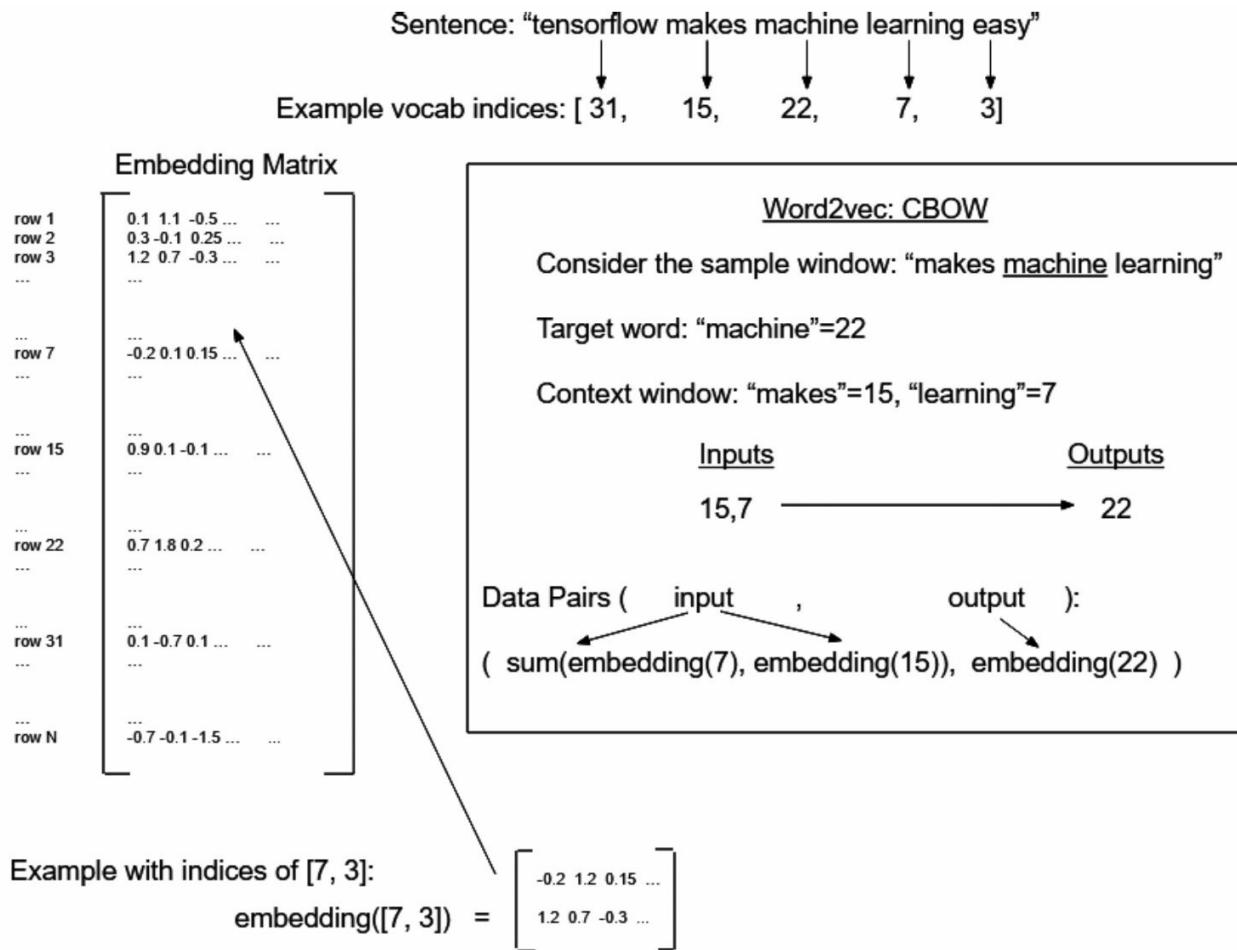


图7-5 CBOW模型如何嵌套数据的描述，其中两边窗口大小各为1

大部分实现代码与上一个例子相同，有一点不同的是如何创建单词嵌套和如何从句子中生成嵌套数据。

为了让代码更易理解，我们把相关的主要函数移到一个单独的text_helpers.py文件中。该文件包含处理数据加载函数、文本归一化函数、单词字典创建函数和批量数据生成函数。

7.5.2 动手做

1. 导入必要的编程库，包括前面的text_helpers.py脚本，该脚本可以进行文本加载和处理。然后创建一个计算图会话，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import numpy as np
import random
import os
import pickle
import string
import requests
import collections
import io
import tarfile

import urllib.request
import text_helpers
from nltk.corpus import stopwords
sess = tf.Session()
```

2. 确保临时数据和参数存储在文件夹中，代码如下：

```
# Make a saving directory if it doesn't exist
data_folder_name = 'temp'
if not os.path.exists(data_folder_name):
    os.makedirs(data_folder_name)
```

3. 声明算法模型的参数，这些参数和上一节中的skip-gram模型类似，代码如下：

```

# Declare model parameters
batch_size = 500
embedding_size = 200
vocabulary_size = 2000
generations = 50000
model_learning_rate = 0.001
num_sampled = int(batch_size/2)
window_size = 3
# Add checkpoints to training
save_embeddings_every = 5000
print_valid_every = 5000
print_loss_every = 100
# Declare stop words
stops = stopwords.words('english')
# We pick some test words. We are expecting synonyms to appear
valid_words = ['love', 'hate', 'happy', 'sad', 'man', 'woman']

```

4. 调用第一步中封装的辅助函数、数据加载函数和文本归一化函数。在本例中，设置电影影评大于三个单词，代码如下：

```

texts, target = text_helpers.load_movie_data(data_folder_name)
texts = text_helpers.normalize_text(texts, stops)
# Texts must contain at least 3 words
target = [target[ix] for ix, x in enumerate(texts) if len(x.split()) > 2]
texts = [x for x in texts if len(x.split()) > 2]

```

5. 创建单词字典，以便查找单词。同时，我们也需要一个逆序单词字典，可以通过索引查找单词。当我们想打印出验证单词集中每个单词最近的单词时，可使用逆序单词字典，代码如下：

```

word_dictionary = text_helpers.build_dictionary(texts,
vocabulary_size)
word_dictionary_rev = dict(zip(word_dictionary.values(), word_dictionary.keys()))
text_data = text_helpers.text_to_numbers(texts, word_dictionary)
# Get validation word keys
valid_examples = [word_dictionary[x] for x in valid_words]

```

6. 初始化待拟合的单词嵌套并声明算法模型的数据占位符，代码如下：

```

embeddings = tf.Variable(tf.random_uniform([vocabulary_size,
embedding_size], -1.0, 1.0))
# Create data/target placeholders
x_inputs = tf.placeholder(tf.int32, shape=[batch_size,
2*window_size])
y_target = tf.placeholder(tf.int32, shape=[batch_size, 1])
valid_dataset = tf.constant(valid_examples, dtype=tf.int32)

```

7. 处理单词嵌套。因为CBOW模型将上下文窗口内的单词嵌套叠加在一起，所以创建一个循环将窗口内的所有单词嵌套加在一起，代码如下：

```

# Lookup the word embeddings and
# Add together window embeddings:
embed = tf.zeros([batch_size, embedding_size])
for element in range(2*window_size):
    embed += tf.nn.embedding_lookup(embeddings, x_inputs[:, element])

```

8. 使用TensorFlow内建的NCE损失函数。因为本例的输出结果稀疏性太强，导致softmax函数收敛存在一定问题，代码如下：

```

# NCE loss parameters
nce_weights = tf.Variable(tf.truncated_normal([vocabulary_size,
embedding_size], stddev=1.0 / np.sqrt(embedding_size)))
nce_biases = tf.Variable(tf.zeros([vocabulary_size]))
# Declare loss function (NCE)
loss = tf.reduce_mean(tf.nn.nce_loss(nce_weights, nce_biases,
embed,
y_target, num_sampled, vocabulary_size))

```

9. 如上一节中的skip-gram模型一样，我们使用余弦相似度来度量验证单词集中每个单词最接近的单词，代码如下：

```

norm = tf.sqrt(tf.reduce_sum(tf.square(embeddings), 1, keep_
dims=True))
normalized_embeddings = embeddings / norm
valid_embeddings = tf.nn.embedding_lookup(normalized_embeddings,
valid_dataset)
similarity = tf.matmul(valid_embeddings, normalized_embeddings,
transpose_b=True)

```

10. 为了保存词向量，我们需要加载TensorFlow的train.Saver()方法。该方法默认会保存整个计算图会

话，但是本例中我们会指定参数只保存嵌套变量，并设置名字。这里设置保存的名字与计算图中的变量名相同，代码如下：

```
saver = tf.train.Saver({"embeddings": embeddings})
```

11.现在声明优化器函数，初始化模型变量，代码如下：

```
optimizer = tf.train.GradientDescentOptimizer(learning_rate=model_
learning_rate).minimize(loss)

init = tf.initialize_all_variables()
sess.run(init)
```

12.最后，遍历迭代训练，打印损失函数，保存单词嵌套到指定文件夹，代码如下：

```

loss_vec = []
loss_x_vec = []
for i in range(generations):
    batch_inputs, batch_labels = text_helpers.generate_batch_
data(text_data, batch_size, window_size, method='cbow')
    feed_dict = {x_inputs : batch_inputs, y_target : batch_labels}
    # Run the train step
    sess.run(optimizer, feed_dict=feed_dict)
    # Return the loss
    if (i+1) % print_loss_every == 0:
        loss_val = sess.run(loss, feed_dict=feed_dict)
        loss_vec.append(loss_val)
        loss_x_vec.append(i+1)
        print('Loss at step {} : {}'.format(i+1, loss_val))

    # Validation: Print some random words and top 5 related words
    if (i+1) % print_valid_every == 0:
        sim = sess.run(similarity, feed_dict=feed_dict)
        for j in range(len(valid_words)):
            valid_word = word_dictionary_rev[valid_examples[j]]
            top_k = 5 # number of nearest neighbors
            nearest = (-sim[j, :]).argsort()[1:top_k+1]
            log_str = "Nearest to {}:".format(valid_word)
            for k in range(top_k):
                close_word = word_dictionary_rev[nearest[k]]
                print_str = '{} {}'.format(log_str, close_word)
            print(print_str)

    # Save dictionary + embeddings
    if (i+1) % save_embeddings_every == 0:
        # Save vocabulary dictionary
        with open(os.path.join(data_folder_name, 'movie_vocab.
pkl'), 'wb') as f:
            pickle.dump(word_dictionary, f)

        # Save embeddings
        model_checkpoint_path = os.path.join(os.getcwd(), data_
folder_name, 'cbow_movie_embeddings.ckpt')
        save_path = saver.save(sess, model_checkpoint_path)
        print('Model saved in file: {}'.format(save_path))

```

13.输出结果如下：

```
Loss at step 100 : 62.04829025268555
Loss at step 200 : 33.182334899902344
Loss at step 49900 : 1.6794960498809814
Loss at step 50000 : 1.5071022510528564
Nearest to love: clarity, cult, cliched, literary, memory,
Nearest to hate: bringing, gifted, almost, next, wish,
Nearest to happy: ensemble, fall, courage, uneven, girls,
Nearest to sad: santa, devoid, biopic, genuinely, becomes,
Nearest to man: project, stands, none, soul, away,
Nearest to woman: crush, even, x, team, ensemble,
Model saved in file: .../temp/cbow_movie_embeddings.ckpt
```

14.text_helpers.py脚本中最后一个函数是上一节的generate_batch_data() 函数，这里稍微修改一下，增加一个cbow方法，代码如下：

```
elif method=='cbow':
    batch_and_labels = [(x[:y] + x[(y+1):], x[y]) for x,y in
zip(window_sequences, label_indices)]
    # Only keep windows with consistent 2*window_size
    batch_and_labels = [(x,y) for x,y in batch_and_labels if
len(x)==2*window_size]
    batch, labels = [list(x) for x in zip(*batch_and_labels)]
```

7.5.3 工作原理

在本节中，Word2Vec嵌套的CBOW模型和skip-gram模型非常相似。主要的不同点是生成数据和单词嵌套的处理。

本节我们加载文本数据，归一化文本，创建词汇字典，使用词汇字典查找嵌套，组合嵌套并训练神经网络模型预测目标单词。

7.5.4 延伸学习

值得注意的是，CBOW方法是在上下文窗口内单词嵌套叠加上进行训练并预测目标单词的。Word2Vec的CBOW方法更平滑，更适用于小文本数据集。

7.6 使用TensorFlow的Word2Vec预测

本节将使用前面学过的单词嵌套策略进行分类。

7.6.1 开始

现在已经创建并保存了CBOW单词嵌套，我们使用它们在电影影评数据集上做情感分析。本节将介绍如何加载和使用预训练的嵌套，并使用这些单词嵌套进行情感分析，通过训练线性逻辑回归模型来预测电影的好坏。

情感分析是一个相当棘手的任务，因为很难捕捉到人类语言真实含义的微妙变化和细微区别。挖苦、玩笑和模棱两可的含义使得任务异常艰难。我们将创建一个线性逻辑回归模型训练电影影评数据集，来看是否可以得到上一节CBOW模型嵌套之外的信息。因为本节关注的是加载和使用预训练好的单词嵌套，所以这里尽量不使用复杂算法模型。

7.6.2 动手做

1. 导入必要的编程库和计算图会话，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import numpy as np
import random
import os
import pickle
import string
import requests
import collections
import io
import tarfile
import urllib.request
import text_helpers
from nltk.corpus import stopwords
sess = tf.Session()
```

2. 声明算法模型参数。注意，选择与前一节中CBOW方法相同的嵌套大小，代码如下：

```
embedding_size = 200
vocabulary_size = 2000
batch_size = 100
max_words = 100
stops = stopwords.words('english')
```

3. 用text_helpers.py脚本加载和转换文本数据集，代码如下：

```

data_folder_name = 'temp'
texts, target = text_helpers.load_movie_data(data_folder_name)
# Normalize text
print('Normalizing Text Data')
texts = text_helpers.normalize_text(texts, stops)
# Texts must contain at least 3 words
target = [target[ix] for ix, x in enumerate(texts) if len(x.
split()) > 2]
texts = [x for x in texts if len(x.split()) > 2]

train_indices = np.random.choice(len(target),
round(0.8*len(target)), replace=False)
test_indices = np.array(list(set(range(len(target))) - set(train_
indices)))
texts_train = [x for ix, x in enumerate(texts) if ix in train_
indices]
texts_test = [x for ix, x in enumerate(texts) if ix in test_
indices]
target_train = np.array([x for ix, x in enumerate(target) if ix in
train_indices])
target_test = np.array([x for ix, x in enumerate(target) if ix in
test_indices])

```

4.现在加载CBOW嵌套中保存的单词字典，这使得我们拥有相同的单词到嵌套索引的映射，代码如下：

```

dict_file = os.path.join(data_folder_name, 'movie_vocab.pkl')
word_dictionary = pickle.load(open(dict_file, 'rb'))

```

5.通过单词字典将加载的句子转化为数值型numpy数组，代码如下：

```

text_data_train = np.array(text_helpers.text_to_numbers(texts_
train, word_dictionary))
text_data_test = np.array(text_helpers.text_to_numbers(texts_test,
word_dictionary))

```

6.由于电影影评长度不一，我们用同一长度（设为100个单词长度）将其标准化。如果电影影评长度少于100个单词，我们将用0去填充，代码如下：

```

text_data_train = np.array([x[0:max_words] for x in [y+[0]*max_
words for y in text_data_train]])
text_data_test = np.array([x[0:max_words] for x in [y+[0]*max_
words for y in text_data_test]])

```

7.声明逻辑回归的模型变量和占位符，代码如下：

```
A = tf.Variable(tf.random_normal(shape=[embedding_size, 1]))
b = tf.Variable(tf.random_normal(shape=[1, 1]))
# Initialize placeholders
x_data = tf.placeholder(shape=[None, max_words], dtype=tf.int32)
y_target = tf.placeholder(shape=[None, 1], dtype=tf.float32)
```

8.为了使得TensorFlow可以重用训练过的词向量，首先需要给存储方法设置一个变量。这里创建一个嵌套变量，其形状与将要加载的单词嵌套相同，代码如下：

```
embeddings = tf.Variable(tf.random_uniform([vocabulary_size,
                                           embedding_size], -1.0, 1.0))
```

9.在计算图中加入嵌套查找操作，计算句子中所有单词的平均嵌套，代码如下：

```
embed = tf.nn.embedding_lookup(embeddings, x_data)
# Take average of all word embeddings in documents
embed_avg = tf.reduce_mean(embed, 1)
```

10.声明模型操作和损失函数。记住，损失函数中已经内建了sigmoid操作，代码如下：

```
model_output = tf.add(tf.matmul(embed_avg, A), b)
# Declare loss function (Cross Entropy loss)
loss = tf.reduce_mean(tf.nn.sigmoid_cross_entropy_with_
logits(model_output, y_target))
```

11.在计算图中增加预测函数和准确度函数，评估训练模型的准确度，代码如下：

```
prediction = tf.round(tf.sigmoid(model_output))
predictions_correct = tf.cast(tf.equal(prediction, y_target),
                           tf.float32)
accuracy = tf.reduce_mean(predictions_correct)
```

12.声明优化器函数，并初始化下面的模型变量，代码如下：

```
my_opt = tf.train.AdagradOptimizer(0.005)
train_step = my_opt.minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)
```

13.随机初始化单词嵌套后，调用Saver方法来加载上一节中保存好的CBOW嵌套到嵌套变量，代码如下：

```

model_checkpoint_path = os.path.join(data_folder_name, 'cbow_movie_
embeddings.ckpt')
saver = tf.train.Saver({"embeddings": embeddings})
saver.restore(sess, model_checkpoint_path)

```

14.开始迭代训练。注意，每迭代100次就保存训练集和测试集的损失和准确度。每迭代500次就打印一次模型状态，代码如下：

```

train_loss = []
test_loss = []
train_acc = []
test_acc = []
i_data = []
for i in range(10000):
    rand_index = np.random.choice(text_data_train.shape[0],
size=batch_size)
    rand_x = text_data_train[rand_index]
    rand_y = np.transpose([target_train[rand_index]])
    sess.run(train_step, feed_dict={x_data: rand_x, y_target:
rand_y})

    # Only record loss and accuracy every 100 generations
    if (i+1)%100==0:
        i_data.append(i+1)
        train_loss_temp = sess.run(loss, feed_dict={x_data:
rand_x, y_target: rand_y})
        train_loss.append(train_loss_temp)

        test_loss_temp = sess.run(loss, feed_dict={x_data: text_
data_test, y_target: np.transpose([target_test])})
        test_loss.append(test_loss_temp)

        train_acc_temp = sess.run(accuracy, feed_dict={x_data:
rand_x, y_target: rand_y})
        train_acc.append(train_acc_temp)
        test_acc_temp = sess.run(accuracy, feed_dict={x_data:
text_data_test, y_target: np.transpose([target_test])})
        test_acc.append(test_acc_temp)
    if (i+1)%500==0:
        acc_and_loss = [i+1, train_loss_temp, test_loss_temp,
train_acc_temp, test_acc_temp]
        acc_and_loss = [np.round(x,2) for x in acc_and_loss]
        print('Generation # {}. Train Loss (Test Loss): {:.2f}
({:.2f}). Train Acc (Test Acc): {:.2f} ({:.2f})'.format(*acc_and_
loss))

```

15. 打印结果如下：

```
Generation # 500. Train Loss (Test Loss): 0.70 (0.71). Train Acc  
(Test Acc): 0.52 (0.48)  
Generation # 1000. Train Loss (Test Loss): 0.69 (0.72). Train Acc  
(Test Acc): 0.56 (0.47)  
...  
Generation # 9500. Train Loss (Test Loss): 0.69 (0.70). Train Acc  
(Test Acc): 0.57 (0.55)  
Generation # 10000. Train Loss (Test Loss): 0.70 (0.70). Train Acc  
(Test Acc): 0.59 (0.55)
```

16. 绘制训练集和测试集损失函数和准确度的代码，所绘图像见图7-6和图7-7：

```
# Plot loss over time  
plt.plot(i_data, train_loss, 'k-', label='Train Loss')  
plt.plot(i_data, test_loss, 'r--', label='Test Loss', linewidth=4)  
plt.title('Cross Entropy Loss per Generation')  
plt.xlabel('Generation')  
plt.ylabel('Cross Entropy Loss')  
plt.legend(loc='upper right')  
plt.show()  
  
# Plot train and test accuracy  
plt.plot(i_data, train_acc, 'k-', label='Train Set Accuracy')  
plt.plot(i_data, test_acc, 'r--', label='Test Set Accuracy',  
linewidth=4)  
plt.title('Train and Test Accuracy')  
plt.xlabel('Generation')  
plt.ylabel('Accuracy')  
plt.legend(loc='lower right')  
plt.show()
```

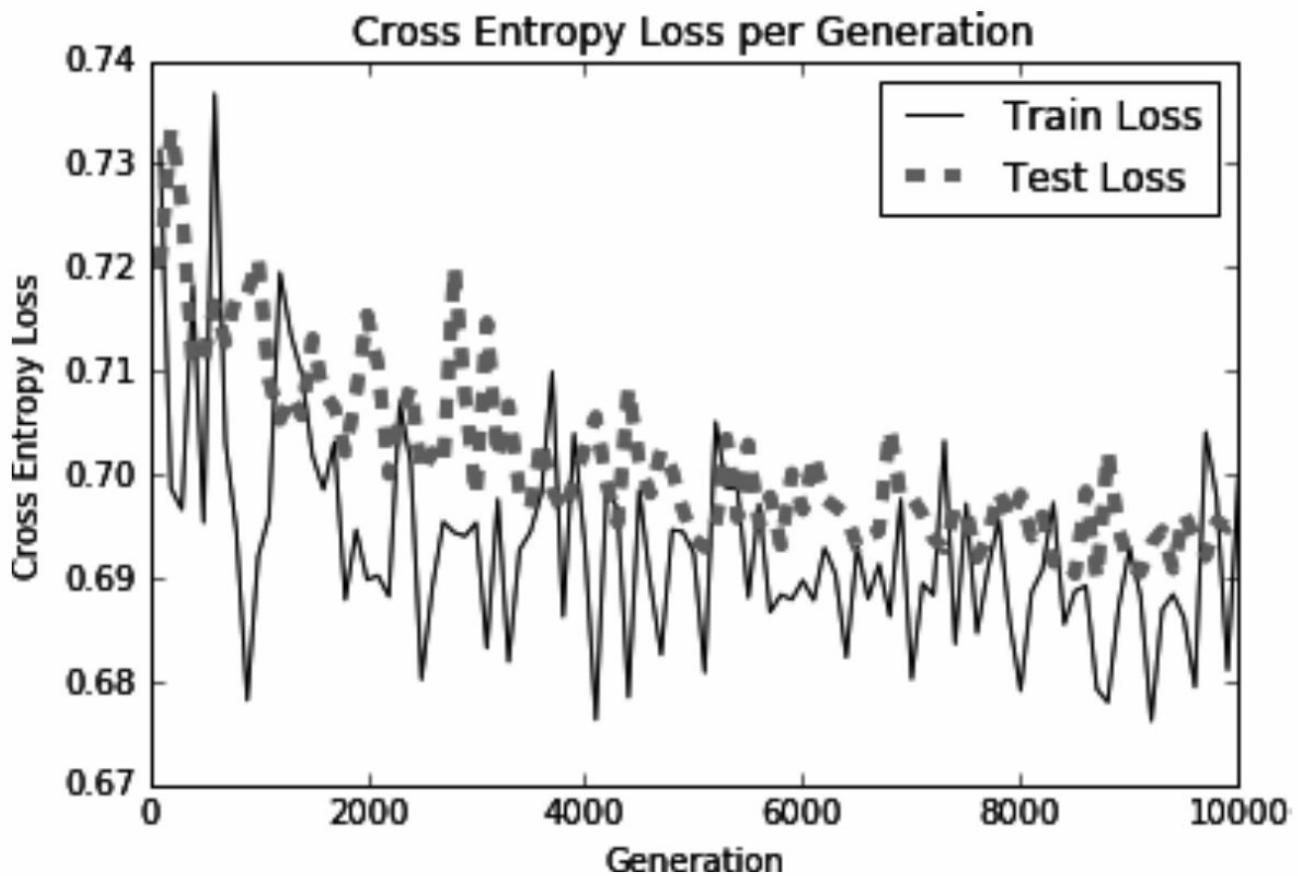


图7-6 迭代10000次的训练集和测试集损失图

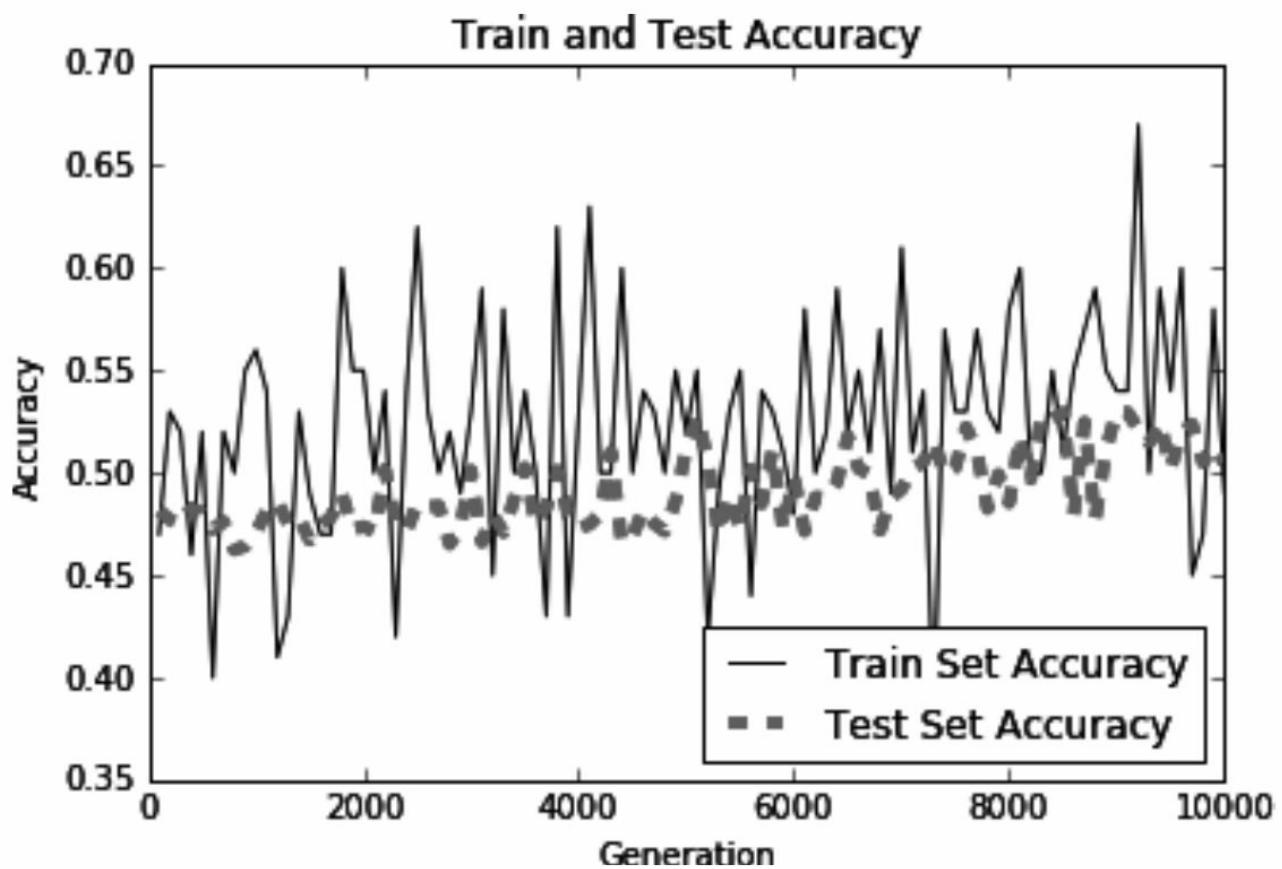


图7-7 迭代10000次的训练集准确度和测试集准确度趋势图，两者准确度均在缓慢提高。值得注意的

是，该模型性能较差，仅仅比随机预测好那么一点点

7.6.3 工作原理

我们加载前一节的CBOW嵌套，并在电影影评的平均嵌套上进行逻辑回归模型训练。本节的关注点是，如何从磁盘上加载模型变量到已经初始化的当前模型变量中，以及如何存储和加载其他单词字典来训练嵌套。当使用相同的单词嵌套时，需要使用相同的单词到嵌套索引的映射。

7.6.4 延伸学习

我们获得了60%的情感预测准确度。例如，预知单词great背后的含义是一件非常困难的任务，该单词可以用在正面或者负面的电影影评中。

为了解决该问题，我们计划使用文档本身创建嵌套来解决情感问题。我们可以利用Doc2Vec来解决情感分析问题。

7.7 用TensorFlow实现基于Doc2Vec的情感分析

现在知道如何训练单词嵌套了，我们可以扩展这些方法使其成为文档嵌套。本节将使用TensorFlow实现基于Doc2Vec的情感分析。

7.7.1 开始

在上一节关于Word2Vec的方法中，我们处理的是单词之间的上下文关系。但是没有考虑单词和单词所在文档之间的关系。Word2Vec方法的扩展之一就是Doc2Vec方法，其考虑文档的影响。

Doc2Vec方法的基本思想是引入文档嵌套，同时连同单词嵌套一起帮助判断文档的感情色彩。例如，如果单词movie和love接连出现，那也不能帮助我们判断该电影影评的情感。影评可能谈论他们如何喜爱电影，也可能谈论他们如何讨厌电影。但是，如果电影影评有足够的长度，并且包含多个负面词汇，那么文档整体的感情色彩可以帮助我们预测最近的单词。

Doc2Vec方法只是简单地增加了一个文档嵌套矩阵，并使用单词的窗口乘以文档索引进行单词预测。在一个文档中的所有单词窗口有相同的文档索引。值得一提的是，如何结合文档嵌套和单词嵌套是讨论重点。我们将单词窗口内的单词嵌套求和，主要有两种结合这些单词嵌套和文档嵌套的方法。一般将文档嵌套和单词嵌套相加，或者将文档嵌套直接追加在单词嵌套后面。如果将两种嵌套相加，那么要求文档嵌套的大小和单词嵌套大小相同；如果将两种嵌套直接追加，那么需要增加逻辑回归模型的变量数量。本节我们将讲解如何处理连接两种嵌套。不过一般来讲，对于小数据集，两种嵌套相加的方法是更好的选择。

首先进行电影影评的文档嵌套和单词嵌套，然后分割为训练集和测试集，训练逻辑回归模型，并评估该方法是否可以提高预测影评情感的准确度。

7.7.2 动手做

1. 导入必要的编程库，开始一个计算图会话，代码如下：

```
import tensorflow as tf
import matplotlib.pyplot as plt
import numpy as np
import random
import os
import pickle
import string
import requests
import collections
import io
import tarfile
import urllib.request
import text_helpers
from nltk.corpus import stopwords
sess = tf.Session()
```

2. 加载影评数据集，代码如下：

```
data_folder_name = 'temp'
if not os.path.exists(data_folder_name):
    os.makedirs(data_folder_name)
texts, target = text_helpers.load_movie_data(data_folder_name)
```

3. 声明算法模型参数，代码如下：

```

batch_size = 500
vocabulary_size = 7500
generations = 100000
model_learning_rate = 0.001
embedding_size = 200 # Word embedding size
doc_embedding_size = 100 # Document embedding size
concatenated_size = embedding_size + doc_embedding_size
num_sampled = int(batch_size/2)
window_size = 3 # How many words to consider to the left.
# Add checkpoints to training
save_embeddings_every = 5000
print_valid_every = 5000
print_loss_every = 100
# Declare stop words
stops = stopwords.words('english')
# We pick a few test words.
valid_words = ['love', 'hate', 'happy', 'sad', 'man', 'woman']

```

4.归一化电影影评，确保每条影评都大于指定的窗口大小，代码如下：

```

texts = text_helpers.normalize_text(texts, stops)
# Texts must contain at least as much as the prior window size
target = [target[ix] for ix, x in enumerate(texts) if len(x.split())
> window_size]
texts = [x for x in texts if len(x.split()) > window_size]
assert(len(target)==len(texts))

```

5.创建单词字典。值得注意的是，我们无须创建文档字典。文档索引仅仅是文档的索引值，每个文档有唯一的索引值，代码如下：

```

word_dictionary = text_helpers.build_dictionary(texts, vocabulary_size)
word_dictionary_rev = dict(zip(word_dictionary.values(), word_dictionary.keys()))
text_data = text_helpers.text_to_numbers(texts, word_dictionary)
# Get validation word keys
valid_examples = [word_dictionary[x] for x in valid_words]

```

6.定义单词嵌套和文档嵌套。然后声明对比噪声损失函数，代码如下：

```

embeddings = tf.Variable(tf.random_uniform([vocabulary_size,
embedding_size], -1.0, 1.0))
doc_embeddings = tf.Variable(tf.random_uniform([len(texts), doc_
embedding_size], -1.0, 1.0))
# NCE loss parameters
nce_weights = tf.Variable(tf.truncated_normal([vocabulary_size,
concatenated_size],
                                              stddev=1.0 /
np.sqrt(concatenated_size)))
nce_biases = tf.Variable(tf.zeros([vocabulary_size]))

```

7. 声明Doc2Vec索引和目标单词索引的占位符。注意，输入索引的大小是窗口大小加1，这是因为每个生成的数据窗口将有一个额外的文档索引，代码如下：

```

x_inputs = tf.placeholder(tf.int32, shape=[None, window_size + 1])
y_target = tf.placeholder(tf.int32, shape=[None, 1])
valid_dataset = tf.constant(valid_examples, dtype=tf.int32)

```

8. 创建嵌套函数将单词嵌套求和，然后连接文档嵌套，代码如下：

```

embed = tf.zeros([batch_size, embedding_size])
for element in range(window_size):
    embed += tf.nn.embedding_lookup(embeddings, x_inputs[:, element])
doc_indices = tf.slice(x_inputs, [0, window_size], [batch_size, 1])
doc_embed = tf.nn.embedding_lookup(doc_embeddings, doc_indices)
# concatenate embeddings
final_embed = tf.concat(1, [embed, tf.squeeze(doc_embed)])

```

9. 现在声明损失函数并创建优化器，代码如下：

```

loss = tf.reduce_mean(tf.nn.nce_loss(nce_weights, nce_biases,
final_embed, y_target, num_sampled, vocabulary_size))

# Create optimizer
optimizer =
tf.train.GradientDescentOptimizer(learning_rate=model_learning_
rate)
train_step = optimizer.minimize(loss)

```

10. 声明验证单词集的余弦距离，代码如下：

```
norm = tf.sqrt(tf.reduce_sum(tf.square(embeddings), 1,
keep_dims=True))
normalized_embeddings = embeddings / norm
valid_embeddings = tf.nn.embedding_lookup(normalized_embeddings,
valid_dataset)
similarity = tf.matmul(valid_embeddings, normalized_embeddings,
transpose_b=True)
```

11.为了保存嵌套，创建模型的saver函数，然后初始化模型变量，代码如下：

```
saver = tf.train.Saver({"embeddings": embeddings, "doc_
embeddings": doc_embeddings})
init = tf.initialize_all_variables()
sess.run(init)

Test
loss_vec = []
loss_x_vec = []
for i in range(generations):
    batch_inputs, batch_labels = text_helpers.generate_batch_
data(text_data, batch_size,
window_size, method='doc2vec')
    feed_dict = {x_inputs : batch_inputs, y_target : batch_labels}
```

```

# Run the train step
sess.run(train_step, feed_dict=feed_dict)

# Return the loss
if (i+1) % print_loss_every == 0:
    loss_val = sess.run(loss, feed_dict=feed_dict)
    loss_vec.append(loss_val)
    loss_x_vec.append(i+1)
    print('Loss at step {} : {}'.format(i+1, loss_val))

# Validation: Print some random words and top 5 related words
if (i+1) % print_valid_every == 0:
    sim = sess.run(similarity, feed_dict=feed_dict)
    for j in range(len(valid_words)):
        valid_word = word_dictionary_rev[valid_examples[j]]
        top_k = 5 # number of nearest neighbors
        nearest = (-sim[j, :]).argsort()[1:top_k+1]
        log_str = "Nearest to {}:".format(valid_word)
        for k in range(top_k):
            close_word = word_dictionary_rev[nearest[k]]
            log_str = '{} {},'.format(log_str, close_word)
        print(log_str)

# Save dictionary + embeddings
if (i+1) % save_embeddings_every == 0:
    # Save vocabulary dictionary
    with open(os.path.join(data_folder_name, 'movie_vocab.pkl'), 'wb') as f:
        pickle.dump(word_dictionary, f)

    # Save embeddings
    model_checkpoint_path = os.path.join(os.getcwd(), data_folder_name, 'doc2vec_movie_embeddings.ckpt')
    save_path = saver.save(sess, model_checkpoint_path)
    print('Model saved in file: {}'.format(save_path))

```

12. 打印结果如下：

```
Loss at step 100 : 126.176816940307617
Loss at step 200 : 89.608322143554688
Loss at step 99900 : 17.733346939086914
Loss at step 100000 : 17.384489059448242
Nearest to love: ride, with, by, its, start,
Nearest to hate: redundant, snapshot, from, performances,
extravagant,
Nearest to happy: queen, chaos, them, succumb, elegance,
Nearest to sad: terms, pity, chord, wallet, morality,
Nearest to man: of, teen, an, our, physical,
Nearest to woman: innocuous, scenes, prove, except, lady,
Model saved in file: /.../temp/doc2vec_movie_embeddings.ckpt
```

13.训练完Doc2Vec嵌套，我们能使用这些嵌套训练逻辑回归模型，预测影评情感色彩。首先设置逻辑回归模型的一些参数，代码如下：

```
max_words = 20 # maximum review word length
logistic_batch_size = 500 # training batch size
```

14.分割数据集为训练集和测试集，代码如下：

```
train_indices = np.sort(np.random.choice(len(target),
round(0.8*len(target)), replace=False))
test_indices = np.sort(np.array(list(set(range(len(target))) -
set(train_indices))))
texts_train = [x for ix, x in enumerate(texts) if ix in train_
indices]
texts_test = [x for ix, x in enumerate(texts) if ix in test_
indices]
target_train = np.array([x for ix, x in enumerate(target) if ix in
train_indices])
target_test = np.array([x for ix, x in enumerate(target) if ix in
test_indices])
```

15.将电影影评转换成数值型的单词索引，填充或者裁剪每条影评为20个单词，代码如下：

```

text_data_train = np.array(text_helpers.text_to_numbers(texts_
train,
word_dictionary))
text_data_test = np.array(text_helpers.text_to_numbers(texts_test,
word_dictionary))
# Pad/crop movie reviews to specific length
text_data_train = np.array([x[0:max_words] for x in [y+[0]*max_
words
for y in text_data_train]])
text_data_test = np.array([x[0:max_words] for x in [y+[0]*max_
words
for y in text_data_test]])

```

16. 声明逻辑回归模型的数据占位符、模型变量、模型操作和损失函数，代码如下：

```

# Define Logistic placeholders
log_x_inputs = tf.placeholder(tf.int32, shape=[None, max_words +
1])
log_y_target = tf.placeholder(tf.int32, shape=[None, 1])
A = tf.Variable(tf.random_normal(shape=[concatenated_size,1]))
b = tf.Variable(tf.random_normal(shape=[1,1]))

# Declare logistic model (sigmoid in loss function)
model_output = tf.add(tf.matmul(log_final_embed, A), b)

# Declare loss function (Cross Entropy loss)
logistic_loss = tf.reduce_mean(tf.nn.sigmoid_cross_entropy_with_
logits(model_output,
tf.cast(log_y_target, tf.float32)))

```

17. 创建另外一个嵌套函数。前半部分的一个嵌套函数是训练3个单词窗口和文档索引预测最近的单词。这里也是类似的功能，不同的是训练20个单词的影评，代码如下：

```

# Add together element embeddings in window:
log_embed = tf.zeros([logistic_batch_size, embedding_size])
for element in range(max_words):
    log_embed += tf.nn.embedding_lookup(embeddings, log_x_
inputs[:, element])
log_doc_indices = tf.slice(log_x_inputs, [0,max_words],[logistic_
batch_size,1])
log_doc_embed = tf.nn.embedding_lookup(doc_embeddings,log_doc_
indices)
# concatenate embeddings
log_final_embed = tf.concat(1, [log_embed, tf.squeeze(log_doc_
embed)])

```

18. 创建预测函数和准确度，评估迭代训练模型。然后声明优化器函数，初始化所有模型变量，代码如下：

```

prediction = tf.round(tf.sigmoid(model_output))
predictions_correct = tf.cast(tf.equal(prediction, tf.cast(log_y_
target, tf.float32)), tf.float32)
accuracy = tf.reduce_mean(predictions_correct)
# Declare optimizer
logistic_opt = tf.train.GradientDescentOptimizer(learning_
rate=0.01)
logistic_train_step = logistic_opt.minimize(logistic_loss, var_
list=[A, b])
# Initialize Variables
init = tf.initialize_all_variables()
sess.run(init)

```

19. 开始训练逻辑回归模型，代码如下：

```
train_loss = []
test_loss = []
train_acc = []
test_acc = []
i_data = []
for i in range(10000):
    rand_index = np.random.choice(text_data_train.shape[0] ,
size=logistic_batch_size)
    rand_x = text_data_train[rand_index]
    # Append review index at the end of text data
    rand_x_doc_indices = train_indices[rand_index]
    rand_x = np.hstack((rand_x, np.transpose([rand_x_doc_
indices])))
    rand_y = np.transpose([target_train[rand_index]])

    feed_dict = {log_x_inputs : rand_x, log_y_target : rand_y}
    sess.run(logistic_train_step, feed_dict=feed_dict)

    # Only record loss and accuracy every 100 generations
    if (i+1)%100==0:
        rand_index_test = np.random.choice(text_data_test.
shape[0], size=logistic_batch_size)
        rand_x_test = text_data_test[rand_index_test]
```

```

# Append review index at the end of text data
rand_x_doc_indices_test = test_indices[rand_index_test]
rand_x_test = np.hstack((rand_x_test,
np.transpose([rand_x_doc_indices_test])))
rand_y_test = np.transpose([target_test[rand_index_test]])

test_feed_dict = {log_x_inputs: rand_x_test, log_y_target:
rand_y_test}

i_data.append(i+1)
train_loss_temp = sess.run(logistic_loss, feed_dict=feed_
dict)
train_loss.append(train_loss_temp)
test_loss_temp = sess.run(logistic_loss, feed_dict=test_
feed_dict)
test_loss.append(test_loss_temp)

train_acc_temp = sess.run(accuracy, feed_dict=feed_dict)
train_acc.append(train_acc_temp)

test_acc_temp = sess.run(accuracy, feed_dict=test_feed_
dict)
test_acc.append(test_acc_temp)
if (i+1)%500==0:
    acc_and_loss = [i+1, train_loss_temp, test_loss_temp,
train_acc_temp, test_acc_temp]
    acc_and_loss = [np.round(x,2) for x in acc_and_loss]
    print('Generation # {}. Train Loss (Test Loss): {:.2f} '
({:.2f}). Train Acc (Test Acc): {:.2f} {:.2f})'.format(*acc_and_
loss))

```

20. 打印结果如下：

```

Generation # 500. Train Loss (Test Loss): 5.62 (7.45). Train Acc
(Test Acc): 0.52 (0.48)
Generation # 10000. Train Loss (Test Loss): 2.35 (2.51). Train Acc
(Test Acc): 0.59 (0.58)

```

21. 我们已经创建了独立的批量数据生成的方法——text_helpers.generate_batch_data() 函数。本节前面使用该方法训练Doc2Vec嵌套，代码如下：

```
def generate_batch_data(sentences, batch_size, window_size,
method='skip_gram'):
    # Fill up data batch
    batch_data = []
    label_data = []
    while len(batch_data) < batch_size:
        # select random sentence to start
        rand_sentence_ix = int(np.random.choice(len(sentences),
size=1))
        rand_sentence = sentences[rand_sentence_ix]
        # Generate consecutive windows to look at
        window_sequences = [rand_sentence[max((ix-window_size), 0):(ix+window_size+1)] for ix, x in enumerate(rand_sentence)]
        # Denote which element of each window is the center word
```

```
f interest
    label_indices = [ix if ix<window_size else window_size for
ix,x in enumerate(window_sequences)]
        # Pull out center word of interest for each window and
create a tuple for each window
        if method=='skip_gram':
            ...
        elif method=='cbow':
            ...
        elif method=='doc2vec':
            # For doc2vec we keep LHS window only to predict
target word
                batch_and_labels = [(rand_sentence[i:i+window_size],
rand_sentence[i+window_size]) for i in range(0, len(rand_
sentence)-window_size)]
                batch, labels = [list(x) for x in zip(*batch_and_
labels)]
                # Add document index to batch!! Remember that we must
extract the last index in batch for the doc-index
                batch = [x + [rand_sentence_ix] for x in batch]
            else:
                raise ValueError('Method {} not implemented
yet.'.format(method))

        # extract batch and labels
        batch_data.extend(batch[:batch_size])
        label_data.extend(labels[:batch_size])
# Trim batch and label at the end
batch_data = batch_data[:batch_size]
label_data = label_data[:batch_size]

# Convert to numpy array
batch_data = np.array(batch_data)
label_data = np.transpose(np.array([label_data]))

return(batch_data, label_data)
```

7.7.3 工作原理

在本节中，我们进行了两个迭代训练。第一个是训练Doc2Vec嵌套，第二个是在电影影评上训练逻辑回归模型预测影评情感色彩。

虽然情感分析预测的准确度没有增加多少（仍然约为60%），但是我们成功实现了电影影评数据集的Doc2Vec的连接（级联）版本。因为逻辑回归模型不能捕捉到自然语言处理中的非线性行为特征，所以为了提高预测的准确度，我们可以尝试用不同的参数训练Doc2Vec嵌套，也可以使用稍微复杂一些的算法模型。

第8章 卷积神经网络

在过去的几年中，卷积神经网络（Convolutional Neural Networks， CNN）在图像识别方面有了重大突破。本章主要包含以下知识点：

- TensorFlow实现简单的CNN
- TensorFlow实现进阶的CNN
- 再训练已有的CNN模型
- TensorFlow实现模仿大师绘画（Neuralstyle）
- TensorFlow实现DeepDream

值得注意的是，读者可以在GitHub上找到所有代码，网址为：https://github.com/nfmccclure/tensorflow_cookbook。

8.1 卷积神经网络介绍

从数学意义上讲，卷积是一个函数在另外一个函数中的叠加。在本例中，我们将在图像中应用矩阵乘法过滤器。图8-1展示了图像卷积如何工作。

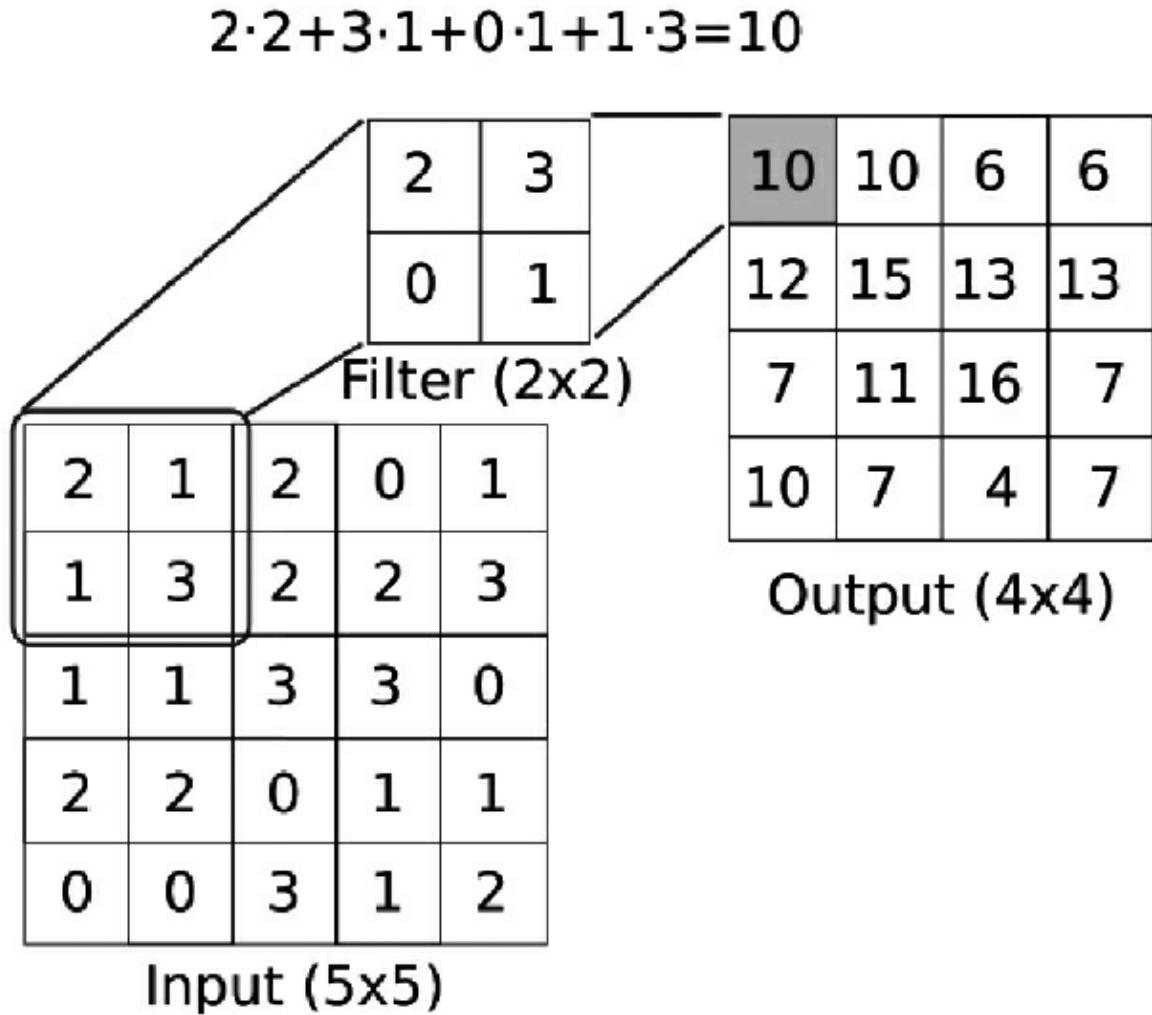


图8-1 在图像中应用卷积过滤器操作创建新特征层，其中卷积过滤器大小为 2×2 ，在 5×5 的输入图像的两个方向上以步长为1进行卷积。结果是一个 4×4 矩阵

卷积神经网络也有些必要的操作，比如引入非线性（ReLU函数），或者聚合参数（maxpool函数），以及其他相似的操作。前面的图像是在一个 5×5 的数组上进行卷积操作的例子，其中卷积过滤器为 2×2 的矩阵，步长为1，且仅考虑有效位置。可训练的变量是该操作中 2×2 的过滤器权重。一般紧跟着卷积之后的是聚合操作，比如池化。图8-2提供一个池化操作的例子。

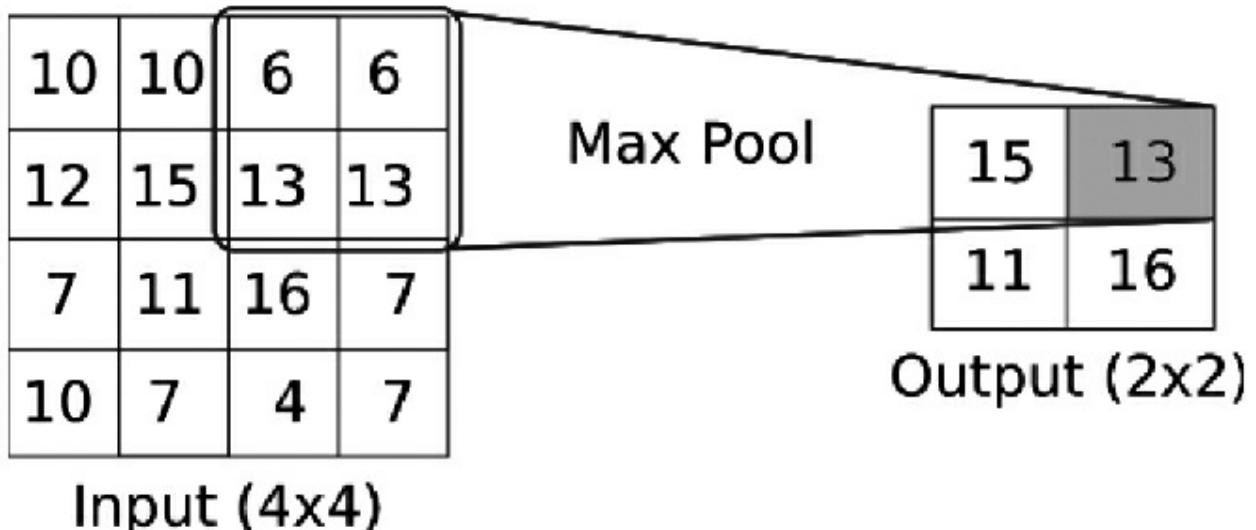


图8-2 池化操作的例子。在本例中，窗口大小为 2×2 ，在 4×4 的输入（有效位置）的两个方向上以步长为2进行操作。结果是 2×2 的矩阵

虽然我们准备创建自定义的CNN来进行图像识别，但是，强烈推荐读者使用现有的架构方案，我们在后续章节中也会使用。



一般采用预训练网络，并在最后用全连接在新的数据集上再训练预训练的神经网络。该方法是非常有用的，后续章节也会详细讲述，并再训练已存在的架构来提升CIFAR-10的预测效果。

8.2 用TensorFlow实现简单的CNN

本节将开发一个四层卷积神经网络，提升预测MNIST数字的准确度。前两个卷积层由Convolution-ReLU-maxpool操作组成，后两层是全联接层。

8.2.1 开始

为了访问MNIST数据集，TensorFlow的contrib包包含数据加载功能。数据集加载之后，我们设置算法模型变量，创建模型，批量训练模型，并且可视化损失函数、准确度和一些抽样数字。

8.2.2 动手做

1. 加载必要的编程库，开始计算图会话，代码如下：

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from tensorflow.contrib.learn.python.learn.datasets.mnist import
read_data_sets
sess = tf.Session()
```

2. 加载数据集，转化图像为 28×28 的数组，代码如下：

```
data_dir = 'temp'
mnist = read_data_sets(data_dir)
train_xdata = np.array([np.reshape(x, (28, 28)) for x in mnist.train.images])
test_xdata = np.array([np.reshape(x, (28, 28)) for x in mnist.test.images])
train_labels = mnist.train.labels
test_labels = mnist.test.labels
```



注意，下载的MNIST数据集包括验证数据集。验证数据集的大小与测试数据集相同。如果我们进行超参数调优或者模型选择，需要加载测试数据集和验证数据集。

3. 设置模型参数。由于图像是灰度图，所以该图像的深度为1，即颜色通道数为1，代码如下：

```
batch_size = 100
learning_rate = 0.005
evaluation_size = 500
image_width = train_xdata[0].shape[0]
image_height = train_xdata[0].shape[1]
target_size = max(train_labels) + 1
num_channels = 1
generations = 500
eval_every = 5
conv1_features = 25
conv2_features = 50
max_pool_size1 = 2
max_pool_size2 = 2
fully_connected_size1 = 100
```

4.为数据集声明占位符。同时，声明训练数据集变量和测试数据集变量。本例中的训练批量大小和评估大小可以根据实际训练和评估的机器物理内存来调整，代码如下：

```
x_input_shape = (batch_size, image_width, image_height, num_channels)
x_input = tf.placeholder(tf.float32, shape=x_input_shape)
y_target = tf.placeholder(tf.int32, shape=(batch_size))
eval_input_shape = (evaluation_size, image_width, image_height,
num_channels)
eval_input = tf.placeholder(tf.float32, shape=eval_input_shape)
eval_target = tf.placeholder(tf.int32, shape=(evaluation_size))
```

5.声明卷积层的权重和偏置，权重和偏置的参数在前面的步骤中已设置过，代码如下：

```
conv1_weight = tf.Variable(tf.truncated_normal([4, 4, num_channels, conv1_features], stddev=0.1, dtype=tf.float32))

conv1_bias = tf.Variable(tf.zeros([conv1_features], dtype=tf.float32))

conv2_weight = tf.Variable(tf.truncated_normal([4, 4, conv1_features, conv2_features], stddev=0.1, dtype=tf.float32))

conv2_bias = tf.Variable(tf.zeros([conv2_features], dtype=tf.float32))
```

6.声明全连接层的权重和偏置，代码如下：

```
resulting_width = image_width // (max_pool_size1 * max_pool_size2)
resulting_height = image_height // (max_pool_size1 * max_pool_size2)
full1_input_size = resulting_width * resulting_height*conv2_features
full1_weight = tf.Variable(tf.truncated_normal([full1_input_size,
fully_connected_size1], stddev=0.1, dtype=tf.float32))
full1_bias = tf.Variable(tf.truncated_normal([fully_connected_size1],
stddev=0.1, dtype=tf.float32))
full2_weight = tf.Variable(tf.truncated_normal([fully_connected_size1,
target_size], stddev=0.1, dtype=tf.float32))
full2_bias = tf.Variable(tf.truncated_normal([target_size],
stddev=0.1, dtype=tf.float32))
```

7. 声明算法模型。首先，创建一个模型函数my_conv_net()，注意该函数的层权重和偏置。当然，为了最后两层全连接层能有效工作，我们将前两层卷积层的结果摊平，代码如下：

```

def my_conv_net(input_data):
    # First Conv-ReLU-MaxPool Layer
    conv1 = tf.nn.conv2d(input_data, conv1_weight, strides=[1, 1,
    1, 1], padding='SAME')
    relu1 = tf.nn.relu(tf.nn.bias_add(conv1, conv1_bias))
    max_pool1 = tf.nn.max_pool(relu1, ksize=[1, max_pool_size1,
    max_pool_size1, 1], strides=[1, max_pool_size1, max_pool_size1,
    1], padding='SAME')
    # Second Conv-ReLU-MaxPool Layer
    conv2 = tf.nn.conv2d(max_pool1, conv2_weight, strides=[1, 1,
    1, 1], padding='SAME')
    relu2 = tf.nn.relu(tf.nn.bias_add(conv2, conv2_bias))
    max_pool2 = tf.nn.max_pool(relu2, ksize=[1, max_pool_size2,
    max_pool_size2, 1], strides=[1, max_pool_size2, max_pool_size2,
    1], padding='SAME')
    # Transform Output into a 1xN layer for next fully connected
    layer
    final_conv_shape = max_pool2.get_shape().as_list()
    final_shape = final_conv_shape[1] * final_conv_shape[2] *
    final_conv_shape[3]
    flat_output = tf.reshape(max_pool2, [final_conv_shape[0],
    final_shape])
    # First Fully Connected Layer
    fully_connected1 = tf.nn.relu(tf.add(tf.matmul(flat_output,
    full1_weight), full1_bias))
    # Second Fully Connected Layer
    final_model_output = tf.add(tf.matmul(fully_connected1, full2_
    weight), full2_bias)
    return(final_model_output)

```

8. 声明训练模型，代码如下：

```

model_output = my_conv_net(x_input)
test_model_output = my_conv_net(eval_input)

```

9. 因为本例的预测结果不是多分类，而仅仅是一类，所以使用softmax函数作为损失函数代码如下：

```

loss = tf.reduce_mean(tf.nn.sparse_softmax_cross_entropy_with_
logits(model_output, y_target))

```

10. 创建训练集和测试集的预测函数。同时，创建对应的准确度函数，评估模型的准确度，代码如下：

```

prediction = tf.nn.softmax(model_output)
test_prediction = tf.nn.softmax(test_model_output)
# Create accuracy function
def get_accuracy(logits, targets):
    batch_predictions = np.argmax(logits, axis=1)
    num_correct = np.sum(np.equal(batch_predictions, targets))
return(100. * num_correct/batch_predictions.shape[0])

```

11. 创建优化器函数，声明训练步长，初始化所有的模型变量，代码如下：

```

my_optimizer = tf.train.MomentumOptimizer(learning_rate, 0.9)
train_step = my_optimizer.minimize(loss)
# Initialize Variables
init = tf.initialize_all_variables()
sess.run(init)

```

12. 开始训练模型。遍历迭代随机选择批量数据进行训练。我们在训练集批量数据和测试集批量数据上评估模型，保存损失函数和准确度。我们看到，在迭代500次之后，测试数据集上的准确度达到96%~97%，代码如下：

```

train_loss = []
train_acc = []
test_acc = []
for i in range(generations):
    rand_index = np.random.choice(len(train_xdata), size=batch_size)
    rand_x = train_xdata[rand_index]
    rand_x = np.expand_dims(rand_x, 3)
    rand_y = train_labels[rand_index]
    train_dict = {x_input: rand_x, y_target: rand_y}
    sess.run(train_step, feed_dict=train_dict)
    temp_train_loss, temp_train_preds = sess.run([loss, prediction], feed_dict=train_dict)
    temp_train_acc = get_accuracy(temp_train_preds, rand_y)
    if (i+1) % eval_every == 0:
        eval_index = np.random.choice(len(test_xdata), size=evaluation_size)
        eval_x = test_xdata[eval_index]
        eval_x = np.expand_dims(eval_x, 3)

```

```
eval_y = test_labels[eval_index]
test_dict = {eval_input: eval_x, eval_target: eval_y}
test_preds = sess.run(test_prediction, feed_dict=test_dict)
temp_test_acc = get_accuracy(test_preds, eval_y)
# Record and print results
train_loss.append(temp_train_loss)
train_acc.append(temp_train_acc)
test_acc.append(temp_test_acc)
acc_and_loss = [(i+1), temp_train_loss, temp_train_acc,
temp_test_acc]
acc_and_loss = [np.round(x,2) for x in acc_and_loss]
```

13.输出结果如下：

```
print('Generation # {}. Train Loss: {:.2f}. Train Acc (Test Acc): {:.2f} ({:.2f})'.format(*acc_and_loss))
Generation # 5. Train Loss: 2.37. Train Acc (Test Acc): 7.00 (9.80)
Generation # 10. Train Loss: 2.16. Train Acc (Test Acc): 31.00 (22.00)
Generation # 15. Train Loss: 2.11. Train Acc (Test Acc): 36.00 (35.20)
Generation # 490. Train Loss: 0.06. Train Acc (Test Acc): 98.00 (97.40)
Generation # 495. Train Loss: 0.10. Train Acc (Test Acc): 98.00 (95.40)
Generation # 500. Train Loss: 0.14. Train Acc (Test Acc): 98.00 (96.00)
```

14.使用Matplotlib模块绘制损失函数和准确度的代码，所绘图像见图8-3：

```

eval_indices = range(0, generations, eval_every)
# Plot loss over time
plt.plot(eval_indices, train_loss, 'k-')
plt.title('Softmax Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Softmax Loss')
plt.show()
# Plot train and test accuracy
plt.plot(eval_indices, train_acc, 'k-', label='Train Set Accuracy')
plt.plot(eval_indices, test_acc, 'r--', label='Test Set Accuracy')
plt.title('Train and Test Accuracy')
plt.xlabel('Generation')
plt.ylabel('Accuracy')

plt.legend(loc='lower right')
plt.show()

```

15.运行如下代码打印最新结果中的六幅抽样图（见图8-4）。

```

# Plot the 6 of the last batch results:
actuals = rand_y[0:6]
predictions = np.argmax(temp_train_preds, axis=1)[0:6]

images = np.squeeze(rand_x[0:6])
Nrows = 2
Ncols = 3
for i in range(6):
    plt.subplot(Nrows, Ncols, i+1)
    plt.imshow(np.reshape(images[i], [28,28]), cmap='Greys_r')
    plt.title('Actual: ' + str(actuals[i]) + ' Pred: ' + str(predictions[i]), fontsize=10)
    frame = plt.gca()
    frame.axes.get_xaxis().set_visible(False)
    frame.axes.get_yaxis().set_visible(False)

```

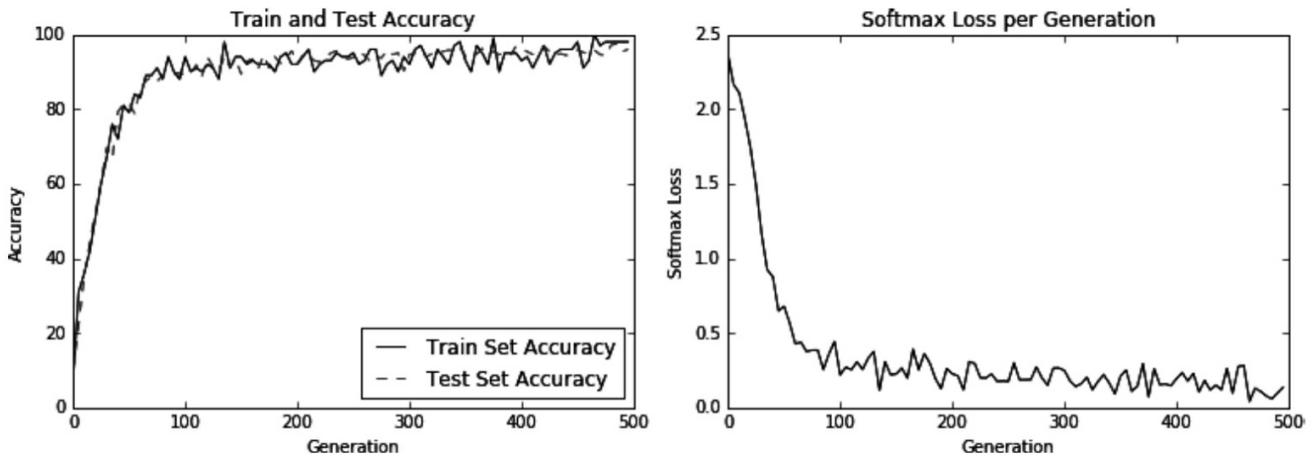


图8-3 左图是训练集和测试集迭代训练500次的准确度；右图是训练集和测试集迭代训练500次的softmax损失函数

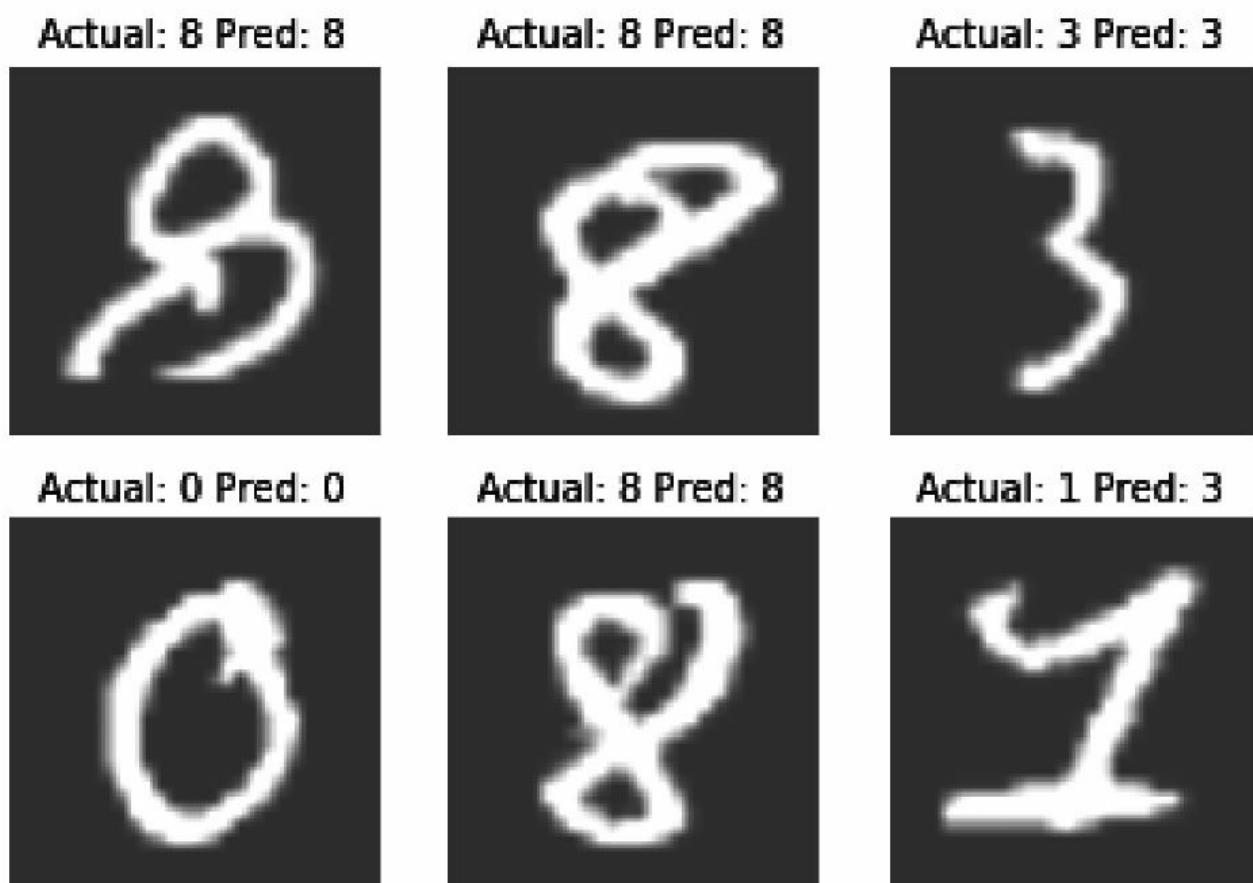


图8-4 六幅随机图标题中的实际数字和预测数字。右下角图片预测为数字3，实际是数字1。

8.2.3 工作原理

我们提升了算法模型在MNIST数据集的性能，并且从原始数据集训练模型迅速获得了约97%的准确度。模型中前两层是卷积操作、ReLU和maxpool的组合。后两层是全联接层。在本例中，批量训练的批量大小为100，在迭代训练中观察准确度和损失函数，最后绘制六幅随机图片以及对应的实际数字和预测数字。

卷积神经网络算法在图像识别方向效果很好。部分原因是卷积层操作将图片中重要的部分特征转化成低维特征。卷积神经网络模型创建它们的特征，并用该特征预测。

8.2.4 延伸学习

在最近几年，CNN模型在图像识别领域发展迅速。有许多相当杰出的观点和架构方案频出。Arxiv.org网站（<https://arxiv.org/>）收录该领域的论文，该网站是由康奈尔大学创建并维护的。Arxiv.org网站包含许多领域最新发表的文章，比如计算机科学及其子领域，如计算机视觉和图像识别（<https://arxiv.org/list/cs.CV/recent>）。

8.2.5 参考

下面是一些卷积神经网络算法的学习资料:

- ▶ Stanford University has a great wiki at: http://scarlet.stanford.edu/teach/index.php/An_Introduction_to_Convolutional_Neural_Networks
- ▶ *Deep Learning* by Michael Nielsen, at: <http://neuralnetworksanddeeplearning.com/chap6.html>
- ▶ *An Introduction to Convolutional Neural Networks* by Jianxin Wu at: <http://cs.nju.edu.cn/wujx/paper/CNN.pdf>

8.3 用TensorFlow实现进阶的CNN

CNN模型在图像识别上的扩展是如何增加网络深度的。如果我们有足够大的数据集，就会提高预测的准确度。重复卷积操作、maxpool操作和ReLU操作是增加神经网络深度的标准方法。许多准确度高的图像识别网络都使用该方法。

8.3.1 开始

本节将实现一个更复杂的读取图像数据的方法，并使用更大的CNN模型进行CIFAR10数据集（<https://www.cs.toronto.edu/~kriz/cifar.html>）上的图像识别。该图片数据集有60000张 32×32 像素的图片，分10个类别。图片可能的分类是：airplane、automobile、bird、cat、deer、dog、frog、horse、ship和truck。

大部分图片数据集都太大，不能全部放入内存。TensorFlow的做法是建立一个图像管道从文件中一次批量读取；而我们会建立一个图像数据读取器，然后创建一个批量数据的队列。

一般地，对于图像识别的数据，都会在模型训练前将图片随机打乱。本例中，我们将进行随机裁剪、翻转和调节亮度。

本节是TensorFlow官方CIFAR-10例子的改写版，其中官方例子见参考部分。我们将官方例子写成脚本，并将逐行解读重要的代码。我们也会将一些常量值和参数调整为论文中引用的值，具体会在详细步骤中指明。

8.3.2 动手做

1. 导入必要的编程库，创建一个计算图会话，代码如下：

```
import os
import sys
import tarfile
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from six.moves import urllib
sess = tf.Session()
```

2. 声明一些模型参数。将训练集和测试集的批量大小设为128。我们总共迭代20000次，并且每迭代50次打印出状态值。每迭代500次，我们将在测试集的批量数据上进行模型评估。设置图片长度和宽度，以及随机裁剪图片的大小。颜色通道设为3通道（红色、绿色和蓝色），目标分类设为10类。最后声明存储数据和批量图片的位置。具体代码如下：

```
batch_size = 128
output_every = 50
generations = 20000
eval_every = 500
image_height = 32
image_width = 32
crop_height = 24
crop_width = 24
num_channels = 3
num_targets = 10
data_dir = 'temp'
extract_folder = 'cifar-10-batches-bin'
```

3. 推荐降低学习率来训练更好的模型，所以我们采用指数级减小学习率：学习率初始值设为0.1，每迭代250次指数级减少学习率，因子为10%。公式为： $0.1 \cdot 0.9^x$ ，其中x是当前迭代的次数。TensorFlow默认是连续减小学习率，但是也接受阶梯式更新学习率，代码如下：

```
learning_rate = 0.1
lr_decay = 0.9
num_gens_to_wait = 250.
```

4. 设置读取二进制CIFAR-10图片的参数，代码如下：

```
image_vec_length = image_height * image_width * num_channels
record_length = 1 + image_vec_length
```

5. 设置下载CIFAR-10图像数据集的URL和数据目录，代码如下：

```
data_dir = 'temp'
if not os.path.exists(data_dir):
    os.makedirs(data_dir)
cifar10_url = 'http://www.cs.toronto.edu/~kriz/cifar-10-binary.
tar.gz'
data_file = os.path.join(data_dir, 'cifar-10-binary.tar.gz')
if not os.path.isfile(data_file):
    # Download file
    filepath, _ = urllib.request.urlretrieve(cifar10_url, data_
file, progress)
    # Extract file
    tarfile.open(filepath, 'r:gz').extractall(data_dir)
```

6. 使用read_cifar_files() 函数建立图片读取器，返回一个随机打乱的图片。首先，声明一个读取固定字节长度的读取器；然后从图像队列中读取图片，抽取图片并标记；最后使用TensorFlow内建的图像修改函数随机打乱图片，代码如下：

```

def read_cifar_files(filename_queue, distort_images = True):
    reader = tf.FixedLengthRecordReader(record_bytes=record_length)
    key, record_string = reader.read(filename_queue)
    record_bytes = tf.decode_raw(record_string, tf.uint8)
    # Extract label
    image_label = tf.cast(tf.slice(record_bytes, [0], [1]), tf.int32)
    # Extract image
    image_extracted = tf.reshape(tf.slice(record_bytes, [1], [image_vec_length]), [num_channels, image_height, image_width])
    # Reshape image
    image_uint8image = tf.transpose(image_extracted, [1, 2, 0])
    reshaped_image = tf.cast(image_uint8image, tf.float32)
    # Randomly Crop image
    final_image = tf.image.resize_image_with_crop_or_pad(reshaped_image, crop_width, crop_height)
    if distort_images:
        # Randomly flip the image horizontally, change the brightness and contrast
        final_image = tf.image.random_flip_left_right(final_image)
        final_image = tf.image.random_brightness(final_image, max_delta=63)
        final_image = tf.image.random_contrast(final_image, lower=0.2, upper=1.8)
    # Normalize whitening
    final_image = tf.image.per_image_whitening(final_image)
    return(final_image, image_label)

```

7. 声明批量处理使用的图像管道填充函数。首先，需要建立读取图片的列表，定义如何用TensorFlow内建函数创建的input producer对象读取这些图片列表。把input producer传入上一步创建的图片读取函数read_cifar_files () 中。然后创建图像队列的批量读取器，shuffle_batch () 。具体代码如下：

```

def input_pipeline(batch_size, train_logical=True):
    if train_logical:
        files = [os.path.join(data_dir, extract_folder, 'data_
batch_{}.bin'.format(i)) for i in range(1, 6)]
    else:
        files = [os.path.join(data_dir, extract_folder, 'test_
batch.bin')]
    filename_queue = tf.train.string_input_producer(files)
    image, label = read_cifar_files(filename_queue)

    min_after_dequeue = 1000
    capacity = min_after_dequeue + 3 * batch_size
    example_batch, label_batch = tf.train.shuffle_batch([image,
label], batch_size, capacity, min_after_dequeue)
    return(example_batch, label_batch)

```



设置合适的min_after_dequeue值是相当重要的。该参数是设置抽样图片缓存最小值。TensorFlow官方文档推荐设置为 (#threads+error margin) *batch_size。注意，该参数设置太大会导致更多的shuffle。从图像队列中shuffle大的图像数据集需要更多的内存。

8. 声明模型函数。本例的模型使用两个卷积层，接着是三个全联接层。为了便于声明模型变量，我们将定义两个变量函数。两层卷积操作各创建64个特征。第一个全联接层联接第二个卷积层，有384个隐藏节点。第二个全联接层联接刚才的384个隐藏节点到192个隐藏节点。最后的隐藏层操作联接192个隐藏节点到10个输出分类。具体见下面"#"注释部分，代码如下：

```
def cifar_cnn_model(input_images, batch_size, train_logical=True):
    def truncated_normal_var(name, shape, dtype):
        return(tf.get_variable(name=name, shape=shape,
dtype=dtype, initializer=tf.truncated_normal_
initializer(stddev=0.05)))
    def zero_var(name, shape, dtype):
        return(tf.get_variable(name=name, shape=shape,
dtype=dtype, initializer=tf.constant_initializer(0.0)))
    # First Convolutional Layer
    with tf.variable_scope('conv1') as scope:
        # Conv_kernel is 5x5 for all 3 colors and we will create
64 features
        conv1_kernel = truncated_normal_var(name='conv_kernel1',
shape=[5, 5, 3, 64], dtype=tf.float32)
        # We convolve across the image with a stride size of 1
        conv1 = tf.nn.conv2d(input_images, conv1_kernel, [1, 1, 1,
1], padding='SAME')
        # Initialize and add the bias term
        conv1_bias = zero_var(name='conv_bias1', shape=[64],
```

```
dtype=tf.float32)
    conv1_add_bias = tf.nn.bias_add(conv1, conv1_bias)
    # ReLU element wise
    relu_conv1 = tf.nn.relu(conv1_add_bias)
# Max Pooling
pool1 = tf.nn.max_pool(relu_conv1, ksize=[1, 3, 3, 1],
strides=[1, 2, 2, 1], padding='SAME', name='pool_layer1')

# Local Response Normalization
norm1 = tf.nn.lrn(pool1, depth_radius=5, bias=2.0, alpha=1e-3,
beta=0.75, name='norm1')
# Second Convolutional Layer
with tf.variable_scope('conv2') as scope:
    # Conv kernel is 5x5, across all prior 64 features and we
create 64 more features
    conv2_kernel = truncated_normal_var(name='conv_kernel2',
shape=[5, 5, 64, 64], dtype=tf.float32)
    # Convolve filter across prior output with stride size of
1
    conv2 = tf.nn.conv2d(norm1, conv2_kernel, [1, 1, 1, 1],
padding='SAME')
    # Initialize and add the bias
    conv2_bias = zero_var(name='conv_bias2', shape=[64],
dtype=tf.float32)
    conv2_add_bias = tf.nn.bias_add(conv2, conv2_bias)
    # ReLU element wise
    relu_conv2 = tf.nn.relu(conv2_add_bias)
# Max Pooling
pool2 = tf.nn.max_pool(relu_conv2, ksize=[1, 3, 3, 1],
strides=[1, 2, 2, 1], padding='SAME', name='pool_layer2')
# Local Response Normalization (parameters from paper)
norm2 = tf.nn.lrn(pool2, depth_radius=5, bias=2.0, alpha=1e-3,
beta=0.75, name='norm2')
# Reshape output into a single matrix for multiplication for
the fully connected layers
reshaped_output = tf.reshape(norm2, [batch_size, -1])
reshaped_dim = reshaped_output.get_shape()[1].value

# First Fully Connected Layer
with tf.variable_scope('full1') as scope:
    # Fully connected layer will have 384 outputs.
    full_weight1 = truncated_normal_var(name='full_mult1',
shape=[reshaped_dim, 384], dtype=tf.float32)
    full_bias1 = zero_var(name='full_bias1', shape=[384],
dtype=tf.float32)
    full_layer1 = tf.nn.relu(tf.add(tf.matmul(reshaped_output,
full_weight1), full_bias1))
# Second Fully Connected Layer
with tf.variable_scope('full2') as scope:
    # Second fully connected layer has 192 outputs.
    full_weight2 = truncated_normal_var(name='full_mult2',
shape=[384, 192], dtype=tf.float32)
```

```

        full_bias2 = zero_var(name='full_bias2', shape=[192],
                               dtype=tf.float32)
        full_layer2 = tf.nn.relu(tf.add(tf.matmul(full_layer1,
                                              full_weight2), full_bias2))
        # Final Fully Connected Layer -> 10 categories for output
        (num_targets)
        with tf.variable_scope('full3') as scope:
            # Final fully connected layer has 10 (num_targets)
            outputs.
            full_weight3 = truncated_normal_var(name='full_mult3',
                                                shape=[192, num_targets],
                                                dtype=tf.float32)
            full_bias3 = zero_var(name='full_bias3', shape=[num_targets],
                                  dtype=tf.float32)
            final_output = tf.add(tf.matmul(full_layer2, full_weight3),
                                  full_bias3)

    return(final_output)

```

归一化参数采用参考论文中的值，见8.4.3节。

9.创建损失函数。本例使用softmax损失函数，因为一张图片应该属于其中一个类别，所以输出结果应该是10类分类的概率分布，代码如下：

```

def cifar_loss(logits, targets):
    # Get rid of extra dimensions and cast targets into integers
    targets = tf.squeeze(tf.cast(targets, tf.int32))
    # Calculate cross entropy from logits and targets
    cross_entropy = tf.nn.sparse_softmax_cross_entropy_with_
    logits(logits, targets)
    # Take the average loss across batch size
    cross_entropy_mean = tf.reduce_mean(cross_entropy)
    return(cross_entropy_mean)

```

10.定义训练步骤函数。在训练步骤中学习率将指数级减小，代码如下：

```
def train_step(loss_value, generation_num):
    # Our learning rate is an exponential decay (stepped down)
    model_learning_rate = tf.train.exponential_decay(learning_rate,
                                                     generation_num, num_gens_to_wait, lr_decay, staircase=True)
    # Create optimizer
    my_optimizer = tf.train.GradientDescentOptimizer(model_learning_rate)
    # Initialize train step
    train_step = my_optimizer.minimize(loss_value)
    return(train_step)
```

11. 创建批量图片的准确度函数。该函数输入logits和目标向量，输出平均准确度。训练批量图片和测试批量图片都可以使用该准确度函数，代码如下：

```
def accuracy_of_batch(logits, targets):
    # Make sure targets are integers and drop extra dimensions
    targets = tf.squeeze(tf.cast(targets, tf.int32))
    # Get predicted values by finding which logit is the greatest
    batch_predictions = tf.cast(tf.argmax(logits, 1), tf.int32)

    # Check if they are equal across the batch
    predicted_correctly = tf.equal(batch_predictions, targets)
    # Average the 1's and 0's (True's and False's) across the batch size
    accuracy = tf.reduce_mean(tf.cast(predicted_correctly, tf.float32))
    return(accuracy)
```

12. 有了图像管道函数input_pipeline()后，我们开始初始化训练图像管道和测试图像管道，代码如下：

```
images, targets = input_pipeline(batch_size, train_logical=True)
test_images, test_targets = input_pipeline(batch_size, train_logical=False)
```

13. 初始化训练模型。值得注意的是，需要在创建训练模型时声明scope.reuse_variables()，这样可以在创建测试模型时重用训练模型相同的模型参数，代码如下：

```
with tf.variable_scope('model_definition') as scope:  
    # Declare the training network model  
    model_output = cifar_cnn_model(images, batch_size)  
    # Use same variables within scope  
    scope.reuse_variables()  
    # Declare test model output  
    test_output = cifar_cnn_model(test_images, batch_size)
```

14. 初始化损失函数和测试准确度函数。然后声明迭代变量。该迭代变量需要声明为非训练型变量，并传入训练函数，用于计算学习率的指数级衰减值，代码如下：

```
loss = cifar_loss(model_output, targets)  
accuracy = accuracy_of_batch(test_output, test_targets)  
generation_num = tf.Variable(0, trainable=False)  
train_op = train_step(loss, generation_num)
```

15. 初始化所有模型变量，然后运行TensorFlow的start_queue_runners() 函数启动图像管道。图像管道通过赋值字典传入批量图片，开始训练模型和测试模型输出，代码如下：

```
init = tf.initialize_all_variables()  
sess.run(init)  
tf.train.start_queue_runners(sess=sess)
```

16. 现在遍历迭代训练，保存训练集损失函数和测试集准确度，代码如下：

```
train_loss = []  
test_accuracy = []  
for i in range(generations):  
    _, loss_value = sess.run([train_op, loss])  
    if (i+1) % output_every == 0:  
        train_loss.append(loss_value)  
        output = 'Generation {}: Loss = {:.5f}'.format((i+1),  
loss_value)  
        print(output)  
    if (i+1) % eval_every == 0:
```

```
[temp_accuracy] = sess.run([accuracy])
test_accuracy.append(temp_accuracy)
acc_output = ' --- Test Accuracy='
{:.2f}%.format(100.*temp_accuracy)
print(acc_output)
```

17.输出结果如下：

```
Generation 19500: Loss = 0.04461
--- Test Accuracy = 80.47%.
Generation 19550: Loss = 0.01171
Generation 19600: Loss = 0.06911
Generation 19650: Loss = 0.08629
Generation 19700: Loss = 0.05296
Generation 19750: Loss = 0.03462
Generation 19800: Loss = 0.03182
Generation 19850: Loss = 0.07092
Generation 19900: Loss = 0.11342
Generation 19950: Loss = 0.08751
Generation 20000: Loss = 0.02228
--- Test Accuracy = 83.59%.
```

18.使用matplotlib模块绘制损失函数和准确度（见图8-5），代码如下：

```
eval_indices = range(0, generations, eval_every)
output_indices = range(0, generations, output_every)
# Plot loss over time
plt.plot(output_indices, train_loss, 'k-')
plt.title('Softmax Loss per Generation')
plt.xlabel('Generation')
plt.ylabel('Softmax Loss')
plt.show()
# Plot accuracy over time
plt.plot(eval_indices, test_accuracy, 'k-')
plt.title('Test Accuracy')
plt.xlabel('Generation')
plt.ylabel('Accuracy')
plt.show()
```

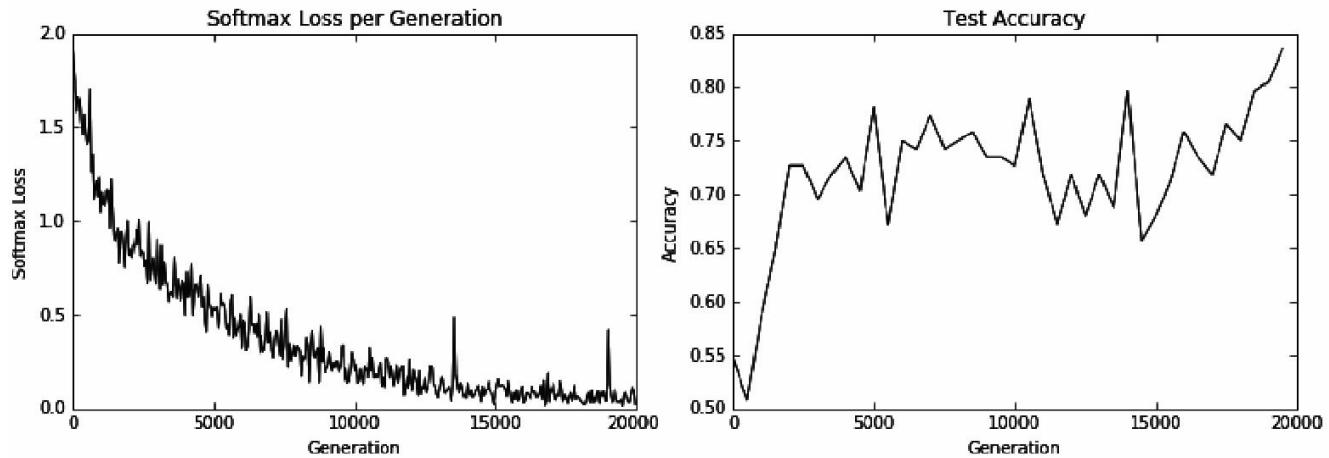


图8-5 左图是训练集损失函数图；右图是测试集准确度图。CIFAR-10图像识别的CNN模型达到75%的准确度

8.3.3 工作原理

下载CIFAR-10图片数据集后，我们建立图像管道。关于图像管道的详细信息请见官方TensorFlow CIFAR-10示例。我们使用训练图片管道和测试图片管道预测图片的准确分类。在最后，模型训练在测试数据集上达到了75%的准确度。

8.3.4 参考

- ▶ For more information about the CIFAR-10 dataset, please see *Learning Multiple Layers of Features from Tiny Images*, Alex Krizhevsky, 2009. <https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf>
- ▶ To see original TensorFlow code, visit <https://github.com/tensorflow/tensorflow/tree/r0.11/tensorflow/models/image/cifar10>
- ▶ For more on local response normalization, please see, *ImageNet Classification with Deep Convolutional Neural Networks*, Krizhevsky, A., et. al. 2012. <http://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks>

8.4 再训练已有的CNN模型

从原始数据集开始训练一个全新的图像识别模型需耗费大量时间和计算力。如果我们可以重用预训练好的网络训练图片，将会缩短计算时间。本节将展示如何使用预训练好的TensorFlow图像模型，微调后训练其他图片数据集。

8.4.1 开始

基本思路是重用预训练模型的卷积层的权重和结构，然后重新训练全联接层。TensorFlow官方提供一个利用已有的CNN模型进行再训练的例子（见8.4.4节）。本节将展示如何在CIFAR-10图片数据集上使用相同的方法。我们采用的CNN网络使用了非常流行的Inception架构。Inception CNN模型由Google公司创建，并在许多图像识别基准测试中表现不俗，详情请见8.4.4节中的论文。

下面的Python脚本显示如何下载CIFAR-10图片数据集，自动分割图片数据、标注，并保存到训练集和测试集文件中的十个分类；然后展示如何训练图片数据集。

8.4.2 动手做

1. 导入必要的编程库，包括下载、解压和保存CIFAR-10图片数据的编程库，代码如下：

```
import os
import tarfile
import _pickle as cPickle

import numpy as np
import urllib.request
import scipy.misc
```

2. 定义CIFAR-10图片数据链接，创建存储数据的临时文件夹，并声明图片的十个分类，代码如下：

```
cifar_link = 'https://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz'
data_dir = 'temp'
if not os.path.isdir(data_dir):
    os.makedirs(data_dir)
objects = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog',
'frog', 'horse', 'ship', 'truck']
```

3. 下载CIFAR-10.tar数据文件，并解压缩文件，代码如下：

```
target_file = os.path.join(data_dir, 'cifar-10-python.tar.gz')
if not os.path.isfile(target_file):
    print('CIFAR-10 file not found. Downloading CIFAR data (Size = 163MB)')
    print('This may take a few minutes, please wait.')
    filename, headers = urllib.request.urlretrieve(cifar_link,
target_file)
# Extract into memory
tar = tarfile.open(target_file)
tar.extractall(path=data_dir)
tar.close()
```

4. 创建训练所需的文件夹结构。临时目录下有两个文件夹train_dir和validation_dir。每个文件夹下有10个子文件夹，分别存储10个目标分类，代码如下：

```

# Create train image folders
train_folder = 'train_dir'
if not os.path.isdir(os.path.join(data_dir, train_folder)):
    for i in range(10):
        folder = os.path.join(data_dir, train_folder, objects[i])
        os.makedirs(folder)
# Create test image folders
test_folder = 'validation_dir'
if not os.path.isdir(os.path.join(data_dir, test_folder)):
    for i in range(10):
        folder = os.path.join(data_dir, test_folder, objects[i])
        os.makedirs(folder)

```

5.为了保存图片，我们将创建函数从内存中加载图片并存入文件夹，代码如下：

```

def load_batch_from_file(file):
    file_conn = open(file, 'rb')
    image_dictionary = cPickle.load(file_conn, encoding='latin1')
    file_conn.close()
    return(image_dictionary)

```

6.在上一步的文件夹中，为每个目标分类保存一个文件，代码如下：

```

def save_images_from_dict(image_dict, folder='data_dir'):

    for ix, label in enumerate(image_dict['labels']):
        folder_path = os.path.join(data_dir, folder,
objects[label])
        filename = image_dict['filenames'][ix]
        #Transform image data
        image_array = image_dict['data'][ix]
        image_array.resize([3, 32, 32])
        # Save image
        output_location = os.path.join(folder_path, filename)
        scipy.misc.imsave(output_location, image_array.transpose())

```

7.对于上一步的函数，遍历下载数据文件，并把每个图片保存到正确的位置，代码如下：

```

data_location = os.path.join(data_dir, 'cifar-10-batches-py')
train_names = ['data_batch_' + str(x) for x in range(1,6)]
test_names = ['test_batch']
# Sort train images
for file in train_names:
    print('Saving images from file: {}'.format(file))
    file_location = os.path.join(data_dir, 'cifar-10-batches-py',
file)
    image_dict = load_batch_from_file(file_location)
    save_images_from_dict(image_dict, folder=train_folder)
# Sort test images
for file in test_names:
    print('Saving images from file: {}'.format(file))
    file_location = os.path.join(data_dir, 'cifar-10-batches-py',
file)
    image_dict = load_batch_from_file(file_location)
    save_images_from_dict(image_dict, folder=test_folder)

```

8. Python脚本最后部分是创建标注文件。该文件用标注（而不是数值索引）自解释输出结果，代码如下：

```

cifar_labels_file = os.path.join(data_dir, 'cifar10_labels.txt')
print('Writing labels file, {}'.format(cifar_labels_file))
with open(cifar_labels_file, 'w') as labels_file:
    for item in objects:
        labels_file.write("{}\n".format(item))

```

9. 上面的脚本运行之后，下载图片数据集并排序归类。接着按TensorFlow官方示例操作，先复制例子源码，代码如下：

```
git clone https://github.com/tensorflow/models/tree/master/inception/inception
```

10. 为了重用已训练好的模型，我们下载神经网络权重并应用于新神经网络模型，代码如下：

```

me@computer:~$ curl -O http://download.tensorflow.org/models/image/imagenet/inception-v3-2016-03-01.tar.gz
me@computer:~$ tar xzf inception-v3-2016-03-01.tar.gz

```

11. 准备好图片文件，我们将其转为TFRecords对象，代码如下：

```
me@computer:~$ python3 data/build_image_data.py  
--train_directory="temp/train_dir/"  
--validation_directory="temp/validation_dir"  
--output_directory="temp/" --labels_file="temp/cifar10_labels.txt"
```

12. 使用bazel模块训练算法模型，设置fine_tune参数为true。该脚本每迭代10次输出损失函数。我们可以随时终止进程，因为模型输出结果都保存于temp/training_results文件夹。我们能从该文件夹加载模型数据进行模型评估，代码如下：

```
me@computer:~$ bazel-bin/inception/flowers_train  
--train_dir="temp/training_results" --data_dir="temp/data_dir"  
--pretrained_model_checkpoint_path="model.ckpt-157585"  
--fine_tune=True --initial_learning_rate=0.001  
--input_queue_memory_factor=1
```

13. 训练输出结果如下：

```
2016-09-18 12:16:32.563577: step 1290, loss = 2.02 (1.2 examples/sec; 26.965 sec/batch)  
2016-09-18 12:25:41.316540: step 1300, loss = 2.01 (1.2 examples/sec; 26.357 sec/batch)
```

8.4.3 工作原理

TensorFlow官方示例训练模型是基于已训练好的CNN模型，其要求从CIFAR-10图像数据创建文件夹。我们将CIFAR-10图像数据转化成TFRecords文件格式进行模型训练。注意，我们是微调已有的网络模型，重新训练全连接层来拟合10个目标分类。

8.4.4 参考

- ▶ Official Tensorflow Inception-v3 tutorial: <https://github.com/tensorflow/models/tree/master/inception>
- ▶ Googlenet Inception-v3 paper: <https://arxiv.org/abs/1512.00567>

8.5 用TensorFlow实现模仿大师绘画

图像识别CNN模型训练好之后，我们能用网络结构训练其他感兴趣的数据或者图像处理。StyleNet程序试图学习一幅图的风格，并将该图像风格应用于另外一幅图（保持后者的图片结构或者内容）。如果我们能找到CNN模型中间层节点分离出图像风格，就可以应用于另外的图片内容上。

8.5.1 开始

StyleNet程序需输入两幅图片，将一幅图片的图像风格应用于另外一幅图的内容上。该程序基于2015年发布的著名文章“*A Neural Algorithm of Artistic Style*”，见8.5.4节。该文章的作者发现一些CNN模型的中间层存在某些属性可以编码图片风格和图片内容。最后，我们从风格图片中训练图片风格层，从原始图片中训练图片内容层，并且反向传播这些计算损失函数，从而让原始图片更像风格图片。

我们将下载文章中推荐的网络——imagenet-vgg-19。imagenet-vgg-16网络也表现不错，但是前述文章中推荐的是imagenet-vgg-19网络。

8.5.2 动手做

1. 下载预训练的网络，存为.mat文件格式。mat文件格式是一种matlab对象，利用Python的scipy模块读取该文件。下面是下载mat对象的链接，该模型保存在Python脚本同一文件夹下。

<http://www.vlfeat.org/matconvnet/models/beta16/imagenet-vgg-verydeep-19.mat>

2. 导入必要的编程序库，代码如下：

```
import os
import scipy.misc
import numpy as np
import tensorflow as tf
```

3. 开始创建计算图会话，声明两幅图片（原始图片和风格图片）的位置。我们将使用本书的封面作为原始图片；梵高的大作《Starry Night》作为风格图片。这两幅图片可以在

GitHub (https://github.com/nfmccleure/tensorflow_cookbook) 上下载，代码如下：

```
sess = tf.Session()
original_image_file = 'temp/book_cover.jpg'
style_image_file = 'temp/starry_night.jpg'
```

4. 设置模型参数：mat文件位置、网络权重、学习率、迭代次数和输出中间图片的频率。该权重可以增加应用于原始图片中风格图片的权重。这些参数可以根据实际需求稍微做出调整，代码如下：

```
vgg_path = 'imagenet-vgg-verydeep-19.mat'
original_image_weight = 5.0
style_image_weight = 200.0
regularization_weight = 50.0
learning_rate = 0.1
generations = 10000

output_generations = 500
```

5. 使用scipy模块加载两幅图片，并将风格图片的维度调整的和原始图片一致，代码如下：

```
original_image = scipy.misc.imread(original_image_file)
style_image = scipy.misc.imread(style_image_file)
# Get shape of target and make the style image the same
target_shape = original_image.shape
style_image = scipy.misc.imresize(style_image, target_shape[1] /
style_image.shape[1])
```

6.从文章中获知，我们能定义各层出现的顺序，本例使用文章作者约定的名称，代码如下：

```
vgg_layers = ['conv1_1', 'relu1_1',
'conv1_2', 'relu1_2', 'pool1',
'conv2_1', 'relu2_1',
'conv2_2', 'relu2_2', 'pool2',
'conv3_1', 'relu3_1',
'conv3_2', 'relu3_2',
'conv3_3', 'relu3_3',
'conv3_4', 'relu3_4', 'pool3',
'conv4_1', 'relu4_1',
'conv4_2', 'relu4_2',
'conv4_3', 'relu4_3',
'conv4_4', 'relu4_4', 'pool4',
'conv5_1', 'relu5_1',
'conv5_2', 'relu5_2',
'conv5_3', 'relu5_3',
'conv5_4', 'relu5_4']
```

7.定义函数抽取mat文件中的参数，代码如下：

```
def extract_net_info(path_to_params):
    vgg_data = scipy.io.loadmat(path_to_params)
    normalization_matrix = vgg_data['normalization'][0][0][0]
    mat_mean = np.mean(normalization_matrix, axis=(0,1))
    network_weights = vgg_data['layers'][0]
    return(mat_mean, network_weights)
```

8.基于上述加载的权重和网络层定义，通过TensorFlow的内建函数来创建网络。迭代训练每层，并分配合适的权重和偏置，代码如下：

```

def vgg_network(network_weights, init_image):
    network = {}
    image = init_image
    for i, layer in enumerate(vgg_layers):
        if layer[1] == 'c':
            weights, bias = network_weights[i][0][0][0]
            weights = np.transpose(weights, (1, 0, 2, 3))
            bias = bias.reshape(-1)

            conv_layer = tf.nn.conv2d(image, tf.constant(weights),
(1, 1, 1, 1), 'SAME')
            image = tf.nn.bias_add(conv_layer, bias)
        elif layer[1] == 'r':
            image = tf.nn.relu(image)
        else:
            image = tf.nn.max_pool(image, (1, 2, 2, 1), (1, 2, 2,
1), 'SAME')
        network[layer] = image
    return(network)

```

9.参考文章中推荐了为原始图片和风格图片分配中间层的一些策略。在本例中，原始图片采用relu4_2层，风格图片采用reluX_1层组合，代码如下：

```

original_layer = 'relu4_2'
style_layers = ['relu1_1', 'relu2_1', 'relu3_1', 'relu4_1',
'relu5_1']

```

10.运行extract_net_info()函数获取网络权重和平均值。在图片的起始位置增加一个维度，调整图片的形状为四维。TensorFlow的图像操作是针对四维的，所以需要增加维度，代码如下：

```

normalization_mean, network_weights = extract_net_info(vgg_path)
shape = (1,) + original_image.shape
style_shape = (1,) + style_image.shape
original_features = {}
style_features = {}

```

11.声明image占位符，并创建该占位符的网络，代码如下：

```

image = tf.placeholder('float', shape=shape)
vgg_net = vgg_network(network_weights, image)

```

12.归一化原始图片矩阵，接着运行网络，代码如下：

```
original_minus_mean = original_image - normalization_mean
original_norm = np.array([original_minus_mean])
original_features[original_layer] = sess.run(vgg_net[original_layer],
feed_dict={image: original_norm})
```

13.为步骤9中选择的每个风格层重复上述过程，代码如下：

```
image = tf.placeholder('float', shape=style_shape)
vgg_net = vgg_network(network_weights, image)
style_minus_mean = style_image - normalization_mean
style_norm = np.array([style_minus_mean])
for layer in style_layers:
    layer_output = sess.run(vgg_net[layer], feed_dict={image:
style_norm})
    layer_output = np.reshape(layer_output, (-1, layer_output.
shape[3]))
    style_gram_matrix = np.matmul(layer_output.T, layer_output) /
layer_output.size

    style_features[layer] = style_gram_matrix
```

14.为了创建综合的图片，我们开始加入随机噪声，并运行网络，代码如下：

```
initial = tf.random_normal(shape) * 0.05
image = tf.Variable(initial)
vgg_net = vgg_network(network_weights, image)
```

15.声明第一个损失函数，该损失函数是原始图片的，定义为步骤9中选择的原始图片的relu4_2层输出与步骤12中归一化原始图片的输出的差值的L2范数，代码如下：

```
original_loss = original_image_weight * (2 * tf.nn.l2_loss(vgg_
net[original_layer] - original_features[original_layer]) /
original_features[original_layer].size)
```

16.为风格图片的每个层计算损失函数，代码如下：

```

style_loss = 0
style_losses = []
for style_layer in style_layers:
    layer = vgg_net[style_layer]
    feats, height, width, channels = [x.value for x in layer.get_
shape()]
    size = height * width * channels
    features = tf.reshape(layer, (-1, channels))
    style_gram_matrix = tf.matmul(tf.transpose(features),
features) / size
    style_expected = style_features[style_layer]
    style_losses.append(2 * tf.nn.l2_loss(style_gram_matrix -
style_expected) / style_expected.size)
style_loss += style_image_weight * tf.reduce_sum(style_losses)

```

17.第三个损失项成为总变分损失，该损失函数来自于总变分的计算。其相似于总变分去噪，真实图片有较低的局部变分，噪声图片具有较高的局部变分。下面代码中的关键部分是second_term_numerator，其减去附近的像素，高噪声的图片有较高的变分。我们最小化损失函数。具体代码如下：

```

total_var_x = sess.run(tf.reduce_prod(image[:,1:,:,:].get_
shape()))
total_var_y = sess.run(tf.reduce_prod(image[:, :, 1:,:].get_
shape()))
first_term = regularization_weight * 2
second_term_numerator = tf.nn.l2_loss(image[:,1:,:,:] -
image[:, :shape[1]-1,:,:])
second_term = second_term_numerator / total_var_y
third_term = (tf.nn.l2_loss(image[:, :, 1:,:]) -
image[:, :, :shape[2]-1,:]) / total_var_x
total_variation_loss = first_term * (second_term + third_term)

```

18.最小化总的损失函数。其中，总的损失函数是原始图片损失、风格图片损失和总变分损失的组合，代码如下：

```
loss = original_loss + style_loss + total_variation_loss
```

19.声明优化器函数，初始化所有模型变量，代码如下：

```

optimizer = tf.train.GradientDescentOptimizer(learning_rate)
train_step = optimizer.minimize(loss)
sess.run(tf.initialize_all_variables())

```

20.遍历迭代训练模型，频繁地打印更新的状态并保存临时图片文件。因为运行该算法的速度依赖于图片的选择，所以需要保存临时图片。在迭代次数较大的情况下，当临时图片显示训练的结果足够好时，我们

可以随时停止该训练过程，代码如下：

```
for i in range(generations) :  
    sess.run(train_step)  
    # Print update and save temporary output  
    if (i+1) % output_generations == 0:  
        print('Generation {} out of {}'.format(i + 1,  
generations))  
        image_eval = sess.run(image)  
        best_image_add_mean = image_eval.reshape(shape[1:]) +  
normalization_mean  
        output_file = 'temp_output_{}.jpg'.format(i)  
        scipy.misc.imsave(output_file, best_image_add_mean)
```

21. 算法训练结束，我们将保存最后的输出结果（见图8-6），代码如下：

```
image_eval = sess.run(image)  
best_image_add_mean = image_eval.reshape(shape[1:]) +  
normalization_mean  
output_file = 'final_output.jpg'  
scipy.misc.imsave(output_file, best_image_add_mean)
```

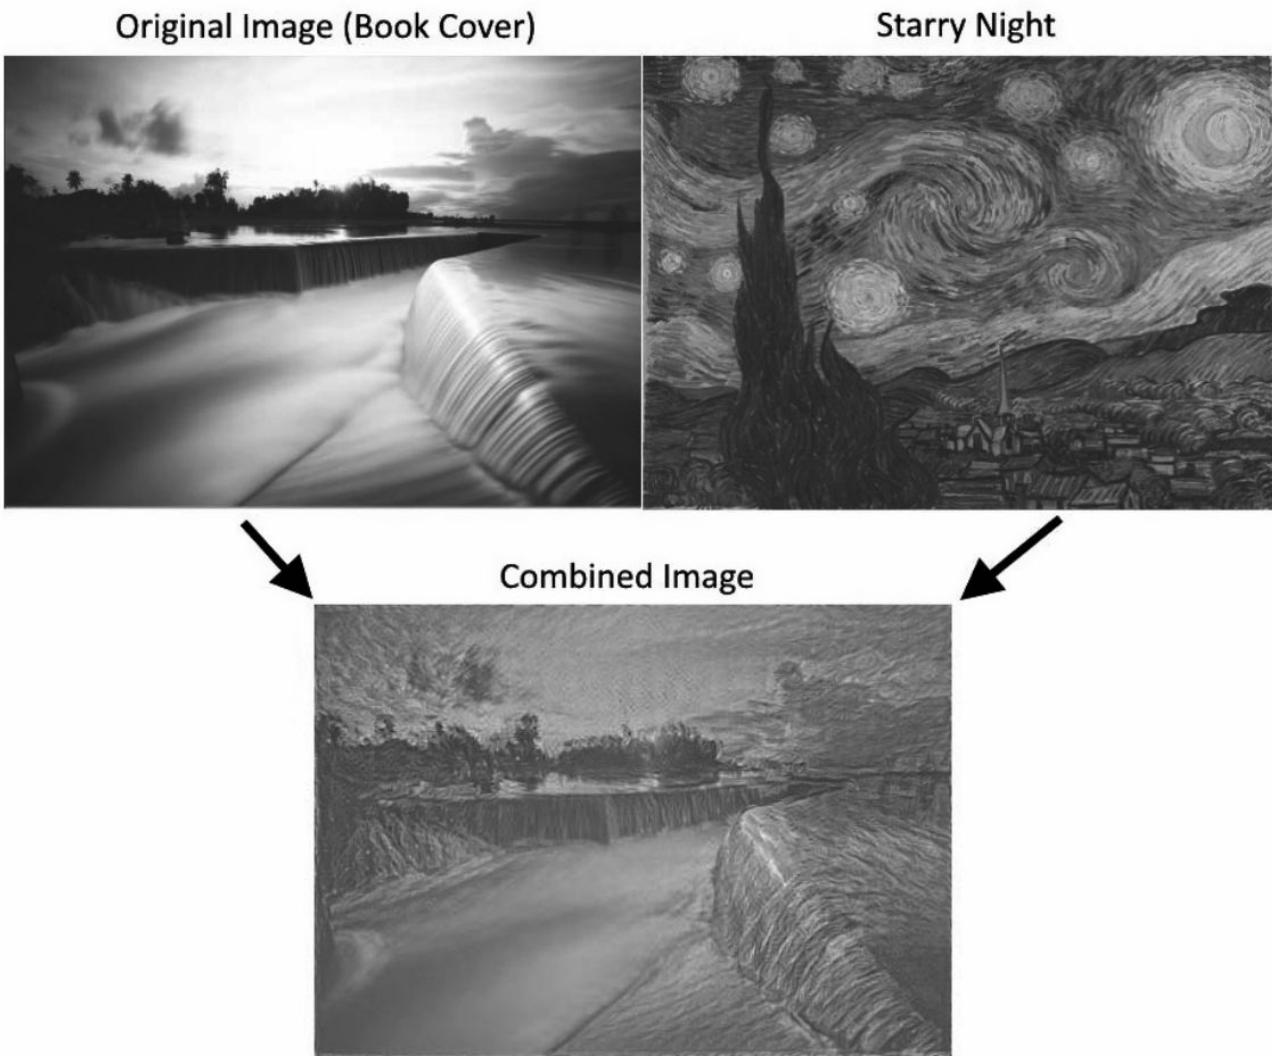


图8-6 使用StyleNet算法训练图片的Starry Night风格。注意，可以使用不同的权重获取不同的图片风格

8.5.3 工作原理

首先，加载两幅图片，然后加载预训练好的网络权重，为原始图片和风格图片分配网络层。我们计算三种损失函数：原始图片损失、风格图片损失和总变分损失。然后训练随机噪声图片，其包含风格图片的风格和原始图片的内容。

8.5.4 参考

- ▶ *A Neural Algorithm of Artistic Style* by Gatys, Ecker, Bethge. 2015. <https://arxiv.org/abs/1508.06576>.

8.6 用TensorFlow实现DeepDream

重用已训练好的CNN模型的另外一个应用是利用已标注特征（比如，猫耳朵或者鸟的羽毛）的中间层来迁移任意图片。本节将介绍TensorFlow的Deep Dream的示例，同时会详细讲解更多细节。

8.6.1 开始

TensorFlow官方示例通过一个脚本展示如何实现DeepDream，该脚本见8.6.4节。官方例子虽好但省略了部分细节，本节将详细介绍脚本的每行代码，并微调部分代码以兼容Python 3。

8.6.2 动手做

1. 在开始实现DeepDream之前，我们需要下载GoogleNet，其为CIFAR-1000图片数据集上已训练好的CNN模型，代码如下：

```
me@computer:~$ wget https://storage.googleapis.com/download.tensorflow.org/models/inception5h.zip  
me@computer:~$ unzip inception5h.zip
```

2. 导入必要的代码库，并创建一个计算图会话，代码如下：

```
import os  
import matplotlib.pyplot as plt  
import numpy as np  
import PIL.Image  
import tensorflow as tf  
from io import BytesIO  
graph = tf.Graph()  
sess = tf.InteractiveSession(graph=graph)
```

3. 声明解压的模型参数的位置，并且将这些参数加载进TensorFlow的计算图，代码如下：

```
# Model location  
model_fn = 'tensorflow_inception_graph.pb'  
# Load graph parameters  
with tf.gfile.FastGFile(model_fn, 'rb') as f:  
    graph_def = tf.GraphDef()  
    graph_def.ParseFromString(f.read())
```

4. 创建输入数据的占位符，设置`imagenet_mean`为117.0；然后导入计算图定义，并传入归一化的占位符，代码如下：

```
# Create placeholder for input  
t_input = tf.placeholder(np.float32, name='input')  
# Imagenet average bias to subtract off images  
imagenet_mean = 117.0  
t_preprocessed = tf.expand_dims(t_input - imagenet_mean, 0)  
tf.import_graph_def(graph_def, {'input': t_preprocessed})
```

5. 导入卷积层进行可视化，并在后续处理DeepDream时使用，代码如下：

```
# Create a list of layers that we can refer to later
layers = [op.name for op in graph.get_operations() if
op.type=='Conv2D' and 'import/' in op.name]
# Count how many outputs for each layer
feature_nums = [int(graph.get_tensor_by_name(name+':0').get_
shape() [-1]) for name in layers]
```

6.现在可以找某一层进行可视化了。我们可以通过层的名字或者特征数字139来查看。对图片进行噪声处理，代码如下：

```
layer = 'mixed4d_3x3_bottleneck_pre_relu'
channel = 139
img_noise = np.random.uniform(size=(224, 224, 3)) + 100.0
```

7.声明函数来绘制图片数组，代码如下：

```
def showarray(a, fmt='jpeg'):
    # First make sure everything is between 0 and 255
    a = np.uint8(np.clip(a, 0, 1)*255)
    # Pick an in-memory format for image display
    f = BytesIO()
    # Create the in memory image
    PIL.Image.fromarray(a).save(f, fmt)
    # Show image
    plt.imshow(a)
```

8.在计算图中创建层迭代函数来简化重复的代码，其以层的名字来迭代，代码如下：

```
def T(layer):
#Helper for getting layer output tensor
    return graph.get_tensor_by_name("import/%s:0"%layer)
```

9.下面封装一个创建占位符的函数，其可以指定参数返回占位符，代码如下：

```

# The following function returns a function wrapper that will
create the placeholder
# inputs of a specified dtype
def tffunc(*argtypes):
    '''Helper that transforms TF-graph generating function into a
regular one.

    See "resize" function below.
    '''

    placeholders = list(map(tf.placeholder, argtypes))

    def wrap(f):
        out = f(*placeholders)
        def wrapper(*args, **kw):
            return out.eval(dict(zip(placeholders, args)),
session=kw.get('session'))
        return wrapper
    return wrap

```

10. 创建调整图片大小的函数，其可以指定图片大小。该函数采用TensorFlow的内建图片线性差值函数tf.image.resize.bilinear()，代码如下：

```

bilinear():

# Helper function that uses TF to resize an image
def resize(img, size):
    img = tf.expand_dims(img, 0)
    # Change 'img' size by linear interpolation
    return tf.image.resize_bilinear(img, size)[0,:,:,:]

```

11. 现在需要一种方法更新源图片，让其更像选择的特征。我们通过指定图片的梯度如何计算来实现。我们定义函数计算图片上子区域（方格）的梯度计算，使得梯度计算更快。我们将在图片的x轴和y轴方向上随机移动或者滚动，这将平滑方格的影响，代码如下：

```

def calc_grad_tiled(img, t_grad, tile_size=512):
    '''Compute the value of tensor t_grad over the image in a tiled
way.

    Random shifts are applied to the image to blur tile boundaries
over
    multiple iterations.'''
    # Pick a subregion square size
    sz = tile_size
    # Get the image height and width
    h, w = img.shape[:2]
    # Get a random shift amount in the x and y direction
    sx, sy = np.random.randint(sz, size=2)
    # Randomly shift the image (roll image) in the x and y
    directions
    img_shift = np.roll(np.roll(img, sx, 1), sy, 0)
    # Initialize the while image gradient as zeros
    grad = np.zeros_like(img)
    # Now we loop through all the sub-tiles in the image
    for y in range(0, max(h-sz//2, sz),sz):
        for x in range(0, max(w-sz//2, sz),sz):
            # Select the sub image tile
            sub = img_shift[y:y+sz,x:x+sz]
            # Calculate the gradient for the tile
            g = sess.run(t_grad, {t_input:sub})
            # Apply the gradient of the tile to the whole image
            gradient
            grad[y:y+sz,x:x+sz] = g
    # Return the gradient, undoing the roll operation
    return np.roll(np.roll(grad, -sx, 1), -sy, 0)

```

12. 声明DeepDream函数。DeepDream算法的对象是选择特征的平均值。损失函数是基于梯度的，其依赖于输入图片和选取特征之间的距离。分割图像为高频部分和低频部分，在低频部分上计算梯度。将高频部分的结果再分割为高频部分和低频部分，重复前面的过程。原始图片和低频图片称为octaves。对传入的每个对象，计算其梯度并应用到图片中，代码如下：

```
def render_deeppdream(t_obj, img0=img_noise,
                      iter_n=10, step=1.5, octave_n=4, octave_
scale=1.4):
    # defining the optimization objective, the objective is the
    mean of the feature
    t_score = tf.reduce_mean(t_obj)
    # Our gradients will be defined as changing the t_input to get
    closer tothe values of t_score. Here, t_score is the mean of the
    feature we select.
    # t_input will be the image octave (starting with the last)
    t_grad = tf.gradients(t_score, t_input)[0] # behold the power
    of automatic differentiation!
    # Store the image
    img = img0
    # Initialize the image octave list
    octaves = []
    # Since we stored the image, we need to only calculate n-1
    octaves
    for i in range(octave_n-1):
        # Extract the image shape
        hw = img.shape[:2]
        # Resize the image, scale by the octave_scale (resize by
        linear interpolation)
        lo = resize(img, np.int32(np.float32(hw)/octave_scale))
        # Residual is hi. Where residual = image - (Resize lo to
        be hw-shape)
        hi = img-resize(lo, hw)
        # Save the lo image for re-iterating
        img = lo
        # Save the extracted hi-image
        octaves.append(hi)

    # generate details octave by octave
    for octave in range(octave_n):
        if octave>0:
            # Start with the last octave
            hi = octaves[-octave]
            #
            img = resize(img, hi.shape[:2])+hi
        for i in range(iter_n):
            # Calculate gradient of the image.
            g = calc_grad_tiled(img, t_grad)
            # Ideally, we would just add the gradient, g, but
            # we want do a forward step size of it ('step'),
            # and divide it by the avg. norm of the gradient, so
            # we are adding a gradient of a certain size each
```

```
step.  
        # Also, to make sure we aren't dividing by zero, we  
add 1e-7.  
        img += g*(step / (np.abs(g).mean() + 1e-7))  
        print('.', end = '')  
        showarray(img/255.0)
```

13.所有函数准备好之后，开始运行DeepDream算法，代码如下（对应的图见图8-7）：

```
# Run Deep Dream  
if __name__=="__main__":  
    # Create resize function that has a wrapper that creates  
    # specified placeholder types  
    resize = tffunc(np.float32, np.int32)(resize)  
  
    # Open image  
    img0 = PIL.Image.open('book_cover.jpg')  
    img0 = np.float32(img0)  
    # Show Original Image  
    showarray(img0/255.0)  
    # Create deep dream  
    render_deeppdream(T(layer)[:, :, :, 139], img0, iter_n=15)  
    sess.close()
```

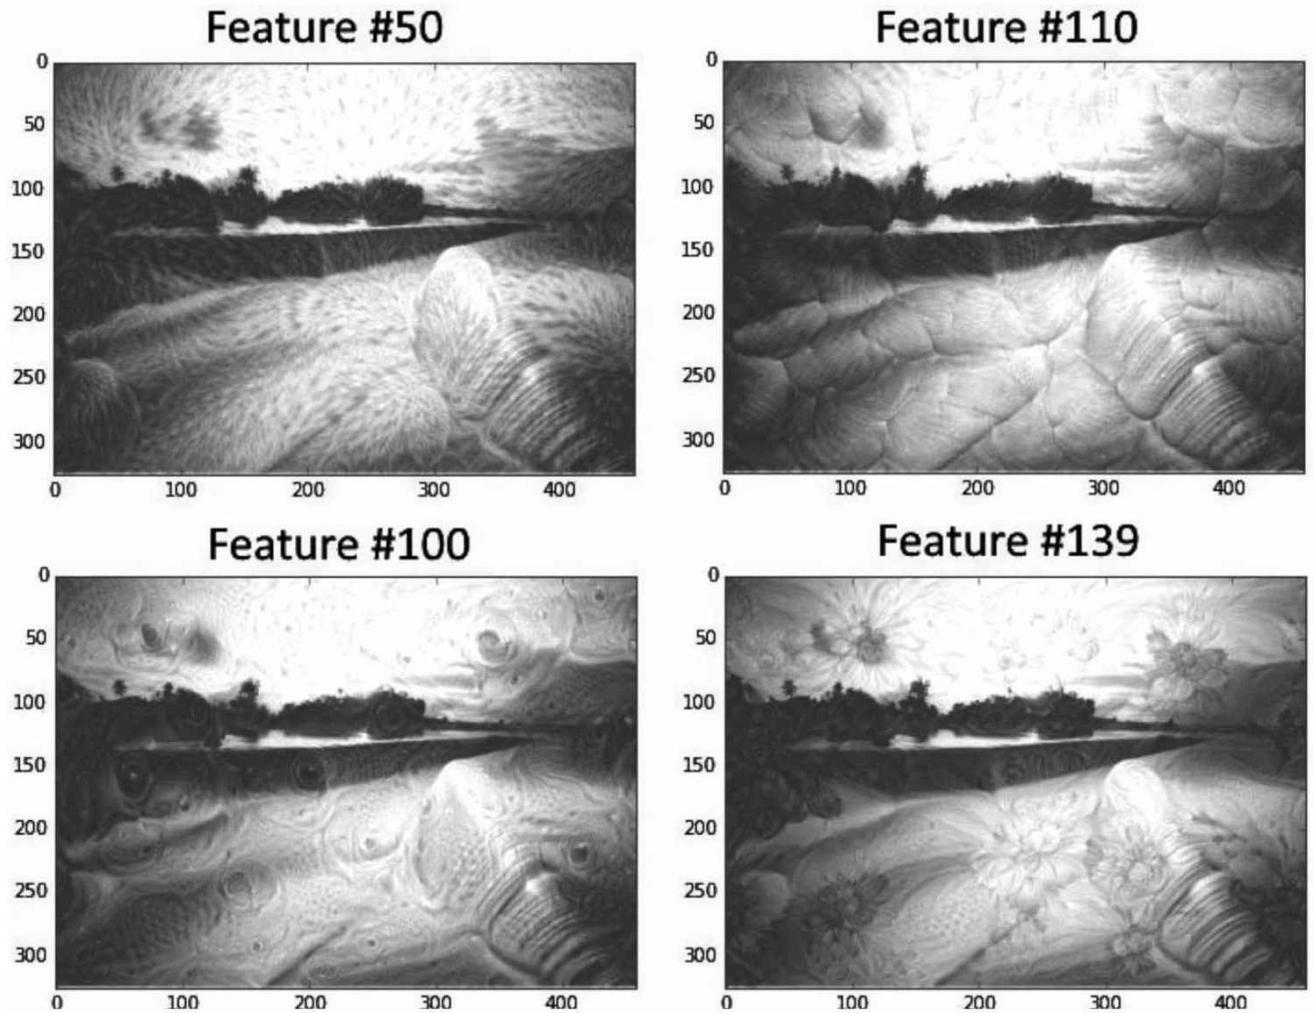


图8-7 采用DeepDream训练的封面图，特征数分别为50、110、100和139

8.6.3 延伸学习

我们希望读者访问官方DeepDream例子了解更多参考信息，也可以阅读Google research关于DeepDream的博客，见8.6.4节。

8.6.4 参考

- ▶ The TensorFlow tutorial on DeepDream: <https://github.com/tensorflow/tensorflow/tree/master/tensorflow/examples/tutorials/deepdream>
- ▶ The original Google research blog post on DeepDream: <https://research.googleblog.com/2015/06/inceptionism-going-deeper-into-neural.html>

第9章 递归神经网络

本章详细介绍递归神经网络（recurrent neural network， RNN），以及如何使用TensorFlow实现递归神经网络。首先介绍如何使用递归神经网络预测垃圾短信；然后基于RNN的变种创建莎士比亚著作文本；最后创建一个RNN的Seq2Seq翻译模型将英文翻译为德文。学完本章将掌握以下知识点：

- TensorFlow实现RNN模型进行垃圾短信预测

- TensorFlow实现LSTM模型

- TensorFlow实现LSTM一层

- TensorFlow实现Seq2Seq翻译模型

- TensorFlow实现孪生RNN预测相似度

注意，本章的代码可以在GitHub上浏览，网址为：https://github.com/nfmccleure/tensorflow_cookbook。

9.1 递归神经网络介绍

9.1 递归神经网络介绍

前面介绍的所有机器学习算法都没有考虑序列数据的情况。为了处理序列数据，我们将扩展神经网络以存储前一次迭代的输出，这类神经网络算法称为递归神经网络。全联接网络的公式为：

$$y = \sigma(Ax)$$

其中， A 为加权权重， x 为输入层。运行激励函数 σ ，会返回输出层 y 。如果有序列输入数据， x_1, x_2, x_3, \dots ，我们修改全联接层从而把前一个输入考虑在内，表达式如下：

$$y_t = \sigma(By_{t-1} + Ax_t)$$

在递归迭代的基础上获取下一个输入。通过softmax函数得到概率分布输出，表达式如下：

$$s_t = softmax(Cy_t)$$

一旦有了所有序列的输出 $\{s_1, s_2, s_3, \dots\}$ ，我们可以只考虑最后一个输出作为目标数值或者目标分类。图9-1清晰地展示了该架构是如何工作的。

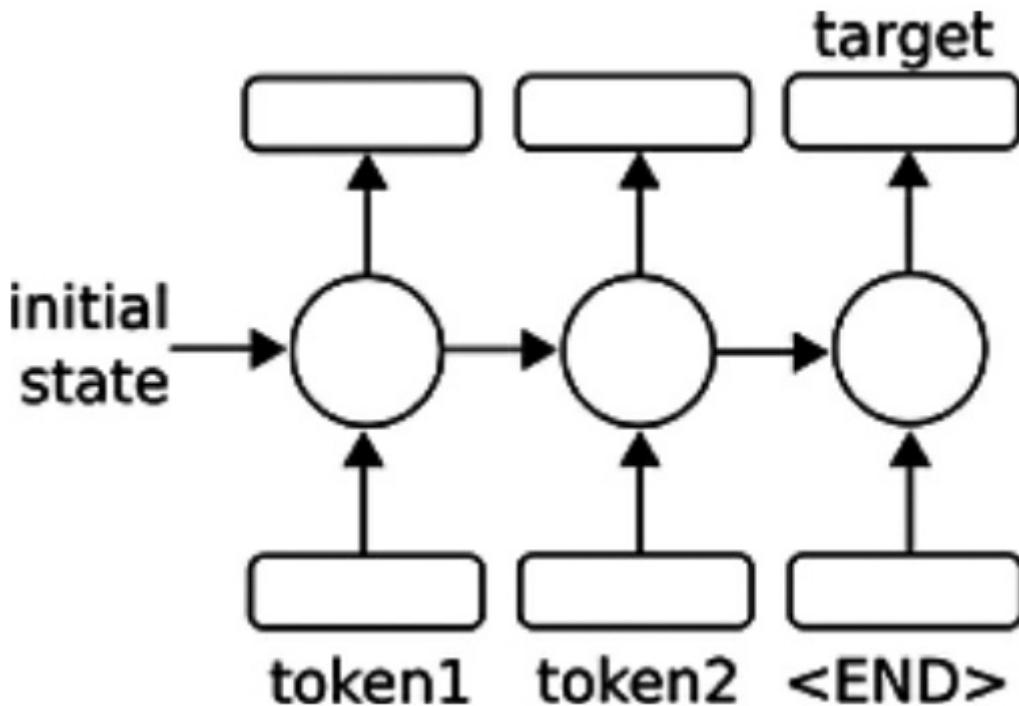


图9-1 token序列输入，最后一个序列输出结果作为预测输出结果（预测单个数值或者分类）

我们也可以把序列输出结果作为序列（见图9-2），即Seq2Seq模型：

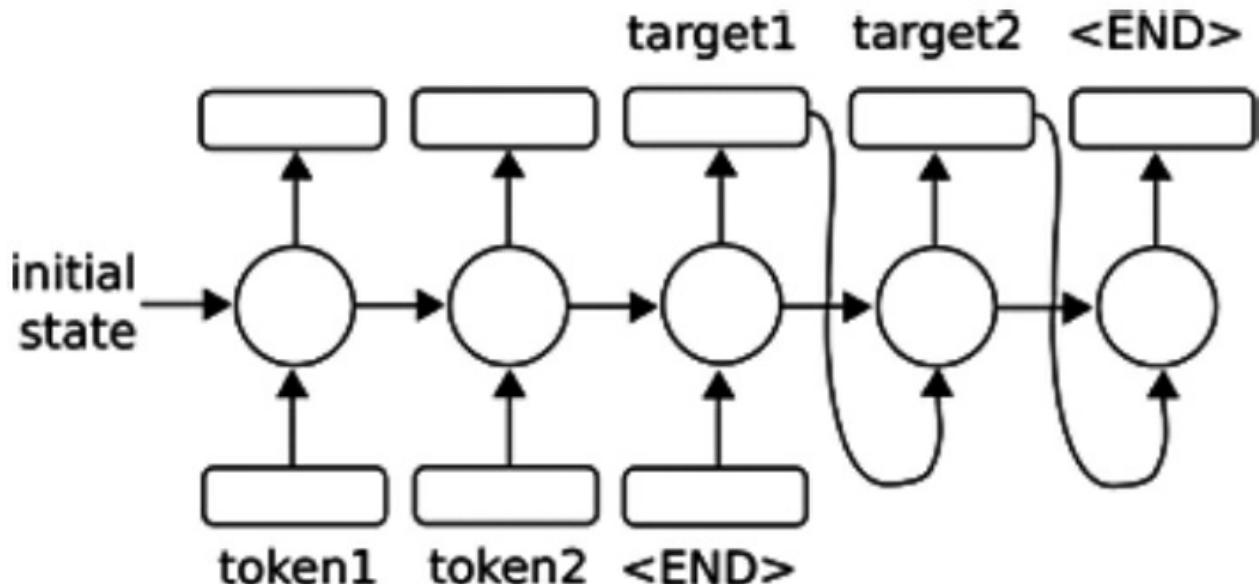


图9-2 我们可以将序列输出结果反馈回模型生成多个输出结果（以预测一个序列）

对于任意长度的序列，利用反向传播算法训练创建长时间依赖的梯度。这样会出现梯度消失或者梯度爆炸的问题。在本章后续部分，我们将探索LSTM（Long Short Term Memory，长短期记忆）单元的RNN单元算法解决该问题。基本思想是LSTM单元引入门操作（gate），该门操作控制序列上信息的流动。后续章节将会详细讲解。



当RNN模型处理NLP时，编码用来描述将数据（NLP中的单词或者字符）转换为数值型RNN特征的过程；解码用来描述将数值型RNN特征转换成输出的单词或者字符的过程。

9.2 用TensorFlow实现RNN模型进行垃圾短信预测

应用标准的RNN单元预测奇异数值型输出。

9.2.1 开始

本节将用TensorFlow实现一个标准的RNN模型，预测文本短信是正常短信还是垃圾短信。本例使用UCI大学的机器学习仓库中的SMS垃圾短信数据集。本例使用的预测架构是，嵌套文本中的输入RNN序列，取最后一个RNN输出作为是否为垃圾短信（1或0）的预测。

9.2.2 动手做

1. 导入必要的编程库，代码如下：

```
import os
import re
import io
import requests
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
from zipfile import ZipFile
```

2. 开始计算图会话，并设置RNN模型参数。训练数据20个epoch，批量大小为250。短信最大长度为25个单词，超过的部分会被截取掉，不够的部分用0填充。RNN模型由10个单元组成。我们仅仅处理词频超过10的单词，每个单词会嵌套在长度为50的词向量中。dropout概率为占位符，训练模型时设为0.5，评估模型时设为1.0。具体代码如下：

```
sess = tf.Session()
epochs = 20
batch_size = 250
max_sequence_length = 25
rnn_size = 10
embedding_size = 50
min_word_frequency = 10
learning_rate = 0.0005
dropout_keep_prob = tf.placeholder(tf.float32)
```

3. 获取SMS文本数据集。首先，在下载文本数据集前检查是否已下载过。如果已经下载过数据集，直接从文件中读取，代码如下：

```

data_dir = 'temp'
data_file = 'text_data.txt'
if not os.path.exists(data_dir):
    os.makedirs(data_dir)
if not os.path.isfile(os.path.join(data_dir, data_file)):
    zip_url = 'http://archive.ics.uci.edu/ml/machine-learning-
databases/00228/smsspamcollection.zip'
    r = requests.get(zip_url)
    z = ZipFile(io.BytesIO(r.content))
    file = z.read('SMSSpamCollection')
    # Format Data
    text_data = file.decode()
    text_data = text_data.encode('ascii', errors='ignore')
    text_data = text_data.decode().split('\n')
    # Save data to text file
    with open(os.path.join(data_dir, data_file), 'w') as file_
conn:
        for text in text_data:
            file_conn.write("{}\n".format(text))
else:
    # Open data from text file
    text_data = []
    with open(os.path.join(data_dir, data_file), 'r') as file_
conn:
        for row in file_conn:
            text_data.append(row)
    text_data = text_data[:-1]
text_data = [x.split('\t') for x in text_data if len(x)>=1]
[text_data_target, text_data_train] = [list(x) for x in zip(*text_
data)]

```

4. 我们将清洗文本数据集，移除特殊字符，将所有文本转为小写，以空格提取单词，代码如下：

```

def clean_text(text_string):
    text_string = re.sub(r'([^\s\w]|_|[0-9])+', '', text_string)
    text_string = " ".join(text_string.split())
    text_string = text_string.lower()
    return(text_string)
# Clean texts
text_data_train = [clean_text(x) for x in text_data_train]

```



注意从文本数据中清洗移除特殊字符的步骤，有时可以用空格替换该特殊字符。在理想情况下，需要根据数据集的格式选择具体的方法处理。

5. 使用TensorFlow内建的词汇处理器处理文本。该步骤将文本转换为索引列表，代码如下：

```
vocab_processor = tf.contrib.learn.preprocessing.  
VocabularyProcessor(max_sequence_length,min_frequency=min_word_  
frequency)  
text_processed = np.array(list(vocab_processor.fit_transform(text_  
data_train)))
```

6. 随机shuffle文本数据集，代码如下：

```
text_processed = np.array(text_processed)  
text_data_target = np.array([1 if x=='ham' else 0 for x in text_  
data_target])  
shuffled_ix = np.random.permutation(np.arange(len(text_data_  
target)))  
x_shuffled = text_processed[shuffled_ix]  
y_shuffled = text_data_target[shuffled_ix]
```

7. 分割数据集为80-20的训练-测试数据集，代码如下：

```
ix_cutoff = int(len(y_shuffled)*0.80)  
x_train, x_test = x_shuffled[:ix_cutoff], x_shuffled[ix_cutoff:]  
y_train, y_test = y_shuffled[:ix_cutoff], y_shuffled[ix_cutoff:]  
vocab_size = len(vocab_processor.vocabulary_)  
  
print("Vocabulary Size: {:d}".format(vocab_size))  
print("80-20 Train Test split: {:d} -- {:d}".format(len(y_train),  
len(y_test)))
```



本小节我们不准备做超参数调优。如果读者有这方面的需求，请在预处理前将数据集分割为训练集-测试集-验证集。`scikit-learn`的`model_selection.train_test_split()`函数可以随机分割（划分）训练集和测试集。

8. 声明计算图的占位符。输入数据`x_data`是形状为`[None, max_sequence_length]`的占位符，其以短信最大

允许的长度为批量大小。输出结果y_output的占位符为整数0或者1，即正常短信或者垃圾短信，代码如下：

```
x_data = tf.placeholder(tf.int32, [None, max_sequence_length])
y_output = tf.placeholder(tf.int32, [None])
```

9. 创建输入数据x_data的嵌套矩阵和嵌套查找操作，代码如下：

```
embedding_mat = tf.Variable(tf.random_uniform([vocab_size,
embedding_size], -1.0, 1.0))
embedding_output = tf.nn.embedding_lookup(embedding_mat, x_data)
```

10. 声明算法模型。首先，初始化RNN单元的类型，大小为10。然后通过动态RNN函数

tf.nn.dynamic_rnn() 创建RNN序列，接着增加dropout操作，代码如下：

```
cell = tf.nn.rnn_cell.BasicRNNCell(num_units = rnn_size)
output, state = tf.nn.dynamic_rnn(cell, embedding_output,
dtype=tf.float32)
output = tf.nn.dropout(output, dropout_keep_prob)
```



注意，动态RNN允许变长序列。即使本例所使用的是固定长度的序列，我们也推荐使用TensorFlow的tf.nn.dynamic_rnn() 函数。主要原因是：实践证明动态RNN实际计算更快，并且允许RNN中运行不同长度的序列。

11. 为了进行预测，转置并重新排列RNN的输出结果，剪切最后的输出结果，代码如下：

```
output = tf.transpose(output, [1, 0, 2])
last = tf.gather(output, int(output.get_shape()[0]) - 1)
```

12. 为了完成RNN预测，我们通过全联接层将rnn_size大小的输出转换为二分类输出，代码如下：

```
weight = tf.Variable(tf.truncated_normal([rnn_size, 2],
stddev=0.1))
bias = tf.Variable(tf.constant(0.1, shape=[2]))
logits_out = tf.nn.softmax(tf.matmul(last, weight) + bias)
```

13. 声明损失函数。本例使用TensorFlow的sparse_softmax函数，目标值是int型索引，logits是float型，代码如下：

```
losses = tf.nn.sparse_softmax_cross_entropy_with_logits(logits_out, y_output)
loss = tf.reduce_mean(losses)
```

14. 创建准确度函数，比较训练集和测试集的训练结果，代码如下：

```
accuracy = tf.reduce_mean(tf.cast(tf.equal(tf.argmax(logits_out, 1), tf.cast(y_output, tf.int64)), tf.float32))
```

15. 创建优化器函数，初始化模型变量，代码如下：

```
optimizer = tf.train.RMSPropOptimizer(learning_rate)
train_step = optimizer.minimize(loss)
init = tf.initialize_all_variables()
sess.run(init)
```

16. 开始遍历迭代训练模型。遍历数据集多次，最佳实践表明：每个epoch都需随机shuffle数据，避免过拟合，代码如下：

```

train_loss = []
test_loss = []
train_accuracy = []
test_accuracy = []
# Start training
for epoch in range(epochs):
    # Shuffle training data
    shuffled_ix = np.random.permutation(np.arange(len(x_train)))
    x_train = x_train[shuffled_ix]
    y_train = y_train[shuffled_ix]
    num_batches = int(len(x_train)/batch_size) + 1
    for i in range(num_batches):
        # Select train data
        min_ix = i * batch_size
        max_ix = np.min([len(x_train), ((i+1) * batch_size)])
        x_train_batch = x_train[min_ix:max_ix]
        y_train_batch = y_train[min_ix:max_ix]

        # Run train step
        train_dict = {x_data: x_train_batch, y_output: y_train_
batch, dropout_keep_prob:0.5}
        sess.run(train_step, feed_dict=train_dict)

        # Run loss and accuracy for training
        temp_train_loss, temp_train_acc = sess.run([loss, accuracy],
feed_dict=train_dict)
        train_loss.append(temp_train_loss)
        train_accuracy.append(temp_train_acc)

    # Run Eval Step
    test_dict = {x_data: x_test, y_output: y_test, dropout_keep_
prob:1.0}
    temp_test_loss, temp_test_acc = sess.run([loss, accuracy],
feed_dict=test_dict)

    test_loss.append(temp_test_loss)
    test_accuracy.append(temp_test_acc)
    print('Epoch: {}, Test Loss: {:.2}, Test Acc: {:.2}'.format(epoch+1, temp_test_loss, temp_test_acc))

```

17.输出结果如下：

```
Vocabulary Size: 933
80-20 Train Test split: 4459 -- 1115
Epoch: 1, Test Loss: 0.59, Test Acc: 0.83
Epoch: 2, Test Loss: 0.58, Test Acc: 0.83
Epoch: 19, Test Loss: 0.46, Test Acc: 0.86
Epoch: 20, Test Loss: 0.46, Test Acc: 0.86
```

18.绘制训练集、测试集损失和准确度的代码如下：

```
epoch_seq = np.arange(1, epochs+1)
plt.plot(epoch_seq, train_loss, 'k--', label='Train Set')
plt.plot(epoch_seq, test_loss, 'r-', label='Test Set')
plt.title('Softmax Loss')
plt.xlabel('Epochs')
plt.ylabel('Softmax Loss')
plt.legend(loc='upper left')
plt.show()

# Plot accuracy over time
plt.plot(epoch_seq, train_accuracy, 'k--', label='Train Set')
plt.plot(epoch_seq, test_accuracy, 'r-', label='Test Set')
plt.title('Test Accuracy')
plt.xlabel('Epochs')
plt.ylabel('Accuracy')
plt.legend(loc='upper left')
plt.show()
```

9.2.3 工作原理

在本节中，我们创建RNN分类模型预测SMS短信文本是否为垃圾短信。本例在测试集上的训练准确度为86%。图9-3是测试集和训练集的准确度和损失函数图。

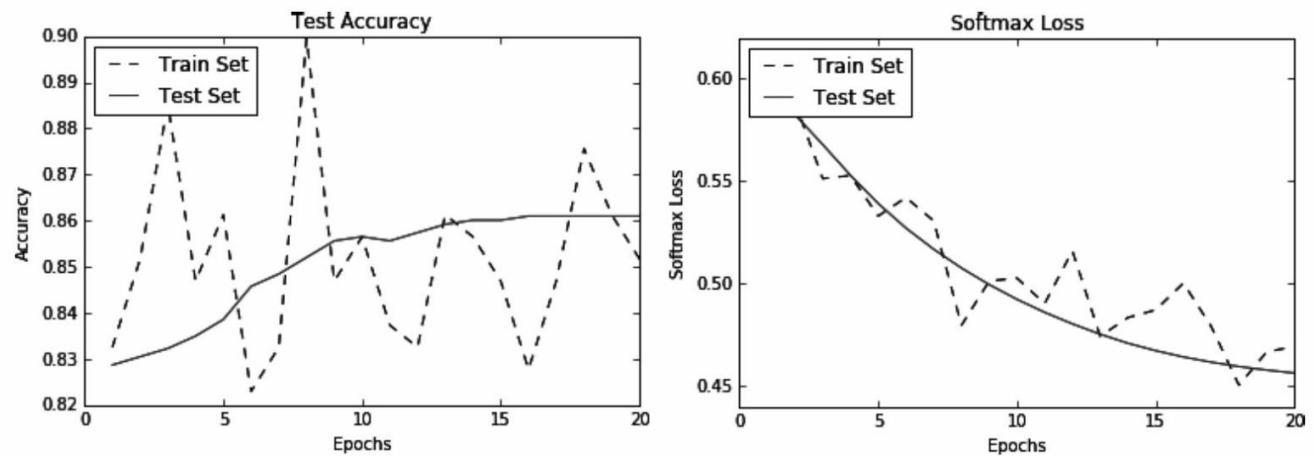


图9-3 训练集和测试集的准确度图（左图）和损失函数图（右图）

9.2.4 延伸学习

对于序列数据，强烈推荐对训练集（全部数据）进行多次训练（对于非序列数据也推荐这样处理）。全部数据进行一次训练称为epoch。同时强烈建议，在每个epoch之前进行随机shuffle数据。

9.3 用TensorFlow实现LSTM模型

本节通过引入LSTM单元，将RNN模型扩展为可以处理长序列的模型。

9.3.1 开始

LSTM递归神经网络是传统递归神经网络的变种。该时间递归神经网络可以解决变长RNN模型的梯度消失或者爆炸的问题。为了解决梯度问题，LSTM单元引入一个内部忘记门（forget gate），该门操作可以修改一个单元到下一个单元的信息流转。为了清晰阐明LSTM递归神经网络是如何工作的，我们将逐步分析LSTM公式的无偏版本。第一步，与常规的RNN模型一样：

$$i_t = \sigma (B_i h_{t-1} + A_i x_t)$$

为了弄明白什么信息可以遗忘或者删除，我们通过下面的公式评估候选信息。这些信息称为记忆单元：

$$C_t = \tanh (B_C h_{t-1} + A_C x_t)$$

现在我们通过忘记矩阵（forget matrix）修改可选的记忆单元，其计算公式如下：

$$f_t = \sigma (B_f h_{t-1} + A_f x_t)$$

将前面的记忆信息与遗忘记忆结合，然后与可选的记忆单元相加得到新的记忆信息：

$$N_t = i_t \cdot C_t + f_t N_{t-1}$$

结合前面的所有项获得记忆单元的输出：

$$O_t = \sigma (B_O h_{t-1} + A_O x_t + D_O N_t)$$

之后，通过迭代更新 h ，计算公式：

$$h_t = O_t \cdot \tanh (N_t)$$

LSTM递归神经网络的理念是通过记忆单元忘记或者修改输入信息。



本例使用TensorFlow的一大好处是，我们不必维护这些操作和相关的反向传播状

态。TensorFlow会维护这些状态信息，并根据模型的损失函数、优化器函数和学习率计算梯度来自动更新模型变量值。

本节将会使用带有LSTM结构的序列RNN模型在莎士比亚文本数据集上训练，预测下一个单词。我们将为该模型传入短语（比如，`thou art more`），看训练的模型是否可以预测出短语接下来的单词。

9.3.2 动手做

1. 导入必要的编程库，代码如下：

```
import os
import re
import string
import requests
import numpy as np
import collections
import random
import pickle
import matplotlib.pyplot as plt
import tensorflow as tf
```

2. 开始计算图会话，并设置RNN参数，代码如下：

```
sess=tf.Session()
# Set RNN Parameters
min_word_freq = 5
rnn_size = 128
epochs = 10
batch_size = 100
learning_rate = 0.001
training_seq_len = 50
embedding_size = rnn_size
save_every = 500
eval_every = 50
prime_texts = ['thou art more', 'to be or not to', 'wherfore art thou']
```

3. 定义数据和模型的文件夹和文件名。我们将保留连字符和省略符，因为莎士比亚频繁地使用这些字符来组合单词和音节，代码如下：

```

data_dir = 'temp'
data_file = 'shakespeare.txt'
model_path = 'shakespeare_model'
full_model_dir = os.path.join(data_dir, model_path)
# Declare punctuation to remove, everything except hyphens and
# apostrophes
punctuation = string.punctuation
punctuation = ''.join([x for x in punctuation if x not in ['-', "'"]])

```

4. 下载文本数据集。如果该数据集存在，我们将直接加载数据；如果不存在，我们将下载该文本数据集，并保存，代码如下：

```

if not os.path.exists(full_model_dir):
    os.makedirs(full_model_dir)
# Make data directory
if not os.path.exists(data_dir):

    os.makedirs(data_dir)
print('Loading Shakespeare Data')
# Check if file is downloaded.
if not os.path.isfile(os.path.join(data_dir, data_file)):
    print('Not found, downloading Shakespeare texts from www.
gutenberg.org')
    shakespeare_url = 'http://www.gutenberg.org/cache/epub/100/
pg100.txt'
    # Get Shakespeare text
    response = requests.get(shakespeare_url)
    shakespeare_file = response.content
    # Decode binary into string
    s_text = shakespeare_file.decode('utf-8')
    # Drop first few descriptive paragraphs.
    s_text = s_text[7675:]
    # Remove newlines
    s_text = s_text.replace('\r\n', '')
    s_text = s_text.replace('\n', '')

    # Write to file
    with open(os.path.join(data_dir, data_file), 'w') as out_conn:
        out_conn.write(s_text)
else:
    # If file has been saved, load from that file
    with open(os.path.join(data_dir, data_file), 'r') as file_
conn:
        s_text = file_conn.read().replace('\n', '')

```

5. 清洗莎士比亚文本，移除标点符号和多余的空格，代码如下：

```
s_text = re.sub(r'\[ \]'.format(punctuation), ' ', s_text)
s_text = re.sub('\s+', ' ', s_text).strip().lower()
```

6. 创建莎士比亚词汇表。我们创建build_vocab() 返回两个单词字典（单词到索引的映射和索引到单词的映射），其中出现的单词要符合频次要求，代码如下：

```
def build_vocab(text, min_word_freq):
    word_counts = collections.Counter(text.split(' '))
    # limit word counts to those more frequent than cutoff
    word_counts = {key:val for key, val in word_counts.items() if val>min_word_freq}
    # Create vocab --> index mapping
    words = word_counts.keys()
    vocab_to_ix_dict = {key:(ix+1) for ix, key in enumerate(words)}
    # Add unknown key --> 0 index
    vocab_to_ix_dict['unknown']=0
    # Create index --> vocab mapping
    ix_to_vocab_dict = {val:key for key, val in vocab_to_ix_dict.items()}

    return(ix_to_vocab_dict, vocab_to_ix_dict)

ix2vocab, vocab2ix = build_vocab(s_text, min_word_freq)
vocab_size = len(ix2vocab) + 1
```



处理文本时，我们需要注意单词索引为0的值，将其保存并填充。对于未知单词也采取相同方法处理。

7. 有了单词词汇表，我们将莎士比亚文本转换成索引数组，代码如下：

```

s_text_words = s_text.split(' ')
s_text_ix = []
for ix, x in enumerate(s_text_words):
    try:
        s_text_ix.append(vocab2ix[x])
    except:
        s_text_ix.append(0)
s_text_ix = np.array(s_text_ix)

```

8.本例将展示如何用class对象创建算法模型。我们将使用相同的模型（相同模型参数）来训练批量数据和抽样生成的文本。如果没有class对象，将很难用抽样方法训练相同的模型。在理想情况下，该class代码单独保存在一个Python文件中，它可以在脚本起始位置导入，代码如下：

```

class LSTM_Model():
    def __init__(self, rnn_size, batch_size, learning_rate,
                 training_seq_len, vocab_size, infer=False):
        self.rnn_size = rnn_size
        self.vocab_size = vocab_size
        self.infer = infer
        self.learning_rate = learning_rate

        if infer:
            self.batch_size = 1
            self.training_seq_len = 1
        else:
            self.batch_size = batch_size
            self.training_seq_len = training_seq_len

        self.lstm_cell = tf.nn.rnn_cell.BasicLSTMCell(rnn_size)
        self.initial_state = self.lstm_cell.zero_state(self.batch_size,
                                                       tf.float32)

        self.x_data = tf.placeholder(tf.int32, [self.batch_size,
                                               self.training_seq_len])
        self.y_output = tf.placeholder(tf.int32, [self.batch_size,
                                                self.training_seq_len])

        with tf.variable_scope('lstm_vars'):
            # Softmax Output Weights

```

```

        W = tf.get_variable('W', [self.rnn_size, self.vocab_
size], tf.float32, tf.random_normal_initializer())
        b = tf.get_variable('b', [self.vocab_size],
tf.float32, tf.constant_initializer(0.0))

        # Define Embedding
        embedding_mat = tf.get_variable('embedding_mat',
[self.vocab_size, self.rnn_size], tf.float32, tf.random_normal_
initializer())

        embedding_output = tf.nn.embedding_lookup(embedding_
mat, self.x_data)
        rnn_inputs = tf.split(1, self.training_seq_len,
embedding_output)
        rnn_inputs_trimmed = [tf.squeeze(x, [1]) for x in rnn_
inputs]

        # If we are inferring (generating text), we add a 'loop'
function
        # Define how to get the i+1 th input from the i th output
        def inferred_loop(prev, count):
            prev_transformed = tf.matmul(prev, W) + b
            prev_symbol = tf.stop_gradient(tf.argmax(prev_
transformed, 1))
            output = tf.nn.embedding_lookup(embedding_mat, prev_
symbol)
            return(output)

        decoder = tf.nn.seq2seq.rnn_decoder
        outputs, last_state = decoder(rnn_inputs_trimmed,
                                         self.initial_state,
                                         self.lstm_cell,
                                         loop_function=inferred_loop
if infer else None)
        # Non inferred outputs
        output = tf.reshape(tf.concat(1, outputs), [-1, self.rnn_
size])
        # Logits and output
        self.logit_output = tf.matmul(output, W) + b
        self.model_output = tf.nn.softmax(self.logit_output)

        loss_fun = tf.nn.seq2seq.sequence_loss_by_example
        loss = loss_fun([self.logit_output], [tf.reshape(self.y_
output, [-1])],
                         [tf.ones([self.batch_size * self.training_seq_
len])],
                         self.vocab_size)
        self.cost = tf.reduce_sum(loss) / (self.batch_size * self.
training_seq_len)
        self.final_state = last_state
        gradients, _ = tf.clip_by_global_norm(tf.gradients(self.

```

```

cost, tf.trainable_variables()), 4.5)
optimizer = tf.train.AdamOptimizer(self.learning_rate)
self.train_op = optimizer.apply_gradients(zip(gradients,
tf.trainable_variables()))

def sample(self, sess, words=ix2vocab, vocab=vocab2ix, num=10,
prime_text='thou art'):
    state = sess.run(self.lstm_cell.zero_state(1, tf.float32))
    word_list = prime_text.split()
    for word in word_list[:-1]:
        x = np.zeros((1, 1))
        x[0, 0] = vocab[word]
        feed_dict = {self.x_data: x, self.initial_state:state}
        [state] = sess.run([self.final_state], feed_dict=feed_
dict)
    out_sentence = prime_text
    word = word_list[-1]
    for n in range(num):
        x = np.zeros((1, 1))
        x[0, 0] = vocab[word]
        feed_dict = {self.x_data: x, self.initial_state:state}
        [model_output, state] = sess.run([self.model_output,
self.final_state], feed_dict=feed_dict)
        sample = np.argmax(model_output[0])
        if sample == 0:
            break
        word = words[sample]
        out_sentence = out_sentence + ' ' + word
    return(out_sentence)

```

9. 声明LSTM模型及其测试模型。使用tf.variable_scope管理模型变量，使得测试LSTM模型可以复用训练LSTM模型相同的参数，代码如下：

```

with tf.variable_scope('lstm_model') as scope:
    # Define LSTM Model
    lstm_model = LSTM_Model(rnn_size, batch_size, learning_rate,
                           training_seq_len, vocab_size)
    scope.reuse_variables()
    test_lstm_model = LSTM_Model(rnn_size, batch_size, learning_
rate,
                               training_seq_len, vocab_size, infer=True)

```

10. 创建saver操作，并分割输入文本为相同的批量大小的块，然后初始化模型变量，代码如下：

```
saver = tf.train.Saver()
# Create batches for each epoch
num_batches = int(len(s_text_ix)/(batch_size * training_seq_len))
+ 1
# Split up text indices into subarrays, of equal size
batches = np.array_split(s_text_ix, num_batches)

# Reshape each split into [batch_size, training_seq_len]
batches = [np.resize(x, [batch_size, training_seq_len]) for x in
batches]
# Initialize all variables
init = tf.initialize_all_variables()
sess.run(init)
```

11.现在通过epoch迭代训练，并在每个epoch之前将数据shuffle。虽然文本数据是相同的，但是会用numpy.roll（）函数改变顺序，代码如下：

```
train_loss = []
iteration_count = 1
for epoch in range(epochs):
    # Shuffle word indices
    random.shuffle(batches)
    # Create targets from shuffled batches
    targets = [np.roll(x, -1, axis=1) for x in batches]
    # Run a through one epoch
    print('Starting Epoch #{} of {}'.format(epoch+1, epochs))
    # Reset initial LSTM state every epoch
    state = sess.run(lstm_model.initial_state)
    for ix, batch in enumerate(batches):
        training_dict = {lstm_model.x_data: batch, lstm_model.y_
output: targets[ix]}
        c, h = lstm_model.initial_state
        training_dict[c] = state.c
        training_dict[h] = state.h

        temp_loss, state, _ = sess.run([lstm_model.cost, lstm_
model.final_state, lstm_model.train_op], feed_dict=training_dict)
        train_loss.append(temp_loss)

        # Print status every 10 gens
        if iteration_count % 10 == 0:
            summary_nums = (iteration_count, epoch+1, ix+1, num_
batches+1, temp_loss)
            print('Iteration: {}, Epoch: {}, Batch: {} out of {}, 
Loss: {:.2f}'.format(*summary_nums))

        # Save the model and the vocab
        if iteration_count % save_every == 0:
            # Save model
            model_file_name = os.path.join(full_model_dir,
'model')
            saver.save(sess, model_file_name, global_step =
iteration_count)
            print('Model Saved To: {}'.format(model_file_name))
            # Save vocabulary
            dictionary_file = os.path.join(full_model_dir, 'vocab.
pkl')
            with open(dictionary_file, 'wb') as dict_file_conn:
```

```
pickle.dump( [vocab2ix, ix2vocab], dict_file_conn)

if iteration_count % eval_every == 0:
    for sample in prime_texts:
        print(test_lstm_model.sample(sess, ix2vocab,
vocab2ix, num=10, prime_text=sample))

iteration_count += 1
```

12.输出结果如下：

```
Loading Shakespeare Data
Cleaning Text
Building Shakespeare Vocab
Vocabulary Length = 8009
Starting Epoch #1 of 10.
Iteration: 10, Epoch: 1, Batch: 10 out of 182, Loss: 10.37
Iteration: 20, Epoch: 1, Batch: 20 out of 182, Loss: 9.54
...
Iteration: 1790, Epoch: 10, Batch: 161 out of 182, Loss: 5.68
Iteration: 1800, Epoch: 10, Batch: 171 out of 182, Loss: 6.05
thou art more than i am a
to be or not to the man i have
wherefore art thou art of the long
Iteration: 1810, Epoch: 10, Batch: 181 out of 182, Loss: 5.99
```

13.绘制训练损失随epoch的趋势图（见图9-4），代码如下：

```
plt.plot(train_loss, 'k-')
plt.title('Sequence to Sequence Loss')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()
```

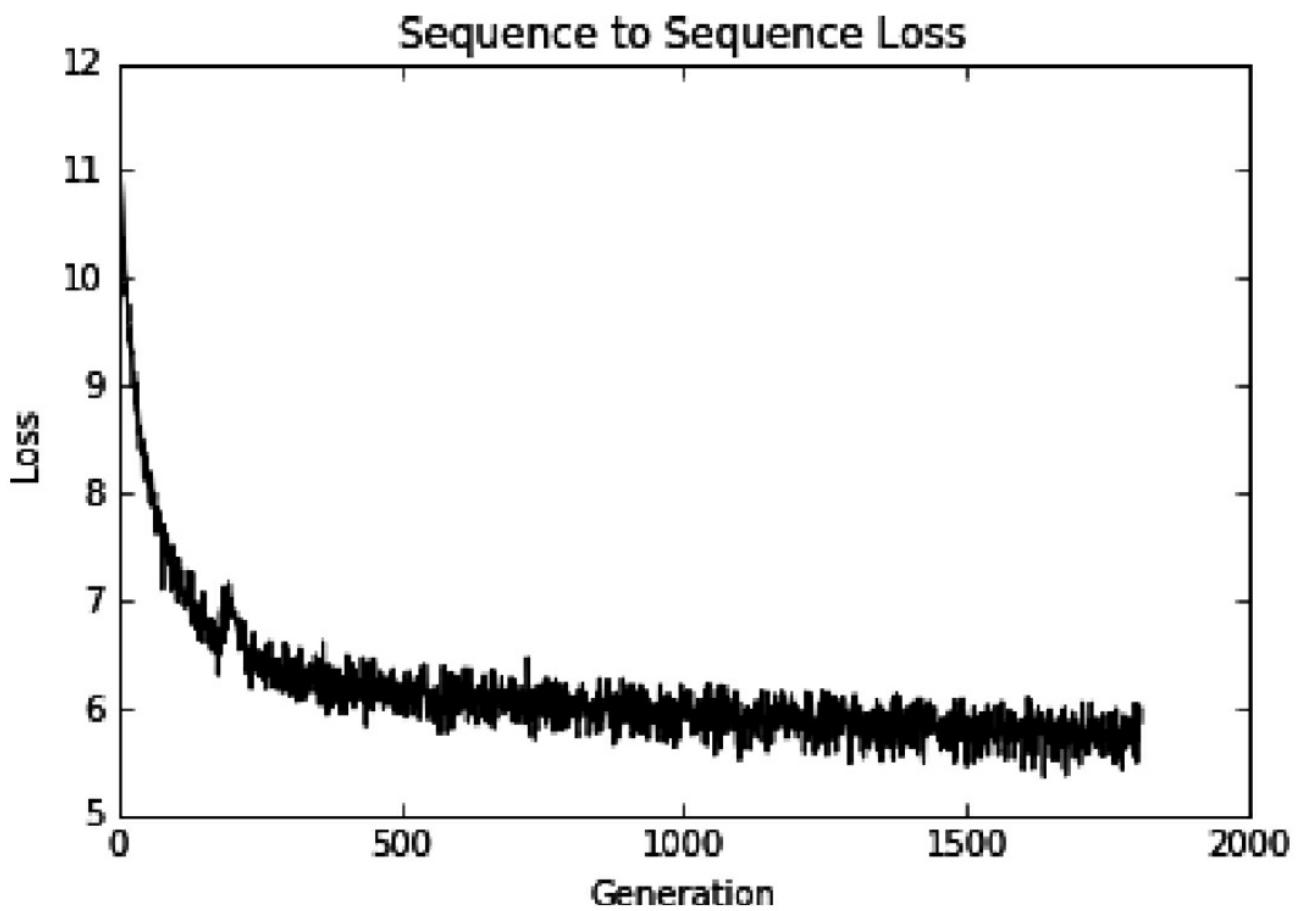


图9-4 模型迭代训练的Seq2 Seq损失图

9.3.3 工作原理

在本例中，我们基于莎士比亚词汇构建带有LSTM结构的RNN模型预测下一个单词。通过增加序列大小、降低学习率，或者增加模型的epoch，可能会提高该模型的预测效果。

9.3.4 延伸学习

对于抽样的方法，我们实现的是贪婪抽样法。贪婪抽样法会不断地出现重复的短语。例如，可能重复地说“for the for the for the....”为了防止出现该问题，我们实现一个随机抽样单词的方法，通过基于输出结果的logits或者概率分布进行加权抽样。

9.4 Stacking多个LSTM Layer

如同增加神经网络或者CNN的深度一样，我们也可以增加RNN的深度。本节应用三层LSTM促进莎士比亚文本的生成。

9.4.1 开始

我们通过Stacking组合多个LSTM层增加递归神经网络模型的深度。必要时，我们可以将目标输出作为输入赋值给另外一个网络。为了看清其中的工作原理，这里以两层网络举例，见图9-5。

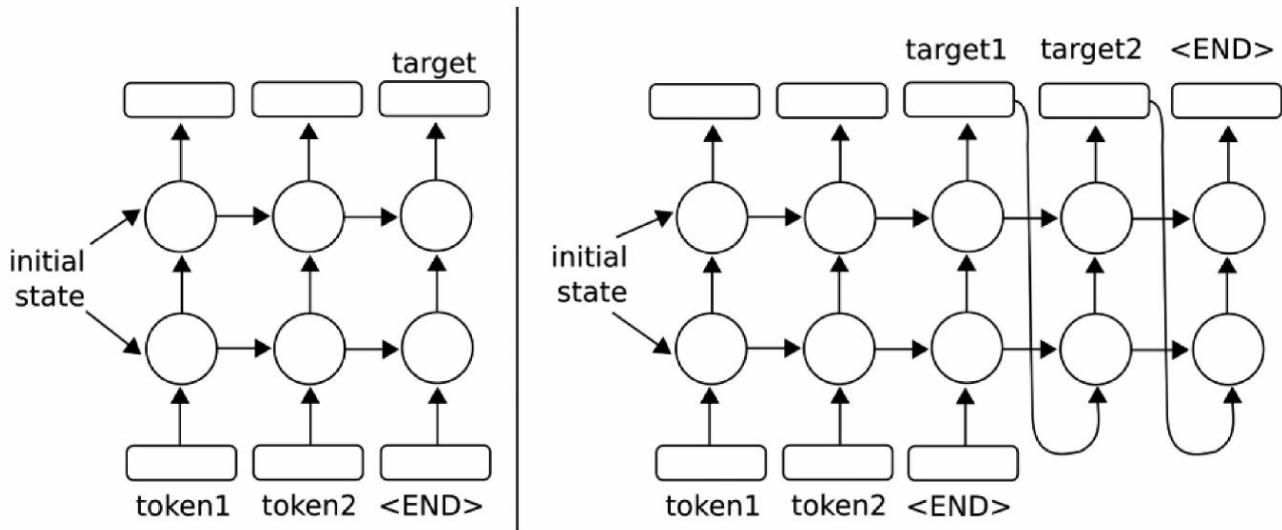


图9-5 在前一幅图的基础上，扩展一层RNN为两层

TensorFlow使用MultiRNNCell（）函数轻松地实现多层组合，该函数输入参数为RNN单元列表。用Python调用MultiRNNCell（[rnn_cell]*num_layers）很容易创建一个多层RNN。

本节将展示前一节中相同的莎士比亚文本的预测。但是本例有两个变化：第一个变化是采用Stacking组合三层LSTM代替原有的一层网络；第二个变化是字符级别的预测代替单词级别的预测。字符级别的预测将极大地减少词汇表，表中仅有40个字符（26个字母，10个数字，1个空格，3个特殊字符）。

9.4.2 动手做

为了不重复展示和上一节相同的代码，本例只解释有区别的代码。完整源代码见GitHub，地址为：https://github.com/nfmccleure/tensorflow_cookbook。

1. 设置RNN模型的层数。该参数放在脚本起始位置，其他模型参数如下：

```
num_layers = 3  
min_word_freq = 5  
rnn_size = 128  
epochs = 10
```

2. 第一个主要的变化是，我们将以字符来加载、处理和传入文本，而不是单词。清洗完文本数据之后，通过Python的list()函数分割整个文本，代码如下：

```
s_text = re.sub(r'\[ \]'.format(punctuation), ' ', s_text)  
s_text = re.sub('\s+', ' ', s_text).strip().lower()  
# Split up by characters  
char_list = list(s_text)
```

3. 现在需要改变原有一层LSTM模型为多层。接收num_layers变量，然后利用TensorFlow的MultiRNNCell()函数创建多层RNN模型，代码如下：

```

class LSTM_Model():
    def __init__(self, rnn_size, num_layers, batch_size, learning_rate,
                 training_seq_len, vocab_size, infer_sample=False):
        self.rnn_size = rnn_size
        self.num_layers = num_layers
        self.vocab_size = vocab_size
        self.infer_sample = infer_sample
        self.learning_rate = learning_rate
    ...
    self.lstm_cell = tf.nn.rnn_cell.BasicLSTMCell(rnn_size)
    self.lstm_cell = tf.nn.rnn_cell.MultiRNNCell([self.lstm_cell] * self.num_layers)
    self.initial_state = self.lstm_cell.zero_state(self.batch_size, tf.float32)

    self.x_data = tf.placeholder(tf.int32, [self.batch_size, self.training_seq_len])
    self.y_output = tf.placeholder(tf.int32, [self.batch_size, self.training_seq_len])

```

TensorFlow的MultiRNNCell（）函数的输入参数为RNN单元列表。本例中的RNN层是相同的，但是你也可以采用任何RNN层Stacking组合。

4.其他代码都与上一节相同，这里不再赘述。训练模型输出如下：

```

Building Shakespeare Vocab by Characters
Vocabulary Length = 40
Starting Epoch #1 of 10
Iteration: 9430, Epoch: 10, Batch: 889 out of 950, Loss: 1.54
Iteration: 9440, Epoch: 10, Batch: 899 out of 950, Loss: 1.46
Iteration: 9450, Epoch: 10, Batch: 909 out of 950, Loss: 1.49
thou art more than the
to be or not to the serva
wherefore art thou dost thou
Iteration: 9460, Epoch: 10, Batch: 919 out of 950, Loss: 1.41
Iteration: 9470, Epoch: 10, Batch: 929 out of 950, Loss: 1.45
Iteration: 9480, Epoch: 10, Batch: 939 out of 950, Loss: 1.59
Iteration: 9490, Epoch: 10, Batch: 949 out of 950, Loss: 1.42

```

5.最后的输出文本的抽样如下：

thou art more fancy with
to be or not to be for be
wherefore art thou art thou

6.绘制迭代训练的损失函数（见图9-6），代码如下：

```
plt.plot(train_loss, 'k-')
plt.title('Sequence to Sequence Loss')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()
```

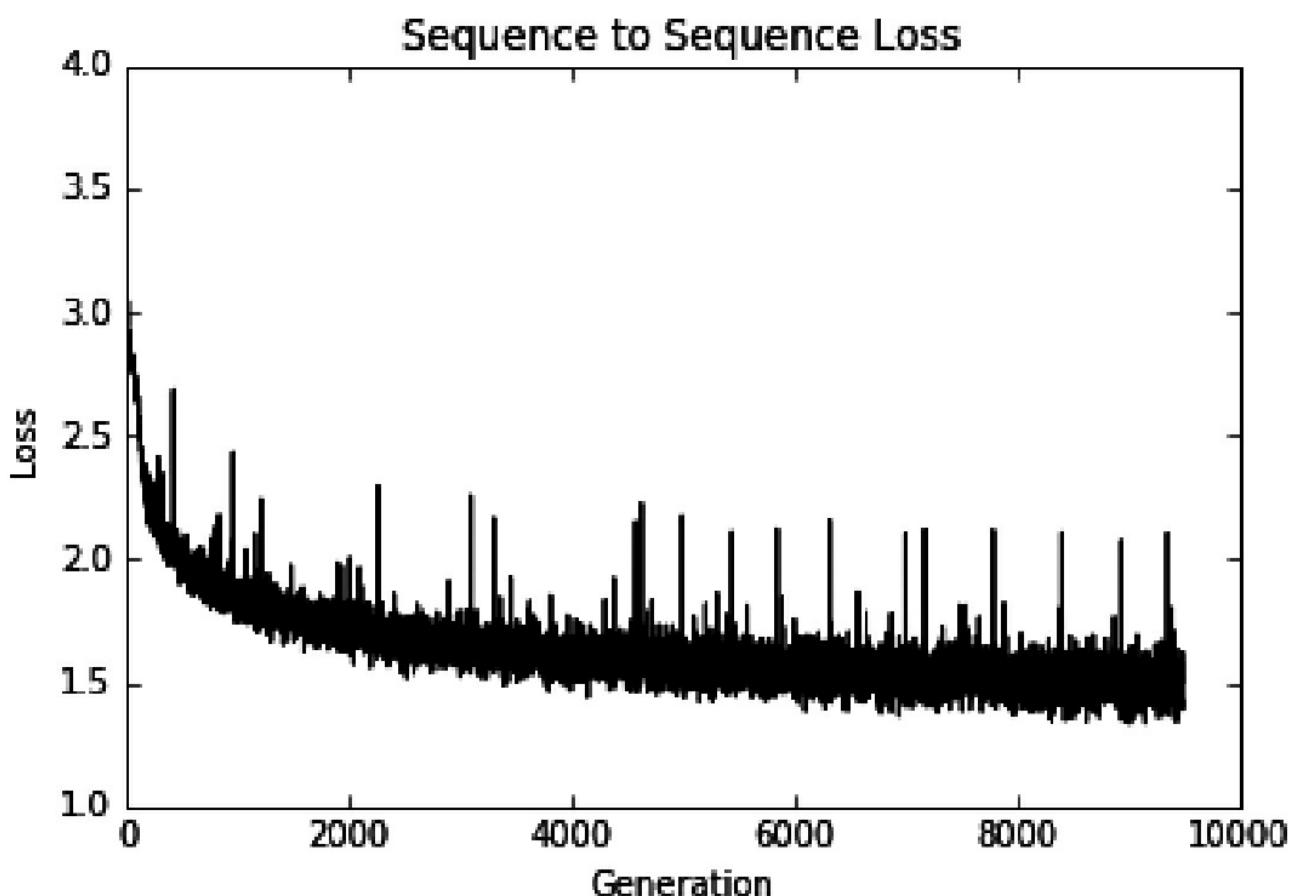


图9-6 多层LSTM RNN模型的迭代训练损失图

9.4.3 工作原理

TensorFlow通过MultiRNNCell（）函数输入RNN单元列表即可将RNN层扩展为多层RNN。本节使用的莎士比亚文本数据集和上一节相同，但是处理时用字符而不是单词。我们传入文本数据进入三层LSTM模型生成莎士比亚文本。发现在迭代训练10个epoch后，训练模型已经可以生成古英语的单词。

9.5 用TensorFlow实现Seq2Seq翻译模型

因为每个RNN单元都有输出，所以我们能训练RNN序列预测变长的序列。本节将利用该特性创建英语到德语的翻译模型。

9.5.1 开始

本节将构建翻译模型将英语翻译为德语。TensorFlow自带模型函数来进行Seq2Seq翻译模型训练。我们将介绍如何训练翻译模型，并在英语-德语句子上应用。语料数据来自网站（<http://www.manythings.org/>），ZIP格式的文件。该数据是tab键分割的英语-德语句子翻译（例如，hello./t hallo），由成千上万个变长句子组成。

9.5.2 动手做

1. 导入必要的编程库，创建一个计算图会话，代码如下：

```
import os
import string
import requests
import io
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
from zipfile import ZipFile
from collections import Counter
from tensorflow.models.rnn.translate import seq2seq_model
sess = tf.Session()
```

2. 设置模型参数。学习率设为0.1，本例也会每迭代100次衰减1%的学习率，这会在迭代过程中微调算法模型。设置截止最大梯度。RNN大小为500。英语和德语词汇的词频设为10000。我们将所有词汇转为小写，并移除标点符号。将德语umlaut（元音变音，ä、ë、ï、ö 和ü）和eszett（德文字母之一，ß）转为字母数字，归一化德语词汇。具体代码如下：

```
learning_rate = 0.1
lr_decay_rate = 0.99
lr_decay_every = 100
max_gradient = 5.0
batch_size = 50
num_layers = 3
rnn_size = 500
layer_size = 512
```

```
generations = 10000
vocab_size = 10000
save_every = 1000
eval_every = 500
output_every = 50
punct = string.punctuation
data_dir = 'temp'
data_file = 'eng_ger.txt'
model_path = 'seq2seq_model'
full_model_dir = os.path.join(data_dir, model_path)
```

3.准备三个英文句子测试翻译模型，看下训练的模型效果，代码如下：

```
test_english = ['hello where is my computer',
                'the quick brown fox jumped over the lazy dog',
                'is it going to rain tomorrow']
```

4.创建模型文件夹。检查语料文件是否已下载，如果已经下载过语料文件，则直接读取文件；如果没有下载，则下载并保存到指定文件夹，代码如下：

```

if not os.path.exists(full_model_dir):
    os.makedirs(full_model_dir)
# Make data directory
if not os.path.exists(data_dir):
    os.makedirs(data_dir)
print('Loading English-German Data')
# Check for data, if it doesn't exist, download it and save it
if not os.path.isfile(os.path.join(data_dir, data_file)):
    print('Data not found, downloading Eng-Ger sentences from www.
manythings.org')
    sentence_url = 'http://www.manythings.org/anki/deu-eng.zip'
    r = requests.get(sentence_url)
    z = ZipFile(io.BytesIO(r.content))
    file = z.read('deu.txt')
    # Format Data
    eng_ger_data = file.decode()
    eng_ger_data = eng_ger_data.encode('ascii', errors='ignore')
    eng_ger_data = eng_ger_data.decode().split('\n')
    # Write to file
    with open(os.path.join(data_dir, data_file), 'w') as out_conn:
        for sentence in eng_ger_data:
            out_conn.write(sentence + '\n')
else:
    eng_ger_data = []
    with open(os.path.join(data_dir, data_file), 'r') as in_conn:
        for row in in_conn:
            eng_ger_data.append(row[:-1])

```

5. 清洗预料数据集，移除标点符号，分割句子中的英语和德语，并全部转为小写，代码如下：

```

eng_ger_data = [''.join(char for char in sent if char not in
punct) for sent in eng_ger_data]

# Split each sentence by tabs
eng_ger_data = [x.split('\t') for x in eng_ger_data if len(x)>=1]
[english_sentence, german_sentence] = [list(x) for x in zip(*eng_
ger_data)]
english_sentence = [x.lower().split() for x in english_sentence]
german_sentence = [x.lower().split() for x in german_sentence]

```

6. 创建英语词汇表和德语词汇表，其中词频都要求至少10000。不符合词频要求的单词标为0（未知）。

大部分低频词为代词（名字或者地名）。具体代码如下：

```

all_english_words = [word for sentence in english_sentence for
word in sentence]
all_english_counts = Counter(all_english_words)
eng_word_keys = [x[0] for x in all_english_counts.most_
common(vocab_size-1)] # -1 because 0=unknown is also in there
eng_vocab2ix = dict(zip(eng_word_keys, range(1,vocab_size)))
eng_ix2vocab = {val:key for key, val in eng_vocab2ix.items()}
english_processed = []
for sent in english_sentence:
    temp_sentence = []
    for word in sent:
        try:
            temp_sentence.append(eng_vocab2ix[word])
        except:
            temp_sentence.append(0)
    english_processed.append(temp_sentence)
all_german_words = [word for sentence in german_sentence for word
in sentence]
all_german_counts = Counter(all_german_words)
ger_word_keys = [x[0] for x in all_german_counts.most_
common(vocab_size-1)]
ger_vocab2ix = dict(zip(ger_word_keys, range(1,vocab_size)))
ger_ix2vocab = {val:key for key, val in ger_vocab2ix.items()}
german_processed = []
for sent in german_sentence:
    temp_sentence = []
    for word in sent:
        try:
            temp_sentence.append(ger_vocab2ix[word])
        except:
            temp_sentence.append(0)
    german_processed.append(temp_sentence)

```

7. 预处理测试词汇，将其写入词汇索引中，代码如下：

```

test_data = []
for sentence in test_english:
    temp_sentence = []
    for word in sentence.split(' '):
        try:
            temp_sentence.append(eng_vocab2ix[word])
        except:

```

```

# Use '0' if the word isn't in our vocabulary
temp_sentence.append(0)
test_data.append(temp_sentence)

```

8.因为某些句子太长或者太短，所以我们为不同长度的句子创建单独的模型。做这些的原因之一是最小化短句子中填充字符的影响。解决该问题的方法之一是将相似长度的句子分桶处理。我们为每个分桶设置长度范围，这样相似长度的句子就会进入同一个分桶，代码如下：

```

x_maxs = [5, 7, 11, 50]
y_maxs = [10, 12, 17, 60]
buckets = [x for x in zip(x_maxs, y_maxs)]
bucketed_data = [[] for _ in range(len(x_maxs))]
for eng, ger in zip(english_processed, german_processed):
    for ix, (x_max, y_max) in buckets:
        if (len(eng) <= x_max) and (len(ger) <= y_max):
            bucketed_data[ix].append([eng, ger])
            break

```

9.将上述参数传入TensorFlow内建的Seq2Seq模型。创建translation_model()函数保证训练模型和测试模型可以共享相同的变量，代码如下：

```

def translation_model(sess, input_vocab_size, output_vocab_size,
                      buckets, rnn_size, num_layers, max_gradient,
                      learning_rate, lr_decay_rate, forward_only):
    model = seq2seq_model.Seq2SeqModel(
        input_vocab_size,
        output_vocab_size,
        buckets,
        rnn_size,
        num_layers,
        max_gradient,
        batch_size,
        learning_rate,
        lr_decay_rate,
        forward_only=forward_only,
        dtype=tf.float32)
    return(model)

```

10.创建训练模型，使用tf.variable_scope管理模型变量，声明训练模型的变量在scope范围内可重用。创建测试模型，其批量大小为1，代码如下：

```
input_vocab_size = vocab_size
output_vocab_size = vocab_size
with tf.variable_scope('translate_model') as scope:
    translate_model = translation_model(sess, vocab_size, vocab_
size,
                                         buckets, rnn_size, num_
layers,
                                         max_gradient, learning_
rate,
                                         lr_decay_rate, False)
#Reuse the variables for the test model
scope.reuse_variables()
test_model = translation_model(sess, vocab_size, vocab_size,
                                         buckets, rnn_size, num_layers,
                                         max_gradient, learning_rate,
                                         lr_decay_rate, True)
test_model.batch_size = 1
```

11. 初始化模型变量，代码如下：

```
init = tf.initialize_all_variables()
sess.run(init)
```

12. 调用step()函数迭代训练Seq2Seq模型。TensorFlow的Seq2Seq模型有get_batch()函数，该函数可以从分桶索引迭代批量句子。衰减学习率，保存Seq2Seq训练模型，并利用测试句子进行模型评估。具体代码如下：

```
train_loss = []
for i in range(generations):
    rand_bucket_ix = np.random.choice(len(bucketed_data))

    model_outputs = translate_model.get_batch(bucketed_data, rand_
bucket_ix)
    encoder_inputs, decoder_inputs, target_weights = model_outputs

    # Get the (gradient norm, loss, and outputs)
    _, step_loss, _ = translate_model.step(sess, encoder_inputs,
decoder_inputs, target_weights, rand_bucket_ix, False)

    # Output status
    if (i+1) % output_every == 0:
        train_loss.append(step_loss)
        print('Gen #{} out of {}. Loss: {:.4}'.format(i+1,
generations, step_loss))

    # Check if we should decay the learning rate
    if (i+1) % lr_decay_every == 0:
        sess.run(translate_model.learning_rate_decay_op)

    # Save model
    if (i+1) % save_every == 0:
        print('Saving model to {}'.format(full_model_dir))
        model_save_path = os.path.join(full_model_dir, "eng_ger_
translation.ckpt")
        translate_model.saver.save(sess, model_save_path, global_
step=i)

    # Eval on test set
    if (i+1) % eval_every == 0:
        for ix, sentence in enumerate(test_data):
            # Find which bucket sentence goes in
            bucket_id = next(index for index, val in enumerate(x_
maxs) if val>=len(sentence))
            # Get RNN model outputs
            encoder_inputs, decoder_inputs, target_weights = test_
model.get_batch(
                {bucket_id: [(sentence, [])]}, bucket_id)
```

```

    # Get logits
    _, test_loss, output_logits = test_model.step(sess,
encoder_inputs, decoder_inputs, target_weights, bucket_id, True)
        ix_output = [int(np.argmax(logit, axis=1)) for logit
in output_logits]
            # If there is a 0 symbol in outputs end the output
there.
            ix_output = ix_output[0:[ix for ix, x in enumerate(ix_
output+ [0]) if x==0] [0]]
            # Get german words from indices
            test_german = [ger_ix2vocab[x] for x in ix_output]
            print('English: {}'.format(test_english[ix]))
            print('German: {}'.format(test_german))

```

13.下面是输出结果:

```

Gen #0 out of 10000. Loss: 7.377
Gen #9800 out of 10000. Loss: 3.875
Gen #9850 out of 10000. Loss: 3.748
Gen #9900 out of 10000. Loss: 3.615
Gen #9950 out of 10000. Loss: 3.889
Gen #10000 out of 10000. Loss: 3.071
Saving model to temp/seq2seq_model.
English: hello where is my computer
German: ['wo', 'ist', 'mein', 'ist']
English: the quick brown fox jumped over the lazy dog
German: ['die', 'alte', 'ist', 'von', 'mit', 'hund', 'zu']
English: is it going to rain tomorrow
German: ['ist', 'es', 'morgen', 'kommen']

```

14.使用matplotlib模块绘制训练损失图（见图9-7），代码如下:

```

loss_generations = [i for i in range(generations) if i%output_
every==0]
plt.plot(loss_generations, train_loss, 'k-')
plt.title('Sequence to Sequence Loss')
plt.xlabel('Generation')
plt.ylabel('Loss')
plt.show()

```

9.5.3 工作原理

本节使用TensorFlow内建的Seq2Seq模型将英语翻译为德语。

虽然我们的测试句子并没有得到很好的翻译效果，但是仍有提升的空间。如果模型训练时间加长，改变分桶策略，就可以提高翻译水平。

9.5.4 延伸学习

在manythings网站上也有其他语言的双语语料库（<http://www.manythings.org/anki/>），读者可以下载使用其他语料库。

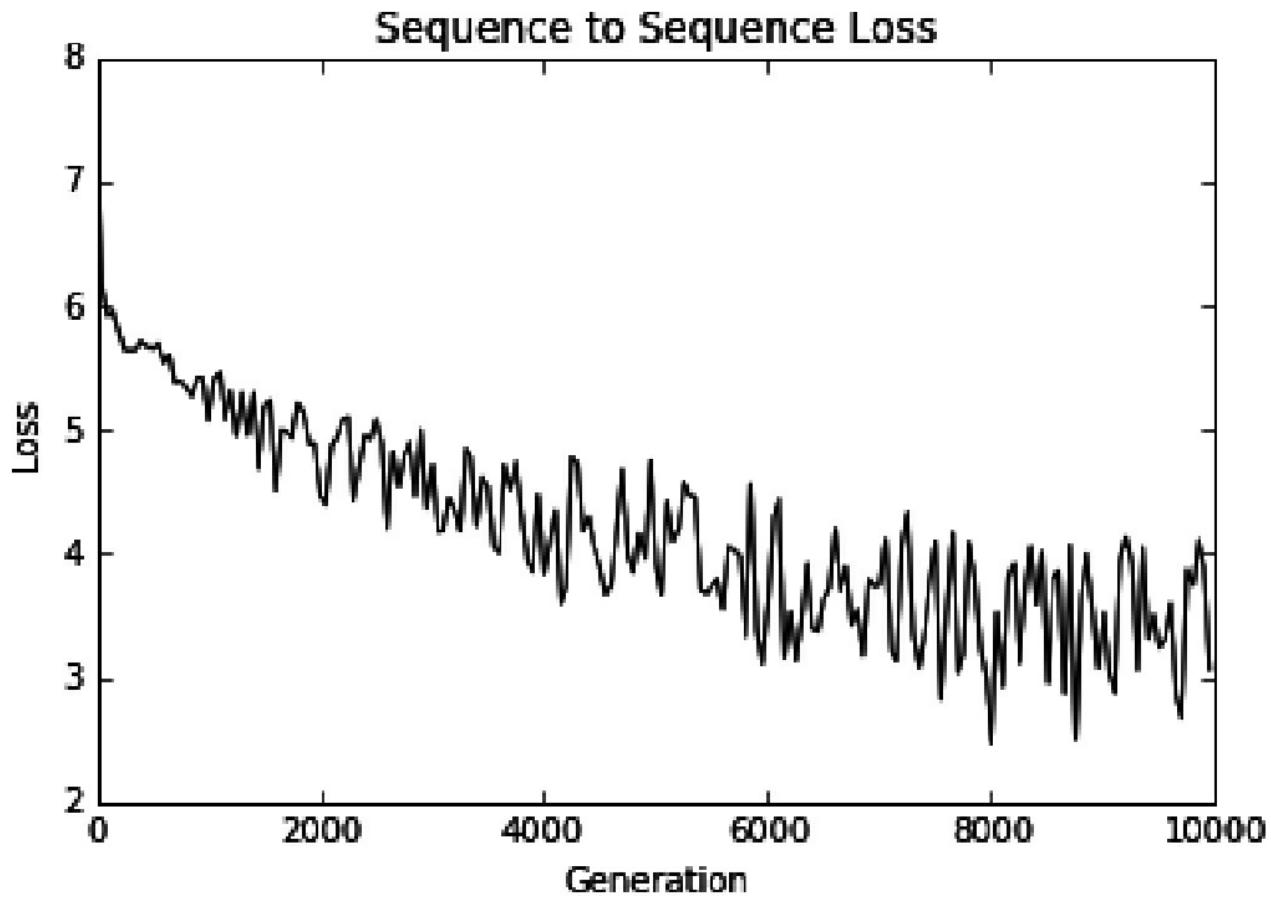


图9-7 Seq2Seq翻译模型（英语翻译为德语）迭代训练10000次的损失趋势图

9.6 TensorFlow实现孪生RNN预测相似度

相对于其他算法模型来讲，RNN模型的一大优点就是能处理变长的序列数据。利用该特性以及其可以生成全新的序列数据，我们能创建方法度量输入序列和另外的序列之间的相似度。本节将训练孪生相似度RNN模型度量记录地址之间的相似度。

9.6.1 开始

在本节中，我们将构建一个双向RNN模型，加入一个全联接层，全联接层输出固定长度的数值型向量。我们创建一个双向RNN层，输入地址，并将输出传入全联接层，该全联接层输出固定长度的数值型向量（长度为100）。然后比较两个向量输出的余弦相似度，其值在-1和1之间。输入数据与目标相似则为1，否则为-1。余弦距离的预测仅仅为输出结果的符号值（负值意味着不相似，正值意味着相似）。我们能利用该网络进行记录匹配，取基准地址与查询地址之间余弦距离最高的。图9-8是网络架构图。

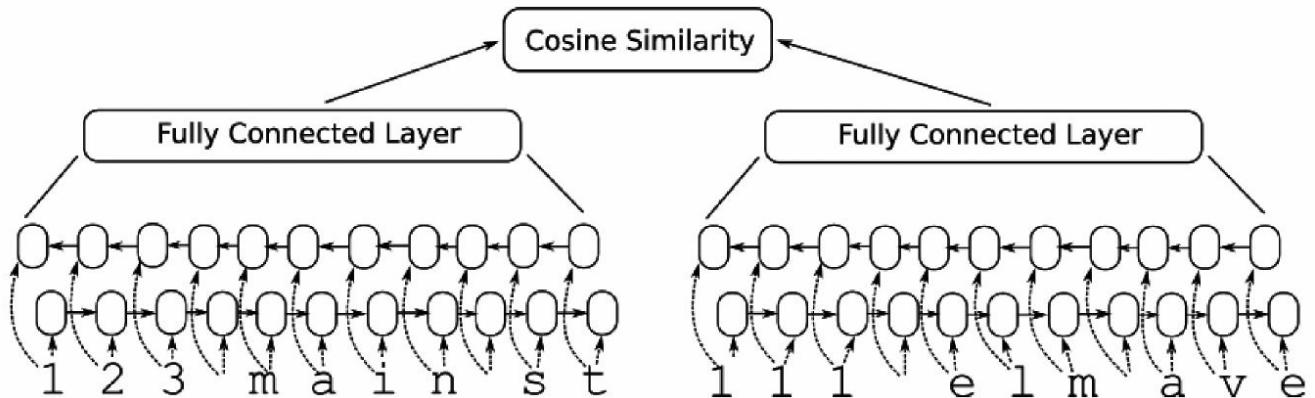


图9-8 李生RNN相似度模型的架构图

该模型的优点是，可以接受从未见过的地址并进行比较，输出-1到1。我们将在代码中选择从未见过的地址进行测试，查看模型是否能匹配相似的地址。

9.6.2 动手做

1. 导入必要的编程库，创建一个计算图会话，代码如下：

```
import os
import random
import string
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
sess = tf.Session()
```

2. 设置模型参数，代码如下：

```
batch_size = 200
n_batches = 300
max_address_len = 20
margin = 0.25
num_features = 50
dropout_keep_prob = 0.8
```

3. 创建一个孪生RNN相似度模型类，代码如下：

```
def snn(address1, address2, dropout_keep_prob,
       vocab_size, num_features, input_length):

    # Define the siamese double RNN with a fully connected layer
    # at the end
    def siamese_nn(input_vector, num_hidden):
        cell_unit = tf.nn.rnn_cell.BasicLSTMCell

        # Forward direction cell
        lstm_forward_cell = cell_unit(num_hidden, forget_bias=1.0)
        lstm_forward_cell = tf.nn.rnn_cell.DropoutWrapper(lstm_
forward_cell, output_keep_prob=dropout_keep_prob)

        # Backward direction cell
        lstm_backward_cell = cell_unit(num_hidden, forget_
bias=1.0)
        lstm_backward_cell = tf.nn.rnn_cell.DropoutWrapper(lstm_
backward_cell, output_keep_prob=dropout_keep_prob)

        # Split title into a character sequence
        input_embed_split = tf.split(1, input_length, input_
vector)
        input_embed_split = [tf.squeeze(x, squeeze_dims=[1]) for x
in input_embed_split]

        # Create bidirectional layer
```

```
outputs, _, _ = tf.nn.bidirectional_rnn(lstm_forward_cell,
                                         lstm_backward_
cell,
                                         input_embed_split,
                                         dtype=tf.float32)
# Average The output over the sequence
temporal_mean = tf.add_n(outputs) / input_length

# Fully connected layer
output_size = 10
A = tf.get_variable(name="A", shape=[2*num_hidden, output_
size],
                     dtype=tf.float32,
                     initializer=tf.random_normal_
initializer(stddev=0.1))
b = tf.get_variable(name="b", shape=[output_size],
                     dtype=tf.float32,
                     initializer=tf.random_normal_
initializer(stddev=0.1))

final_output = tf.matmul(temporal_mean, A) + b
final_output = tf.nn.dropout(final_output, dropout_keep_
prob)

return(final_output)

with tf.variable_scope("siamese") as scope:
    output1 = siamese_nn(address1, num_features)
    # Declare that we will use the same variables on the
second string
    scope.reuse_variables()
    output2 = siamese_nn(address2, num_features)

# Unit normalize the outputs
output1 = tf.nn.l2_normalize(output1, 1)
output2 = tf.nn.l2_normalize(output2, 1)
# Return cosine distance
#   in this case, the dot product of the norms is the same.
dot_prod = tf.reduce_sum(tf.mul(output1, output2), 1)

return(dot_prod)
```



使用tf.variable_scope可在Siamese网络的两个部分共享变量参数。注意，余弦距离是归一化向量的点积。

4. 声明预测函数，该函数是余弦距离的符号值，代码如下：

```
def get_predictions(scores) :  
    predictions = tf.sign(scores, name="predictions")  
    return(predictions)
```

5. 声明损失函数。我们希望为error预留一个margin（类似于SVM模型）。损失函数项中包括正损失和负损失。具体代码如下：

```

def loss(scores, y_target, margin):
    # Calculate the positive losses
    pos_loss_term = 0.25 * tf.square(tf.sub(1., scores))
    pos_mult = tf.cast(y_target, tf.float32)

    # Make sure positive losses are on similar strings
    positive_loss = tf.mul(pos_mult, pos_loss_term)

    # Calculate negative losses, then make sure on dissimilar
    # strings
    neg_mult = tf.sub(1., tf.cast(y_target, tf.float32))

    negative_loss = neg_mult*tf.square(scores)

    # Combine similar and dissimilar losses
    loss = tf.add(positive_loss, negative_loss)

    # Create the margin term. This is when the targets are 0.,
    # and the scores are less than m, return 0.

    # Check if target is zero (dissimilar strings)
    target_zero = tf.equal(tf.cast(y_target, tf.float32), 0.)
    # Check if cosine outputs is smaller than margin
    less_than_margin = tf.less(scores, margin)
    # Check if both are true
    both_logical = tf.logical_and(target_zero, less_than_margin)
    both_logical = tf.cast(both_logical, tf.float32)
    # If both are true, then multiply by (1-1)=0.
    multiplicative_factor = tf.cast(1. - both_logical, tf.float32)
    total_loss = tf.mul(loss, multiplicative_factor)

    # Average loss over batch
    avg_loss = tf.reduce_mean(total_loss)
    return(avg_loss)

```

6. 声明准确度函数，代码如下：

```

def accuracy(scores, y_target):
    predictions = get_predictions(scores)
    correct_predictions = tf.equal(predictions, y_target)
    accuracy = tf.reduce_mean(tf.cast(correct_predictions,
tf.float32))
    return(accuracy)

```

7. 使用基准地址创建有“打印错误”的相似地址，代码如下：

```

def create_typo(s):
    rand_ind = random.choice(range(len(s)))
    s_list = list(s)

    s_list[rand_ind]=random.choice(string.ascii_lowercase +
'0123456789')
    s = ''.join(s_list)
    return(s)

```

8. 将街道号、街道名和街道后缀随机组合生成数据。街道名和街道后缀的列表如下：

```

street_names = ['abbey', 'baker', 'canal', 'donner', 'elm',
'fifth', 'grandvia', 'hollywood', 'interstate', 'jay', 'kings']
street_types = ['rd', 'st', 'ln', 'pass', 'ave', 'hwy', 'cir',
'dr', 'jct']

```

9. 生成测试查询地址和基准地址，代码如下：

```

test_queries = ['111 abbey ln', '271 donner cicle',
                 '314 king avenue', 'tensorflow is fun']
test_references = ['123 abbey ln', '217 donner cir', '314 kings
ave', '404 hollywood st', 'tensorflow is so fun']

```



最后的查询和基准地址对于本例模型来说都未见过，但是我们希望模型能识别出它们的相似性。

10. 定义如何生成批量数据。本例的批量数据是一半相似的地址（基准地址和“打印错误”地址）和一半不相似的地址。不相似的地址是通过读取地址列表的后半部分，并使用numpy.roll() 函数将其向右循环移动1位获取的，代码如下：

```

def get_batch(n):
    # Generate a list of reference addresses with similar
    addresses that have
    # a typo.
    numbers = [random.randint(1, 9999) for i in range(n)]
    streets = [random.choice(street_names) for i in range(n)]
    street_suffs = [random.choice(street_types) for i in range(n)]
    full_streets = [str(w) + ' ' + x + ' ' + y for w,x,y in
zip(numbers, streets, street_suffs)]
    typo_streets = [create_typos(x) for x in full_streets]
    reference = [list(x) for x in zip(full_streets, typo_streets)]

    # Shuffle last half of them for training on dissimilar
    addresses
    half_ix = int(n/2)
    bottom_half = reference[half_ix:]
    true_address = [x[0] for x in bottom_half]
    typo_address = [x[1] for x in bottom_half]
    typo_address = list(np.roll(typo_address, 1))
    bottom_half = [[x,y] for x,y in zip(true_address, typo_
address)]
    reference[half_ix:] = bottom_half

    # Get target similarities (1's for similar, -1's for non-
similar)
    target = [1]*(n-half_ix) + [-1]*half_ix
    reference = [[x,y] for x,y in zip(reference, target)]
    return(reference)

```

11. 定义地址词汇表，以及如何将地址one-hot编码为索引，代码如下：

```

vocab_chars = string.ascii_lowercase + '0123456789 '
vocab2ix_dict = {char:(ix+1) for ix, char in enumerate(vocab_
chars)}
vocab_length = len(vocab_chars) + 1

# Define vocab one-hot encoding
def address2onehot(address,
                    vocab2ix_dict = vocab2ix_dict,
                    max_address_len = max_address_len):
    # translate address string into indices
    address_ix = [vocab2ix_dict[x] for x in list(address)]

    # Pad or crop to max_address_len
    address_ix = (address_ix + [0]*max_address_len)[0:max_address_
len]
    return(address_ix)

```

12. 处理好词汇表，我们开始声明模型占位符和嵌套查找函数。对于嵌套查找来说，我们将使用one-hot编码嵌套，使用单位矩阵作为查找矩阵，代码如下：

```

address1_ph = tf.placeholder(tf.int32, [None, max_address_len],
name="address1_ph")
address2_ph = tf.placeholder(tf.int32, [None, max_address_len],
name="address2_ph")
y_target_ph = tf.placeholder(tf.int32, [None], name="y_target_ph")
dropout_keep_prob_ph = tf.placeholder(tf.float32, name="dropout_
keep_prob")

# Create embedding lookup
identity_mat = tf.diag(tf.ones(shape=[vocab_length]))
address1_embed = tf.nn.embedding_lookup(identity_mat, address1_ph)
address2_embed = tf.nn.embedding_lookup(identity_mat, address2_ph)

```

13. 声明算法模型、准确度、损失函数和预测操作，代码如下：

```

# Define Model
text_snn = model.snn(address1_embed, address2_embed, dropout_keep_
prob_ph,
                      vocab_length, num_features, max_address_len)

# Define Accuracy
batch_accuracy = model.accuracy(text_snn, y_target_ph)

# Define Loss
batch_loss = model.loss(text_snn, y_target_ph, margin)

# Define Predictions
predictions = model.get_predictions(text_snn)

```

14.在开始训练模型之前，增加优化器函数，初始化变量，代码如下：

```
# Declare optimizer
optimizer = tf.train.AdamOptimizer(0.01)
# Apply gradients
train_op = optimizer.minimize(batch_loss)
# Initialize Variables
init = tf.global_variables_initializer()
sess.run(init)
```

15.现在遍历迭代训练，记录损失函数和准确度，代码如下：

```
train_loss_vec = []
train_acc_vec = []
for b in range(n_batches):
    # Get a batch of data
    batch_data = get_batch(batch_size)
    # Shuffle data
    np.random.shuffle(batch_data)
    # Parse addresses and targets
    input_addresses = [x[0] for x in batch_data]
    target_similarity = np.array([x[1] for x in batch_data])
    address1 = np.array([address2onehot(x[0]) for x in input_addresses])
    address2 = np.array([address2onehot(x[1]) for x in input_addresses])

    train_feed_dict = {address1_ph: address1,
                      address2_ph: address2,
                      y_target_ph: target_similarity,
                      dropout_keep_prob_ph: dropout_keep_prob}

    _, train_loss, train_acc = sess.run([train_op, batch_loss,
                                         batch_accuracy],
                                        feed_dict=train_feed_dict)
    # Save train loss and accuracy
    train_loss_vec.append(train_loss)
    train_acc_vec.append(train_acc)
```

16.训练模型之后，我们处理测试查询和基准地址来查看模型效果，代码如下：

```
test_queries_ix = np.array([address2onehot(x) for x in test_queries])
test_references_ix = np.array([address2onehot(x) for x in test_references])
num_refs = test_references_ix.shape[0]
best_fit_refs = []
for query in test_queries_ix:
    test_query = np.repeat(np.array([query]), num_refs, axis=0)
    test_feed_dict = {address1_ph: test_query,
                      address2_ph: test_references_ix,
                      y_target_ph: target_similarity,
                      dropout_keep_prob_ph: 1.0}
    test_out = sess.run(text_snn, feed_dict=test_feed_dict)
    best_fit = test_references[np.argmax(test_out)]
    best_fit_refs.append(best_fit)
print('Query Addresses: {}'.format(test_queries))
print('Model Found Matches: {}'.format(best_fit_refs))
```

17.输出结果如下：

```
Query Addresses: ['111 abbey ln', '271 doner cicle', '314 king
avenue', 'tensorflow is fun']
Model Found Matches: ['123 abbey ln', '217 donner cir', '314 kings
ave', 'tensorflow is so fun']
```

9.6.3 延伸学习

从测试查询和基准地址可以看出，训练的模型不仅能判别正确的基准地址，也可以生成非地址词语。通过训练模型的损失和准确度来看下模型的效果（见图9-9）。

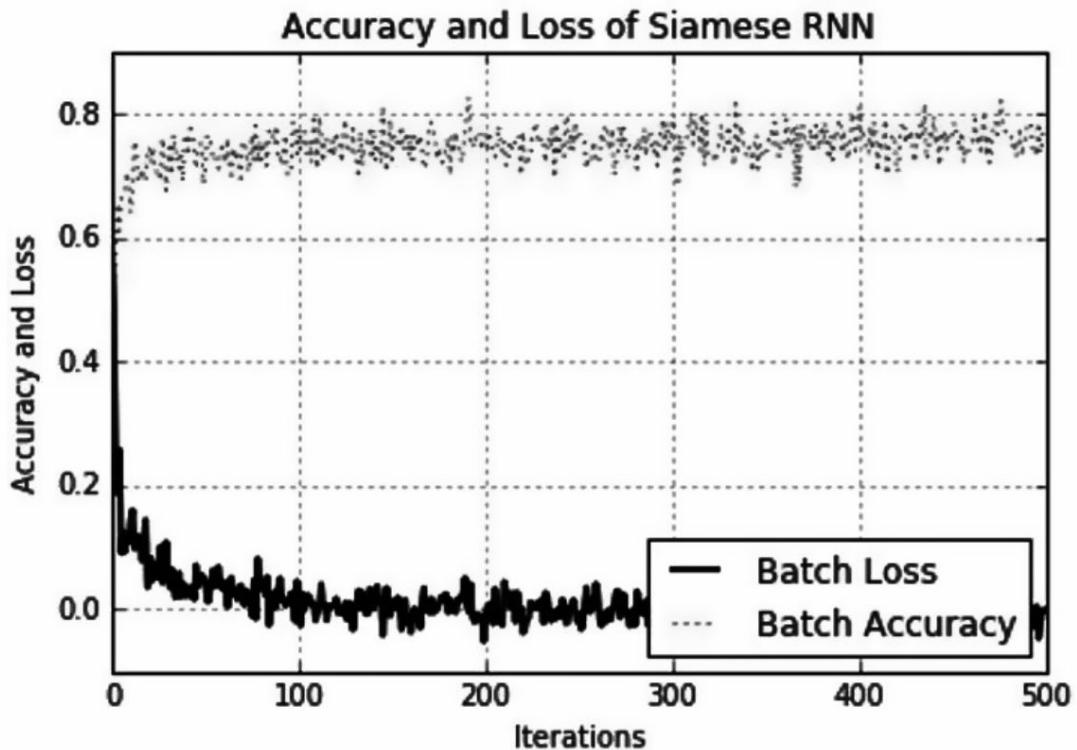


图9-9 孪生RNN相似度模型训练的准确度和损失趋势图

注意，本例没有指定测试集来练习，因为本例是生成数据。我们创建批量函数每次创建新的批量数据，所以模型输入的都是新数据，用批量损失和准确度代替测试损失和准确度。但是对于实际的有限数据集来讲，并不一定都正确，所以我们需要训练集和测试集来评估模型效果。

第10章 TensorFlow产品化

本章将介绍以下知识点：

- TensorFlow的单元测试
- TensorFlow的多设备使用
- 分布式TensorFlow实践
- TensorFlow产品化开发提示
- TensorFlow产品化的实例

10.1 简介

到目前为止，我们覆盖了如何使用TensorFlow训练和评估各种模型。本章将展示如何编写产品化使用的代码。产品级代码的定义有很多，这里我们将产品级代码定义为有单元测试，分开训练和评估代码，有效地存储和加载数据管道中各种所需的部分以及创建计算图会话。



本章提供的Python脚本需在命令行运行。测试运行后会在屏幕上打印日志。

10.2 TensorFlow的单元测试

测试代码使得原型设计更快、调试更有效、调整更快、代码分享也更容易。本节TensorFlow的单元测试实现相当容易。

10.2.1 开始

当编写一个TensorFlow模型时，单元测试帮助我们测试代码功能。当我们想调整代码单元时，测试确保这些改变不会破坏模型。本节将在MNIST数据集上创建一个简单的CNN网络，并实现三种不同的单元测试来介绍如何在TensorFlow中编写单元测试。

Python有一个名为Nose的测试库。TensorFlow也有内建的测试函数，我们将展示如何使用这些函数测试张量对象的值，并且没有在计算图会话中评估该值。

1. 导入必要的编程库，并格式化数据集，代码如下：

```
import numpy as np
import tensorflow as tf
from tensorflow.contrib.learn.python.learn.datasets.mnist import
read_data_sets
from tensorflow.python.framework import ops
ops.reset_default_graph()
# Start a graph session
sess = tf.Session()
# Load data
data_dir = 'temp'
mnist = read_data_sets(data_dir)
# Convert images into 28x28 (they are downloaded as 1x784)
train_xdata = np.array([np.reshape(x, (28,28)) for x in mnist.
train.images])
test_xdata = np.array([np.reshape(x, (28,28)) for x in mnist.test.
images])
# Convert labels into one-hot encoded vectors
train_labels = mnist.train.labels
test_labels = mnist.test.labels
# Set model parameters
batch_size = 100
learning_rate = 0.005
evaluation_size = 100
image_width = train_xdata[0].shape[0]
image_height = train_xdata[0].shape[1]
target_size = max(train_labels) + 1
num_channels = 1 # greyscale = 1 channel
generations = 100
eval_every = 5
conv1_features = 25
conv2_features = 50
max_pool_size1 = 2 # NxN window for 1st max pool layer
max_pool_size2 = 2 # NxN window for 2nd max pool layer
fully_connected_size1 = 100
dropout_prob = 0.75
```

2. 声明模型的占位符、变量和模型表达式，代码如下：

```
# Declare model placeholders
x_input_shape = (batch_size, image_width, image_height, num_
channels)
x_input = tf.placeholder(tf.float32, shape=x_input_shape)
y_target = tf.placeholder(tf.int32, shape=(batch_size))
eval_input_shape = (evaluation_size, image_width, image_height,
num_channels)
eval_input = tf.placeholder(tf.float32, shape=eval_input_shape)
```

```

eval_target = tf.placeholder(tf.int32, shape=(evaluation_size))
dropout = tf.placeholder(tf.float32, shape=())
# Declare model parameters
conv1_weight = tf.Variable(tf.truncated_normal([4, 4, num_
channels, conv1_features],
                                              stddev=0.1,
                                              dtype=tf.float32))
conv1_bias = tf.Variable(tf.zeros([conv1_features], dtype=tf.
float32))
conv2_weight = tf.Variable(tf.truncated_normal([4, 4, conv1_
features, conv2_features],
                                              stddev=0.1,
                                              dtype=tf.float32))
conv2_bias = tf.Variable(tf.zeros([conv2_features], dtype=tf.
float32))
# fully connected variables
resulting_width = image_width // (max_pool_size1 * max_pool_size2)
resulting_height = image_height // (max_pool_size1 * max_pool_
size2)
full1_input_size = resulting_width * resulting_height * conv2_
features
full1_weight = tf.Variable(tf.truncated_normal([full1_input_size,
fully_connected_size1],
                                              stddev=0.1, dtype=tf.float32))
full1_bias = tf.Variable(tf.truncated_normal([fully_connected_\
size1], stddev=0.1, dtype=tf.float32))
full2_weight = tf.Variable(tf.truncated_normal([fully_connected_\
size1, target_size],
                                              stddev=0.1,
                                              dtype=tf.float32))
full2_bias = tf.Variable(tf.truncated_normal([target_size],
stddev=0.1, dtype=tf.float32))
# Initialize Model Operations
def my_conv_net(input_data):
    # First Conv-ReLU-MaxPool Layer
    conv1 = tf.nn.conv2d(input_data, conv1_weight, strides=[1, 1,
1, 1], padding='SAME')
    relu1 = tf.nn.relu(tf.nn.bias_add(conv1, conv1_bias))
    max_pool1 = tf.nn.max_pool(relu1, ksize=[1, max_pool_size1,
max_pool_size1, 1],
                               strides=[1, max_pool_size1, max_
pool_size1, 1], padding='SAME')
    # Second Conv-ReLU-MaxPool Layer
    conv2 = tf.nn.conv2d(max_pool1, conv2_weight, strides=[1, 1,
1, 1], padding='SAME')
    relu2 = tf.nn.relu(tf.nn.bias_add(conv2, conv2_bias))
    max_pool2 = tf.nn.max_pool(relu2, ksize=[1, max_pool_size2,
max_pool_size2, 1],
                               strides=[1, max_pool_size2, max_
pool_size2, 1], padding='SAME')
    # Transform Output into a 1xN layer for next fully connected
layer
    final_conv_shape = max_pool2.get_shape().as_list()

```

```

    final_shape = final_conv_shape[1] * final_conv_shape[2] *
final_conv_shape[3]
    flat_output = tf.reshape(max_pool2, [final_conv_shape[0],
final_shape])
    # First Fully Connected Layer
    fully_connected1 = tf.nn.relu(tf.add(tf.matmul(flat_output,
full1_weight), full1_bias))
    # Second Fully Connected Layer
    final_model_output = tf.add(tf.matmul(fully_connected1, full2_
weight), full2_bias)

    # Add dropout
    final_model_output = tf.nn.dropout(final_model_output,
dropout)

    return(final_model_output)
model_output = my_conv_net(x_input)
test_model_output = my_conv_net(eval_input)

```

3. 创建损失函数、预测和准确度操作，然后初始化模型变量，代码如下：

```

# Declare Loss Function (softmax cross entropy)
loss = tf.reduce_mean(tf.nn.sparse_softmax_cross_entropy_with_
logits(model_output, y_target))
# Create a prediction function
prediction = tf.nn.softmax(model_output)
test_prediction = tf.nn.softmax(test_model_output)
# Create accuracy function
def get_accuracy(logits, targets):
    batch_predictions = np.argmax(logits, axis=1)
    num_correct = np.sum(np.equal(batch_predictions, targets))
    return(100. * num_correct/batch_predictions.shape[0])
# Create an optimizer
my_optimizer = tf.train.MomentumOptimizer(learning_rate, 0.9)
train_step = my_optimizer.minimize(loss)
# Initialize Variables
init = tf.initialize_all_variables()
sess.run(init)

```

4. 使用`tf.test.TestCase()`类来测试占位符或者变量的值。在本例中，我们确保dropout概率大于0.25，代码如下：

```

# Check values of tensors!
class drop_out_test(tf.test.TestCase):
    # Make sure that we don't drop too much
    def dropout_greaterthan(self):
        with self.test_session():
            self.assertGreater(dropout.eval(), 0.25)

```

5. 测试准确度函数的功能正确。我们按预期创建一个样例数组，测试返回100%的准确度，代码如下：

```

# Test accuracy function
class accuracy_test(tf.test.TestCase):
    # Make sure accuracy function behaves correctly
    def accuracy_exact_test(self):
        with self.test_session():
            test_preds = [[0.9, 0.1], [0.01, 0.99]]
            test_targets = [0, 1]
            test_acc = get_accuracy(test_preds, test_targets)
            self.assertEqual(test_acc.eval(), 100.)

```

6. 测试张量的形状符合预期。测试模型输出结果是预期的[batch_size, target_size]形状，代码如下：

```

# Test tensorshape
class shape_test(tf.test.TestCase):
    # Make sure our model output is size [batch_size, num_classes]
    def output_shape_test(self):
        with self.test_session():
            numpy_array = np.ones([batch_size, target_size])
            self.assertShapeEqual(numpy_array, model_output)

```

7. 为了运行测试，我们只需要执行下面的命令，并紧跟其后的迭代训练，代码如下：

```

# Perform unit tests
tf.test.main()
# Start training loop
for i in range(generations):

```

8. 如果在命令后运行程序，将得到如下输出：

```

$python3 implementing_unit_tests.py
Ran 3 tests in 0.000s
OK

```

9.完整的代码可以在本书的GitHub地址（https://github.com/nfmcclure/tensorflow_cookbook/）获取。

10.2.2 工作原理

本例实现了三种单元测试：张量值、操作输出结果和张量形状。关于TensorFlow更多的单元测试函数请浏览https://www.tensorflow.org/versions/master/api_docs/python/test.html。

注意，单元测试可以帮助我们确保代码的功能符合预期，提供分享代码的信心，并使代码可重用。

10.3 TensorFlow的并发执行

读者很明显地看到TensorFlow和计算图天生适合并行计算。计算图可以由不同的处理器来处理。本节将介绍如何在同一台机器上访问不同的处理器。

10.3.1 开始

本节将展示如何在同一系统上访问多个设备，并训练算法模型。对于单个CPU，这是很常见的并发问题。对于单个或者多个GPU，其可以共享计算能力。如果TensorFlow能访问这些设备，通过贪婪过程它将自动在多个设备上分布式计算。但是TensorFlow也允许程序通过命名空间的方式指定哪个操作将在哪个设备上执行。

为了访问GPU设备，需要安装TensorFlow的GPU版。安装TensorFlow的GPU版请访问：https://www.tensorflow.org/versions/master/get_started/os_setup.html#download-and-setup，并根据自身操作系统选择安装步骤。值得一提的是，TensorFlow的GPU版要求安装CUDA来使用GPU。

本节将介绍一系列的命令来访问操作系统上的各种设备，并找出哪个设备可供TensorFlow使用。

10.3.2 动手做

1.为了能够找到TensorFlow的什么操作正在使用什么设备，我们在计算图会话中传入一个config参数，将log_device_placement设为True。当我们在命令行运行脚本时，会看到指定设备输出，代码如下：

```
import tensorflow as tf
sess = tf.Session(config=tf.ConfigProto(log_device_
placement=True))
a = tf.constant([1.0, 2.0, 3.0, 4.0, 5.0, 6.0], shape=[2, 3],
name='a')
b = tf.constant([1.0, 2.0, 3.0, 4.0, 5.0, 6.0], shape=[3, 2],
name='b')
c = tf.matmul(a, b)
# Runs the op.
print(sess.run(c))
```

2.从控制台运行下面的命令：

```
$python3 using_multiple_devices.py
Device mapping: no known devices.
I tensorflow/core/common_runtime/direct_session.cc:175] Device
mapping:
MatMul: /job:localhost/replica:0/task:0/cpu:0
I tensorflow/core/common_runtime/simple_placer.cc:818] MatMul: /
job:localhost/replica:0/task:0/cpu:0
b: /job:localhost/replica:0/task:0/cpu:0
I tensorflow/core/common_runtime/simple_placer.cc:818] b: /
job:localhost/replica:0/task:0/cpu:0
a: /job:localhost/replica:0/task:0/cpu:0
I tensorflow/core/common_runtime/simple_placer.cc:818] a: /
job:localhost/replica:0/task:0/cpu:0
[[ 22.  28.]
 [ 49.  64.]]
```

3.有时，我们希望搞清楚TensorFlow正在使用的设备。当加载先前保存过的模型，并且该模型在计算图中已分配固定设备时，服务器可提供不同的设备给计算图使用。实现该功能只需在config设置软设备，代码如下：

```
config = tf.ConfigProto()
config.allow_soft_placement = True
sess_soft = tf.Session(config=config)
```

4. 当使用GPU时，TensorFlow默认占据大部分GPU内存。虽然这也是时常期望的，但是我们能谨慎分配GPU内存。当TensorFlow一直不释放GPU内存时，如有必要，我们可以设置GPU内存增长选项让GPU内存分配缓慢增大到最大限制，代码如下：

```
config.gpu_options.allow_growth = True
sess_grow = tf.Session(config=config)
```

5. 如果希望限制死TensorFlow使用GPU内存的百分比，可以使用config设置per_process_gpu_memory_fraction，代码如下：

```
config.gpu_options.per_process_gpu_memory_fraction = 0.4
sess_limited = tf.Session(config=config)
```

6. 有时，我们希望代码健壮到可以决定运行多少GPU合适。TensorFlow有内建函数可以探测到。如果我们期望代码在GPU内存合适时利用GPU计算能力，并分配指定操作给GPU，那么该功能是有益的。具体代码如下：

```
if tf.test.is_built_with_cuda():
```

7. 我们希望分配指定操作给GPU。下面是一个示例代码，做了一些简单的计算，并将它们分配给主CPU和两个副GPU，代码如下：

```
with tf.device('/cpu:0'):  
    a = tf.constant([1.0, 3.0, 5.0], shape=[1, 3])  
    b = tf.constant([2.0, 4.0, 6.0], shape=[3, 1])  
  
    with tf.device('/gpu:0'):  
        c = tf.matmul(a,b)  
        c = tf.reshape(c, [-1])  
  
    with tf.device('/gpu:1'):  
        d = tf.matmul(b,a)  
        flat_d = tf.reshape(d, [-1])  
  
    combined = tf.mul(c, flat_d)  
print(sess.run(combined))
```

10.3.3 工作原理

当希望为TensorFlow的操作指定机器的特定设备，我们需要知道如何引用该设备。在TensorFlow中，设备名约定俗成的命名如下表所示。

设备	设备名
主 CPU	/cpu:0
副 CPU	/cpu:1
主 GPU	/gpu:0
副 GPU	/gpu:1
第三 GPU	/gpu:2

10.3.4 延伸学习

TensorFlow在云服务上运行越来越容易。许多云服务提供商提供带有主CPU和GPU的GPU实例。亚马逊（Amazon Web Services， AWS）的G实例和P2实例提供GPU计算能力加速TensorFlow的处理。也有AWS机器学习镜像（AWS Machine Image， AMI），其提供免费的启动项已安装TensorFlow的GPU实例。

10.4 分布式TensorFlow实践

为了扩展TensorFlow的并行能力，可将分开的计算图操作以分布式的方式运行在不同的机器上。本节主要介绍分布式TensorFlow实践。

10.4.1 开始

TensorFlow发布之后几个月，Google公司发布了分布式的TensorFlow。这是TensorFlow生态系统的一个巨大提升，允许构建一个TensorFlow集群（分布于不同的worker机器），共享相同的训练和评估模型的计算任务。使用分布式的TensorFlow只需要简单地设置worker节点参数，然后为不同的worker节点分配不同的作业。

本节将建立两个本地worker并分配不同的作业。

10.4.2 动手做

1.加载TensorFlow，定义两个本地worker（端口分别为2222和2223），代码如下：

```
import tensorflow as tf
# Cluster for 2 local workers (tasks 0 and 1):
cluster = tf.train.ClusterSpec({'local': ['localhost:2222',
'localhost:2223']})
```

2.将两个worker加入到集群中，并标记task数字，代码如下：

```
server = tf.train.Server(cluster, job_name="local", task_index=0)
server = tf.train.Server(cluster, job_name="local", task_index=1)
```

3.现在我们为每个worker分配一个task。第一个worker将初始化两个矩阵（每个是 25×25 维度）。第二个worker计算每个矩阵所有元素的和。然后自动分配将两个和求和的任务，并打印出结果，代码如下：

```
mat_dim = 25
matrix_list = {}
with tf.device('/job:local/task:0'):
    for i in range(0, 2):
        m_label = 'm_{}'.format(i)
        matrix_list[m_label] = tf.random_normal([mat_dim, mat_dim])
# Have each worker calculate the sums
sum_outs = {}
with tf.device('/job:local/task:1'):
    for i in range(0, 2):
        A = matrix_list['m_{}'.format(i)]
        sum_outs['m_{}'.format(i)] = tf.reduce_sum(A)
    # Sum all the sums
    summed_out = tf.add_n(list(sum_outs.values()))
with tf.Session(server.target) as sess:
    result = sess.run(summed_out)
    print('Summed Values:{}'.format(result))
```

4.运行下面的命令：

```
$ python3 parallelizing_tensorflow.py
I tensorflow/core/distributed_runtime/rpc/grpc_channel.cc:197]
Initialize GrpcChannelCache for job local -> {0 -> localhost:2222,
1 -> localhost:2223}
I tensorflow/core/distributed_runtime/rpc/grpc_server_lib.cc:206]
Started server with target: grpc://localhost:2222
I tensorflow/core/distributed_runtime/rpc/grpc_channel.cc:197]
Initialize GrpcChannelCache for job local -> {0 -> localhost:2222,
1 -> localhost:2223}
I tensorflow/core/distributed_runtime/rpc/grpc_server_lib.cc:206]
Started server with target: grpc://localhost:2223
I tensorflow/core/distributed_runtime/master_session.cc:928] Start
master session 252bb6f530553002 with config:
Summed Values:-21.12611198425293
```

10.4.3 工作原理

使用分布式的TensorFlow相当容易。我们只需在集群服务器中为worker节点分配带名字的IP。然后就可以手动或者自动为worker节点分配操作任务。

10.5 TensorFlow产品化开发提示

如果我们想在产品中使用机器学习的脚本，那还是有些最佳实践的注意点。本节将指出一些有用的最佳实践。

10.5.1 开始

本节总结提炼了TensorFlow产品化的注意点。这些包括如何最有效地保存和加载词汇表、计算图、模型变量和检查点。我们也会讨论如何使用TensorFlow的命令行参数解析器和日志级别。

10.5.2 动手做

1.当运行TensorFlow程序时，我们可能希望确保内存中没有其他计算图会话，或者每次调试程序时重置计算图会话，代码如下：

```
from tensorflow.python.framework import ops  
ops.reset_default_graph()
```

2.当处理文本或者任意数据管道，我们需要确保保存处理过的数据，以便随后用相同的方式处理评估数据。如果处理文本数据，我们需要确定保存和加载词汇字典。下面的代码是保存JSON格式的词汇字典的例子：

```
import json  
word_list = ['to', 'be', 'or', 'not', 'to', 'be']  
vocab_list = list(set(word_list))  
vocab2ix_dict = dict(zip(vocab_list, range(len(vocab_list))))  
ix2vocab_dict = {val:key for key, val in vocab2ix_dict.items()}  
# Save vocabulary  
import json  
with open('vocab2ix_dict.json', 'w') as file_conn:  
    json.dump(vocab2ix_dict, file_conn)  
# Load vocabulary  
with open('vocab2ix_dict.json', 'r') as file_conn:  
    vocab2ix_dict = json.load(file_conn)
```



本例使用JSON格式存储词汇字典，但是我们也可以将其存储为txt、CSV或者二进制文件。如果词汇字典太大，则建议使用二进制文件。用pickle库创建pkl二进制文件。但是pkl文件在不同的Python版本间不能兼容。

3.为了保存算法模型的计算图和变量，我们在计算图中创建Saver()操作。建议在模型训练过程中按一定规则保存模型。具体代码如下：

```
# After model declaration, add a saving operations  
saver = tf.train.Saver()
```

```

# Then during training, save every so often, referencing the
training generation
for i in range(generations):
    ...
    if i%save_every == 0:
        saver.save(sess, 'my_model', global_step=step)
# Can also save only specific variables:
saver = tf.train.Saver({'my_var': my_variable})

```



注意，Saver（）操作也可以传参数。它能接收变量和张量的字典来保存指定元素，也可以接收checkpoint_every_n_hours参数来按时间规则保存操作，而不是按迭代次数。默认保存操作只保存最近的五个模型（考虑存储空间），但是也可以通过max_to_keep选项改变（默认值为5）。

4.在保存算法模型之前，确保为模型重要的操作命名。如果不提前命名，TensorFlow很难加载指定占位符、操作或者变量。TensorFlow的大部分操作和函数都接受name参数，代码如下：

```

conv_weights = tf.Variable(tf.random_normal(), name='conv_
weights')
loss = tf.reduce_mean(..., name='loss')

```

5.TensorFlow的tf.apps.flags库使得执行命令行参数解析相当容易。你可以定义string、float、integer或者boolean型的命令行参数。运行tf.app.run（）函数即可运行带有flag参数的main（）函数，代码如下：

```
tf.app.flags.DEFINE_string("worker_locations", "", "List of worker addresses.")
tf.app.flags.DEFINE_float('learning_rate', 0.01, 'Initial learning rate.')
tf.app.flags.DEFINE_integer('generations', 1000, 'Number of training generations.')
tf.app.flags.DEFINE_boolean('run_unit_tests', False, 'If true, run tests.')
# Need to define a 'main' function for the app to run
def main(_):
    worker_ips = FLAGS.worker_locations.split(",")
    learning_rate = FLAGS.learning_rate
    generations = FLAGS.generations
    run_unit_tests = FLAGS.run_unit_tests
# Run the Tensorflow app
if __name__ == "__main__":
    tf.app.run()
```

6.TensorFlow有内建的logging设置日志级别。其日志级别可设置为DEBUG、INFO、WARN、ERROR和FATAL， 默认级别是WARN， 代码如下：

```
tf.logging.set_verbosity(tf.logging.WARN)
# WARN is the default value, but to see more information, you can set it to
#     INFO or DEBUG
tf.logging.set_verbosity(tf.logging.DEBUG)
```

10.5.3 工作原理

本节提供了在TensorFlow中编写产品级代码的注意事项。我们希望通过介绍app-flag的概念、模型的存储和logging，使得读者能习惯地用这些工具编写代码，并能理解这些工具在他人代码中的运用。使用其他方法也可以写出产品级代码，下一节将展示一个完整的示例。

10.6 TensorFlow产品化的实例

产品级机器学习模型的最佳实践是分开训练和评估代码。本节将展示评估脚本，包括单元测试、模型保存和加载，以及模型评估。

10.6.1 开始

本节将展示如何使用上面的产品级标准实现评估脚本。代码实际由训练脚本和评估脚本组成，但是本节将只讲解评估脚本。注意，两个脚本都可以在GitHub (https://github.com/nfmccleure/tensorflow_cookbook/) 在线获取。

本例将实现第9章的第一个RNN模型例子，预测短信文本信息是否为垃圾信息。我们假设RNN模型已训练好并保存，同时带有词汇表。

10.6.2 动手做

1. 导入必要的编程库，声明TensorFlow应用的flag，代码如下：

```
import os
import re
import numpy as np
import tensorflow as tf
from tensorflow.python.framework import ops
ops.reset_default_graph()
tf.app.flags.DEFINE_string("storage_folder", "temp", "Where to
store model and data.")
tf.app.flags.DEFINE_string('model_file', False, 'Model file
location.')
tf.app.flags.DEFINE_boolean('run_unit_tests', False, 'If true, run
tests.')
FLAGS = tf.app.flags.FLAGS
```

2. 声明文本清洗函数，在训练脚本中也有相同的清洗函数，代码如下：

```
def clean_text(text_string):
    text_string = re.sub(r'([^\s\w]|_|[0-9])+', '', text_string)
    text_string = "".join(text_string.split())
    text_string = text_string.lower()
    return(text_string)
```

3. 加载词汇处理函数，代码如下：

```
def load_vocab():
    vocab_path = os.path.join(FLAGS.storage_folder, "vocab")
    vocab_processor = tf.contrib.learn.preprocessing.
VocabularyProcessor.restore(vocab_path)
    return(vocab_processor)
```

4. 有了清洗的文本数据和词汇处理函数，即可创建数据处理管道，代码如下：

```
def process_data(input_data, vocab_processor):
    input_data = clean_text(input_data)
    input_data = input_data.split()
    processed_input = np.array(list(vocab_processor.
transform(input_data)))
    return(processed_input)
```

5.我们需要数据评估模型。我们将要求用户在屏幕上输入文本，然后处理输入文本和返回处理文本，代码如下：

```
def get_input_data():
    input_text = input("Please enter a text message to evaluate:")
    vocab_processor = load_vocab()
    return(process_data(input_text, vocab_processor))
```



对于本例而言，我们通过要求用户输入来创建评估数据，也有许多应用通过提供文件或者API来获取数据，我们可以根据需要调整输入函数。

6.对于单元测试，应确保文本处理函数的行为符合预期，代码如下：

```
class clean_test(tf.test.TestCase):
    # Make sure cleaning function behaves correctly
    def clean_string_test(self):
        with self.test_session():
            test_input = '--Tensorflow\'s so Great! Don\'t you
think so?      '
            test_expected = 'tensorflows so great don you think
so'
            test_out = clean_text(test_input)
            self.assertEqual(test_expected, test_out)
```

7.现在，有了算法模型和数据集，我们运行主函数。该主函数获取数据集，建立计算图，加载模型变量，传入处理过的数据，打印输出结果，代码如下：

```

def main(args):
    # Get flags
    storage_folder = FLAGS.storage_folder
    # Get user input text
    x_data = get_input_data()

    # Load model
    graph = tf.Graph()
    with graph.as_default():
        sess = tf.Session()
        with sess.as_default():
            # Load the saved meta graph and restore variables
            saver = tf.train.import_meta_graph("{}{}.meta".
format(os.path.join(storage_folder, "model.ckpt")))
            saver.restore(sess, os.path.join(storage_folder,
"model.ckpt"))

            # Get the placeholders from the graph by name
            x_data_ph = graph.get_operation_by_name("x_data_ph").
outputs[0]
            dropout_keep_prob = graph.get_operation_by_
name("dropout_keep_prob").outputs[0]
            probability_outputs = graph.get_operation_by_
name("probability_outputs").outputs[0]
            # Make the prediction
            eval_feed_dict = {x_data_ph: x_data, dropout_keep_.
prob: 1.0}
            probability_prediction = sess.run(tf.reduce_.
mean(probability_outputs, 0), eval_feed_dict)

            # Print output (Or save to file or DB connection?)
            print('Probability of Spam: {:.4}'.format(probability_.
prediction[1]))

```

8.如下代码展示了main() 函数或单元测试如何运行。

```

if __name__ == "__main__":
    if FLAGS.run_unit_tests:
        # Perform unit tests
        tf.test.main()

    else:
        # Run evaluation
        tf.app.run()

```

10.6.3 工作原理

对于模型评估，我们能加载带TensorFlow app-flag的命令行参数，加载模型和词汇处理函数，然后运行处理过的数据训练模型并进行预测。

注意，应通过命令行运行本节的脚本；在创建算法模型和词汇字典前应检测训练脚本。

第11章 TensorFlow的进阶应用

本章将包含以下内容：

- TensorFlow可视化：Tensorboard

- TensorFlow实现遗传算法

- TensorFlow实现k-means算法

- TensorFlow解决常微分方程问题

本章所有代码可以在GitHub (https://github.com/nfmccleure/tensorflow_cookbook.) 获取。

11.1 简介

到目前为止，我们已经看到TensorFlow能够实现许多算法模型，但是TensorFlow能做的远不止于此。本章将展示如何使用Tensorboard，Tensorboard是TensorFlow的可视化模块，允许可视化模型训练过程中的统计指标、曲线图和图像。剩余的章节将介绍TensorFlow的group函数的实现逐步更新。该函数帮助我们实现遗传算法、k-means聚类和常微分方程（ODE）的求解。

11.2 TensorFlow可视化：Tensorboard

机器学习算法的监控和故障解决是一个令人畏惧的任务。特别地，在训练模型时，你必须等待很长时间，有时甚至不知道结果。这时使用TensorFlow的可视化工具Tensorboard可以图形化计算图，绘制模型训练中重要的值（损失、准确度和批量训练时间等）。

11.2.1 开始

为了展示Tensorboard的各种使用方法，本节再次实现第3章中的线性回归模型。使用TensorFlow的损失函数和反向传播来拟合直线。下面将介绍在Tensorboard中如何监控数值型数值，和数据集的直方图，以及如何创建图像。

11.2.2 动手做

1. 导入必要的编程库，代码如下：

```
import os
import io
import time
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
```

2. 初始化计算图会话，创建summary-writer将Tensorboard summary写入Tensorboard文件夹，代码如下：

```
sess = tf.Session()
# Create a visualizer object
summary_writer = tf.train.SummaryWriter('tensorboard', tf.get_default_graph())
```

3. 确保summary_writer写入的Tensorboard文件夹存在，代码如下：

```
if not os.path.exists('tensorboard'):
    os.makedirs('tensorboard')
```

4. 设置模型参数，为模型生成线性数据集。注意，设置真实斜率true_slope为2（注：迭代训练时，我们将随着时间的变化可视化斜率，直到取到真实斜率值），代码如下：

```
batch_size = 50
generations = 100
# Create sample input data
x_data = np.arange(1000)/10.
true_slope = 2.
y_data = x_data * true_slope + np.random.normal(loc=0.0, scale=25,
size=1000)
```

5. 分割数据集为测试集和训练集，代码如下：

```
train_ix = np.random.choice(len(x_data), size=int(len(x_data)*0.9), replace=False)
test_ix = np.setdiff1d(np.arange(1000), train_ix)
x_data_train, y_data_train = x_data[train_ix], y_data[train_ix]
x_data_test, y_data_test = x_data[test_ix], y_data[test_ix]
```

6. 创建占位符、变量、模型操作、损失和优化器操作，代码如下：

```
x_graph_input = tf.placeholder(tf.float32, [None])
y_graph_input = tf.placeholder(tf.float32, [None])
# Declare model variables
m = tf.Variable(tf.random_normal([1], dtype=tf.float32),
name='Slope')
# Declare model
output = tf.mul(m, x_graph_input, name='Batch_Multiplication')
# Declare loss function (L1)
residuals = output - y_graph_input

l2_loss = tf.reduce_mean(tf.abs(residuals), name="L2_Loss")
# Declare optimization function
my_optim = tf.train.GradientDescentOptimizer(0.01)
train_step = my_optim.minimize(l2_loss)
```

7. 创建Tensorboard操作汇总一个标量值。该汇总的标量值为模型的斜率估计，代码如下：

```
with tf.name_scope('Slope_Estimate'):
    tf.scalar_summary('Slope_Estimate', tf.squeeze(m))
```

8. 添加到Tensorboard的另一个汇总数据是直方图汇总。该直方图汇总输入张量，输出曲线图和直方图，

代码如下：

```
with tf.name_scope('Loss_and_Residuals'):
    tf.histogram_summary('Histogram_Errors', l2_loss)
    tf.histogram_summary('Histogram_Residuals', residuals)
```

9. 创建完这些汇总操作，我们创建汇总合并操作综合所有的汇总数据，然后初始化模型变量，代码如下：

```

summary_op = tf.merge_all_summaries()
# Initialize Variables
init = tf.initialize_all_variables()
sess.run(init)

```

10.现在训练线性回归模型，将每次迭代训练写入汇总数据，代码如下：

```

for i in range(generations):
    batch_indices = np.random.choice(len(x_data_train),
size=batch_size)
    x_batch = x_data_train[batch_indices]
    y_batch = y_data_train[batch_indices]
    _, train_loss, summary = sess.run([train_step, l2_loss,
summary_op,
                                feed_dict={x_graph_input: x_batch,
y_graph_input: y_batch})

    test_loss, test_resids = sess.run([l2_loss, residuals], feed_
dict={x_graph_input: x_data_test,
y_graph_input: y_data_test})

    if (i+1)%10==0:
        print('Generation {} of {}. Train Loss: {:.3}, Test Loss: {:.3}'.format(i+1, generations, train_loss, test_loss))

    log_writer = tf.train.SummaryWriter('tensorboard')
    log_writer.add_summary(summary, i)

```

11.为了可视化数据点拟合的线性回归模型，我们创建protobuf格式的图形。开始之前，我们创建函数输出protobuf格式的图形，代码如下：

```

def gen_linear_plot(slope):
    linear_prediction = x_data * slope
    plt.plot(x_data, y_data, 'b.', label='data')
    plt.plot(x_data, linear_prediction, 'r-', linewidth=3,
label='predicted line')
    plt.legend(loc='upper left')
    buf = io.BytesIO()
    plt.savefig(buf, format='png')
    buf.seek(0)
    return(buf)

```

12. 创建并且将protobuf格式的图形增加到Tensorboard，代码如下：

```
slope = sess.run(m)
plot_buf = gen_linear_plot(slope[0])
# Convert PNG buffer to TF image
image = tf.image.decode_png(plot_buf.getvalue(), channels=4)
# Add the batch dimension
image = tf.expand_dims(image, 0)
# Add image summary
image_summary_op = tf.image_summary("Linear Plot", image)
image_summary = sess.run(image_summary_op)
log_writer.add_summary(image_summary, i)
log_writer.close()
```



注意Tensorboard写图形汇总太频繁。例如，如果我们迭代训练10000次每次都写入汇总数据，那将生成10000副图。这会迅速吃掉磁盘空间。

11.3 Tensorboard的进阶

从命令行运行上面的脚本：

```
$ python3 using_tensorboard.py
```

```
Run the command: $tensorboard --logdir="tensorboard" Then navigate  
to http://127.0.0.0:6006  
Generation 10 of 100. Train Loss: 20.4, Test Loss: 20.5.  
Generation 20 of 100. Train Loss: 17.6, Test Loss: 20.5.  
Generation 90 of 100. Train Loss: 20.1, Test Loss: 20.5.  
Generation 100 of 100. Train Loss: 19.4, Test Loss: 20.5.
```

然后运行指定的命令启动Tensorboard，代码如下：

```
$ tensorboard --logdir="tensorboard"  
Starting TensorBoard b'29' on port 6006  
(You can navigate to http://127.0.1.1:6006)
```

图11-1是Tensorboard看到的样例图形。

图11-1是迭代100次标量汇总（斜率估计）的趋势图，可以看到最后取值为2。

图11-2展示了直方图汇总的可视化。

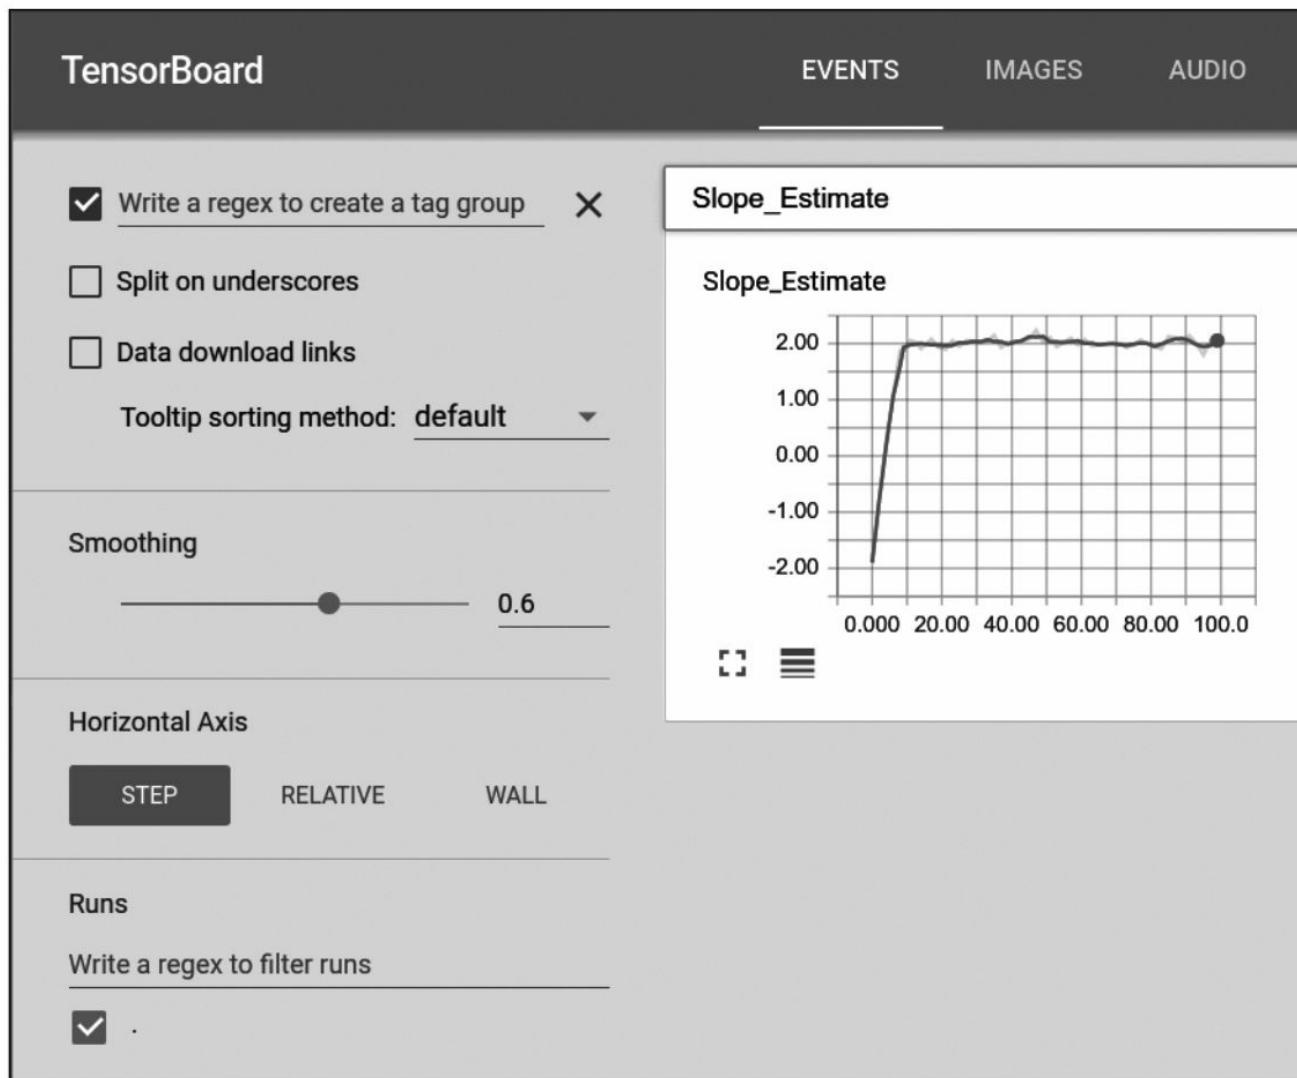


图11-1 Tensorboard中的标量值、斜率估计的可视化

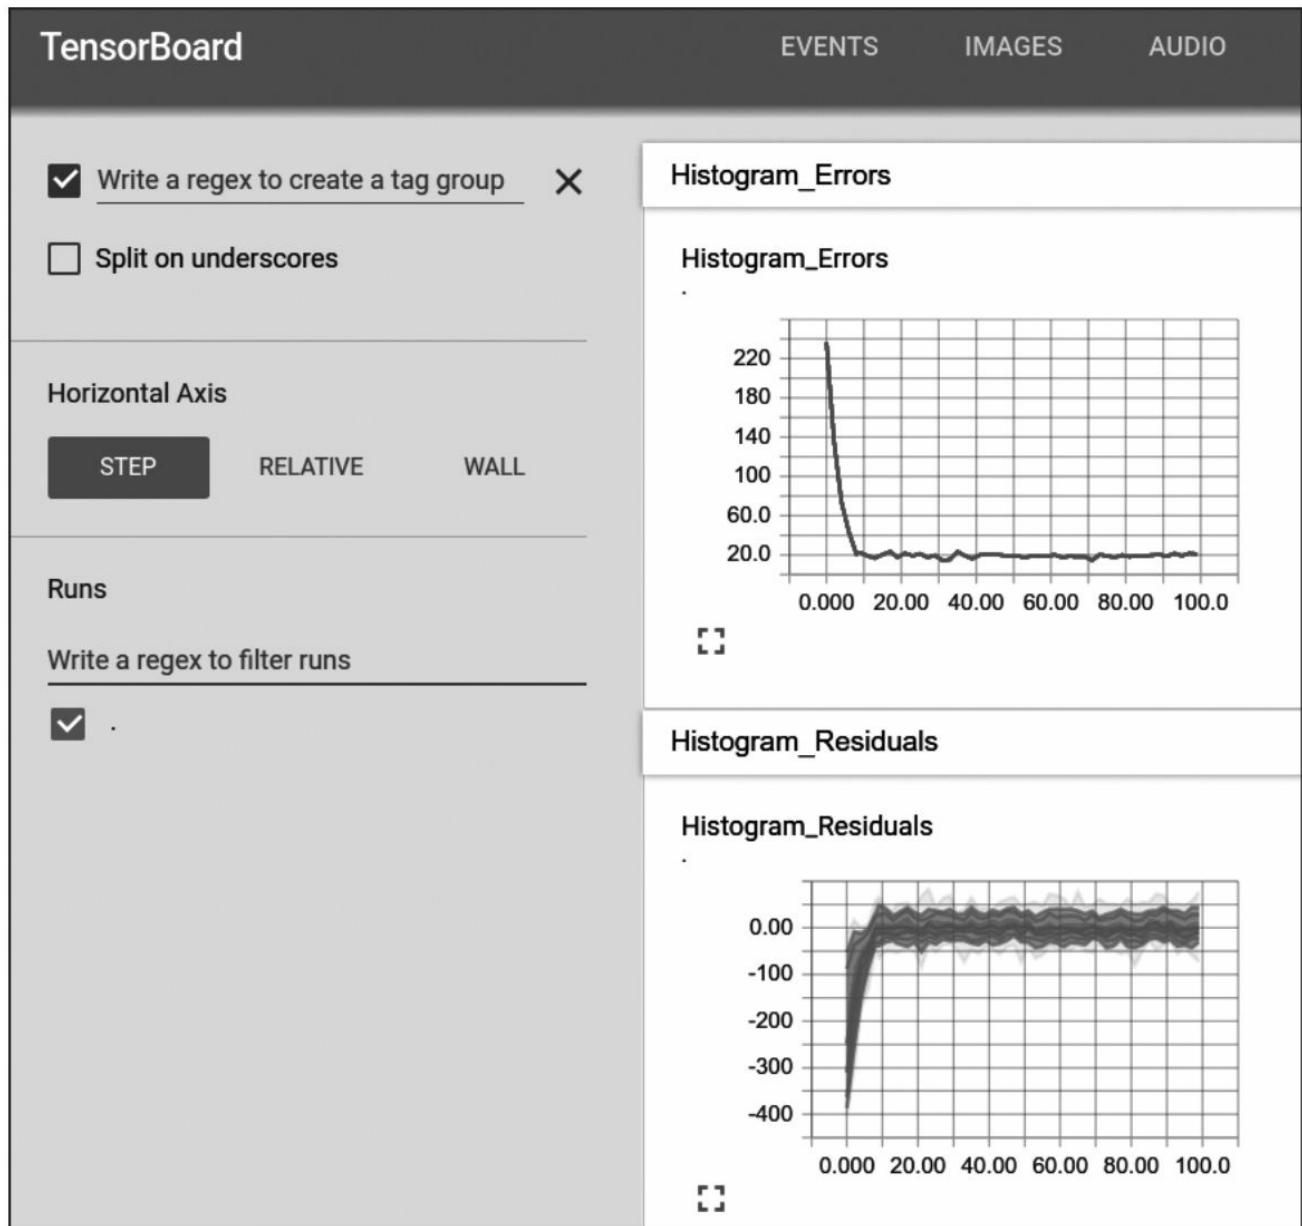


图11-2 可视化模型的误差和残留直方图

图11-3展示的是最终的拟合直线和数据点图形，保存为protobuf格式，插入Tensorboard的图像汇总。

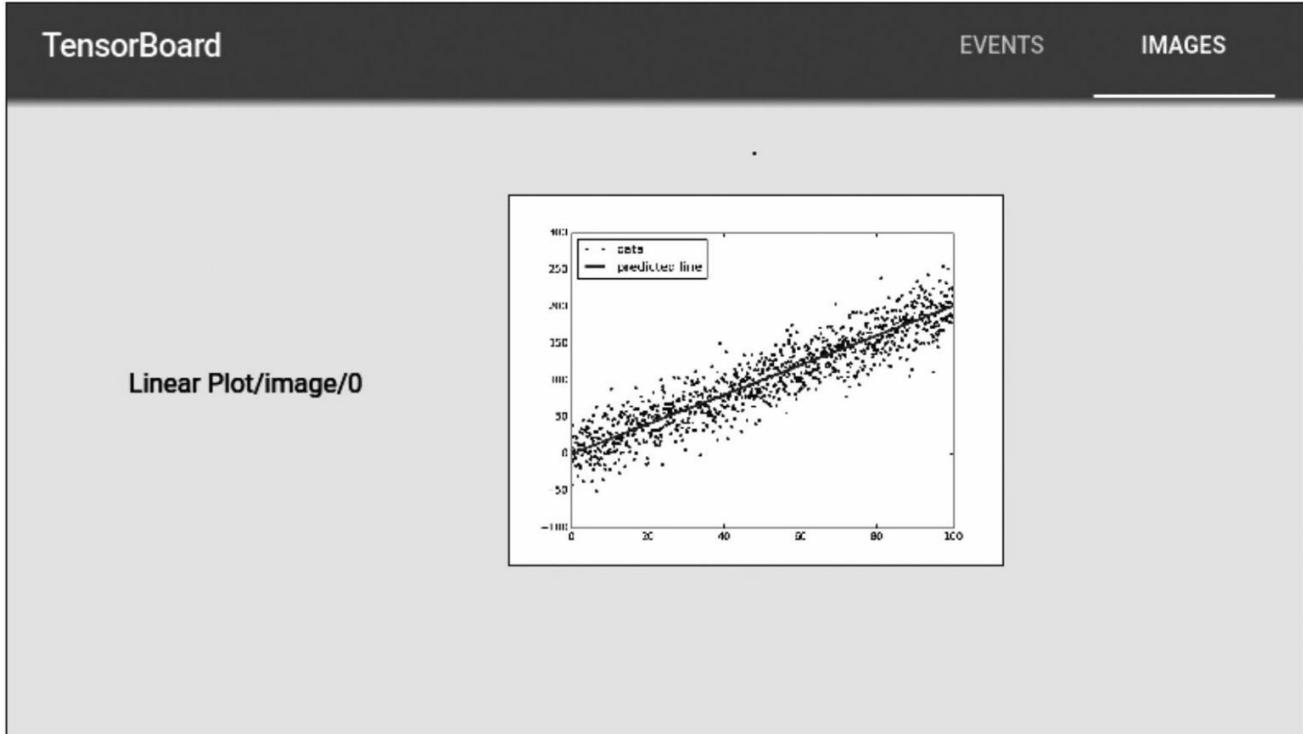


图11-3 Tensorboard中插入的图片

11.4 用TensorFlow实现遗传算法

TensorFlow也可以用来更新任意表示为计算图的迭代型算法。迭代型算法的例子有遗传算法，用于解决最优化的问题。

11.4.1 开始

本节将介绍如何实现一个简单的遗传算法。遗传算法是最优化参数空间（离散的、连续的、光滑的、非光滑的，等等）的有效方法。基本思想是创建一个随机初始化的种群，进化、重组和突变生成新的种群（更好的质量）。通过当前种群的个体的适应度来计算各个个体的适应度。

一般来讲，遗传算法的大体步骤是：先随机初始化种群，通过各个个体的适应度排序，选择适应度较高的个体随机重组（或者交叉）创建下一代种群。这些下一代种群经过轻微变异产生不同于上一代的更好的适应度，然后将其放入父种群。重复前面的过程。

遗传算法停止迭代的标准很多，但是本例中仅仅以迭代的总次数为标准。我们也可以在当前种群个体的适应度达到预期的标准，或者在许多次迭代后最大的适应度不再变化时，停止迭代。

本节将展示如何在TensorFlow中实现遗传算法。我们将生成一个最接近ground truth函数

$$f(x) = \sin\left(\frac{2\pi x}{50}\right)$$
 的个体

（50个float型的数组）。适应度为个体和ground

truth的均方误差的负值。

11.4.2 动手做

1. 导入必要的编程库，代码如下：

```
import os
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
```

2. 接下来，我们设置遗传算法的参数。在本例中，有100个个体，每个长度为50。选择的百分比是20%，即适应度排序前20的个体。变异定义为特征数的倒数，这意味着下一代种群的一个特征会变异。运行遗传算法迭代200次，代码如下：

```
pop_size = 100
features = 50
selection = 0.2
mutation = 1./ features
generations = 200
num_parents = int(pop_size*selection)
num_children = pop_size - num_parents
```

3. 初始化计算图会话，创建ground truth函数，该函数用来计算适应度，代码如下：

```
sess = tf.Session()
# Create ground truth
truth = np.sin(2*np.pi*(np.arange(features, dtype=np.float32))/features)
```

4. 使用TensorFlow的变量（随机正态分布输入）初始化种群，代码如下：

```
population = tf.Variable(np.random.randn(pop_size, features),
dtype=tf.float32)
```

5. 现在创建遗传算法的占位符。该占位符是为ground truth和每次迭代改变的数据。因为我们希望父代变化和变异概率变化交叉，这些都是模型的占位符，代码如下：

```

truth_ph = tf.placeholder(tf.float32, [1, features])
crossover_mat_ph = tf.placeholder(tf.float32, [num_children, features])
mutation_val_ph = tf.placeholder(tf.float32, [num_children, features])

```

6.计算群体的适应度（均方误差的负值），选择较高适应度的个体，代码如下：

```

fitness = -tf.reduce_mean(tf.square(tf.sub(population, truth_ph)), 1)
top_vals, top_ind = tf.nn.top_k(fitness, k=pop_size)

```

7.为了获得最后的结果并绘图，我们希望检索种群中适应度最高的个体，代码如下：

```

best_val = tf.reduce_min(top_vals)
best_ind = tf.arg_min(top_vals, 0)
best_individual = tf.gather(population, best_ind)

```

8.排序父种群，截取适应度较高的个体作为下一代，代码如下：

```

population_sorted = tf.gather(population, top_ind)
parents = tf.slice(population_sorted, [0, 0], [num_parents, features])

```

9.通过创建两个随机shuffle的父种群矩阵来创建下一代种群。将交叉矩阵分别与1和0相加，然后与父种群矩阵相乘，生成每一代的占位符，代码如下：

```

# Indices to shuffle-gather parents
rand_parent1_ix = np.random.choice(num_parents, num_children)
rand_parent2_ix = np.random.choice(num_parents, num_children)
# Gather parents by shuffled indices, expand back out to pop_size too
rand_parent1 = tf.gather(parents, rand_parent1_ix)
rand_parent2 = tf.gather(parents, rand_parent2_ix)
rand_parent1_sel = tf.mul(rand_parent1, crossover_mat_ph)
rand_parent2_sel = tf.mul(rand_parent2, tf.sub(1., crossover_mat_ph))
children_after_sel = tf.add(rand_parent1_sel, rand_parent2_sel)

```

10.最后一个步骤是变异下一代，本例将增加一个随机正常值到下一代种群矩阵的特征分数的倒数，然后将这个矩阵和父种群连接，代码如下：

```

mutated_children = tf.add(children_after_sel, mutation_val_ph)
# Combine children and parents into new population
new_population = tf.concat(0, [parents, mutated_children])

```

11.模型的最后一步是，使用TensorFlow的group（）操作分配下一代种群到父一代种群的变量，代码如下：

```
step = tf.group(population.assign(new_population))
```

12.初始化模型变量，代码如下：

```
init = tf.initialize_all_variables()
sess.run(init)
```

13.迭代训练模型，再创建随机交叉矩阵和变异矩阵，更新每代的种群，代码如下：

```
for i in range(generations):
    # Create cross-over matrices for plugging in.
    crossover_mat = np.ones(shape=[num_children, features])
    crossover_point = np.random.choice(np.arange(1, features-1,
step=1), num_children)
    for pop_ix in range(num_children):
        crossover_mat [pop_ix, 0:crossover_point [pop_ix]] = 0.
    # Generate mutation probability matrices
    mutation_prob_mat = np.random.uniform(size=[num_children,
features])

    mutation_values = np.random.normal(size=[num_children,
features])
    mutation_values [mutation_prob_mat >= mutation] = 0

    # Run GA step
    feed_dict = {truth_ph: truth.reshape([1, features]),
                crossover_mat_ph: crossover_mat,
                mutation_val_ph: mutation_values}
    step.run(feed_dict, session=sess)
    best_individual_val = sess.run(best_individual, feed_
dict=feed_dict)

    if i % 5 == 0:
        best_fit = sess.run(best_val, feed_dict = feed_dict)
        print('Generation: {}, Best Fitness (lowest MSE): {:.2}'.format(i, -best_fit))
```

14.输出结果如下：

Generation: 0, Best Fitness (lowest MSE) : 1.5
Generation: 5, Best Fitness (lowest MSE) : 0.83
Generation: 10, Best Fitness (lowest MSE) : 0.55
Generation: 185, Best Fitness (lowest MSE) : 0.085
Generation: 190, Best Fitness (lowest MSE) : 0.15
Generation: 195, Best Fitness (lowest MSE) : 0.083

11.4.3 工作原理

本节展示了如何使用TensorFlow训练简单的遗传算法。为了验证实现的遗传算法是否工作，我们绘制每次迭代的适应度最高的个体和ground truth趋势图，如图11-4所示。

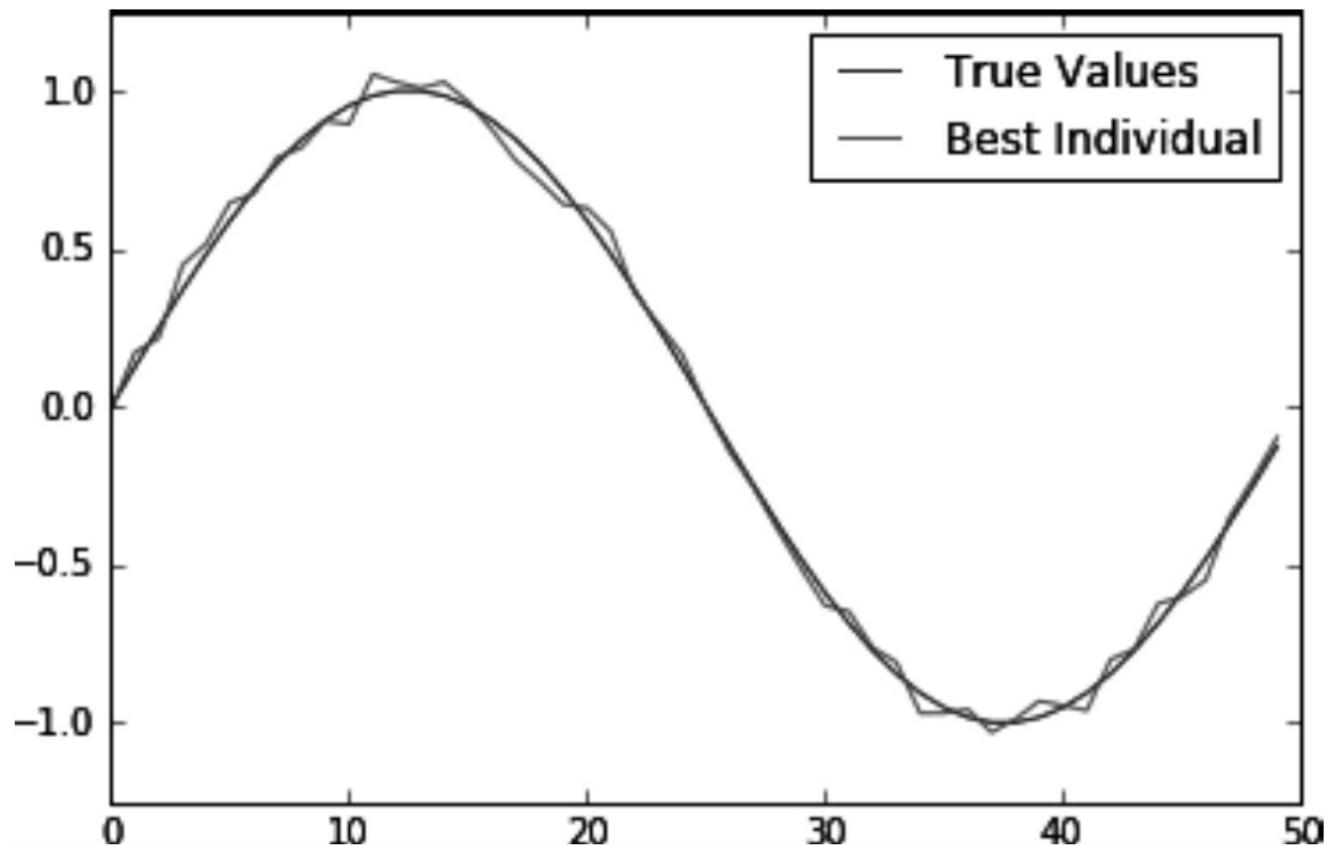


图11-4 迭代200次的适应度最高的个体和ground truth的趋势图。我们发现适应度最高的个体和ground truth相当接近

11.4.4 延伸学习

遗传算法有许多个变种，可以有两个父种群和两个不同的适应度标准（例如，最低MSE和平滑度）。我们能强制变异值不大于1或者不小于-1。本例做了许多不同的调整，这些调整依赖于实际要优化的问题。对于本例来说，适应度计算相当简单，但是对于大部分遗传算法，计算适应度是一项艰巨的任务。例如，如果我们想用遗传算法优化卷积神经网络架构，那么群体个体就有一个参数数组。参数包括过滤器大小、步长，以及卷积层。对于数据集来说，迭代固定次数后，个体的适应度是分类的准确度。如果我们在种群中有100个个体，那么，每次迭代必须评估100个不同的CNN模型。这是非常大强度的计算。

在使用遗传算法解决你的问题之前，需要考虑下多久才能计算完个体的适应度。如果该操作很耗时，则不适合使用遗传算法。

11.5 TensorFlow实现k-means算法

TensorFlow也可以用来实现迭代聚类算法，比如，k-means算法。本节将展示在iris数据集中使用k-means算法的例子。

11.5.1 开始

本书介绍的大部分机器学习算法模型都是有监督模型，TensorFlow是解决该类问题的理想工具。但是TensorFlow也可以使用无监督模型，本例将实现k-means聚类算法。

本例使用的数据是iris数据集。该数据集的一大优点是，我们已经知道其有三类目标（三种鸢尾花）。这让我们明确将会聚类成三个不同的类。

我们将iris数据集聚类成三组，然后和实际标注比较求出聚类的准确度。

11.5.2 动手做

1.开始导入必要的编程库。因为后续需将四维的结果数据转换为二维数据进行可视化，所以也要从sklearn库导入PCA工具，代码如下：

```
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
from sklearn import datasets
from scipy.spatial import cKDTree
from sklearn.decomposition import PCA
from sklearn.preprocessing import scale
```

2.创建一个计算图会话，加载iris数据集，代码如下：

```
sess = tf.Session()
iris = datasets.load_iris()
num_pts = len(iris.data)

num_feats = len(iris.data[0])
```

3.设置分类数、迭代次数，创建计算图所需的变量，代码如下：

```
k=3
generations = 25
data_points = tf.Variable(iris.data)
cluster_labels = tf.Variable(tf.zeros([num_pts], dtype=tf.int64))
```

4.声明每个分组所需的几何中心变量。我们通过随机选择iris数据集中的三个数据点来初始化k-means聚类算法的几何中心，代码如下：

```
rand_starts = np.array([iris.data[np.random.choice(len(iris.data))]] for _ in range(k)])
centroids = tf.Variable(rand_starts)
```

5.计算每个数据点到每个几何中心的距离。本例的计算方法是，将几何中心点和数据点分别放入矩阵中，然后计算两个矩阵的欧式距离，代码如下：

```

centroid_matrix = tf.reshape(tf.tile(centroids, [num_pts, 1]),
[ num_pts, k, num_feats])
point_matrix = tf.reshape(tf.tile(data_points, [1, k]), [num_pts,
k, num_feats])
distances = tf.reduce_sum(tf.square(point_matrix - centroid_
matrix), reduction_indices=2)

```

6. 分配时，是以到每个数据点最小距离为最接近的几何中心点，代码如下：

```
centroid_group = tf.argmin(distances, 1)
```

7. 计算每组分类的平均距离得到新的几何中心点，代码如下：

```

def data_group_avg(group_ids, data):
    # Sum each group
    sum_total = tf.unsorted_segment_sum(data, group_ids, 3)
    # Count each group
    num_total = tf.unsorted_segment_sum(tf.ones_like(data), group_
ids, 3)
    # Calculate average
    avg_by_group = sum_total/num_total
    return(avg_by_group)
means = data_group_avg(centroid_group, data_points)
update = tf.group(centroids.assign(means), cluster_labels.
assign(centroid_group))

```

8. 初始化模型变量，代码如下：

```
init = tf.initialize_all_variables()
sess.run(init)
```

9. 遍历迭代训练，相应地更新每组分类的几何中心点，代码如下：

```

for i in range(generations):
    print('Calculating gen {}, out of {}'.format(i, generations))
    _, centroid_group_count = sess.run([update, centroid_group])

group_count = []
for ix in range(k):
    group_count.append(np.sum(centroid_group_count==ix))
print('Group counts: {}'.format(group_count))

```

10. 输出结果如下：

```
Calculating gen 0, out of 25.  
Group counts: [50, 28, 72]  
Calculating gen 1, out of 25.  
Group counts: [50, 35, 65]  
Calculating gen 23, out of 25.  
Group counts: [50, 38, 62]  
Calculating gen 24, out of 25.  
Group counts: [50, 38, 62]
```

11.为了验证聚类模型，我们使用距离模型预测。看下有多少数据点与实际iris数据集中的鸢尾花物种匹配，代码如下：

```
[centers, assignments] = sess.run([centroids, cluster_labels])  
def most_common(my_list):  
    return(max(set(my_list), key=my_list.count))  
label0 = most_common(list(assignments[0:50]))  
label1 = most_common(list(assignments[50:100]))  
label2 = most_common(list(assignments[100:150]))  
group0_count = np.sum(assignments[0:50]==label0)  
group1_count = np.sum(assignments[50:100]==label1)  
group2_count = np.sum(assignments[100:150]==label2)  
accuracy = (group0_count + group1_count + group2_count)/150.  
print('Accuracy: {:.2}'.format(accuracy))
```

12.输出结果如下：

Accuracy: 0.89

13.为了可视化分组过程，以及是否分离出鸢尾花物种，我们将用PCA工具将四维结果数据转为二维结果数据，并绘制数据点和分组。PCA分解之后，我们创建预测，并在x-y轴网格绘制彩色图形，代码如下：

```
pca_model = PCA(n_components=2)
reduced_data = pca_model.fit_transform(iris.data)
# Transform centers
reduced_centers = pca_model.transform(centers)
# Step size of mesh for plotting
h = .02
x_min, x_max = reduced_data[:, 0].min() - 1, reduced_data[:, 0].max() + 1
y_min, y_max = reduced_data[:, 1].min() - 1, reduced_data[:, 1].max() + 1
xx, yy = np.meshgrid(np.arange(x_min, x_max, h), np.arange(y_min,
y_max, h))
# Get k-means classifications for the grid points
xx_pt = list(xx.ravel())
yy_pt = list(yy.ravel())

xy_pts = np.array([[x,y] for x,y in zip(xx_pt, yy_pt)])
mytree = cKDTree(reduced_centers)
dist, indexes = mytree.query(xy_pts)
indexes = indexes.reshape(xx.shape)
```

14.下面是用matplotlib模块在同一幅图形中绘制所有结果的代码。绘图部分的代码来自sklearn官方文档的示例 (http://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_digits.html)，代码如下（对应的图见图11-5）：

```
plt.clf()
plt.imshow(indexes, interpolation='nearest',
           extent=(xx.min(), xx.max(), yy.min(), yy.max()),
           cmap=plt.cm.Paired,
           aspect='auto', origin='lower')
# Plot each of the true iris data groups
symbols = ['o', '^', 'D']
label_name = ['Setosa', 'Versicolour', 'Virginica']
for i in range(3):
    temp_group = reduced_data[(i*50):(50)*(i+1)]
    plt.plot(temp_group[:, 0], temp_group[:, 1], symbols[i],
             markersize=10, label=label_name[i])
# Plot the centroids as a white X
plt.scatter(reduced_centers[:, 0], reduced_centers[:, 1],
            marker='x', s=169, linewidths=3,
            color='w', zorder=10)
plt.title('K-means clustering on Iris Dataset\n'
          'Centroids are marked with white cross')
plt.xlim(x_min, x_max)
plt.ylim(y_min, y_max)
plt.legend(loc='lower right')
plt.show()
```

**K-means clustering on Iris Dataset
Centroids are marked with white cross**

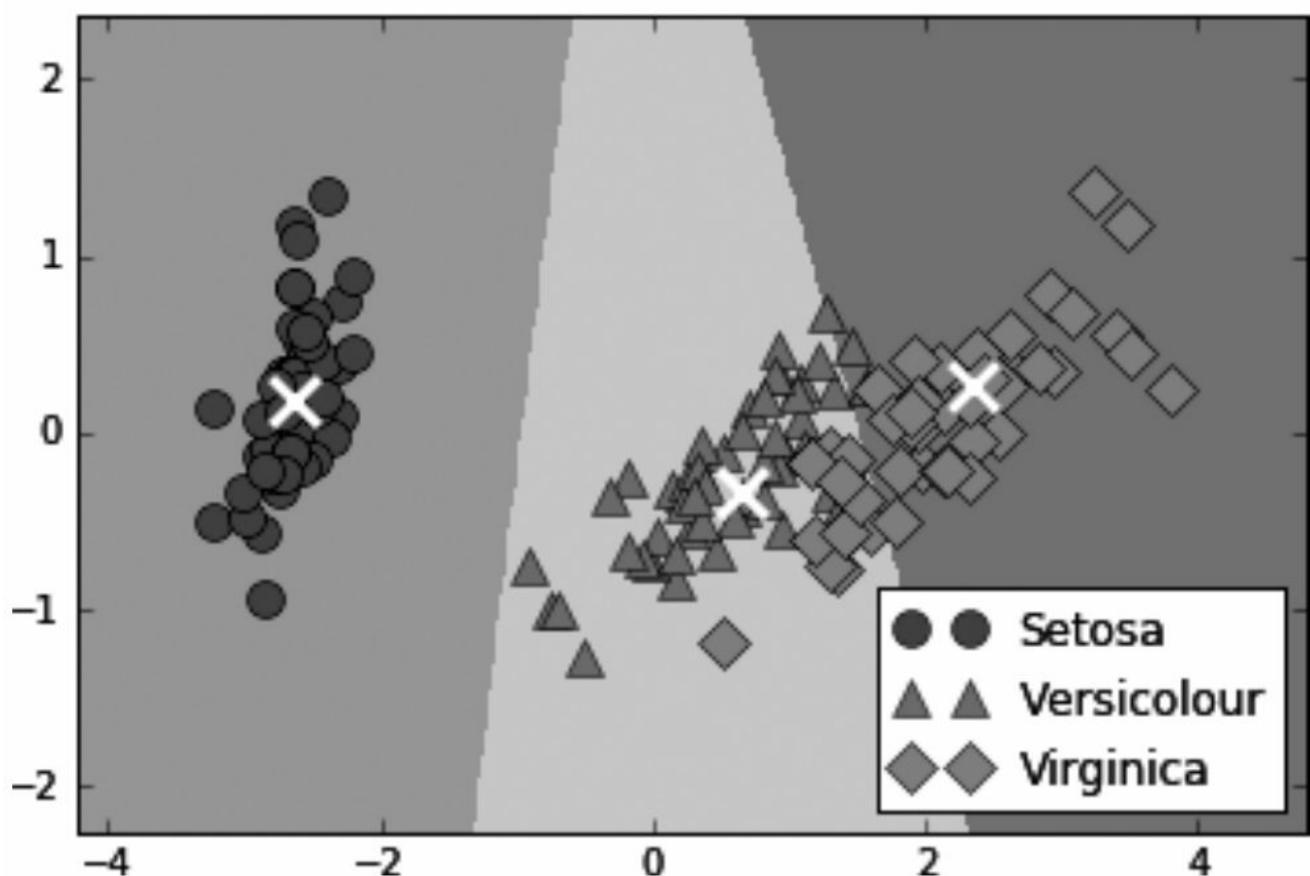


图11-5 展示k-means聚类算法如何进行无监督分类，本例聚合为三类鸢尾花。三类k-means分组为图中三种阴影区域，三种不同的数据点（圆形、三角形和菱形）是三个鸢尾花物种

11.5.3 延伸学习

本节使用TensorFlow将iris数据集聚类为三组。然后计算数据点落入分组的百分比（89%），绘制k-means分组的图形。因为k-means算法作为分类算法的一种，其为局部线性，所以很难学习到杂色鳶尾花（I.versicolour）和维吉尼亚鳶尾花（I.verginica）之间的非线性边界。但是k-means算法的优点是无须标注数据集。

11.6 用TensorFlow求解常微分方程问题

TensorFlow可以实现许多算法，其一个很好的例子是实现常微分方程（ODE）的求解器。求解一个常微分方程数值解是一个很容易用计算图表达的迭代过程。本节将求解洛特卡-沃尔泰拉方程（Lotka-Volterra）掠食者-猎物系统。

11.6.1 开始

本节将介绍如何求解常微分方程系统。我们可以使用前面两节的方法来更新迭代数值，求解常微分方程系统。

本例考虑的著名常微分方程系统是洛特卡-沃尔泰拉方程（Lotka-Volterra）掠食者-猎物系统。其经常用来描述生物系统中，掠食者与猎物进行互动时的动态模型。

1920年，洛特卡-沃尔泰拉系统发布在一篇文章中，见11.6.4节。我们使用文章中相似的参数来描述周期性系统，其离散数学表达式为：

$$f(x) = \sin\left(\frac{2\pi x}{50}\right)$$

$$X_{t+1} = X_t + (aX_t + bX_t Y_t) \Delta t$$

$$Y_{t+1} = Y_t + (cY_t + dX_t Y_t) \Delta t$$

其中， X 是猎物， Y 是掠食者。我们通过 a 、 b 、 c 和 d 的值来决定哪个是猎物，哪个是掠食者。对于猎物， $a>0$, $b<0$; 对于掠食者， $c<0$, $d>0$ 。我们使用TensorFlow实现其离散版的求解器。

11.6.2 动手做

1. 导入必要的编程库，创建一个计算图会话，代码如下：

```
import matplotlib.pyplot as plt
import tensorflow as tf
sess = tf.Session()
```

2. 声明计算图中的常量和变量，代码如下：

```
x_initial = tf.constant(1.0)
y_initial = tf.constant(1.0)
X_t1 = tf.Variable(x_initial)

Y_t1 = tf.Variable(y_initial)
# Make the placeholders
t_delta = tf.placeholder(tf.float32, shape=())
a = tf.placeholder(tf.float32, shape=())
b = tf.placeholder(tf.float32, shape=())
c = tf.placeholder(tf.float32, shape=())
d = tf.placeholder(tf.float32, shape=())
```

3. 实现前面介绍的离散系统，然后更新X和Y的数量，代码如下：

```
X_t2 = X_t1 + (a * X_t1 + b * X_t1 * Y_t1) * t_delta
Y_t2 = Y_t1 + (c * Y_t1 + d * X_t1 * Y_t1) * t_delta
# Update to New Population
step = tf.group(
    X_t1.assign(X_t2),
    Y_t1.assign(Y_t2))
```

4. 初始化计算图，运行离散常微分方程系统展示周期性的行为，代码如下：

```

init = tf.initialize_all_variables()
sess.run(init)
# Run the ODE
prey_values = []
predator_values = []
for i in range(1000):
    # Step simulation (using constants for a known cyclic
    solution)
    step.run({a: (2./3.), b: (-4./3.), c: -1.0, d: 1.0, t_delta:
0.01}, session=sess)
    # Store each outcome
    temp_prey, temp_pred = sess.run([X_t1, Y_t1])
    prey_values.append(temp_prey)
    predator_values.append(temp_pred)

```



获得洛特卡-沃尔泰拉方程的稳定求解与指定参数和起始值有较大关系。我们鼓励读者尝试不同的参数和初始值来看会发生什么。

5.现在绘制掠食者与猎物的值（见图11-6），代码如下：

```

plt.plot(prey_values, label="Prey")
plt.plot(predator_values, label="Predator")
plt.legend(loc='upper right')
plt.show()

```

11.6.3 工作原理

使用TensorFlow实现常微分方程系统的离散版的求解器。对于指定参数，我们看到掠食者与猎物的生态系统确实是周期性变化的。这在生物生态系统中是有意义的，因为如果有太多的掠食者，猎物就会濒临灭绝；缺少猎物，掠食者只能获得更少的食物，那掠食者也会开始濒临灭绝。

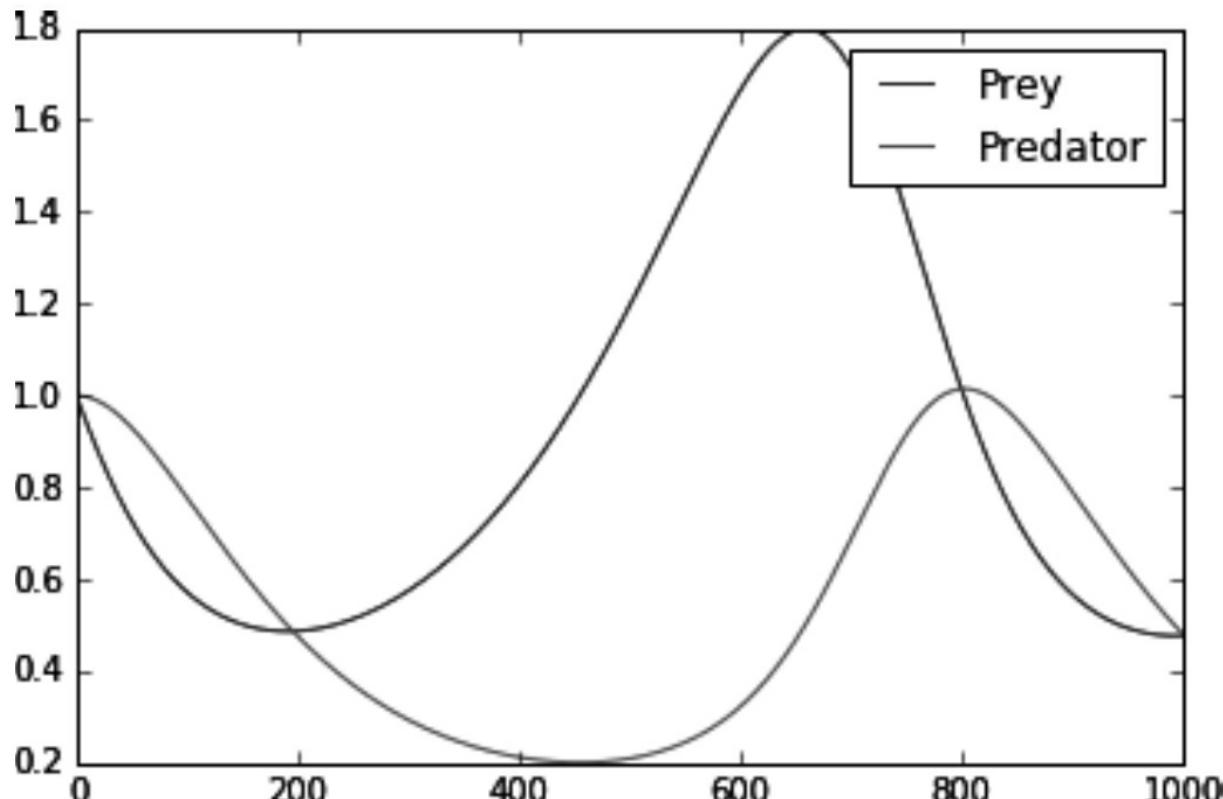


图11-6 ODE求解的掠食者与猎物的数量值的趋势图。我们看到趋势确实呈周期性变化

11.6.4 参考

11.6.4 参考

Lotka, A. J., *Analytical note on certain rhythmic relations in organic systems*. Proc. Nat. Acad. 6 (1920) (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC1084562/>).